

# שיטת חישוביות באופטימיזציה - סיכום הרצאות ותרגולים

סיכום הרצאות.מרצה: כפיר לוי

23 ביולי 2020

## תוכן עניינים

<b>I מושגי מפתח באופטימיזציה ובקמירות</b>	
6 הרצאה 1 ותרגול 1. מבוא והגדירות .....	1
6 חומר מבוא חוזר על מושגים מאלגברה וחזואה .....	1.1
6 המרחב האוקלידי $n$ מימדי $\mathbb{R}^n$ .....	1.1.1
7 תתי מרחבים חסובים של $\mathbb{R}^n$ .....	1.1.2
8 המרחב $n \times m$ מימי $\mathbb{R}^{m \times n}$ .....	1.1.3
8 מכפלה פנימית $\langle \cdot, \cdot \rangle$ .....	1.1.4
8 דוגמאות למכפלה פנימית .....	1.1.5
8 נורמת וקטורים $\  \cdot \ $ .....	1.1.6
9 אי שוויון קושי שורץ .....	1.1.7
9 הוכחת אי שוויון קושי שורץ: .....	
10 ערכים עצמיים וקטוריים עצמיים .....	1.1.8
11 משפט הפירוק הספקטרלי .....	1.1.9
11 רקע: .....	
12 משפט הפירוק: .....	1.1.10
13 עקרונות בסיסיים בטופולוגיה .....	1.1.11
14 קבוצות פתוחות וסגורות .....	1.1.12
15 נקודות שפה וסגור .....	1.1.13
15 קומפקטיביות וחסימות .....	1.1.14
15 טבלה מסכמת של כלל ההגדירות: .....	1.1.15
15 נגזרות .....	1.1.16
17 משפטי קירוב .....	1.1.17
18 חומר של הרצאה 1 .....	1.2
18 סוגיה הביעותנית שניתן לפתור ביעילות .....	1.2.1
18 הגדירות הקשורות למושג הקמירות .....	1.2.2
21 הרצאה 2 .....	2
22 קבוצות וקבוצות קמורות .....	2.1
22 כדורים וחרוטים .....	2.1.1
23 פאון וסימפלקס - גופים קמורים .....	2.1.2
25 סוגיה חרוטים (=קונוסים) - המשך .....	2.1.3
27 תכונות חשובות של קבוצות קמורות .....	2.2
28 תכונות חשובות של פונקציות קמורות .....	2.3
31 על מישורים - לינארי ואפיני .....	2.4
31 פעולות משמרות קמירות .....	2.5
32 תרגיל שימוש במפשט הנ"ל לדוגמא: .....	2.6
33 תרגיל שימוש במסקנה הנ"ל לדוגמא: .....	
36 תרגילי דוגמא לשימוש בשתי המשפטים האחרונים: מרחק מקבוצה .....	
37 פעולות משמרות קמירות .....	

40	.....	טבלה מסכמת: פעולות משמרות קמיות .....	2.6.1
41	.....	טבלה מסכמת: משפטים קמיות .....	2.6.2
41	.....	אנליזת פונקציות קמורות - מונחים ודוגמאות .....	2.7
41	.....	מינוחים נוספים .....	
42	.....	דוגמאות לפונקציות קמורות .....	
42	.....	הרצאה 3 + תחילת הרצאה 4 ) ותרגול 3 .....	3
42	.....	הרצאה .....	3.1
42	.....	טרמינולוגיות .....	3.1.1
42	.....	מתחילה בקטן .....	
42	.....	הגדרה פורמלית - ניסוח כללי .....	
43	.....	תכונות של אוסף הפתרונות של בעית אופטימזציה .....	
45	.....	דוגמאות: .....	3.1.2
47	.....	תכונות ואפיון מסדר ראשון של פתרונות אופטימיים .....	3.1.3
47	.....	תנאי אופטימליות תחת איליצים .....	3.1.4
49	.....	תרגיל לדוגמא : quadratic minimization .....	3.1.5
51	.....	תרגול 3 .....	3.2
51	.....	הרצאה 4 .....	4
51	.....	הרצאה .....	4.1
51	.....	תרגיל לדוגמא: הטלה של נקודה בתחום קמור projection onto a convex set .....	4.1.1
53	.....	(פעולה משמרת בעית אופטימזציה קמורה) אופטימזציה חלקית ( / מינימיזציה חלקית ) .....	4.1.2
53	.....	שימוש לאופטימזציה חלקית: כתיבת בעית SVM בניסוח צירי hinge form of SVM .....	4.1.3
54	.....	החלפת משתניםtrasformation and change of variables .....	4.1.4
54	.....	דוגמאות: תכנות גאומטרי geometric programing .....	4.1.5
56	.....	רלקסציה ("הרגעה") relaxation .....	4.1.6
58	.....	תכנות ליניארי LPs Linear programs .....	4.1.7
61	.....	צורה סנדրית של LP .....	4.1.8
61	.....	תכנות ריבועי QPs Quadratic programs .....	4.1.9
62	.....	צורה הסנדրית של בעיתQP .....	4.1.10
62	.....	SMs semidefinite programs .....	4.1.11
62	.....	מבוא .....	
63	.....	בעית ה SMps semidefinite programs .....	
63	.....	הגדרת SMps semidefinite programs .....	
64	.....	תכנות קווי Cone programs .....	4.1.12
65	.....	תרגול 4 - בעית אופטימזציה קמורות ואלגוריתמים .....	4.2
65	.....	בעית אופטימזציה קמורות .....	4.2.1
65	.....	תנאי מספיק בעיתות קמורות: .....	
67	.....	מבוא לאלגוריתמי אופטימיזציה .....	4.2.2

## II שיטות ואלגוריתמים מסדר ראשון

67	.....	הרצאה 5 ותרגול 5 .....	5
67	.....	הרצאה 5 התחלתה של הנושא Gradient desecnt .....	5.1
68	.....	האלגוריתם GD-Gradient desecnt .....	5.1.1
69	.....	פרשנות (איינרפטציה) לאלא' GD-Gradient desecnt .....	
70	.....	קוצבי התכונות .....	
71	.....	توزואה טיפוסית לבני קוצב התכונות: .....	
71	.....	אנליזה ראשונית .....	
74	.....	נשיך בניתוח של המשפט .....	
75	.....	פוי' קמורה ליפשיץ .....	
76	.....	הוכחת המשפט: .....	
77	.....	פוי' חלוקות .....	5.1.2
79	.....	פעולות משמרות חלוקות: .....	
80	.....	קימירות אל מול לפשיות: .....	

80	הוכחה של GD עבר פון' חלקות . . . . .	
81	הוכחת הלמה: . . . . .	
81	המשפט GD עבר פון' חלקות . . . . .	
82	הוכחת המשפט GD עבר פון' חלקות . . . . .	
83	תרגול 5 . . . . .	5.1.3
83	אל' הגראדיאנט: . . . . .	
85	העשרה אל': Backtracking search . . . . .	
85	הרצאה 6 ותרגול 6 . . . . .	6
85	הרצאה 6 . . . . .	6.1
85	קבבי לימוד : הדוגמה על בעיה ריבועית . . . . .	6.1.1
87	החסם של נדרבו . . . . .	6.1.2
88	אנליזה של אל' של GD עבר פון' שאיין קמורות . . . . .	6.1.3
89	מסקנות מהשיעור הקודם סיכום . . . . .	6.1.4
89	אנליזה של פונקציות קמורות שאין גירות . . . . .	6.1.5
89	אלג' subgradient . . . . .	6.1.6
92	הקשר "קמורה ולפשיצית = סאב גראדיאנטיים חסומים" . . . . .	
92	תכונות של סאב-גרדיינטים . . . . .	
92	דוגמאות של סאב-גרדיינטים של פונקציות לא גירות . . . . .	
93	תכונות של סאב-גרדיינטים . . . . .	
93	אלג' סאב-גרדיינט subgradient descent . . . . .	6.1.7
94	אלג' הסאב גראדיאנט עבר פון' קמורה לפשיצית נותן קצב של $\mathcal{O}(\frac{1}{\epsilon^2})$ . . . . .	
94	אופטימיזציה עם אילוצים . . . . .	6.1.8
95	אלג' projected gradient descent . . . . .	6.1.9
96	דוגמאות להטלה . . . . .	6.1.10
99	תכונות של הטלה . . . . .	
101	תרגול 6 . . . . .	6.2
101	תת גרדיינטים . . . . .	6.2.1
102	הטלה על קבועה קמורה . . . . .	6.2.2
102	אלגוריתם הגרדיינט המוטל . . . . .	6.2.3
102	הרצאה 7 ותרגול 7 . . . . .	7
102	הרצאה 7 . . . . .	7.1
103	אלג' הגרדיינט המוטל projected gradient descent המשך . . . . .	7.1.1
103	התכנסות עבר פון' קמורה ולפשיצית מעל $X$ בסדר גודל של $\mathcal{O}(\frac{1}{\epsilon^2})$ צעדים . . . . .	7.1.2
106	אלג' הגרדיינט: קבבי התכונות מהירים יותר . . . . .	7.1.3
112	אלגוריתם הגרדיינט הסטוכסטי SGD . . . . .	
113	מבנה האלגוריתם: . . . . .	
115	bounded stochastic gradient descent: $\mathcal{O}(\frac{1}{\epsilon^2})$ steps . . . . .	
119	תרגול 7 . . . . .	7.2
119	אופטימיזציה סטוכסטית . . . . .	7.2.1
119	הגדרת הבעיה: . . . . .	
120	Finte sum/FRM . . . . .	
121	אלג' הגרדיינט הסטוכסטי . . . . .	7.2.2
122	אלג' הגרדיינט הסטוכסטי: . . . . .	
122	הרצאה 8 ותרגול 8 . . . . .	8
122	הרצאה 8 . . . . .	8.1
123	הרבבה אפשרית ראשונה לאlg' SGD: אלגוריתם ה Mini-batch SGD . . . . .	8.1.1
124	הרבבה אפשרית שנייה לאlg' SGD: אלגוריתם ה Stochastic subgradient Descent . . . . .	8.1.2
124	הרבבה אפשרית שלישית לאlg' SGD:SGD מושלצת בעיה מושלצת . . . . .	8.1.3
125	موظבציה לאלגוריתם Frank Wolfe . . . . .	8.1.4
126	אלגוריתם Frank Wolfe/conditonal gradient . . . . .	8.1.5
128	תכונות של אלג' פרנק-וולף: . . . . .	
129	דוגמאות: בעיית לאסו . . . . .	

131 . . . . .	מושג ה gap	
133 . . . . .	קביעת גודל ה gap	8.1.6
134 . . . . .	קצב התכנסות לאלגוריתם פרנק וולף	
134 . . . . .	הוכחת קצב ההתכנסות של אל' פרנק וולף:	
137 . . . . .	הרוחבות ושימושים של אל' פרנק וולף:	
138 . . . . .	האצה momentum ומומנטום acceleration	8.1.6
138 . . . . .	סיכום ביינימ	
138 . . . . .	מומנטום	
140 . . . . .	אלגוריתם הגרדיינט המואץ AGD	8.2
140 . . . . .	(נראה אל' שמצויר מאד את אל' הגרדיינט המואץ של נסטרוב, שנראה בתרגול)	
142 . . . . .	תרגול 8	8.2
142 . . . . .	אלגוריתם פרנק וולף	8.2.1
142 . . . . .	מוצבציה לכלל העדכון:	
144 . . . . .	אל' פרנק וולף:	
144 . . . . .	איינורנטיות לטרנספורמציה אפינית	8.2.2
145 . . . . .	מומנטום ואלגוריתם הגרדיינט המואץ של נסטרוב	8.2.3
146 . . . . .	הוספת איבר מומנטום לאל' GD	
147 . . . . .	אלגוריתם הגרדיינט המואץ של נסטרוב Nesterov's accelerated gradient	
148 . . . . .	תרגיל בית 3	8.3

<b>148</b>	<b>III הלגראנגיין והבעיה הדואלית</b>	
149 . . . . .	הרצאה 9 ותרגול 9	9
149 . . . . .	הרצאה 9	9.1
149 . . . . .	לגראנז'יין	9.1.1
151 . . . . .	תמונה חסובה של הלגראנז'יין	
155 . . . . .	תכונות של הבעיה הדואלית	9.1.2
155 . . . . .	דוalianות שלשה	
156 . . . . .	בעיה קמורה	
157 . . . . .	דוגמא	9.1.3
159 . . . . .	דוalianות חזקה	9.1.4
159 . . . . .	דוalianות בעוויות תכונות לינארי linear programs	9.1.5
162 . . . . .	בעיה SVM	9.1.6
164 . . . . .	תרגול 9	9.2
164 . . . . .	דוalianות	9.2.1
167 . . . . .	הרצאה 10 ותרגול 10	10
167 . . . . .	הרצאה 10 תנאי karush kuhn tucker KKT	10.1
167 . . . . .	תזכורת מההרצאה הקודמת	10.1.1
168 . . . . .	תנאי KKT	10.1.2
169 . . . . .	ציר של Complementarity slackness	
169 . . . . .	משפטים שיקילות של KKT ושל פתרון אופטמלי	
169 . . . . .	דוגמאות	10.1.3
173 . . . . .	דוגמא: בעיה ריבועית עם אילוצי שוויון	
173 . . . . .	דוגמא: דוגמא מטורת האינפורמציה	
174 . . . . .	דוגמא: ריבועים פחות מאולצים Constrained Least squares	
178 . . . . .	דוגמא לפתרון KKT בהקשר של SVM	
180 . . . . .	דוגמאות	10.1.4
180 . . . . .	אילוצי לגראנג'	10.1.5
181 . . . . .	Constrained an Lagrange forms	10.1.6
182 . . . . .	תרגול 10	10.2
182 . . . . .	תנאי KKT	10.2.1

183	11	11.1	11.1.1	11.1.2	11.1.3	11.1.4	11.2	11.2.1	11.2.2	11.2.3	11.2.4	12	12.1	12.1.1	12.1.2	12.1.3	12.1.4	12.2	12.2.1	12.2.2	12.2.3	12.2.4	13	13.1					
183 . . . . .	הרצאה ותרגול 11 . . . . .																												
183 . . . . .	הרצאה 11 . . . . .																												
184 . . . . .	שיטת ניוטון . . . . .																												
184 . . . . .	המקרה החד מימי - שיטת ניוטון רפסון . . . . .																												
184 . . . . .	The Babylonian method . . . . .																												
187 . . . . .	שיטת ניוטון לאופטימציה . . . . .																												
187 . . . . .	במקרה ה $d$ מימי . . . . .																												
188 . . . . .	איינרפטציות (דרכי הסתכלות) שונות על שיטת ניוטון . . . . .																												
188 . . . . .	adaptive gradient descent = שיטת ניוטון . . . . .																												
188 . . . . .	שיטות ניוטון - קירובים מסדר שני . . . . .																												
189 . . . . .	תכונות של שיטת ניוטון . . . . .																												
189 . . . . .	איינוואריאנטיות לטרנספורמציה אפינית (תמונה של שיטת ניוטון ) . . . . .																												
190 . . . . .	התכנסות לokaלית Local convergence (תמונה של שיטת ניוטון ) . . . . .																												
191 . . . . .	כשהאתה מתקרב מופיע, אתה כבר שם... . . . . .																												
191 . . . . .	התכנסות סופר אקפוננסצאלית (על-אקספוננסצאלית) . . . . .																												
192 . . . . .	איונטואציה לבבי התכנסות הסופר אקספוננסצאלית . . . . .																												
192 . . . . .	הוכחה של משפט ההתכנסות . . . . .																												
194 . . . . .	קמירות ממש $\Leftarrow$ ההפכי של ההסיאן חזום Bounded inverse hessians . . . . .																												
195 . . . . .	השווואה לשיטות מסדר ראשון . . . . .																												
195 . . . . .	בעיות אופטימציה קוונטקטיבית עם אילוצים . . . . .																												
196 . . . . .	אלג' ניוטון עם אילוצי שוויון (הכללה של שיטת ניוטון): . . . . .																												
196 . . . . .	שיטות קוזי ניוטון: . . . . .																												
196 . . . . .	תרגול 11 . . . . .																												
196 . . . . .	אלג' ניוטון . . . . .																												
197 . . . . .	אלג' גאוס-ניוטון בעיית איבועים פחותים . . . . .																												
200 . . . . .	הרצאה ותרגול 12 . . . . .																												
200 . . . . .	הרצאה 12 . . . . .																												
200 . . . . .	חזרה על שיעור קודם . . . . .																												
200 . . . . .	שבוע שערבר : שיטת ניוטון . . . . .																												
200 . . . . .	היררכיה של שיטות מסדר שני . . . . .																												
201 . . . . .	Barrier Method . . . . .																												
201 . . . . .	log barrier function . . . . .																												
203 . . . . .	Self-concordant . . . . .																												
203 . . . . .	חזרה קרצה לשיטות ניוטון . . . . .																												
203 . . . . .	नितוח התכנסות עברו פון' שיש להם את תוכנת ניוטון (תמונה שהוגדרה על ידי Nesterov and nemirovski self-concordance) . . . . .																												
204 . . . . .	תcovנות self-concordant . . . . .																												
204 . . . . .	תcovנות self-concordant . . . . .																												
204 . . . . .	דוגמאות נוספת לפונקציות self-concordant . . . . .																												
205 . . . . .	אנליזת התכנסות עברו פון' self-concordant בshiota ניוטון . . . . .																												
205 . . . . .	שיטת barrier - barrier העצמה . . . . .																												
206 . . . . .	שיטת Path . . . . .																												
207 . . . . .	מקרה של בעיית LP . . . . .																												
208 . . . . .	נוסיף בחזרה את אילוצי השוויון לעביה . . . . .																												
209 . . . . .	Tanai KKT . . . . .																												
210 . . . . .	Duality gap . . . . .																												
212 . . . . .	Shiota barrier עצמה . . . . .																												
213 . . . . .	barrier שיטה barrier . . . . .																												
214 . . . . .	הרצאה ותרגול 13 . . . . .																												
216 . . . . .	ניתוח התכנסות barrier שיטה barrier . . . . .																												
218 . . . . .	עלות חישובית בפועל של barrier שיטה barrier (כמה איטרציות בשיטה barrier) . . . . .																												
218 . . . . .	עוד כוורתה על barrier . . . . .																												

# חלק I

## מושגי מפתח באופטימיזציה ובקמירות

### 1 הרצתה 1 ותרגול 1 . מבוא והגדרות

1.1 חומר מבוא חוזר על מושגים אלגבריים וחדוווא.

1.1.1 המרחב האוקלידי  $\mathbb{R}^n$  מימדי

הגדרה 1.1  $\mathbb{R}^n$  וקטור עומדה בן  $n$  שורות עם כניסה ממשיות. לדוגמה,

$$\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}$$

$$\mathbf{x}^T = (x_1 \ x_2 \ \dots \ x_n) : \mathbb{R}^n$$

1. חיבור וקטוריים Component wise :

$$\begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} + \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = \begin{pmatrix} x_1 + y_1 \\ x_2 + y_2 \\ \vdots \\ x_n + y_n \end{pmatrix}$$

2. כפל בסקלר:

$$\lambda \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix} = \begin{pmatrix} \lambda x_1 \\ \lambda x_2 \\ \vdots \\ \lambda x_n \end{pmatrix}$$

סימון 2.1 הבסיס הסטנדרטי (נקרא גם הבסיס הקונוני) מסומן  $e_1, e_2, \dots, e_n$ . כאשר  $e_i$  הוא וקטור של אפסים פרט לכינסה ה $i$  שבה היא 1, לדוגמה,

$$e_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, e_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}, \dots, e_n = \begin{pmatrix} 0 \\ 0 \\ 0 \\ \vdots \\ 1 \end{pmatrix}$$

סימון 3.1 הווקטור  $e$  הוא וקטור שכלי 1-ים. כלומר  $e = \begin{pmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{pmatrix}$

**סימון 4.1** הווקטור  $\mathbf{0}$  הוא ווקטור שכלו  $0$ -ים. כלומר

$$\mathbf{0} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix}$$

תתי מרחבים חשובים של  $\mathbb{R}^n$ .

**הגדרה 5.1** תת מרחב הווקטוריים האי שליליים nonnegative orthant הוא תת מרחב של  $\mathbb{R}^n$  שמכיל את כל הווקטורים ב  $\mathbb{R}^n$  שעבורו כל הרכיבים הם אי שליליים. הוא מסומן  $\mathbb{R}_+^n$  ומוגדר כך:

$$\mathbb{R}_+^n = \left\{ (x_1, x_2, \dots, x_n)^T \mid x_1, x_2, \dots, x_n \geq 0 \right\}$$

**הגדרה 6.1** תת מרחב הווקטוריים החיוביים positive orthant הוא תת מרחב של  $\mathbb{R}^n$  שמכיל את כל הווקטורים ב  $\mathbb{R}^n$  שעבורו כל הרכיבים הם חיוביים. הוא מסומן  $\mathbb{R}_{++}^n$  ומוגדר כך:

$$\mathbb{R}_{++}^n = \left\{ (x_1, x_2, \dots, x_n)^T \mid x_1, x_2, \dots, x_n > 0 \right\}$$

**הגדרה 7.1** עבר  $y \in \mathbb{R}^n$ ,  $x$  או תת המרחב של  $\mathbb{R}^n$  שמהווה את **הקטע הסגור** בין  $x$  ל  $y$ , נקרא  $x$  and  $y$  **closed line segment**:

$$[x, y] = \{x + \alpha(y - x) \mid \alpha \in [0, 1]\}$$

**הגדרה 8.1** עבר  $y \in \mathbb{R}^n$ ,  $x$  או תת המרחב של  $\mathbb{R}^n$  שמהווה את **הקטע הפתוח** בין  $x$  ל  $y$ , נקרא  $x$  and  $y$  **open line segment**:

$$(x, y) = \{x + \alpha(y - x) \mid \alpha \in (0, 1)\}$$

**הגדרה 9.1** **unit simplex** מסומן על ידי  $\Delta_n$  ומוגדר על ידי:

$$\Delta_n = \left\{ \mathbf{x} \in \mathbb{R}^n \mid \sum_{i=1}^n x_i = 1, \forall i \in \{1, \dots, n\} : x_i \geq 0 \right\}$$

כלומר, אוסף כל הווקטורים שעבורו כל הרכיבים הם אי שליליים ( $\forall i \in \{1, \dots, n\} : x_i \geq 0$ ) **וגם** שמתקיים שסכום רכיביו הוא  $1$ , כלומר  $\sum_{i=1}^n x_i = 1$ . כלומר  $\mathbf{e}^T \mathbf{x} = 1$

### 1.1.2 המרחב ה $n \times m$ מימדי $\mathbb{R}^{m \times n}$

**הגדה 10.1** המרחב  $\mathbb{R}^{m \times n}$  הוא מרחב כל המטריצות במימד  $n \times m$  ( $m$  שורות ו  $n$  עמודות) בעלות ערכים ממשיים.

$$\text{סימון 11.1 } I_n = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & \dots & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix} \text{ קלומר}$$

$$\text{סימון 12.1 } 0_{m \times n} = \begin{pmatrix} 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & \dots & 0 & 0 \\ 0 & 0 & \dots & 0 & 0 \end{pmatrix} \text{ היא מטריצת האפס.}$$

### 1.1.3 מכפלה פנימית $\langle \cdot, \cdot \rangle$

**הגדה 13.1** מכפלה פנימית. מכפלה פנימית מעל מרחב  $\mathbb{R}^n$  היא פונקציה  $\langle \cdot, \cdot \rangle : \mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$  שמקיימת את כל 4 התכונות הבאות:

$$1. \text{ סמטריה: } \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : \langle \mathbf{x}, \mathbf{y} \rangle = \langle \mathbf{y}, \mathbf{x} \rangle$$

$$2. \text{ אדטיביות: } \forall \mathbf{x}, \mathbf{y}, \mathbf{z} \in \mathbb{R}^n : \langle \mathbf{x}, \mathbf{y} + \mathbf{z} \rangle = \langle \mathbf{x}, \mathbf{y} \rangle + \langle \mathbf{x}, \mathbf{z} \rangle$$

$$3. \text{ הומוגניות: } \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \forall \lambda \in \mathbb{R} : \langle \lambda \mathbf{x}, \mathbf{y} \rangle = \lambda \langle \mathbf{x}, \mathbf{y} \rangle$$

4. **חויביות מוגדרת:** הפונקציה תקרא חיובית מוגדרת אם שני התנאים הבאים מתקיימים:

$$(a) \forall \mathbf{x} \in \mathbb{R}^n : \langle \mathbf{x}, \mathbf{x} \rangle \geq 0$$

$$(b) \langle \mathbf{x}, \mathbf{x} \rangle = 0 \iff \mathbf{x} = 0$$

דוגמאות למכפלה פנימית.

**דוגמה 14.1** : the dot product

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : \langle \mathbf{x}, \mathbf{y} \rangle = \mathbf{x}^T \mathbf{y} = \sum_{i=1}^n x_i y_i$$

**הערה 15.1** מכפלה פנימית זו מכונה המכפלה פנימית הטבעית או המכפלה פנימית הסטנדרטית.

**דוגמה 16.1** : the weighted dot product

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n, \forall \mathbf{w} \in \mathbb{R}_{++}^n : \langle \mathbf{x}, \mathbf{y} \rangle_w = \sum_{i=1}^n w_i x_i y_i$$

### 1.1.4 נורמת וקטורים $\|\cdot\|$

**הגדה 17.1** נורמה מעל מרחב  $\mathbb{R}^n$  היא פונקציה (סקלארית)  $\|\cdot\| : \mathbb{R}^n \rightarrow \mathbb{R}$  שמקיימת את כל 3 התכונות הבאות:

1. **אי שליליות:** הפונקציה תקרא אי שלילית אם שני התנאים הבאים מתקיימים:

$$(a) \forall \mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\| \geq 0$$

$$(b) \|\mathbf{x}\| = 0 \iff \mathbf{x} = 0$$

2. **הומוגניות חיובית:**  $\forall \mathbf{x} \in \mathbb{R}^n, \forall \lambda \in \mathbb{R} : \|\lambda \mathbf{x}\| = |\lambda| \|\mathbf{x}\|$

3. **אי שוויון המשולש:**  $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : \|\mathbf{x} + \mathbf{y}\| \leq \|\mathbf{x}\| + \|\mathbf{y}\|$

**סימון 18.1**  $\|\cdot\|_{\text{sym}}$  הוא סימון לנורמה כלשהיא.

**דוגמה 19.1** דרך טبيعית אחת לייצר נורמה מעל  $\mathbb{R}^n$  היא לחת איזה מכפלה פנימית כלשהיא ( נאcir כי  $\mathbb{R}^n \times \mathbb{R}^n \rightarrow \mathbb{R}$  ) ולחדר את הנורמה הבאה:

$$\forall \mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\| \equiv \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$$

**הערה 20.1** נורמה זו נקראת גם הנורמה המושראית על ידי המכפלה הפנימית.

**הגדרה 21.1** הנורמה שמוגדרת עם המכפלה הפנימית dot product נקראת גם **הנורמה האוקלידית או נורמת  $l_2$**  ומוגדרת ומסומנת כך:

$$\forall \mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_2 = \sqrt{\sum_{i=1}^n |x_i|^2} = \sqrt{\sum_{i=1}^n x_i^2}$$

**הגדרה 22.1** לכל  $p \in \{1, 2, \dots\}$  נגדיר את ה  $\|\cdot\|_p$  norm באופן הבא:

$$\forall \mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_p = \sqrt[p]{\sum_{i=1}^n |x_i|^p}$$

**הגדרה 23.1** נגדיר את ה  $\|\cdot\|_\infty$  norm באופן הבא:

$$\forall \mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\|_\infty = \max_{i \in \{1, \dots, n\}} |x_i|$$

**הערה 24.1** ניתן להראות כי  $\|\cdot\|_p$

**הערה 25.1** נבחן כי  $\|\cdot\|_{\frac{1}{2}}$  אינה נורמה.

**1.1.5 אי שוויון קושי שוורץ**

**משפט 26.1** אי שוויון קושי שוורץ:

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : |\mathbf{x}^T \mathbf{y}| \leq \|\mathbf{x}\| \cdot \|\mathbf{y}\|$$

**הערה 27.1** אי שוויון קושי שוורץ קשור את המכפלה הפנימית והנורמה במרחבי מכפלה פנימית.

כלומר המשפט תקף במרחבים בהם הנורמה היא "הנורמה הטבעית" כפי שהוגדר בהערה 19.1:  $\forall \mathbf{x} \in \mathbb{R}^n : \|\mathbf{x}\| \equiv \sqrt{\langle \mathbf{x}, \mathbf{x} \rangle}$

**הערה 28.1** אי שוויון קושי שוורץ מסומן גם  $|\langle \mathbf{x}, \mathbf{y} \rangle| \leq \|\mathbf{y}\| \cdot \|\mathbf{x}\|$ .

### הוכחת אי שוויון קושי שוורץ:

- טענה: לכל  $\lambda \in \mathbb{R}$  מתקיים  $\|x + \lambda y\|^2 = \lambda^2 \|y\|^2 + 2\lambda \langle x, y \rangle + \|x\|^2$ .

הוכחת הטענה:

$$\begin{aligned}
 \|x + \lambda y\|^2 &= \left( \sqrt{\langle x + \lambda y, x + \lambda y \rangle} \right)^2 \\
 &= \langle x + \lambda y, x + \lambda y \rangle \\
 &= \langle x + \lambda y, x \rangle + \langle x + \lambda y, \lambda y \rangle \\
 &= \langle x, x + \lambda y \rangle + \langle \lambda y, x + \lambda y \rangle \\
 &= \langle x, x \rangle + \langle x, \lambda y \rangle + \langle \lambda y, x \rangle + \langle \lambda y, \lambda y \rangle \\
 &= (\sqrt{\langle x, x \rangle})^2 + \langle \lambda y, x \rangle + \lambda \langle y, x \rangle + (\sqrt{\langle \lambda y, \lambda y \rangle})^2 \\
 &= (\|x\|)^2 + \lambda \langle y, x \rangle + \lambda \langle x, y \rangle + (\|\lambda y\|)^2 \\
 &= \|x\|^2 + \lambda \langle x, y \rangle + \lambda \langle x, y \rangle + (|\lambda| \|y\|)^2 \\
 &= \|x\|^2 + \lambda \langle x, y \rangle + \lambda \langle x, y \rangle + |\lambda|^2 \|y\|^2 \\
 &= \|x\|^2 + 2\lambda \langle x, y \rangle + \lambda^2 \|y\|^2 \\
 &= \lambda^2 \|y\|^2 + 2\lambda \langle x, y \rangle + \|x\|^2
 \end{aligned}$$

- אנו יודעים כי מוגנות הנורמה  $0 \leq \|x + \lambda y\|^2 + 2\langle x, y \rangle \lambda + \|x\|^2 \geq \lambda^2 \|y\|^2$  ולכן מהטענה הקודמת נבע כי  $0 \leq \lambda^2 \|y\|^2 + 2\langle x, y \rangle \lambda + \|x\|^2$  ולכן מהטענה קיבנו פולינום ב  $\lambda$  **במקדמים ממשיים**. נסמן  $\|x\|^2 = a$ ,  $\|y\|^2 = b$ ,  $2\langle x, y \rangle = c$ . קלומר קיבנו את הפולינום  $0 \leq a\lambda^2 + b\lambda + c \geq a\lambda^2 + b\lambda + c$ . ערכו של הפולינום תמיד גדול או שווה לאפס. קלומר הפרבולת שמוגנת על ידי המשוואה לכל היותר נועת בצד  $\lambda$  אך אינה עוברת מתחתיו ולכן **למשואה יש פתרון יחיד לכל היותר**. נזכיר כי הדיסקrimיננטה מסומנת  $\Delta = b^2 - 4ac$ . אנו יודעים (מייקידה) שעבור פולינומים ריבועיים מעלה שדה המשיים מקיימים :

- הדיסקrimיננטה חיובית  $\Delta > 0$  כשייש למשואה שני פתרונות שונים.
- הדיסקrimיננטה שווה לאפס  $\Delta = 0$  כשייש פתרון ממשי יחיד.
- הדיסקrimיננטה שלילית  $\Delta < 0$  כשייש לפולינום פתרונות מעלה השדה  $\mathbb{R}$ . (אלא רק בשדה  $\mathbb{C}$  קלומר פתרונות  $\lambda$  שהם צמודים מורכבים)

למשואה  $a\lambda^2 + b\lambda + c = 0$  יש פתרון יחיד או שאין לה פתרונות (מעל  $\mathbb{R}$ ) מתקיים  $0 \leq \Delta \leq 4ac$  נציב  $b^2 - 4ac \leq 0$  נציג בחרזה את הסימונים ונקבל  $0 \leq b^2 - 4\|y\|^2 \cdot \|x\|^2 \leq (2\langle x, y \rangle)^2 - 4\|y\|^2 \cdot \|x\|^2 \leq 4\|y\|^2 \cdot \|x\|^2$  קלומר  $b^2 - 4\|y\|^2 \cdot \|x\|^2 \leq 0$  נחלק ב 4 וنعביר אגפים ונקבל  $\|x\|^2 \cdot \|y\|^2 \leq b^2$ .

- נבחן כי  $\langle x, y \rangle \in \mathbb{R}$  הוא סקלר ולכן  $|\langle x, y \rangle|^2 \leq \|y\|^2 \cdot \|x\|^2$  והוא סקלר חיובי ולכן  $0 \leq |\langle x, y \rangle|^2 \leq \|y\|^2 \cdot \|x\|^2$ .
- נוציא שורש מכל האגפים (שורש היא חד ערךית מעלה המשיים החשובים) ונקבל  $|\langle x, y \rangle| \leq \sqrt{\|y\| \cdot \|x\|}$ . נזכור כי  $|\langle x, y \rangle| \leq \sqrt{\|x\| \cdot \|y\|}$ .
- נבחן כי תחת הסימונים של אי השוויון קושי שוורץ ושל המכפלה הפנימית dot product מתקיים  $\langle y, x \rangle = x^T y$  ולכן קיבל את אי השוויון קושי שוורץ :

$$|x^T y| \leq \|y\| \cdot \|x\|$$

### 1.1.6 ערכים עצמיים ווקטוריים עצמיים

**הגדרה 29.1** תהא  $A \in \mathbb{R}^{n \times n}$  ווקטור  $v \in \mathbb{R}^n$  לא נקרא.  $Av = \lambda v$  אם קיים  $\lambda \in \mathbb{C}$  כך ש  $v$  הוא **ערך עצמי** המתאים לווקטור העצמי  $v$ .

**הערה 30.1** באופן כללי, למטריצות עם ערכים עצמיים יכולים להיות ערכים עצמיים קומפלקסים.

**משפט 31.1** אם המטריצה  $A \in \mathbb{R}^{n \times n}$  היא סמטרית (מטריצה סמטרית היא מטריצה המקיימת  $A^T = A$ ), אז כל הערכים העצמיים שלה הם בהכרח ממשיים.

**הערה 32.1** ככלומר המשפט במלים אחרות אם המטריצה  $A \in \mathbb{R}^{n \times n}$  היא סמטרית, אז קיימים:

- $\lambda_1, \dots, \lambda_n$  (הערכים העצמיים) כך ש  $\lambda_i \in \mathbb{R}$  ו  $\lambda_i \in \{1, \dots, n\}$ :  $\lambda_i \in \mathbb{R}$  (נדגיש כי האמירה של המשפט כי אלו ע"י ממשיים!)

• וקטוריים שונים מאפס אורתוגונליים  $v_1, v_2, \dots, v_n$  (הווקטורים העצמיים) כך ש  $\forall i \in \{1, \dots, n\}$ :  $Av_i = \lambda_i v_i$ .

**סימון 33.1** הערכים העצמיים של מטריצה סמטרית  $A \in \mathbb{R}^{n \times n}$  מסומנים לפי גודלם כך:

$$\lambda_1(A) \geq \lambda_2(A) \geq \dots \geq \lambda_n(A)$$

**סימון 34.1** הערך העצמי המקסימלי מסומן גם  $\lambda_{\max}(A)$  (ככלומר  $\lambda_1(A)$ ).

**סימון 35.1** הערך העצמי המינימי מסומן גם  $\lambda_{\min}(A)$  (ככלומר  $\lambda_n(A)$ ).

### 1.1.7 משפט הפירוק הספקטרלי

רעיון:

**סימון 36.1** תהא  $A \in \mathbb{R}^{n \times n}$  מטריצה ריבועית נסמן את סכום איברים האלכסון (A).Tr.כלומר

$$\text{Tr}(A) = \sum_{i=1}^n a_{ii} = a_{11} + a_{22} + \dots + a_{nn}$$

**משפט 37.1** סכום איברי האלכסון של מכפלת מטריצות אשר המכפלה שלהם נותנת מטריצה ריבועית, מקיים את התכונות הבאות:

$$\forall A, B \in \mathbb{R}^{m \times n}: \text{Tr}(A^T B) = \text{Tr}(B A^T) = \text{Tr}(A B^T) = \text{Tr}(B^T A) = \sum_{i,j} A_{ij} B_{ij}$$

כלומר הוא מהו סכום של מכפלת כל הכניסות של שתי המטריצות.

ראאה להסביר נוספת ([https://en.wikipedia.org/wiki/Trace\\_\(linear\\_algebra\)](https://en.wikipedia.org/wiki/Trace_(linear_algebra)))

**מסקנה 38.1** מתחת לסימן Tr מטריצות יכולות להתחלף בכפל: כלומר

$$\forall A, B \in \mathbb{R}^{m \times n}: \text{Tr}(AB) = \text{Tr}(BA)$$

**משפט 39.1** לכל  $A, B \in \mathbb{R}^{m \times n}$  מתקיים  $\det(A) \det(B) = \det(AB)$ . כאשר  $\det(A) \det(B) = \det(A) \det(B)$  מסמן את הדטרמיננטה של  $A$ .

**סימון 40.1** מטריצה אלכסונית  $D \in \mathbb{R}^{n \times n}$  מסומנת כך

$$D = \text{diag}(d_1, \dots, d_n) = \begin{pmatrix} d_1 & 0 & 0 & 0 \\ 0 & d_2 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & d_n \end{pmatrix}$$

**הגדרה 41.1** מטריצה אוניטרית.  $A \in \mathbb{R}^{n \times n}$  תקרא אוניטרית אם  $A$  מטריצה הפיכה ו  $A^{-1} = A^T$ .

**הערה 42.1** ככלומר אם  $A \in \mathbb{R}^{n \times n}$  מטריצה אוניטרית אז  $A^T A = AA^T = I_n$ .

**משפט 43.1** אוניטריות  $\iff$  שורותיה הן בסיס אורתונורמלי של  $\mathbb{R}^n$  ביחס למכפלה הפנימית הסטנדרטית בו  $\iff$  عمودיותה הן בסיס אורתונורמלי של  $\mathbb{R}^n$  ביחס למכפלה הפנימית הסטנדרטית בו.

**משפט הפירוק:**

**משפט 44.1** (*הפירוק הספקטרלי*) תהא  $A \in \mathbb{R}^{n \times n}$  מטריצה סמטרית. איז קיימת מטריצה אוניטרית  $U \in \mathbb{R}^{n \times n}$  ומטריצה אלכסונית  $D = \text{diag}(d_1, \dots, d_n)$  ( $I_n$ ) כך ש

$$U^T A U = D$$

**הערה 45.1**  $D$  היא המטריצה אלכסונית כך שכל איבר באלכסון שלה הוא ע"ע של מטריצה  $A \in \mathbb{R}^{n \times n}$ .

**הערה 46.1**  $U$  عمודות מהוות בסיס אורתונומלי למרחב  $\mathbb{R}^n$  אשר عمודותיה הם הוי"ע של  $A$ . (כאשר העמודה  $i$  של  $U$  היא הוגטור העצמי המתאים לערך העצמי  $(d_i)$

**הערה 47.1** מוכפלה של המשווה  $A = UDU^T$  ב  $U$  משמאלו וב  $U^T$  מימין נקבל

**מסקנה 48.1** מסקנות ישירות מהמשפט:

**משפט 49.1** סכום איברי האלכסון של מטריצה סמטרית  $A \in \mathbb{R}^{n \times n}$  שווה לסכום הערכים העצמיים שלה. קלומר

$$\text{if } A \text{ is symmetric} \Rightarrow \text{Tr}(A) = \sum_{i=1}^n \lambda_i(A)$$

הוכחה:

$$\text{Tr}(A) = \text{Tr}(UDU^T) = \text{Tr}(UU^TD) = \text{Tr}(I_nD) = \text{Tr}(D) = \sum_{i=1}^n \lambda_i(A)$$

**משפט 50.1** הדטרמיננטה של  $A \in \mathbb{R}^{n \times n}$  מקיימת

$$\text{if } A \text{ is symmetric} \Rightarrow \det(A) = \prod_{i=1}^n \lambda_i(A)$$

הוכחה:

$$\begin{aligned} \det(A) &= \det(UDU^T) \\ &= \det(U) \cdot \det(D) \cdot \det(U^T) \\ &= \det(U) \cdot \det(U^T) \cdot \det(D) \\ &= \det(UU^T) \cdot \det(D) \\ &= \det(I_n) \cdot \det(D) \\ &= 1 \cdot \det(D) \\ &= \prod_{i=1}^n \lambda_i(A) \end{aligned}$$

**הגדרה 51.1** מטריצה  $A \in \mathbb{R}^{n \times n}$  **סמטרית חיובית מוגדרת** Positive definite אם לכל  $x \in \mathbb{R}^n \neq 0$  מתקיים  $x^T Ax > 0$ . מטבילה מוגדרת  $A \succ 0$ .

**סימון 52.1** קבוצת כל המטריצות החיוביות מוגדרות מסדר  $n$  מסומן  $S_{++}^n$ .

**הגדרה 53.1** מטריצה  $A \in \mathbb{R}^{n \times n}$  称為 Positive semidefinite אם לכל  $x \in \mathbb{R}^n$  אם  $x^T A x \geq 0$  מתקיים  $A \succeq 0$ .  
אם  $A \in \mathbb{R}^{n \times n}$  אז  $x^T A x \geq 0$  אם ורק אם  $A$  שילילת מוגדרת אז מסומנים  $0 \leq A$ .

**סימון 54.1** קבוצת כל המטריצות האי שליליות מוגדרות מסדר  $n$  מסומן  $S_+^n$ .

**משפט 55.1** (הוכח בתרגול) תהא מטריצה  $A \in \mathbb{R}^{n \times n}$  איזי  $\iff A \succ 0 \iff$  כל הערכים העצמיים של  $A$  חיוביים ממש.

**משפט 56.1** (הוכח בתרגול) תהא מטריצה  $A \in \mathbb{R}^{n \times n}$  איזי  $\iff A \succeq 0 \iff$  כל הערכים העצמיים של  $A$  אי שליליים.

**סימון 57.1** נבחן כי אנו מסמנים  $S^n \in \mathbb{R}^{\frac{n(n+1)}{2} \times n}$  את מרחב המטריצות **הסמטריות** בגודל  $n \times n$ .

$$S^n = \left\{ X \in \mathbb{R}^{n \times n} \mid X = X^T \right\} \quad \text{כי עבור מטריצה סמטרית}$$

diagonal  $\overbrace{n}^{\text{דרגות חופש}. \text{כלומר}}$  +  $\overbrace{\frac{n^2 - n}{2}}^{\text{res of the elements}}$   $= \frac{n(n+1)}{2}$

**סיכום הסימונים למרחב המטריצות האחרוניים שפורטו:**

קבוצה	תיאור	פירוש
$S^n$	מרחב המטריצות <b>הסמטריות</b>	$S^n = \left\{ X \in \mathbb{R}^{n \times n} \mid X = X^T \right\}$
$S_+^n$	מרחב המטריצות <b>האי שליליות</b> מוגדרות	$S_+^n = \left\{ X \in S^n \mid X \succeq 0 \right\}$
$S_{++}^n$	מרחב המטריצות <b>החיוביות</b> מוגדרות	$S_{++}^n = \left\{ X \in S^n \mid X \succ 0 \right\}$

**טענה 58.1** לכל  $B \in \mathbb{R}^{n \times n}$  מטריצה ריבועית כלשהיא ולכל  $x \in \mathbb{R}^n$  קיימת מטריצה  $A$  סמטרית (השווה ל  $x^T B x$ ) כך שמתוקים

$$x^T A x = x^T B x$$

הוכחת הטענה:  
 $x^T B x$  הוא סקלאר. ולכן  $x^T B x \in \mathbb{R}$  ומכאן נובע כי

$$\begin{aligned} x^T B x &= \frac{1}{2} (x^T B x + x^T B x) = \frac{1}{2} (x^T B^T x + x^T B x) = \frac{1}{2} (x^T [B^T + B] x) \\ &= \left( x^T \left[ \frac{1}{2} [B^T + B] \right] x \right) = (x^T A x) \end{aligned}$$

נראה כי  $A$  אכן סמטרית כי

$$A = \frac{1}{2} (B^T + B) = \frac{1}{2} (B + B^T) = \left[ \frac{1}{2} (B^T + B) \right]^T = A^T$$

### 1.1.8 עקרונות בסיסיים בטופולוגיה

**הגדרה 59.1** כדור פתוח במרכז  $c \in \mathbb{R}^n$  וברדיוס  $r$ :

$$B(c, r) \equiv \{x \mid \|x - c\| < r\}$$

**הגדרה 60.1** כדור סגור במרכז  $c \in \mathbb{R}^n$  וברדיוס  $r$ :

$$B[c, r] \equiv \{x \mid \|x - c\| \leq r\}$$

**הערה 61.1** ההגדרה היא חוקית לכל נורמה.

**הגדרה 62.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ , נאמר שנקודה  $c \in U$  נקודה פנימית (interior point) של קבוצה  $U$  אם קיים  $r > 0$  עבורו  $B(c, r) \subseteq U$ .

**הגדרה 63.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ , הקבוצה של כל הנקודות  $c \in U$  שמהות נקודות פנימיות נקרא Interior (הפנימ) של  $U$  ומסומן  $\text{int}(U)$ .

$$\text{int}(U) = \{c \in U \mid B(c, r) \subseteq \mathbb{R}^n \text{ for some } r > 0\}$$

**דוגמה 64.1** דוגמאות :

$$\begin{aligned} \text{int}(\mathbb{R}_+^n) &= \mathbb{R}_{++}^n \\ r \in \mathbb{R}_{++} &\Rightarrow \\ r \in \mathbb{R}_{++}^1 &\Rightarrow \\ \Rightarrow \mathbb{R} &\ni r > 0 \\ \forall c \in \mathbb{R}^n, \forall & \underbrace{r \in \mathbb{R}_{++}}_{\text{int}([x, y]) = \emptyset} : \text{int}(B[c, r]) = B(c, r) \end{aligned}$$

### קבוצות פתוחות וסגורות

**הגדרה 65.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ , הקבוצה  $U$  תקרא קבוצה פתוחה Open set אם  $U$  מכילה רק נקודות שמהות נקודות (=נקודות פנים). כלומר  $U = \text{int}(U)$ . כלומר Interior (הפנימ).

**דוגמה 66.1** דוגמאות לקבוצות פתוחות:

- כדור פתוח  $B(c, r)$  (מכאןשמו)
- קו פתוח ורק עבור  $n = 1$ . (בכל  $n > 1$  קו פתוח אינו קבוצה פתוחה)
- המרחב  $\mathbb{R}_{++}^n$

**משפט 67.1** כל איחוד של קבוצות פתוחות הוא קבוצה פתוחה.

**משפט 68.1** כל חיתוך של מספר סופי של קבוצות פתוחות הוא קבוצה פתוחה.

**הגדרה 69.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ , הקבוצה  $U$  תקרא קבוצה סגורה Close set אם  $U$  מכילה את כל גבולות של כל סדרת איברים בה. כלומר  $U$  סגורה  $\iff$  לכל סדרה  $\{x_i\}_{i=1}^\infty \subseteq U$  (סדרה של וקטורים מ $U$ ) המקיים  $x^* = \lim_{i \rightarrow \infty} x_i$  אז  $x^* \in U$ .

**משפט 70.1**  $U$  היא קבוצה סגורה  $\iff$  הקבוצה המשילימה שלה שמסומנת  $U^c$  היא קבוצה פתוחה.

**דוגמה 71.1** דוגמאות לקבוצות סגורות:

- כדור סגור  $[c, r]$
- קו סגור  $[x, y]$
- המרחב  $\mathbb{R}_+^n$
- $\Delta_n = \{x \in \mathbb{R}^n \mid \sum_{i=1}^n x_i = 1, \forall i \in \{1, \dots, n\} : x_i \geq 0\}$  unit simplex (הם ממשמעו  $\Delta_n$  ומשמעותו  $\Delta_n$  שסומן  $\Delta_n$  ומשמעותו  $\Delta_n$  unit simplex).

**הערה 72.1** בנוגע ל $\mathbb{R}^n$  ול $\emptyset$  הם גם נחבות קבוצות פתוחות וגם נחבות קבוצות סגורות.

## נקודות שפה וסגור

**הגדה 73.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ . נאמר שנקודה  $x \in \mathbb{R}^n$  נקודה שפה Boundary Point אם כל סביבה של  $x$  (כלומר כל כדור סביב נקודה  $x$ ) מכילה לפחות נקודה אחת מ  $U$  וגם נקודה אחת מ  $U^c$  (=משלים של  $U$ ).

**סימון 74.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ . הקבוצה של כל הנקודות  $x$  כך שהן נקודות שפה Boundary Points של  $U$  תסומן  $\text{bd}(U)$ .

**הגדה 75.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ . הקבוצה של כל הנקודות  $x$  כך שהן נקודות שפה Boundary Points של הקבוצות הסגורות המכילות את  $U$ . כלומר  $\text{cl}(U) = \bigcap \{T \mid U \subseteq T, T \text{ is closed}\}$ .

$$\text{cl}(U) = U \cup \text{bd}(U)$$

## קומפקטיות וחסימות

**הגדה 76.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ . הקבוצה  $U$  תקרא **חסומה** אם קיים  $M > 0$  כך ש  $U \subseteq B(\mathbf{0}, M)$ .

**הגדה 77.1** בהינתן קבוצה של נקודות  $U \subseteq \mathbb{R}^n$ . הקבוצה  $U$  תקרא **קומפקטיבית** אם  $U$  היא סגורה וחסומה.

### טבלה מסכמת של כלל ההגדדות:

נקודה פנימית (interior point) $U \subseteq \mathbb{R}^n$	נקודה שפה (Boundary Point) $U \subseteq \mathbb{R}^n$	נקודה סגורה $U \subseteq \mathbb{R}^n$	נקודה חסומה $U \subseteq \mathbb{R}^n$	נקודה קומפקטיבית $U \subseteq \mathbb{R}^n$
$B(c, r) \subseteq U$ עבור $r > 0$ קיים				
$C = \text{int}(U) = \{c \in U \mid B(c, r) \subseteq U \text{ for some } r > 0\}$	אם $U$ לא Interior			$C \subseteq U \subseteq \mathbb{R}^n$
$U = \text{int}(U)$	אם $U$ Open set			$U \subseteq \mathbb{R}^n$
$x^* \in U \text{ ו } \lim_{i \rightarrow \infty} x_i = x^* \subseteq U$ (סדרה של וקטורים $x_i$ המקיים $x_i \in U$ לכל $i$ )	כל סדרה $x^*$ קבוצה סגורה	קבוצה $U$ קבוצה פתחה		$U \subseteq \mathbb{R}^n$
$\forall r > 0 : B(x, r) \cap U \neq \emptyset \text{ ו } B(x, r) \cap U^c \neq \emptyset$	מ长时间: $U$ היא קבוצה סגורה $\iff$ הקבוצה המשלימה שלה שטוחה			
$\exists M > 0 : U \subseteq B(\mathbf{0}, M)$		הקבוצה של כל הנקודות $x$ כך שהן נקודות שפה Boundary Points של $U$ (Boundary Point)		
$U$ היא סגורה וחסומה				

### 1.1.9 נגורות

**הגדה 78.1** תחא  $f$  פונקציה המוגדרת מעלה קבוצה  $S \subseteq \mathbb{R}^n$ . תחא  $x \in \text{int}(S)$  נקודה פנימית של  $S$ , כלומר  $f'(x)$  קיימים, אז הוא יקרא הנגזרת המכוונת של  $f$  בנקודה  $x$  בכיוון “ $d$ ” אם הגבול  $\lim_{t \rightarrow 0^+} \frac{f(x+td) - f(x)}{t}$  קיים (הנדסה טריוויאלית) וגם הגבול  $f'(x; d)$  קיימים (of  $f$  at  $x$  along the direction  $d$ ) :

$$f'(x; d) \equiv \lim_{t \rightarrow 0^+} \frac{f(x + td) - f(x)}{t}$$

**סימון 79.1** לכל  $i \in \{1, \dots, n\}$  “הגבול של הנגזרת ה $i$ -הית של  $f$  בנקודה  $x$  בכיוון  $e_i$ ” נקרא “הנגזרת החלקית ה- $i$ -ית של  $f$  בנקודה  $x$ ”. כלומר  $\frac{\partial f}{\partial x_i}(x)$  ומסומן  $(x)$  (The  $i$ -th partial derivative).

$$\frac{\partial f}{\partial x_i}(x) = \lim_{t \rightarrow 0^+} \frac{f(x + t e_i) - f(x)}{t}$$

**הגדה 1 80.1** אם כל הנגזרות החלקיות של  $f$  בנקודה  $x$  קיימות. אז **הגדדיאנט** של  $f$  בנקודה  $x$  מוגדר כך:

$$\nabla f(\mathbf{x}) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \frac{\partial f}{\partial x_2}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\mathbf{x}) \end{pmatrix}$$

**הגדה 1 81.1** תהא  $f$  פונקציה המוגדרת מעל קבוצה **פתוחה**  $U \subseteq \mathbb{R}^n$ . תקרא **גירה ברציפות מעל**  $f: U \rightarrow \mathbb{R}$  אם כל הנגזרות החלקיות שלה קיימות ורציפות ב  $U$ . במקרה זה:

$$f'(\mathbf{x}; \mathbf{d}) = \nabla f(\mathbf{x})^T \mathbf{d}, \quad \mathbf{x} \in U, \mathbf{d} \in \mathbb{R}^n$$

**משפט 1 82.1** תהא  $f$  פונקציה המוגדרת מעל קבוצה **פתוחה**  $U \subseteq \mathbb{R}^n$ . אם  $f$  גירה ברציפות מעל  $U$  אז

$$\forall \mathbf{x} \in U : \lim_{\mathbf{d} \rightarrow 0} \frac{f(\mathbf{x} + \mathbf{d}) - f(\mathbf{x}) - \nabla f(\mathbf{x})^T \mathbf{d}}{\|\mathbf{d}\|} = 0$$

**הערה 1 83.1** דרך אחרת לרשום את אי השוויון לעיל הוא  $f(\mathbf{y}) = f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + o(\|\mathbf{y} - \mathbf{x}\|)$  כאשר  $\lim_{t \rightarrow 0^+} \frac{o(t)}{t} \rightarrow 0$ .

**הגדה 1 84.1** הנגזרת החלקית ה  $(i, j)$  של  $f$  בנקודה  $U \in x$  (אם קיימת) מוגדרת ומסומנת על ידי

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial \left( \frac{\partial f}{\partial x_j} \right)}{\partial x_i}(\mathbf{x})$$

**הגדה 1 85.1** תהא  $f$  פונקציה המוגדרת מעל קבוצה **פתוחה**  $U \subseteq \mathbb{R}^n$ . תקרא **גירה ברציפות פעמיים מעל**  $f: U \rightarrow \mathbb{R}$  אם כל הנגזרות החלקיות מסדר שני שלה **קיימות ורציפות** ב  $U$ . במקרה זה הנגזרות מסדר שני הם סמטריות, כלומר  $\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$  לכל  $i \neq j$  ולכל  $\mathbf{x} \in U$  מתקיים :

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}$$

**הגדה 1 86.1** מטריצת ההאסיאן של  $f$  בנקודה  $\mathbf{x} \in U$  היא מטריצה  $n \times n$  מהצורה :

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_2^2}(\mathbf{x}) & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial x_n \partial x_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{x}) \end{pmatrix}$$

**הערה 1 87.1** אם המטריצה גירה ברציפות פעמיים מעל  $U$  אז מטריצת ההאסיאן היא מטריצה סמטרית.

**משפט 1 88.1** תכונות של :

היו  $g, f: \mathbb{R}^n \rightarrow \mathbb{R}$  פונקציות המוגדרות מעל קבוצה **פתוחה**  $U \subseteq \mathbb{R}^n$ .

. $\nabla(f+g) = \nabla f + \nabla g$  אם  $f, g$  גזירות ברציפות איזי.

. $\nabla(\lambda f) = \lambda \nabla f$  אם  $f$  גזירה ברציפות ו-  $\lambda \in \mathbb{R}$  איזי.

3. אם  $f$  גזירה ברציפות, ו-  $A \in \mathbb{R}^{n \times m}$ , אז  $g(x) = f(Ax)$

$$\begin{aligned}\nabla g(x) &= A^T \nabla f(Ax) \\ \nabla^2 g(x) &= A^T \nabla^2 f(Ax) A\end{aligned}$$

**הערה 89.1** תזכורת : גזירה וקטוריות:

### חוקי גזירה וקטוריות

$$\begin{aligned}\frac{\partial}{\partial x}(a^T x) &= \frac{\partial}{\partial x}(x^T a) = a \\ \frac{\partial}{\partial x}(x^T Ax) &= (A^T + A)x \\ \frac{\partial z}{\partial x} &= \frac{\partial y}{\partial x} \frac{\partial z}{\partial y} \\ \frac{\partial z}{\partial x} &\neq \frac{\partial z}{\partial y} \frac{\partial y}{\partial x} \quad \text{בזרע כיל} \\ \frac{\partial}{\partial x} A^T x &= \frac{\partial}{\partial x} x^T A = A\end{aligned}$$

$$\begin{aligned}\frac{\partial}{\partial x}(Ax + b)^T (Ax + b) &= 2A^T(Ax + b) \\ \frac{\partial}{\partial x}(Ax + b)^T C(Ax + b) &= A^T(C + C^T)(Ax + b) \\ \frac{\partial}{\partial x}(Ax + b)^T (Dx + e) &= A^T(Dx + e) + D^T(Ax + b) \\ \frac{\partial}{\partial x}(Ax + b)^T C(Dx + e) &= A^T C(Dx + e) + D^T C^T(Ax + b)\end{aligned}$$

### משפטי קירוב

**משפט 90.1** **משפט הקירוב הלינארי** (=קירוב טילור מסדר ראשון). תהא  $f : U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$  אשר גזירה ברציפות פרמיים מעלה  $U$ . תהא נקודה  $x \in \mathbb{R}^n$  המקיימת  $x \in U$  ויהא  $r > 0$  המקיים  $B(x, r) \subseteq U$ . אזי לכל נקודה  $y \in \mathbb{R}^n$  בזרע כיל  $[x, y] \in [x, y] \in B(x, r)$  :

$$f(y) = f(x) + \nabla f(x)^T (y - x) + \frac{1}{2} (y - x)^T \nabla^2 f(\xi) (y - x)$$

**משפט 91.1** **משפט הקירוב הריבועי** (=קירוב טילור מסדר שני). תהא  $f : U \subseteq \mathbb{R}^n \rightarrow \mathbb{R}$  אשר גזירה ברציפות פרמיים מעלה  $U$ . תהא נקודה  $x \in \mathbb{R}^n$  המקיימת  $x \in U$  ויהא  $r > 0$  המקיים  $B(x, r) \subseteq U$ . אזי לכל נקודה  $y \in \mathbb{R}^n$  בזרע כיל  $[x, y] \in B(x, r)$  :

$$f(y) = f(x) + \nabla f(x)^T (y - x) + \frac{1}{2} (y - x)^T \nabla^2 f(x) (y - x) + o(\|y - x\|^2)$$

## 1.2 חומר של הרצאה 1

### 1.2.1 סוגי הבעיה שניתן לפתור ב'יעילות'

הערות	סבוכיות	פתרון	צורה מתמטית	שם הבעיה
קל לוחץ. ניתן להוציא גורם רגולציה.	$n^2 k$ ( $A \in \mathbb{R}^{k \times n}$ )	$x^* = (A^T A)^{-1} A^T b$	$\underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimize}} \ A\mathbf{x} - b\ _2^2$	Least squares
קשה לאיזופני המטרה והאלצים הם ליטאים.	$n^2 m$ if $m \geq n$	סבוכיות $n$ אנטירון אלילוי או נסחא סגורה.	$\underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimize}} \ A\mathbf{x} - b\ _2^2$ s.t.: $a_i^T x \leq b_i$ , $i \in \{1, \dots, m\}$	Linear programming
פונקציית המטרה והאלוצים קמורים.	Linear programming Least squares Convex optimization problems	ב夷ות אם מקרה פרטי של	$\underset{\mathbf{x} \in \mathbb{R}^n}{\text{minimize}_g(\mathbf{x})}$ s.t.: $g_i(\mathbf{x}) \leq 0$ , $i \in \{1, \dots, m\}$	Convex optimization problems

### 1.2.2 הגדרות הקשורות למושג הקmirות

הגדרה 92.1 קבוצה קבוצה קמורה אם  $C \subseteq \mathbb{R}^n$  תקרא קבוצה קמורה אם

$$\forall t \in \mathbb{R}, t \in [0, 1] : \\ \forall \mathbf{x}, \mathbf{y} \in C \Rightarrow t\mathbf{x} + (1-t)\mathbf{y} \in C$$

הערה 93.1 במלילם: קבוצה היא קמורה אם לכל 2 נקודות בקבוצה,oko המחבר בין 2 הנקודות מכיל אך ורך נקודות שישיות לקבוצה.



דוגמה 94.1 דוגמא לקבוצה קמורה



דוגמה 95.1 דוגמא לקבוצה שאינה קמורה



סימונו 96.1 תהא פונ'  $f : A \rightarrow B$ . נסמן את תחום ההגדרה של  $f$  dom( $f$ )  $\subseteq \mathbb{R}^n$ .

הגדרה 97.1 תהא פונקציה  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  כך ש dom( $f$ )  $\subseteq \mathbb{R}^n$  והוא קבוצה קונבקסית. אז  $f$  תקרא פונקציה קמורה convext function אם

$$\forall t \in \mathbb{R}, t \in [0, 1] : \\ \forall \mathbf{x}, \mathbf{y} \in \text{dom}(f) \Rightarrow f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$$


הערה 98.1 לעיתים ארשום פון' קונבקסית / פון' קמורה. חשוב לזכור כי זה אותו הדבר (שם לעזיז ועברי לאותו הדבר)

דוגמה 99.1 דוגמא לפונק' קונבקסית





משמעות קמירות מבחן גרפית:

גרפית, הקטע המחבר בין שתי נקודות נמצא מעל לגרף הפונקציה.



**הערה 100.1** כלומר פון'  $f$  תקרא קוונטטיבית אם לכל  $y, x$  בתחום ההגדרה של  $f$ , הקו המחבר בין  $x$  ל  $y$  נמצא מעל הגרף הפונקציה  $f$ .

**דוגמה 101.1** דוגמא לפונקציות לא קמורות



**הגדרה 102.1** פונקציה  $h : \mathbb{R}^n \rightarrow \mathbb{R}$  תקרא אפינית אם לכל  $x \in \mathbb{R}^n$ , קיימים  $a, b \in \mathbb{R}^n$  כך ש  $h(x) = a^T x + b$

**הגדרה 103.1** בעיית אופטימיזציה קמורה. נתונה הבעה הבא

$$\begin{aligned} & \min_{x \in D} f(x) \\ \text{subject to : } & \begin{cases} g_i(x) \leq 0 & , i = 1, \dots, m \\ h_j(x) = 0 & , j = 1, \dots, r \end{cases} \end{aligned}$$

כאשר תחום  $D = \text{dom}(f) \cap \left[ \bigcap_{i=1}^m \text{dom}(g_i) \cap \bigcap_{j=1}^r \text{dom}(h_j) \right]$  קמורה בהינתן ש  $f$  היא פונקציה קמורה ווגם  $g_i(x), i = 1, \dots, m$  ו  $h_j(x), j = 1, \dots, r$  הם פונקציות אפיניות. (כלומר  $h_j(x) = a_j^T x + b_j$ )

**משפט 104.1** אם  $f$  פונקציה קמורה וקיים  $\rho > 0$  כך ש  $\forall y : \|x - y\| \leq \rho \Rightarrow f(x) \leq f(y)$  אז  $f$  מינימום מקומי של  $f$ .

**הערה 105.1** בambilים אחרות, אם  $f$  פונקציה קמורה ו  $x$  הוא מינימום מקומי אז  $x$  הוא מינימום גלובלי.

**הערה 106.1** בambilים אחרות אם  $f$  פונקציה קמורה וקיים  $\rho > 0$  כך ש  $\forall y \in B[x, \rho] : f(x) \leq f(y) \leq f(x)$ .

### משפט 107.1 הוכחה:

נזכיר את הסימון של כדור היחידה הסגור  $B[c, r] \equiv \{x \mid \|x - c\| \leq r\}$ .  
 נתון נתון ש  $f$  היא פונקציה קמורה ונთנו שקיימים  $\rho > 0$  כך ש  $\forall y \in B[x, \rho] : f(x) \leq f(y) \leq f(x)$ .  
 צ"ל שלכל  $y \in \mathbb{R}^n$   $f(x) \leq f(y)$ :

הוכחה:  
 יהא  $y \in \mathbb{R}^n$  יתגלו  $y' \in B[x, \rho]$  ממנהו  $f(x) \leq f(y') \leq f(y)$ .  
 מתקיים  $y' = (1 - \alpha)x + \alpha y$  עבורו  $0 < \alpha < 1$ .  
 מכאן  $y' \in B[x, \rho]$  כי  $|y' - x| \leq |y - x| < \rho$ .

$$\exists \alpha \in (0, 1) \subseteq \mathbb{R} : y' = (1 - \alpha)x + \alpha y \in B[x, \rho]$$

ולכן מהנתון נובע כי  $f(x) \leq f(y') \leq f(y)$  נקבע

$$\begin{aligned} f(x) &\leq f\left(\overbrace{y'}^{(1-\alpha)x+\alpha y}\right) \\ &= f((1 - \alpha)x + \alpha y) \\ &\stackrel{\text{$f$ is convex}}{\leq} (1 - \alpha)f(x) + \alpha f(y) \end{aligned}$$

• מכאן נובע כי

$$\begin{aligned} f(x) &\leq (1 - \alpha)f(x) + \alpha f(y) \\ \Rightarrow (\alpha - 1)f(x) + f(x) &\leq \alpha f(y) \\ \Rightarrow \alpha f(x) &\leq \alpha f(y) \\ \alpha \in (0, 1) \Rightarrow \alpha > 0 &\Rightarrow f(x) \leq f(y) \end{aligned}$$

הראנו כי  $\forall y \in \mathbb{R}^n : f(x) \leq f(y)$  ■ וסיימנו.

## 2 הרצאה 2

**הגדרה 1.2 צורף קמור** Convex combination של קבוצה  $C \subseteq \mathbb{R}^n$  הוא כל צורף לנארי  $\theta_1 x_1 + \dots + \theta_k x_k$  כך ש:  $\sum_{i=1}^k \theta_i = 1$  ו  $\theta_i \geq 0$


**הגדרה 2.2 הקמור** Convex hull (קורי ) של קבוצה  $C$  מסומן  $\text{conv}(C)$  והוא הגדיר את כל הצלופים הקמורים של אלמנטים ב- $C$ .

**משפט 3.2** הקמור של קבוצה  $C$  ( $\text{conv}(C)$ ) הוא קבוצה קמורה.


**הערה 4.2** הקמור של קבוצה  $C$  הוא למעשה הגוף הקמור המינימלי המכיל את כל הנקודות בקבוצה  $C$ .

**הערה 5.2 אינטואיציה** (מotton ויקפדייה)

- במרחב הדו מימדי: ניתן לדמות את הקמור לגומייה, שנמתה כך שתקיים את כולם, ולאחר מכן שוחררה.
- בشرطוט, נניח שהקבוצה  $C$  הם הנקודות השחורות, אז העיגול השחור הוא כמו הגומייה המתוחה שצובעה בכחול והוא הקמור של הקבוצה  $C$  (הגומייה המתוחה הכחולה "שחתלבשה על הנקודות השחורות").



– דוגמאות נוספות לקמור של צורות:



- במרחב התלת מימדי: ניתן לדמות את הקמור ליריעת אלסטית מתוחה, שמקיפה אוסף של עצמים גאומטריים.

**דוגמה 6.2** דוגמאות לקבוצות קמורות:

דוגמא לקבוצה קמורה:	הכרזת קבוצה קמורה:	הערות	שרוטט
כדור גורמה	$\forall t \in \mathbb{R}, t \in [0, 1] : \forall \mathbf{x}, \mathbf{y} \in C \Rightarrow t\mathbf{x} + (1-t)\mathbf{y} \in C$		
hyper plane	$r$ רדיוס נורמה $\ x - \mathbf{y}\  \leq r$	הוא וקטור מינרמל.	
half space	$\mathbf{a} \in \mathbb{R}^n, b \in \mathbb{R}, \ \mathbf{a}\  = 1 : \{\mathbf{x}   \mathbf{a}^T \mathbf{x} = b\}, \mathbf{a} \neq 0$	על משורו הוא נס קבוצה אפייה.	
affine space	$\mathbf{A} \in \mathbb{R}^{n \times n}, \mathbf{b} \in \mathbb{R}^n : \{x   Ax = b\}$	הוא וקטור מינרמל.	
חישוב אפיי	$\{\{x, t\}   \ x\  \leq t\}$	אם $\mathbf{x} \in \mathbb{R}^n$ או $\mathbf{x} \in \mathbb{R}^{n+1}$ חישוב הוא תחת מרחב של $\mathbb{R}^n$	
חישוב גורמה	$\text{conv}(\mathcal{S})$ כלה של קבוצה $\mathcal{S}$	וכאשר בהקשר זהה הסימן $\leq$ מוחשב לכל שורה בנפרד.	
טולינדרומיטים	$\text{conic hull}$ $\text{coni}(\mathcal{S})$	$\text{coni}(\mathcal{S}) = \{\sum_{i=1}^k \theta_i x_i   x_i \in \mathcal{S}, 0 \leq \theta_i \in \mathbb{R}, i, k \in \mathbb{N} \setminus \{0\}\}$	
simplex	$\text{conv}(\mathbf{e}_1, \dots, \mathbf{e}_n)$	$\mathbf{e}_i = (0, \dots, 0, 1, 0, \dots, 0)$	
conic hull	$\mathbf{x}_0 \in C$ ו $C \subseteq \mathbb{R}^n$	$\mathcal{N}_C(\mathbf{x}) = \{\mathbf{y}   \mathbf{y}^T (\mathbf{x} - \mathbf{x}_0) \geq 0 \text{ for all } \mathbf{x} \in C\}$	
normal cone	$\mathbf{x}_0 \in C$ ו $C \subseteq \mathbb{R}^n$	$S^n_+ = \{\mathbf{x} \in S^n   \mathbf{x} \succeq 0\} \in \mathbb{R}^{\frac{n(n+1)}{2}}$	

Figure 1.10 Boundary of positive semidefinite cone in  $S^n$

**הערה 7.2** כל הקבוצות בטבלה הם קבוצות קמורות.

## 2.1 קבוצות וקבוצות קמורות


### 2.1.1 כדורים וחגורות

נזכיר את ההגדרה של כדור (הפעם תחת נורמה  $L_2$ ):

**הגדרה (תזכורת)** : כדור (אוקלידי) (כלומר כדור נורמה תחת הנורמה  $L_2$ ) עם מרכז  $x_c \in \mathbb{R}^n$  ורדיוס  $r \in \mathbb{R}$

$$B[x_c, r] = \{x \mid \|x - x_c\| \leq r\} = \{x_c + ru \mid \|u\|_2 \leq 1\}$$

**הגדרה 8.2 אליפסואיד** הוא סט של נקודות מהצורה  $\left\{x \mid (x - x_c)^T P^{-1} (x - x_c) \leq 1\right\}$  כאשר  $P \in S_{++}^n$  כלומר  $P$  היא חיובית מוגדרת.




**הערה 9.2** הגדרה שקופה לאליפסואיד : סט של נקודות מהצורה  $\{x_c + Au \mid \|u\|_2 \leq 1\}$  היא מטריצה ריבועית  $n \times n$  שאינה סינגולרית (=היפיכה).

**הגדרה (תזכורת) כדור נורמה (הפעם כללית בלשונא)** עם מרכז  $x_c \in \mathbb{R}^n$  ורדיוס  $r$

$$B[x_c, r] = \{x \mid \|x - x_c\| \leq r\} = \{x_c + ru \mid \|u\| \leq 1\}$$


**הערה 10.2** כדור נורמה הוא קובוצה קמורה.

**הגדרה 11.2** חרוט נורמה norm cone מוגדר להיות  $\{(x, t) \mid \|x\| \leq t\}$ .



**הערה 12.2** אם  $x \in \mathbb{R}^n$  אז חרוט נורמה הוא קבוצה מעל המרחב  $\mathbb{R}^{n+1}$ . לדוגמה הشرطו הזה מציג חרוט קונכי מעל הקבוצה  $(x \in \mathbb{R}^2 \text{ כי } t \in \mathbb{R}^3)$

**הערה 13.2** חרוט הנורמה הוא הקבוצה הכהולה (חרוט עצמו, כולל הקצוות) :



**סימון 14.2 שם:** חרות נורמה תחת הנורמה האוקלידית  $L_2$  נקרא גם **חרוט מסדר שני**.

**הערה 15.2** חרות נורמה הוא **קבוצה קמורה**.

### 2.1.2 פאון וסימפלקס – גופים קמורים

**הדרה 16.2 פאון Polyhedron** (פוליהדרון) הוא קבוצה  $\{x \mid Ax \leq b\}$  כאשר  $A \in \mathbb{R}^{n \times n}$ ,  $x, b \in \mathbb{R}^n$  וכאשר בהקשר זהה הסימן  $\leq$  מוחשב לכל שורה בנפרד. כלומר פאון היא הקבוצה המוגדרת על ידי אוסף  $x$ -ים המהווים פתרונות למערכת המשוואות הלינארית (מערכת אילוצים או שיטות ליניאריות) לכלה:

$$\begin{array}{llllll} a_{11}x_1 + & a_{12}x_2 + & \dots + & a_{1n}x_n & \leq & b_1 \\ a_{21}x_1 + & a_{22}x_2 + & \dots + & a_{2n}x_n & \leq & b_2 \\ \vdots & \vdots & & \vdots & & \vdots \\ a_{n1}x_1 + & a_{n2}x_2 + & \dots + & a_{nn}x_n & \leq & b_n \end{array} \quad \text{denoted as } \overbrace{\quad \quad \quad \quad \quad}^{\rightarrow} Ax \leq b$$

**הערה 17.2** שימו לב שגם הקבוצה  $\{x \mid Ax \leq b, Cx = d\}$  מוחשב לכל שורה בנפרד גם הוא פאון.

**הערה 18.2** פאון יכול להיות גם מתואר על ידי  $.A \in \mathbb{R}^{m \times n}$ ,  $x, b \in \mathbb{R}^m$ :

$$\tilde{A} = \begin{pmatrix} A \\ C \\ C \end{pmatrix}, \tilde{m} = \begin{pmatrix} b \\ d \\ -d \end{pmatrix}$$

- כזו ש: תכיל גם אילוצי אי שוויון המקוריים  $Cx \leq d$  וgem תכיל את האילוץ  $Ax \leq b$  וגם תכיל את האילוץ  $-Cx \leq -d$  (כך שלמעה מע' האילוצים הכלולות

– כך שהאילוץ  $\tilde{A}x \leq \tilde{m}$  שקולilia לאילוצים  $Ax \leq b, Cx = d$ . ולכן ההערה נכונה.


**הערה 20.2** פאון היא צורה סגורה. (מכילה את נקודות השפה שלה)

**הערה 21.2** **למה פאון היא צורה קמורה?** הוכחה: נסמן ב-  $a_i^T$  את השורה ה-  $i$  במטריצה  $A$ . אז הפאון  $P$  הוא למעשה  $\bigcap_{i=1}^n \{x \in \mathbb{R}^n \mid a_i^T x \leq b_i\}$ . הקבוצה  $P$  היא קמורה לכל  $i$  כי עבור כל  $i$  קבוצה  $\{x \in \mathbb{R}^n \mid a_i^T x \leq b_i\}$  מהויה חצי מרחב וראינו שזו צורה קמורה. ראנן וכי חיתוך של קבוצות קמורות הוא קבוצה קמורה ולכן  $P$  הולינדרום היא קבוצה קמורה.

**מסקנה 22.2** הפאון שמודדר על ידי  $.A \in \mathbb{R}^{m \times n}$ ,  $x, b \in \mathbb{R}^n$  הוא חיתוך של  $m$  חצאי מרחב שכל אחד מהם במינימ  $\mathbb{R}^n$ .

**הערה 23.2** בחישם האמותיים פאונים הם צורות שלא בהכרח חיות קמורות. אבל בקורס, דרך ההגדירה שלנו מחייבת שפאון הוא קבוצה קמורה. כי בקורס שלנו הפאון המוגדר הוא למעשה הגדרה אמיתית של "פוליהדרון קמור". (קיים פוליהדרונים אחרים אבל האחד שמודדר לנו בקורס מוגדר ככח שהוא קמור).

شرطוטים לדוגמא:



**הגדלה 24.2 סימפלקס simplex** הוא מקרה פרטי של פאון  $x_0, x_1, \dots, x_k$ . הסימפלקס של  $x_0, x_1, \dots, x_k$  נתון על ידי  
**(כלומר הסימפלקס של**  $x_0, x_1, \dots, x_k$  **הוא הקמור** (קרי **קָמוֹן**) **של** הנקודות  $x_0, x_1, \dots, x_k$ )

**הערה 25.2** בשביל  $\text{conv} \{x_0, x_1, \dots, x_k\}$  יכול להיות מוגדר simplex על הנקודות  $x_0, x_1, \dots, x_k$  להיות **אי תלויות אפינית**. לא כנסים להגדלה זו בקורס.

**הערה 26.2** **צורות** הקמור של קבוצה  $C$  הוא למשה הגוף הקמור המינימלי המכיל את כל הנקודות בקבוצה  $C$ .

**הגדלה 27.2** הסימפלקס הוא תת קבוצה של הפאונים ומכיון שכל פאון הוא קמור נובע כי הסימפלקס גם הוא קמור.

**דוגמה 28.2** דוגמא לסימפלקסים:



- סימפלקס 0 מימדי הוא נקודת, סימפלקס 1 מימדי הוא קו, סימפלקס דו מימדי הוא משולש וסימפלקס תלת מימדי הוא פרמידה.

**סימון 29.2** נסמן את **הסימפלקס ההסתברות probability simplex**  $\text{conv} \{e_1, \dots, e_n\}$  (וקטור הבסיס הຕואורי (=ווקטורי היחידה) למרחב  $\mathbb{R}^n$ ). כלומר

$$\text{conv} \{e_1, \dots, e_n\} = \{x \mid x \geq 0, 1^T x = 1\}$$

**הערה 30.2** בקורס זה **simplex probability** נקרא לו **בשם ה simplex**

**הערה 31.2** גוף קמור מאד חשוב ומאוד מיוחד שנטקל בו הרבה בהמשך.


### 2.1.3 סוגים של חוטים (=קונוסים) - המשך

הגדרה 32.2 קבוצה  $C \subseteq \mathbb{R}^n$  תקרא חוט אם


$$x \in C \Rightarrow tx \in C \text{ for all } t \geq 0$$

הערה 33.2 כלומר אם לוקחים כל נקודה בקבוצה ומכפילים אותה בסקלאר חיובי מקבלים נקודה שהיא בקבוצה.

הערה 34.2 קונוס באופן כללי לא חייב להיות קמור. לדוגמה החוט הבא שמורכב מ-2 קרניים בלבד:



נבחן כי הוא לא קמור כי אפשר למצוא שתי נקודות ולמתוות ביניהם קו ולקבל נקודה  $p$  שאינה בקבוצה.



הגדרה 35.2 קבוצה  $C \subseteq \mathbb{R}^n$  תקרא חוט קמור convex cone אם היא קבוצה קמורה וגם היא חוט. כלומר :

$$x_1, x_2 \in C \Rightarrow t_1 x_1 + t_2 x_2 \in C \text{ for all } t_1, t_2 \geq 0$$

הגדרה 36.2 קומבינציה קונית/צראף קוני conic combination של  $x_1, \dots, x_k \in \mathbb{R}^n$  הוא כל צראף קוני

$$\theta_1 x_1 + \dots + \theta_k x_k$$

עבורו

$$\forall i \in \{1, \dots, k\} : \theta_i \geq 0$$

הגדרה 37.2 קומבינציה קונית/conic hull של נקודות היא קבוצת כל הצראפים הקוניים של  $x_1, \dots, x_k \in \mathbb{R}^n$ . כלומר אם


$$S = \{x_1, \dots, x_k\}$$

$$\text{coni}(S) = \left\{ \sum_{i=1}^k \theta_i x_i \mid x_i \in S, 0 \leq \theta_i \in \mathbb{R}, i, k \in \mathbb{N} \setminus \{0\} \right\}$$

מסקנה 38.2 מההגדרה נובע ישירות כי ראשית הצירם  $0 \in \mathbb{R}^n$  מקיימת שהיא שייכת לכל קבוצה  $S$ , כלומר  $\forall S : 0 \in \text{coni}(S)$ .

**הערה 39.2** צרוף קווני של נקודות הוא קבוצה קמורה.

**דוגמה 40.2** (厯וקפדייה) במרחב הדו מימדי, תהא  $S$  קבוצה של כל הנקודות של מעגל שחותך את ראשית הצירים (כמפורט בשרטוט) אז  $S$  הוא חצי משיר הפתוח כלפיו (צבע בכחול). (כלומר לא כולל את ציר  $x$ )  
איור:




**הגדרה 41.2** חרוט נורמלי (normal cone) של הנקודה  $x_0 \in C \subseteq \mathbb{R}^n$  הוא קבוצת כל הווקטורים  $y$  המקיימים  $0 \leq y^T(x - x_0) \leq 0$  לכל  $x \in C$ . כלומר הוא קבוצת כל הווקטורים שמנדרים על משיר תומך (supporting hyper plane) ל  $C$  בנקודה  $x_0$  (ההגדירה של משיר תומך תוגדר בהמשך)

$$\mathcal{N}_C(x) = \{y \mid y^T x_0 \geq y^T x \text{ for all } x \in C\}$$

או במלילים אחרות:

$$\mathcal{N}_C(x) = \{y \mid y^T(x - x_0) \geq 0 \text{ for all } x \in C\}$$


**הערה 42.2** ( $\mathcal{N}_C(x)$ ) הוא תמיד חרוט קמור (convex cone) בלי קשר לקבוצה  $C$ . (ובפרט קבוצה קמורה)



**הערה 43.2** נזכיר כי מכפלה וקטוריים (dot product) מוגדר גם כ


$$a^T b = a \cdot b = |a| |b| \cos(\theta)$$

כאשר  $\theta$  היא הזווית שבין  $a, b$ .



If  $\theta$  is the angle between  $\bar{a}$  and  $\bar{b}$  then

$$\bar{a} \cdot \bar{b} = |\bar{a}| |\bar{b}| \cos \theta$$



$\bar{a} \cdot \bar{b}$  are orthogonal (perpendicular)

if and only if  $\bar{a} \cdot \bar{b} = 0$

**הגדה 44.2** מרחב המטריצות האי שליליות מוגדרות (באנגלית קראו לזה positive semidefinite cone) (זה כנראה סוג של מרחב חרוטי).כלומר  $S^n = \{X \in \mathbb{R}^{n \times n} \mid X = X^T\}$  (כאשר  $S^n$  מסמן את מרחב המטריצות **הסמטריות**)  
 $S_+^n = \{X \in S^n \mid X \succeq 0\}$  (כפי שהוסבר קודם  $S_+^n \in \mathbb{R}^{\frac{n(n+1)}{2}}$ )

**הערה 45.2** מרחב זה הוא מרחב קמור.

**דוגמה 46.2** המרחב positive semidefinite cone מעל  $S^2$  (מטריצות סמטריות  $2 \times 2$ ) ניתן להראות כי

$$X = \begin{bmatrix} x & y \\ y & z \end{bmatrix} \in S_+^2 \iff X \succeq 0 \iff \begin{aligned} x &\geq 0 \\ z &\geq 0 \\ xz &\geq y^2 \end{aligned}$$

איור:




Figure 2.12 Boundary of positive semidefinite cone in  $S^2$ .


## 2.2 תכונות חשובות של קבוצות קמורות

**משפט 47.2** משפט המשיר המפריד separating hyperplane theorem. יהיו שני גופים קמורים  $C, D \subseteq \mathbb{R}^n$  ולא ריקים (כלומר  $C \cap D = \emptyset$  ( $C \neq \emptyset, D \neq \emptyset$ ) כך ש  $\exists$  קיימים  $a, b \in \mathbb{R}^n$  כך  $a^T x \leq b$  עבור כל  $x \in C$  ו-  $a^T x \geq b$  עבור כל  $x \in D$ )

$$\begin{aligned} C &\subseteq \{x \mid a^T x \leq b\} \\ D &\subseteq \{x \mid a^T x \geq b\} \end{aligned}$$

**הערה 48.2** ככלומר, אם יש שני גופים קמורים זרים, יהיה קיים על מישור (לפחות אחד) שייפריד ביניהם.

**דוגמה 49.2** איור לדוגמא:



**הגדלה 50.2** מישור תומך. יהא  $C \subseteq \mathbb{R}^n$  גוף כלשהו ותהא  $x_0 \in \text{bd}(C)$  נקודה שפה של  $C$ , כלומר  $\{x \mid a^T x = a^T x_0\} = \text{cl}(C) \setminus \text{int}(C)$ . יהא  $a \in \mathbb{R}^n \setminus 0$  המקיים  $a^T x_0 \neq 0$ . אז נאמר שהמישור התומך  $\{x \mid a^T x = a^T x_0\}$  קרא המישור התומך ל $C$  בנקודה  $x_0$ .

**הערה 51.2** משמעות הטענה  $x_0 \in \text{bd}(C)$ :  $\forall x \in C : a^T(x - x_0) \leq 0$  ( $a^T x \leq a^T x_0$ )  $\forall x \in C : a^T(x - x_0) \geq 0$  ( $a^T x \geq a^T x_0$ ). כלומר, שזוויות בין  $a$  וקטור שמתחל מ $x_0$  ומסתיים ב $x$  היא או גדולה יותר (ואז קוסינוס הזווית ביניהם יהיה שלילי) או קטנה יותר (ואז קוסינוס הזווית ביניהם יהיה חיובי).

כלומר, שהמישור  $\{x \mid a^T x = a^T x_0\}$  משיק לגוף  $C$  בנקודה  $x_0$ .

**דוגמה 52.2** דוגמא למישור תומך לגוף  $C$  בנקודה  $x_0$ :





Figure 2.21 The hyperplane  $\{x \mid a^T x = a^T x_0\}$  supports  $C$  at  $x_0$ .

**משפט 53.2** משפט המישור התומך (supporting hyperplane theorem). יהא  $C \subseteq \mathbb{R}^n$  גוף קמור ולא ריק ( $C \neq \emptyset$ ) ותהא  $x_0 \in \text{bd}(C)$  נקודה שפה של  $C$ . אז קיים  $a \in \mathbb{R}^n$  כך :

$$C \subseteq \{x \mid a^T x \leq a^T x_0\}$$

**הערה 54.2** במלילים אחרות, “בגבול/בכל נקודות שפה (שנסמן  $x_0$ )” של הגוף הקמור  $C$  תמיד יהיה מישור תומך  $C$  בנקודה  $x_0$ .

**דוגמה 55.2** אייר לדוגמא



### 2.3 תכונות חשובות של פונקציות קמורות

**סימון 56.2** משמעות הסימון ( $f$ ) הוא תחום ההגדרה של הפונקציה  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ . כלומר  $\text{dom}(f) \subseteq \mathbb{R}^n$ .

**משפט 57.2** (מאוד חשוב) איזוינו הגרדיינט First-order characterization תחא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  גירה. אז :

היא פונקציה קמורה  $\forall x, y \in \text{dom}(f) : f(y) \geq f(x) + \nabla f(x)^T(y - x)$   $\iff f$

**מסקנה 2 58.2** (שהיא גם משפט בפני עצמו) תהא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  גזירה וקמורה. אז:  $x$  היא נקודת מינימום גלובלי של  $f$ .

מתוך ההריצאה:

למה הטענה זו מעניינת?


תהא  $x^*$  נקודת המינימום הגלובלי של  $f$

$$f(x^*) \geq f(x) + \nabla f(x)^T (x^* - x) \Rightarrow$$

$$\nabla f(x)^T (x - x^*) \geq \overbrace{f(x) - f(x^*)}^{f(x) > f(x^*)} \Rightarrow$$

$$(-\nabla f(x))^T (x^* - x) > 0 \Rightarrow$$

כלומר: להלכה בכיוון ירידת הגרדיאנט **קורולציה חיובית** עם הכיוון שבו עליינו ליכת על מנת להגיע למינימום הגלובלי.  
איור :



**הערה 59.2** המשמעות שבפונ' גזירות וקמורות : כל נקודת סטצ'יונרית (=כלומר, כל נקודה שבה  $\nabla f(x) = 0$ ) היא **תבונה** נקודת מינימום גלובלי .

**הערה 60.2** ניסוח שקול : יהא  $C \subseteq \mathbb{R}^n$  ותהא  $f : C \rightarrow \mathbb{R}$  גזירהizi :

$$\forall x, y \in C : f(y) \geq f(x) + \langle y - x, \nabla f(x) \rangle \iff f$$

**הערה 61.2** הוכחה:

הוכחת **כיוון אחד של המשפט (תרגילון)**:

תהא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  גזירה וקמורה.

**כיוון**  $\Leftarrow$ :

נוכיח ש  $\nabla f(x) = 0 \Leftarrow x$  היא נקודת מינימום גלובלי של  $f$ .

**הוכחה:**

יהיא פונקציה קמורה.

ולכן, מי שווין הגרדיאנט (שתי או מתקיים):

$$\forall x, y \in \text{dom}(f) : f(y) \geq f(x) + \nabla f(x)^T (y - x)$$


azi עבור  $x$  שעבורו נתנו ש  $\nabla f(x) = 0$  ולכן

$$\forall y \in \text{dom}(f) : f(y) \geq f(x)$$

כלומר קיבלנו שלכל  $y$  מתקיים ש  $f(y) \geq f(x)$  ולכן  $x$  הוא נקודת מינימום גלובלי וסיימנו. ■

**הערה 62.2** המשפט הזה לא נכון עבור פונקציות שאינן קמורות. לדוגמה פונ' ברב מימד עם אוכף.(או שבו  $0 = \nabla f(x)$  אבל היא לא נקודת מינימום גלובלי ולא נקודת של מקסימום גלובלי).

**דוגמה 63.2** פונ' שאינה קמורה עם אוכף ונקודת שבה  $0 = \nabla f(x)$  (באדום) ונקודת זו אינה מינ'/מקס' גלובלי



**משפט 64.2 אפיון מסדר שני** second-order characterization תחא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  גזירה פעמיים ברכיפות. אז :  
 $\forall x \in \text{dom}(f) : \nabla^2 f(x) \succeq 0 \iff f$  היא קמורה

**הערה 65.2**  $\forall x \in \text{dom}(f) : \nabla^2 f(x) \succeq 0$  הכוונה היא שפונ' ההאסיאן של  $f$  בכל נקודת  $x$  היא מטריצה אי שלילית .

**הערה 66.2** ניסוח שקול : יהא  $C \subseteq \mathbb{R}^n$  תחום קמור ותחא  $f : C \rightarrow \mathbb{R}$  גזירה פעמיים ברכיפות אז :  
 $\forall x \in C : \nabla^2 f(x) \succeq 0 \iff f$  היא פונקציה קמורה

**הערה 67.2** זו גם תכונה חזקה מאוד ו שימושית בשביל להוכחת קמירויות.

**דוגמה 68.2** דוגמה לשימוש במשפט ניתן למצוא בהוכחה ש log-sum-exp(softmax) היא פונקציה קמורה.(עמוד 30 הרצאה 2) אני לא מושך אותה כאן כי היא סתם עמוסה.וגם ככה המסקן הזה עמוס.

**משפט 69.2 אי שוויון ינסן** Jensen's inequality אם  $f : \text{dom}(f) \rightarrow \mathbb{R}$  פונקציה קמורה ו  $X$  משתנה אקראי כך ש  $X$  מקבל ערכים בתחום ההגדרה של  $f$ .כלומר  $X \subseteq \text{dom}(f)$  אז

$$f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)]$$

#### אינטואטיבית:

התכוונה של קמירות היא למעשה מקרה פרטי של אי שוויון י่นן.

הגדירה של קמירות היא למעשה "צrhoף ("צrhoף קמור") של שתי נקודות הוא מעל הפונ"

• אי שוויון י่นן משמש בהגדירה זו רק עם יותר מצrhoף של שתי נקודות.

במקרה הבודך  $i = 1, 2, \dots$

$$P(X = x_i) = p_X(i)$$

$$\mathbb{E}[X] = \sum_{i=1}^{\infty} x_i p_X(i)$$

במקרה הרציף (הרחבת לרציף)

$$\mathbb{E}[X] = \int_x x f_X(x) dx$$

כאשר  $(x)$  היא פונ' הצפיפות של  $x$ .

בשני המקרים התוחלת של  $\mathbb{E}[X]$  היא למעשה צrhoף קמור (של כמות סופית/אינסוף נוקודות) של הנקודות  $x_i$ -ים. ומכאן מגיעה האינטואטיבית למשפט.

הוכחת אי שוויון י่นן:  
להשלים מסוף הראצה. 3.

**הערה 70.2** ניסוח שקול לאי שוויון י่นן Jensen's inequality  $f : C \rightarrow \mathbb{R}$ . תהא  $x_1, x_2, \dots, x_N \in C$  פונקציה קמורה ויהי  $\lambda_1, \dots, \lambda_N \geq 0$  ו $\sum_{i=1}^N \lambda_i = 1$  ש

$$f\left(\sum_{i=1}^N \lambda_i x_i\right) \leq \sum_{i=1}^N \lambda_i f(x_i)$$

#### 2.4 על מישורים - לינאריים ואפיניים

הגדירה 71.2 גדר "על מישור לינארי" באופן הבא  $a \in \mathbb{R}^n : \{x \mid a^T x = 0\}$

הערה 72.2  $\mathbb{R}^n \in 0$  שיך לכל על מישור לינארי.

גדר "על מישור אפיני" באופן הבא  $a \in \mathbb{R}^n, b \in \mathbb{R} : \{x \mid a^T x = b\}$

#### 2.5 פעולות נשמרות קמירות

משפט 73.2 חיתוך: חיתוך של גופים קמורים הוא גוף קמור.

דוגמה 74.2 אם  $B, A \subseteq \mathbb{R}^n$  גופים קמורים אז  $C = A \cap B$  הוא גוף קמור.

משפט 75.2 הזוויות כיווץ ומתייהה: אם  $a \in \mathbb{R}, b \in \mathbb{R}^n$  והו גוף קמור לכל  $x \in C \subseteq \mathbb{R}^n$  גוף קמור איי  $aC + b = \{ax + b \mid x \in C\}$

משפט 76.2 פונקציה אפינית או הופכית לה.  $f : \mathbb{R}^m \rightarrow \mathbb{R}^n$  **Affine images and pre images** מהצורה  $f(x) = Ax + b$  ( $=$ פונקציה אפינית) עבור  $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$  ויהי  $C \subseteq \mathbb{R}^n$  גוף מטריצות  $m, n \in \mathbb{N} \setminus \{0\}$  והוא גוף קמור. איי  $f(C) = \{f(x) \mid x \in C\} \subseteq \mathbb{R}^m$

באופן דומה אם  $f : \mathbb{R}^k \rightarrow \mathbb{R}^n$  פונקציה מהצורה  $f(x) = Ax + b$  (פונקציה אפינית) עבור  $m, n \in \mathbb{N} \setminus \{0\}$  גוף מטריצות  $k$  ויהי  $S \subseteq \mathbb{R}^k$  גוף תחום.  $A \in \mathbb{R}^{m \times k}, b \in \mathbb{R}^m$  ובנוסף אם  $f^{-1}(S) = \{x \mid f(x) \in S\} \subseteq \mathbb{R}^k$  איי התחום  $S$  גוף תחום קמור.

<p>linear matrix inequality. (כלומר כולם מטריצות סמטריוו). <b>מערכת אי שיווניות לינארית-מטריצית</b> <math>\{x \in \mathbb{R}^k \mid A(x) \preceq B\}</math> היא התנאי מהצורה <math>A(x) = x_1A_1 + x_2A_2 + \dots + x_kA_k \preceq B</math> עבור <math>x \in \mathbb{R}^k</math> והוא קבוצה קמורה. נסמן <math>C = \{x \mid A(x) \preceq B\}</math>.</p> <p><b>הוכחה:</b></p> <ul style="list-style-type: none"> <li><b>דרכ' ראשונה:</b> לבדוק עבור כל זוג נקודות <math>t \in (0, 1)</math>. <math>x, y \in C</math> שגם <math>tx + (1-t)y \in C</math>.iese. <math>x, y \in C</math> ש <math>A(x) \preceq B</math> ו <math>A(y) \preceq B</math>. אז <math>A(tx + (1-t)y) \preceq B</math> ש <math>A\left(\overbrace{tx + (1-t)y}^z\right) \preceq B</math> ש <math>v \in \mathbb{R}^n</math> מתקיים <math>v^T(z_1A_1 + z_2A_2 + \dots + z_kA_k) \leq 0</math> כלומר לבדוק ש <math>v^T(z_1A_1 + z_2A_2 + \dots + z_kA_k)v \leq v^TBv</math> כלומר לבדוק ש <math>v^T\left(\sum_{i=1}^k z_iA_i - B\right)v \leq 0</math> <math>v^T(B - \sum_{i=1}^k z_iA_i)v \leq 0</math> <math>.z_i = tx_i + (1-t)y_i</math> עבור <math>v^T(B - \sum_{i=1}^k z_iA_i)v \leq 0</math></li> <li><b>דרכ' שנייה:</b> תהא <math>f(x) = B - \sum_{i=1}^n x_iA_i \subseteq \mathbb{S}^n</math> פונקציה איפנית המוגדרת באופן הבא. אנו יודעים כי <math>\mathbb{S}_+^n</math> מוכל ב <math>\mathbb{S}^n</math>. ככלומר <math>\mathbb{S}_+^n \subseteq \mathbb{S}_+^n</math> בנוסף ראיינו כי <math>\mathbb{S}_+^n</math> הוא תחום קמור. עליינו לשים לב כי <math>C = f^{-1}(\mathbb{S}_+^n)</math> ולכן <math>C</math> הוא תחום קמור.</li> </ul> <p><b>הערה 77.2</b> נבחן כי <math>A(x) - B = \mathbb{R}^{\frac{n(n+1)}{2}}</math> ולכן תנאי המשפט מתקיימים. כמו כן ניתן בקשותיחסית להראות כי <math>\{x \mid A(x) \preceq B\} = \{x \mid A(x) - B \leq 0\}</math>.</p>
---

**הגדרה 78.2** הפונקציה  $P : \mathbb{R}^n \times \mathbb{R}_{++} \rightarrow \mathbb{R}^n$  המוגדרת להיות prespective Images Perspective Images  $P(x, z) = \frac{1}{z} \cdot x$

**הערה 79.2** (נבחן כי  $z \in \mathbb{R}_{++} > 0$  כלומר  $z$  (שלם חיובי))

**משפט 80.2** שימור קימיות תחת Perspective Images and preimages :

- אם  $C \subseteq \text{dom}(P)$  היא קבוצה קמורה אז  $P(C)$  היא גם קבוצה קמורה.
- אם  $D$  היא קבוצה קמורה אז גם  $P^{-1}(D) = \{x \mid P(x) \in D\}$  היא קבוצה קמורה.

**הגדרה 81.2** פונקציה  $f(x) = \frac{Ax+b}{c^Tx+d}$  נקראת Linear fractional function. Lineare fractional function. פונקציה אפנית Shurortz עם Linear fractional function. Function. הינה פונקציה Linear fractional function. Function. על ידי  $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$  קלומר. Function. Function. ככלומר  $\mathbb{R}^m, c \in \mathbb{R}^n, d \in \mathbb{R}$

$$f(x) = P(Ax + b, c^Tx + d) = \frac{Ax + b}{c^Tx + d}$$

**הערה 82.2** הפונקציה  $P : \mathbb{R}^m \times \mathbb{R}_{++} \rightarrow \mathbb{R}^m$  היא מקרה פרטי של Linear fractional function

**מסקנה 83.2** מסקנה ישירה מהמשפט הקודם: עבור Linear fractional images and preimages המוגדרות עבור  $c^Tx + d > 0$

- אם  $C \subseteq \text{dom}(f)$  היא קבוצה קמורה בתחום  $P$  היא קבוצה קמורה אז  $f(C)$  היא גם קבוצה קמורה.
- אם  $D$  היא קבוצה קמורה אז גם  $f^{-1}(D) = \{x \mid f(x) \in D\}$  היא קבוצה קמורה.

הנ"ל דוגמא:

יהיו  $U, V \subseteq \mathbb{R}^{nm}$  משתנים אקראיים בדידים מעל  $\{1, \dots, n\}$  ו-  $\{1, \dots, m\}$  בהתאם. נגידר  $C \subseteq \mathbb{R}^{nm}$  קבוצה של הסתברויות משותפות של  $U, V$ . קלומרכל איבר בקבוצה  $C \in C$  מגדיר התפלגות משותפת כך  $p_{i,j} = \mathbb{P}(U = i, V = j)$ . ככלומר היא קבוצה של מטריצות  $n \times m$  (או וקטורים  $mn$ ) שסוכם כל הכניסות שלהם יחד שווה ל 1 (כי הם מותאים פונ' התפלגות משותפת) מותאים את ההתפלגות המשותפת (ניתן להשתקנע ש  $C$  מוכל ב simplex propapility).

נדיר  $D \subseteq \mathbb{R}^{nm}$  הקבוצה המתאימה שמקילה הסתברויות מותנות  $q_{ij} = \mathbb{P}(U = i | V = j)$ . נניח כי  $C$  קבוצה קמורה. נוכיח כי  $D$  קבוצה קמורה.

אנו יודעים כי Linear fractional function נבחר ליצג את  $x$  בתו מטריצה (אבל בחישוב של  $x$  להראות את החישוב  $x$  מחושב בתור Umowa). איזי

$$D = \left\{ q = \begin{pmatrix} q_{11} & q_{12} & \cdots & q_{1m} \\ q_{21} & q_{22} & \vdots & q_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ q_{n1} & q_{n2} & \vdots & q_{nm} \end{pmatrix} \in \mathbb{R}^{nm} : q_{ij} = \frac{p_{ij}}{\sum_{k=1}^n p_{kj}} \text{ for some } p \in C \right\} = f(C)$$

וניתן למצוא Shmbatzut את הטרנספורמציה הנ"ל. (קצת חופר להראות את זה אבל זה אפשרי).  
ולכן מכיוון ש  $D = f(C)$  הוא תחום קמור Linear fractional function משמרת קמירות.

**משפט 84.2** צרוף לנארוי אי שלילי. יהיו  $f_1, \dots, f_m$  פונקציות קמורות. אז לכל  $\alpha_1, \dots, \alpha_m \geq 0$  nonnegative linear combination. סקלרים אי שליליים הפונקציה

$$\alpha_1 f_1 + \dots + \alpha_m f_m$$

היא פונקציה קמורה.

**משפט 85.2** ("מקסימום של פונקציות קמורות") Pointwise maximization. תהיה קבוצה  $S$  ויהיו  $\{f_1, f_2, \dots\}$  פונקציות. אם לכל  $s \in S$  הפונקציה  $f_s$  היא פונקציה קמורה אז הפונקציה  $g(x) = \max_{s \in S} f_s(x)$  גם פונקציה קמורה.

**הערה 86.2** נבחן כי  $S$  יכולה להיות גם קבוצה אינסופית. הקבוצה  $S$  לא חייבת להיות בת מניה.


**הערה 87.2** מניחים במשפט זה שהפונקציות  $\{f_1, f_2, \dots\}$  חיוט תחת אותו domain קלומר

**הערה 88.2** קיימת גרסה של המשפט (שלא למדנו) עבורה אין דרישת שההפונקציות  $\{f_1, f_2, \dots\}$  יחו תחת אותו domain. ואז


$$\text{dom}(g) = \bigcap_{i \in \{1, 2, \dots\}} \text{dom}(f_i)$$

**דוגמה 89.2** אירורים לדוגמא:

ציור מתוך הרצאה:



ציור מהאינטרנט:



הערה 90.2 הוכחת גרסה מצומצמת של המשפט:

נכיח את המשפט עבור קבוצה בת 2 פונקציות. ההוכחה עבור קבוצה גדולה יותר או אינסופית של פונקציות היא דומה אבל דורשת כתיבה מסובכת יותר.

**משפט 91.2** (מקסימום בין 2 פונ' קמורות) אם  $\text{dom}(f) = \text{dom}(g) = \mathbb{R}^m \rightarrow \mathbb{R}^n$  אז הטענה  $\text{dom}(h) \equiv \text{dom}(f) = \mathbb{R}^n \rightarrow \mathbb{R}$  המוגדרת על ידי  $\forall \mathbf{x} \in \mathbb{R}^n : h(\mathbf{x}) = \max\{f(\mathbf{x}), g(\mathbf{x})\}$  היא קמורה בתחום  $\text{dom}(g)$ .

הוכחה:

- $f$  קמורה ולכן לפי הגדרת קמירות  $\forall t \in \mathbb{R}, t \in [0, 1] :$   
 $\forall \mathbf{x}, \mathbf{y} \in \text{dom}(f) \Rightarrow f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y})$
- $g$  קמורה ולכן לפי הגדרת קמירות  $\forall t \in \mathbb{R}, t \in [0, 1] :$   
 $\forall \mathbf{x}, \mathbf{y} \in \text{dom}(g) \Rightarrow g(t\mathbf{x} + (1-t)\mathbf{y}) \leq tg(\mathbf{x}) + (1-t)g(\mathbf{y})$
- איז  $\forall \mathbf{x}, \mathbf{y} \in \text{dom}(h), t \in [0, 1]$  ולכל  $\forall \mathbf{x}, \mathbf{y} \in \text{dom}(h) = \text{dom}(f) = \text{dom}(g)$  מתקיים ש:

$$\begin{aligned} h(t\mathbf{x} + (1-t)\mathbf{y}) &= \max\{f(t\mathbf{x} + (1-t)\mathbf{y}), g(t\mathbf{x} + (1-t)\mathbf{y})\} \\ &\leq \max\{tf(\mathbf{x}) + (1-t)f(\mathbf{y}), tg(\mathbf{x}) + (1-t)g(\mathbf{y})\} \\ &\leq \dots \end{aligned}$$

נשים לב כי

$$\begin{aligned} \forall \mathbf{x} \in \text{dom}(f) : f(\mathbf{x}) &\leq \max\{f(\mathbf{x}), g(\mathbf{x})\} = h(\mathbf{x}) \\ \forall \mathbf{y} \in \text{dom}(f) : f(\mathbf{y}) &\leq \max\{f(\mathbf{y}), g(\mathbf{y})\} = h(\mathbf{y}) \\ \Downarrow \\ \forall t \in \mathbb{R}, t \in [0, 1] : tf(\mathbf{x}) + (1-t)f(\mathbf{y}) &\leq th(\mathbf{x}) + (1-t)h(\mathbf{y}) \end{aligned}$$

באופן דומה,

$$\forall t \in \mathbb{R}, t \in [0, 1] : tg(\mathbf{x}) + (1-t)g(\mathbf{y}) \leq th(\mathbf{x}) + (1-t)h(\mathbf{y})$$

ולכן

$$\begin{aligned} h(t\mathbf{x} + (1-t)\mathbf{y}) &= \max\{f(t\mathbf{x} + (1-t)\mathbf{y}), g(t\mathbf{x} + (1-t)\mathbf{y})\} \\ &\leq \max\{tf(\mathbf{x}) + (1-t)f(\mathbf{y}), tg(\mathbf{x}) + (1-t)g(\mathbf{y})\} \\ &\leq \max\{th(\mathbf{x}) + (1-t)h(\mathbf{y}), th(\mathbf{x}) + (1-t)h(\mathbf{y})\} \\ &= th(\mathbf{x}) + (1-t)h(\mathbf{y}) \end{aligned}$$

וחרנו כי ■  $\forall t \in \mathbb{R}, t \in [0, 1] : h(t\mathbf{x} + (1-t)\mathbf{y}) \leq th(\mathbf{x}) + (1-t)h(\mathbf{y})$  ולכן  $h$  קמורה לפי הגדרה.

**משפט 92.2** (פונקציה קמורה בתחום  $C$ ) תהי פונקציה  $g : \mathbb{R}^{m+n} \rightarrow \mathbb{R}$ . נסמן  $\mathbf{z} = (\mathbf{x}, \mathbf{y}) \in \mathbb{R}^{m+n}$  אם  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^m$  ו-  $\mathbf{z} = \underbrace{g(\mathbf{z})}_{=g(\mathbf{x}, \mathbf{y})}$  קמורה בתחום  $C$ .


$$f(\mathbf{x}) = \min_{\mathbf{y} \in C} g(\mathbf{x}, \mathbf{y})$$

אם היא פונקציה קמורה.

**הערה 93.2** אם לקוביות פו' שקמורה בכמה מישתנים. ומגדרים פו' חדשה שהיא הפו' מינימיזציה של הפו' המקורית בחלק ממשתנים. אז הפו' המתקבלת גם היא קמורה.

#### דוגמה 94.2 דוגמא להמחשה:

זו לא תמונה שمسבירה הci טוב אבל זה יותר טוב מכך:



Examle: distances to a set

תרגיל ראשון מרחוק מקסימלי מקבוצה:  
תהא  $C$  קבוצה כלשהי.

נגידר את פונקציית מינימום המרחוק של  $\mathbb{R}^n \subseteq C$  תחת נורמה שרירותית כלשהי  $\|\cdot\|$  באופן הבא  $\|y\|$  הוכח ש  $f(x)$  היא פונקציה קמורה.

פתרונות:

תהא קבוצה  $S = \mathbb{R}^n$  לכל  $s \in S$  נגידר את הפונקציה  $f_s(x) = \|x - s\|$

- אנו יודעים כי  $\|\cdot\|$  היא קמורה לכל נורמה.

• אנו יודעים כי קומבינציה אפינית משמרת קמירות. כלומר  $g(x) = l(Ax + b)$  אם  $A = I$  ו  $b = -s$

- קיבל  $\|s - x\| = g(x) = f_s(x)$  היא קמורה.

הראנו כי לכל  $s \in S$  היא קמורה ולפי המשפט Pointwise maximization ייבע כי  $f(x) = \max_{y \in C} \|x - y\|$  היא פונקציה קמורה.

תרגיל שני מרחוק מינימלי מקבוצה קמורה:  
תהא  $C$  קבוצה קמורה כלשהי.

נגידר את פונקציית מינימום המרחוק של  $\mathbb{R}^n \subseteq C$  תחת נורמה שרירותית כלשהי  $\|\cdot\|$  באופן הבא  $\|y\|$  הוכח ש  $f(x)$  היא פונקציה קמורה.

פתרונות:

תהא קבוצה  $S = \mathbb{R}^n$  לכל  $s \in S$  נגידר את הפונקציה  $f_s(x) = \|x - s\|$ . מאותו נימוק של קומבינציה אפינית קודם, לכל  $s \in S$   $f_s(x)$  היא קמורה.


לפי המשפט parital minimization (שתי או יותר קבוצות קמורה) ייבע כי  $f(x) = \min_{y \in C} \|x - y\|$  היא פונקציה קמורה.

#### רחוק מקבוצה

## 2.6 פעולות משמרות קmirות

**הגדירה 95.2** Restriction של פונקציה  $f$  היא פונקציה חדשה  $f|_A$  שמשוגת באמצעות צמצום התחום **Restriction**.  
המקורי של  $f$  בפונקציה  $f : A \rightarrow B$  אם גדרה פונקציה  $f|_C$  של פונקציה  $f$  בפונקציה  $f|_C : C \subseteq A : f|_C(c) = f(c)$  עבור  $C \subseteq A$ .

**דוגמה 96.2**  $f(x) = x^2$  אין פונקציה הופכית בתחום  $\mathbb{R}$ . אבל לפונקציה  $f|_{\mathbb{R}^+}$  של פונקציה  $f$  עבר תחום  $\mathbb{R}^+$  יש פונקציה הופכית ( $\sqrt{x}$ ) איור:




**משפט 97.2**  $f$  היא פונקציה קמורה  $\iff$   $f|_C$  עבור כל  $C \subseteq A$  פונקציה קמורה.

**הגדירה 98.2 קבוצת האפיגרף Epigraph** של פונקציה  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  מוגדר להיות קבוצת כל הנקודות שנמצאות על או מעל הפונקציה. האפיגרף של פונקציה  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  מוגדר כולם  $\text{epi}(f) = \{(x, \mu) \mid x \in \mathbb{R}^n, \mu \geq f(x)\} \subseteq \mathbb{R}^{n+1}$

לדוגמא:


**דוגמה 99.2** דוגמא לאפיגרף (צבע בירוק) לפונקציה (צבוע בשחור). שימושו לב שהפונקציה  $f : \mathbb{R} \rightarrow \mathbb{R}$  אбел האפיגרף של  $f$  קי במרחב  $\mathbb{R}^2$ .



**משפט 100.2**  $f$  היא פונקציה קמורה  $\iff$  האפיגרף Epigraph של פונקציה  $f$  היא קבוצה קמורה.

**הגדירה 101.2** קבוצת ה  $t$ -sublevel set של פונקציה  $f$  בתחום  $f$  פונקציה איזי לכל  $t \in \mathbb{R}$ , הקבוצה  $\{x \in \text{dom}(f) \mid f(x) \leq t\}$ .  
תקרא  $S_t$  sublevel set ביחס ל  $t$  של פונקציה  $f$ . סימון אפשרי.

**דוגמה 102.2** דוגמא ל  $\alpha$ -sublevel sets של פונקציה  $f$  ביחס ל  $\alpha$ :



**הערה 103.2** ה  $\{x \in \text{dom}(f) \mid f(x) \leq t\} \subseteq \text{dom}(f) \subseteq \mathbb{R}^n$ . כי  $\mathbb{R}^n \subseteq \mathbb{R}^n$ .

**הערה 104.2** למעשה ה  $\text{sublevel set}$  ביחס ל  $t$  הוא **קבוצת הנקודות בתחום** של  $f$  שהפעלת  $f$  עליהם (=שתחומןם) תנייב ערך קטן מ-

**משפט 105.2** אם  $f$  היא פונקציה קמורה אז לכל ה  $\text{sublevel set}$  של  $f$  ביחס ל  $t$  היא קבוצה קמורה.

**הערה 106.2** המשפט ההופך אינו נכון.

**משפט 107.2** ה **רכבה אפינית (קומבנצייה אפינית)** ( $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ). אם  $f$  היא פונקציה קמורה. אז לכל מתקיים ש  $A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$

**משפט 108.2** כללי הרכבה כללית General composition תהא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $g : \mathbb{R}^m \rightarrow \mathbb{R}$  ו  $h : \mathbb{R} \rightarrow \mathbb{R}$ . כלומר  $(\forall x \in \mathbb{R}^n : f(x) \equiv (h \circ g)(x) \equiv h(g(x))$  (כלומר)

	או				
$f$ קמורה		$g$ קמורה	$h$ קמורה ולא יורדת		אם
$f$ קמורה	$\Leftarrow$	$g$ קעורה	$h$ קמורה ולא עולה		
$f$ קעורה		$g$ קעורה	$h$ קמורה ולא יורדת		
$f$ קעורה		$g$ קמורה	$h$ קמורה ולא עולה		

**דוגמה 109.2** קמורה אם  $e^{g(x)}$  היא קמורה. למה?

• הפונ'  $g : \mathbb{R}^n \rightarrow \mathbb{R}$  עבור  $f(x) = e^{g(x)} \equiv (h \circ g)(x) \equiv h(g(x))$ .

• הפונ'  $h$  היא קמורה ולא יורדת (במקרה זהה היא אפילו עולה ממש). ולכן לפי שורה ראשונה: אם  $g$  קמורה אז  $h$  קמורה.

**דוגמה 110.2**  $\forall x \in \mathbb{R}^n : g(x) = \frac{1}{x}$  היא קמורה אם  $h(x) = \frac{1}{g(x)}$  ב מקרה זה  $h(x) = \frac{1}{\frac{1}{x}} = x$  לכל  $x > 0$ . ולכן  $h'(x) = 1 > 0$  לכל  $x > 0$ . כלומר  $h$  עולה בכל מקום.

**הערה 111.2** אינטואציה לאיך לזכור את הכללים של הרכבה כללית:

$f : \mathbb{R}^n \rightarrow \mathbb{R}$  היא פונ' סקלרית (הפלט הוא חד ממדי) ולכן אם  $\forall x \in \mathbb{R}^n : f''(x) \geq 0$  אז  $f$  היא פונ' קמורה.  
 (ואם  $\forall x \in \mathbb{R}^n : f''(x) \leq 0$  אז  $f$  היא פונ' קעורה).  
 נפעיל את כלל השרשרת פעמיים :

$$\begin{aligned}
 f''(x) &= \frac{\partial^2}{\partial^2 \mathbf{x}} f(\mathbf{x}) \\
 &= \frac{\partial^2}{\partial^2 \mathbf{x}} [h(g(\mathbf{x}))] \\
 &= \frac{\partial}{\partial \mathbf{x}} \left[ \frac{\partial}{\partial \mathbf{x}} [h(g(\mathbf{x}))] \right] \\
 &= \frac{\partial}{\partial \mathbf{x}} \left[ \frac{\partial [h(g(\mathbf{x}))]}{\partial g(\mathbf{x})} \cdot \frac{\partial [g(\mathbf{x})]}{\partial \mathbf{x}} \right] \\
 &= \frac{\partial}{\partial \mathbf{x}} [h'(g(\mathbf{x})) \cdot g'(\mathbf{x})] \\
 &= \left[ \frac{\partial}{\partial \mathbf{x}} (h'(g(\mathbf{x}))) \cdot g'(\mathbf{x}) + h'(g(\mathbf{x})) \cdot \frac{\partial}{\partial \mathbf{x}} (g'(\mathbf{x})) \right] \\
 &= \left[ \left( \frac{\partial h'(g(\mathbf{x}))}{\partial g(\mathbf{x})} \cdot \frac{\partial g(\mathbf{x})}{\partial \mathbf{x}} \right) \cdot g'(\mathbf{x}) + h'(g(\mathbf{x})) \cdot g''(\mathbf{x}) \right] \\
 &= h''(g(\mathbf{x})) \cdot g'(\mathbf{x}) \cdot g'(\mathbf{x}) + h'(g(\mathbf{x})) \cdot g''(\mathbf{x}) \\
 &= h''(g(\mathbf{x})) \cdot (g'(\mathbf{x}))^2 + h'(g(\mathbf{x})) \cdot g''(\mathbf{x})
 \end{aligned}$$

כלומר

$$f''(x) = h''(g(x)) \cdot (g'(x))^2 + h'(g(x)) \cdot g''(x)$$

- אם  $h''(g(\mathbf{x})) \geq 0$  קמורה אז  $.h''(g(\mathbf{x})) \geq 0$
- $(g'(x))^2$  הוא תמיד חיובי (ריבוע של איזה שהוא מספר הוא תמיד חיובי).
- אם  $g$  קמורה אז  $g''(x) \geq 0$  ואם  $g''(x) > 0$  לא עולה אז  $h'(g(x)) \geq 0$  ובפרט גם  $h'(g(x)) \geq 0$  ולכון
- אם  $h$  היא קמורה ולא יורדת וגם  $g$  קמורה אז  $f$  קמורה:

$$f''(x) = \underbrace{h''(g(\mathbf{x}))}_{\substack{\text{h is convex} \\ \geq 0}} \cdot \underbrace{(g'(\mathbf{x}))^2}_{\substack{\text{always} \\ \geq 0}} + \underbrace{h'(g(\mathbf{x}))}_{\substack{\text{h is nondecreasing} \\ \geq 0}} \cdot \underbrace{g''(x)}_{\substack{\text{g is convex:} \\ \geq 0}} \geq 0 \Rightarrow f \text{ is convex}$$

- אם  $h$  היא קמורה ולא עולה וגם  $g$  קעורה אז  $f$  קמורה:

$$f''(x) = \underbrace{h''(g(\mathbf{x}))}_{\substack{\text{h is convex} \\ \geq 0}} \cdot \underbrace{(g'(\mathbf{x}))^2}_{\substack{\text{always} \\ \geq 0}} + \underbrace{h'(g(\mathbf{x}))}_{\substack{\text{h is nonincreasing} \\ \leq 0}} \cdot \underbrace{g''(x)}_{\substack{\text{g is concave:} \\ \leq 0}} \geq 0 \Rightarrow f \text{ is convex}$$

הערה 112.2 אפשר להראות זאת גם על המשפטים האחרים בטבלה. לפי אותה הנוסחה .

**הערה 113.2** (ניסוח דומה לשפט 1 בטהלה מעתה מתוק תרגול 3 (הניסוח מדויק יותר כי הוא מתייחס לתחומי ההגדרות של הפונ')  
הא  $f, g : \mathbb{R}^n \rightarrow \mathbb{R}$ ,  $I \subseteq \mathbb{R}$ ,  $f : C \rightarrow I$ ,  $g : I \rightarrow \mathbb{R}$  קמורות ו  $g(f(x))$  היא פונק' קמורה.

$$g : \mathbb{R}^k \rightarrow \mathbb{R}^k$$

$h : \mathbb{R}^k \rightarrow \mathbb{R}$  כאשר  $h(g(\mathbf{x})) = h(g_1(\mathbf{x}), g_2(\mathbf{x}), g_3(\mathbf{x}), \dots, g_k(\mathbf{x}))$  נניח ש **Vector comostion 114.2 משפט**

$$f : \mathbb{R}^n \rightarrow \mathbb{R}$$

אזי :

אזי				
קמורה $f$	$\Leftrightarrow$	$i \in \{1, \dots, k\}$	$g_i$ קמורה עבור כל $\mathbf{x}$	$h$ קמורה ולא יורדת עבור כל ארגומנט בפרט.
קמורה $f$		$i \in \{1, \dots, k\}$	$g_i$ קעורה עבור כל $\mathbf{x}$	$h$ קמורה ולא עולה עבור כל ארגומנט בפרט.
קעורה $f$		$i \in \{1, \dots, k\}$	$g_i$ קעורה עבור כל $\mathbf{x}$	$h$ קמורה ולא יורדת עבור כל ארגומנט בפרט.
קעורה $f$		$i \in \{1, \dots, k\}$	$g_i$ קמורה עבור כל $\mathbf{x}$	$h$ קמורה ולא עולה עבור כל ארגומנט בפרט.

**דוגמה 115.2** ( $g_i$  היא קמורה אם  $\sum_{i=1}^M \log g_i(x)$  הוא סכום של  $\log$ -ים לא יורדת עבור ערכים חיוביים).

**הערה 116.2** הוכחת קמיות של softmax נראית בתרגול ונוסף לכך למסמך בהמשך.

## 2.6.1 טבלה מסכמת: פעולות נשמרות קמיות

פעולות נשמרות קמיות - טבלה מסכמת	
תיאור הפעולה	שם הפעולה
$A, B$ convex $\Rightarrow A \cap B = C$ convex	חיתוך
$a \in \mathbb{R}, b \in \mathbb{R}^n$ $aC + b = \{a\mathbf{x} + b \mid \mathbf{x} \in C\}$ גוף קמור או גוף קמור לכל $C \subseteq \mathbb{R}^n$ ו-	הזהויות וטיהות
$\forall a \in \mathbb{R}, b \in \mathbb{R}^n$ : $C$ convex $\Rightarrow aC + b$ convex	
$f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ , $\forall m, n \in \mathbb{N} \setminus \{0\}$ , $A \in \mathbb{R}^{m \times n}$ , $b \in \mathbb{R}^m$ , $f(\mathbf{x}) = A\mathbf{x} + b$ :	Affine images and pre images
$C$ convex $\Rightarrow f(C) = \{f(\mathbf{x}) \mid \mathbf{x} \in C\}$ convex	
$D$ convex $\Rightarrow f^{-1}(D) = \{\mathbf{x} \mid f(\mathbf{x}) \in D\}$ convex	
$\forall m, n \in \mathbb{N} \setminus \{0\}$ , $A \in \mathbb{R}^{m \times n}$ , $b \in \mathbb{R}^m$ , $P : \mathbb{R}^n \times \mathbb{R}_{++} \rightarrow \mathbb{R}^n$	Perspective Images
$\forall (\mathbf{x}, z) \in \mathbb{R}^n \times \mathbb{R}_{++}$ : $P(\mathbf{x}, z) = \frac{1}{z} \cdot \mathbf{x} \in \mathbb{R}^n$ note that $z > 0$	
$C \subseteq \text{dom}(P)$ convex $\Rightarrow P(C)$ convex	
$D$ convex $\Rightarrow P^{-1}(D)$ convex	
$\forall m, n \in \mathbb{N} \setminus \{0\}$ , $A \in \mathbb{R}^{m \times n}$ , $b \in \mathbb{R}^m$ , $c \in \mathbb{R}^n$ , $d \in \mathbb{R}$ , such that $c^T \mathbf{x} + d > 0$ , $f : \mathbb{R}^n \rightarrow \mathbb{R}^m$ , $f(\mathbf{x}) = P(A\mathbf{x} + b, c^T \mathbf{x} + d) = \frac{A\mathbf{x} + b}{c^T \mathbf{x} + d}$ :	Linear fractional function
$C \subseteq \text{dom}(f)$ convex $\Rightarrow f(C)$ convex	
$D$ convex $\Rightarrow f^{-1}(D)$ convex	
	(Perspective Images)
$f_1, \dots, f_m$ convex and $\alpha_1, \dots, \alpha_m \geq 0$ $\Rightarrow g = \alpha_1 f_1 + \dots + \alpha_m f_m$ convex	צורך לפחות אחד שלילי (=צורך טשיינות או שלילי)
let be set $S$ and let $\{f_1, f_2, \dots\}$ a set of functions if $\forall s \in S$ : $f_s$ convex functions $\Rightarrow g(\mathbf{x}) = \max_{s \in S} f_s(\mathbf{x})$ is a convex function	Pointwise maximization (המשפט נכון גם עבור טשיינות ולא רק עבור מקסימום)
denote $\mathbf{z} = \mathbf{x}, \mathbf{y}$ $= g(\mathbf{x}, \mathbf{y})$	Partial minimization
let $f$ be convex and $f$ and $g$ convex functions $\Rightarrow g(\mathbf{x}) = \min_{y \in C} g(\mathbf{x}, \mathbf{y})$ is a convex function	Affine composition

משפטים קמירות - טבלה מסכמת
$f$ היא פונקציה קמורה $\Leftrightarrow$ $f$ של פונקציה $f$ עברו כל קו היא פונקציה קמורה.
חיה פונקציה קמורה $\Leftrightarrow$ האפיגרפ $E$ של פונקציה $f$ קבוצה קמורה.
חיה פונקציה קמורה $\Leftrightarrow$ לכל $t$ הוא קבוצה קמורה (הערכה: חכיוון ההפוך לא נכון)
חיה פונקציה קמורה $\Leftrightarrow$ $\forall \mathbf{x}, \mathbf{y} \in \text{dom}(f) : f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$
תחא $\mathbb{R}^n \rightarrow \mathbb{R}$ גירה וקורה אזי: $\nabla f(\mathbf{x}) = 0 \Leftrightarrow \mathbf{x}$ היא נקודת מינימום גלובל של $f$ .
תחא $\mathbb{R}^n \rightarrow \mathbb{R}$ גירה פעומים ברציפות אזי:
חיה קמורה $\Leftrightarrow \forall x \in \text{dom}(f) : \nabla^2 f(\mathbf{x}) \succeq 0$ והוא תומם קמורה ומס (Jensen's inequality)
כלומר אם $X \subseteq \text{dom}(f)$ אז $f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)]$
אם $f$ קמורה $\Leftrightarrow \forall x, y > 0$ ( $x, y$ היא קמורה (נתנו ש $x > 0$ ))

## 2.7 אנליזת פונקציות קמירות - מונחים ודוגמאות

### מונחים נוספים

**משפט 117.2** פונקציה קуורה. פונקציה  $f$  תקרא Куורה  $\Leftrightarrow$  היא פונקציה קמורה. (כלומר האי שוויונות של הקמירות מתקיימות בכוון הפוך)

זכור בהגדרת קמירות:

**הגדרה** תהא פונקציה  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  כך ש  $\text{dom}(f) \subseteq \mathbb{R}^n$  כאשר הוא קבוצה קונבקטית. אזי  $f$  תקרא **פונקציה קמורה** אם convex function

$$\begin{aligned} \forall t \in \mathbb{R}, t \in [0, 1] : \\ \forall \mathbf{x}, \mathbf{y} \in \text{dom}(f) \Rightarrow f(t\mathbf{x} + (1-t)\mathbf{y}) \leq tf(\mathbf{x}) + (1-t)f(\mathbf{y}) \end{aligned}$$

**הגדרה 118.2** פונקציה קמורה ממש  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ : פונקציה  $f$  תקרא כך ש  $f$  קמורה ממש אם היא פונקציה קמורה וגם

$$\begin{aligned} \forall t \in \mathbb{R}, t \in (0, 1) : \\ \forall \mathbf{x}, \mathbf{y} \in \text{dom}(f) \text{ such that } \mathbf{x} \neq \mathbf{y} \Rightarrow f(t\mathbf{x} + (1-t)\mathbf{y}) < tf(\mathbf{x}) + (1-t)f(\mathbf{y}) \end{aligned}$$

**הערה 119.2** כלומר  $f$  היא קמורה וגם  $f$  אינה קו לינארית.

**הערה 120.2** כלומר,  $f$  קמורה ממש אם בהגדרת הקמירות מחליפים כל אי שוויון חלש  $\leq$  באי שוויון חריף  $<$ .

**הגדרה 121.2** פונקציה קמורה חזק  $f : \mathbb{R}^n \rightarrow \mathbb{R}$ : פונקציה  $f$  קמורה חזק strong convex אם קיים  $m > 0$  כלשהו כך ש  $\|\mathbf{x}\|_2^2 - f - \frac{m}{2}$  היא פונקציה קמורה.

**הערה 122.2** פונקציה קמורה חזק זו תכונה מאוד שימושית וחשובה.

**משפט 123.2** פונקציה קמורה חזק  $\Leftrightarrow$  פונקציה קמורה ממש  $\Leftrightarrow$  פונקציה קמורה. (כלומר  $\text{strongly convex} \Rightarrow \text{strictly convex} \Rightarrow \text{convex}$ )

**הערה 124.2** קיים משפט והגדרות מקבילים עבור פונקציות קעורות.

## דוגמאות לפונקציות קמורות

הערות	ש	פונקיה	$f : \mathbb{R}^n \rightarrow \mathbb{R}$	תנאי ל함ירות	תנאי ל함ירות
פונקיות של $\mathbb{R} \rightarrow \mathbb{R}$	אקספונטית עבורה $x \in \mathbb{R}, a \in \mathbb{R}$	$e^{ax}$	$a \in \mathbb{R}$ לכל $x \in \mathbb{R}$ (לעומת לא קמורה)	$\times$	
	חזקקה $x^a$		$0 \leq a \leq 1$ או $a \geq 1$ ו- $a \neq 0$ עבור $x \in \mathbb{R}_+$ (לעומת $x^2$ )	$\times$	קמורה לכל $0 \leq a \leq 1$
	לוגריתם	$\log(x)$	$x > 0$ (לעומת לא קמורה)	$\times$	$x \in \mathbb{R}_+$ (לעומת לא קמורה)
וחיד: בلمור $\mathbb{R} \rightarrow \mathbb{R}$	פונקיות אפיניות	$Q \in \mathbb{R}^{n \times n}, b^T \in \mathbb{R}^n : \frac{1}{2}x^T Qx + b^T x + c$	$Q$ שילית מוגדרת או הפונקיה תמייד קמורה	$\times$	לא כתוב.
	Least squares loss	$A \in \mathbb{R}^{n \times n}, y \in \mathbb{R}^n : \ y - Ax\ _2^2$	$A^T A$ תמייד לכל $n \times n$ (כגון $A$ תמייד $0 \leq$ )	$\times$	(לעומת לא קמורה)
(מסקנה משורה קודמת)	נורמה	$\ x\ _p$ , $\ x\ _\infty$	קמורה תמיד	$\times$	לא כתוב.
	פונקיות אינדיקטור	$I_C(x) = \begin{cases} 0 & x \in C \\ \infty & x \notin C \end{cases}$	אם $C$ הוא קבוצה קמורה, $I_C(x)$ היא קמורה.	$\times$	
(פונקיות התמן מודדת את המרחק של מישרים וטומכים לקבוצה $C$ מהירашתית)	פונקציית התמן	$I_C^*(x) = \max_{y \in C} x^T y$	קמורה תמיד, לכל $C$ (ב- $C$ קמורה וגם עבורה שאינה קמורה)	$\times$	
	פונקיות המקסימום	$f(x) = \max\{x_1, \dots, x_n\}$	קמורה תמיד	$\times$	(לעומת לא קמורה)

## 3 הרצתה 3 + תחילת הרצתה 4 ) ותרגול 3 .

### 3.1 הרצתה

שיעור קודם הتمקדמו בתכונות של פונ' קמורות. בחלק זהה נדבר בעיקר על אופטימיזציה.

#### 3.1.1 טרמינולוגיות

##### מתחלים בקטן

- הבעיה נקראת "בעית אופטימיזציה קמורה ללא אילוצים" אם:  

$$\min_{x \in \mathbb{R}^d} f(x)$$

$$f : \mathbb{R}^d \longrightarrow \mathbb{R}$$
- הבעיה נקראת "בעית אופטימיזציה קמורה עם אילוצים" אם:  

$$\min_{x \in C \subseteq \mathbb{R}^d} f(x)$$

$$f : \mathbb{R}^d \longrightarrow \mathbb{R}$$

וגם התחום  $C$  הוא תחום קמור.

(ה אילוצים הם ש  $x$  חייבים להיות שייכים לתחום  $C$ ).

##### הגדרה פורמלית - ניסוח כללי

##### הגדרה 1.3 הבעיה

$$\begin{aligned} & \min_{x \in D} f(x) \\ & \text{(subject to) s.t.:} \\ & \forall i \in \{1, \dots, m\} : g_i(x) \leq 0 \\ & Ax = b \end{aligned}$$


נקראת "בעית אופטימיזציה קמורה" כאשר

- $f : \mathbb{R}^d \longrightarrow \mathbb{R}$  היא פונקציה קמורה.  $f$  נקראת **פונקציית המטריה**.
- $\forall i \in \{1, \dots, m\} : g_i(x) \leq 0$  הם פונקציות קמורות.  $g_i$  נקראת **אילוצי אי השוויון**.

**הערה 2.3** התחום  $D$  מוגדר על ידי  $D = \text{dom}(f) \cap \bigcap_{i=1}^m \text{dom}(g_i)$  (בד"כ אנו לא מציינים במפורש את  $D$ )

- אם קיימת נקודה  $x$  המקיים:  $\forall i \in \{1, \dots, m\} : g_i(x) \leq 0$  וגם  $x \in D$ . אזי  $x$  נקראת נקודה פיאבולית (כלומר  $x$  מקיימת את האילוצים). feasible point
- כלומר נקודה  $x$  נקראת פיאבולית אם היא מקיימת את האילוצים של הבעיה.
- הערך המינימלי של  $f(x)$  תחת כל הנקודות  $x$  שמקיימות את האילוצים (כלומר כל ה  $x$ -feasible points) נקרא **הערך האופטמלי**.
- אם  $x$  היא נקודה פיאבולית וגם  $f(x) = f^*$  אזי  $x$  נקרא **אופטמלי** optimal. או נקראת **פתרונות-optimal**.
- אם  $x$  היא נקודה פיאבולית וגם  $f(x) < f^*$  עבור  $\epsilon > 0$  כלשהו, אזי נקודה  $x$  תקרא " $\epsilon$ -օպטמלי" ( $\epsilon$ -optimal) גם
- כמעט בדרך כלל לא נחפש פתרון אופטמלי ונסתפק במציאת פתרון שהוא  $\epsilon$ -օպטמלי.

ציר של דוגמא ל  $\epsilon$ -օպטמלי.



- אם  $x$  היא נקודה פיאבולית וגם  $g_i(x) = 0$  נאמר ש  $g_i$  היא **פעילה** בנקודת  $x$
- מינימזציה של פונ' קמורה יכול להיות מובטאת על ידי מקסימזציה של פונ' קורה:

$$\begin{array}{ccc} \min_{x \in D} f(x) & & \max_{x \in D} -f(x) \\ (\text{subject to}) \text{ s.t :} & & (\text{subject to}) \text{ s.t :} \\ \forall i \in \{1, \dots, m\} : g_i(x) \leq 0 & \iff & \forall i \in \{1, \dots, m\} : g_i(x) \leq 0 \\ Ax = b & & Ax = b \end{array}$$

שתי הבעיות נקראות בעיות אופטימיזציה.


#### תכונות של אוסף הפתרונות של בעיית אופטימיזציה

הגדרה 3.3 נסמן  $X_{\text{opt}}$  להיות אוסף הנקודות שמהוות פתרון של בעיית האופטימיזציה הקמורה. אזי

$$X_{\text{opt}} = \left\{ x \mid \begin{array}{l} x = \arg \min_{\tilde{x}} f(\tilde{x}) \\ \text{s.t : } \forall i \in \{1, \dots, m\} : g_i(\tilde{x}) \leq 0, Ax = b \end{array} \right\}$$

משפט 4.3 **תכונה 1 :** הקבוצה  $X_{\text{opt}}$  היא קבוצה קמורה.

**דוגמה 5.3** איוור לדוגמא:



וכחה: הוכחה:

הוכחת המשפט:

יהו  $y \in X_{\text{opt}} \subseteq \mathbb{R}^n$  וכאן  $x$ ,  $y$  פתרונות לבעיית האופטימיזציה (מהגדרת כלומר

$$\begin{aligned} \forall i \in \{1, \dots, m\} : g_i(y) \leq 0, Ay = b, \quad \text{and } f(x) = f(y) = f^* \\ \forall i \in \{1, \dots, m\} : g_i(x) \leq 0, Ax = b \end{aligned}$$

יהא  $t \in [0, 1]$  כשלחו.  
עלינו להוכיח כי  $(tx + (1-t)y) \in X_{\text{opt}}$  כלומר  $tx + (1-t)y$  פתרון.

- תחילת נראה כי  $(tx + (1-t)y)$  היא נקודה פיאבולית:

$(tx + (1-t)y)$  מקיימת את אילוצי האי שווין:

$$\forall i \in \{1, \dots, m\} : g_i(tx + (1-t)y) \stackrel{\text{g}_i \text{ is convex}}{\leq} t \underbrace{g_i(x)}_{\geq 0} + (1-t) \underbrace{g_i(y)}_{\leq 0} \leq 0$$

:  $A(tx + (1-t)y) = b$  מקיימת את האילוץ  $(tx + (1-t)y)$  –

$$A(tx + (1-t)y) = t(Ax) + (1-t)(Ay) = tb + (1-t)b = b$$

$(tx + (1-t)y)$  היא נקודה פיאבולית.

- מתקיים  $f(tx + (1-t)y) = f^*$ .

$$f(tx + (1-t)y) \stackrel{f \text{ is convex}}{\leq} tf(x) + (1-t)f(y) = tf^* + (1-t)f^* = f^*$$

ולכן  $(y)$  פתרון. ולכן  $(tx + (1-t)y) \in X_{\text{opt}}$ .

■

**משפט 6.3 תבונה 2:** אם  $f$  היא קמורה ממש strictely convex אז הפתרון הוא יחיד  $X_{\text{opt}}$  כלומר קבוצה שמכילה בדיק איבר אחד.

**טענה 7.3** הרבה פעמים עולה השאלה "כמה פתרונות יש לבעיה". אם מראים שפונ' המטריה היא קמורה ממש אז הפתרון הוא בהכרח

יחיד.

**הערה 8.3** במשפט זה אפשר להתעלם מהאלג'טים.

**מסקנה 9.3**  $f$  קמורה ממש  $\Leftrightarrow$  יש לבעה פתרון יחיד.

**הערה 10.3** המשפט ההפוך לא נכון. אם הפול' היא לא קמורה ממש זה לא אומר כלום אם קיים או לא קיים פתרון יחיד.

**הערה 11.3 תזכורת:** אם  $f$  גירה פעמיים אז:  $f$  קמורה ממש  $\Leftrightarrow \forall x \in \text{dom}(f) : \nabla^2 f(x) \succ 0$

**סיכום בנייניס:**

$\forall x \in \text{dom}(f) : \nabla^2 f(x) \succeq 0$
$\forall x \in \text{dom}(f) : \nabla^2 f(x) \succ 0$

**3.1.2 דוגמאות:**

**הגדרה 12.3 בעיית לasso:** בהינתן  $X \in \mathbb{R}^{n \times p}$  ו  $y \in \mathbb{R}^n$  נגידר את ה **lasso problem בעית לasso**:

$$\begin{aligned} & \min_{\beta \in \mathbb{R}^p} \|y - X\beta\|_2^2 \\ & \text{subject to } \|\beta\|_1 \leq s \end{aligned}$$

הרצאה 3 ש夸 14 שואלים שאלות על הבעה הנ'ל. המרצה דילג עליה. (וain פתרונות לביעות במצגת). אז נסתפק בזה.

**הגדרה 13.3** בהינתן  $y \in \{-1, 1\}^n$  ו  $x_1, \dots, x_n \in \mathbb{R}^p$  ו  $C \geq 0$ . נגידר את בעית ה **SVM בעית הוקטורים התומכים** באופן הבא :

$$\begin{aligned} & \min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}, \xi \in \mathbb{R}^n} \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i \\ & \text{subject to } \xi_i \geq 0, i = 1, \dots, n \\ & y_i (x_i^T \beta + \beta_0) \geq 1 - \xi_i, i = 1, 2, \dots, n \end{aligned}$$

**הערה 14.3** נדבר על הבעה זו בהרחבה בהרצאה 4.

**הערה 15.3** משתנה האופטימציה כאן הוא שרשור של כמה אלמטרים  $(\beta, \xi, \beta_0)$  וקטוריים  $\beta$  סקלאר).

**האם בעית SVM היא בעית אופטימוציה קמורה?**

• **פונקציית המטריה:**

- החלק  $\sum_{i=1}^p \beta_i^2 = \|\beta\|_2^2$  היא פונק' קמורה (כי  $\|\cdot\|_2$  קמורה ונוטנטפלטים אי שליליים ו- לא יורדת וקמורה על  $\mathbb{R}_+$  ולכון לפי כללי הרכבה  $\|\beta\|_2^2$  קמורה). כפל קבוע חיובי איינו משנה את הקmirיות ולכון  $\frac{1}{2} \|\beta\|_2^2$  קמורה.

- החלק  $\sum_{i=1}^n \xi_i$  הוא מעשה שווה ל  $\|\xi\|_1$  בתחום בו  $0 \leq \xi_i \leq 1$ .  $\forall i \in \{1, \dots, n\}$ .  $\|\cdot\|_1$  קמורה ולכון  $\|\cdot\|_1$  עברו  $C$  אי שלילי היה גם קמורה.

- שני החלקים של פונ' המטריה קמורים. חיבור של שני פונ' קמורים נותן פונ' קמורה(אפשר להוכיח את זה)

- ולכון נובע כי פונ' המטריה :  $\xi_i \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i$  קמורה.

• **אלג'טים:**

- **האלג'ט**  $n$ ,  $i = 1, \dots, n$ ,  $\xi_i \geq 0$  שקול לאילג'ט  $-\xi_i \leq 0$ . כלומר שcolaה לאילג'טים:  $\xi_i = 0$  או פונ' לינארית ולכון קמורה.

– **האילוץ**  $y_i (x_i^T \beta + \beta_0) \geq 1 - \xi_i$  הוא אילוץ קמור כי

$$\begin{aligned} y_i (x_i^T \beta + \beta_0) \geq 1 - \xi_i &\iff \\ -1 + \xi_i + y_i (x_i^T \beta + \beta_0) \geq 0 &\iff \\ \underbrace{1 - \xi_i - y_i (x_i^T \beta + \beta_0)}_{\equiv h_i(\beta, \beta_0, \xi)} \leq 0 \end{aligned}$$

והפונ'  $(\xi, \beta, \beta_0)$  היא לינארית ב- $\xi, \beta, \beta_0$ . ולכן היא פונ' קמורה.

– לכן נובע כי האילוצים הם קמורים.

- הראנו כי פונ' המטריה לינארית וגם האילוצים לינאריים ולכן הבעה היא בעיית אופטימיזציה קמורה.

**מה היא קבוצת כל הנקודות הפיזבוליות ? feasible sets**

היא קבוצת כל ה- $(\xi, \beta, \beta_0)$  אשר מקיימות את האילוצים (שחן :  
האם הפתרון לבועית SVM הוא פתרון ייחידי ?

**הערה 16.3** הכליל היחיד כרגע שיש לנו בארגז הכללים ע"מ להוכיח ייחidot פתרון, הוא להראות שהבעיה היא קמורה ממש. אז הפתרון הוא בהרכח ייחיד. (ואם היא לא קמורה ממש, אין אמירה לגבי ייחidot הפתרון).  
עלינו לבחון את ההסיאן של פונ' המטריה (אפשר להתעלם מהאיילוצים) ככלומר

$$\begin{aligned} \nabla^2 f(\beta, \beta_0, \xi) &= \frac{\partial^2 f(\beta, \beta_0, \xi)}{\partial^2 (\beta, \beta_0, \xi)} \\ &= \frac{\partial^2 \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i}{\partial^2 (\beta, \beta_0, \xi)} \\ &= \frac{1}{2} \cdot \frac{\partial^2 \|\beta\|_2^2}{\partial^2 (\beta, \beta_0, \xi)} + C \underbrace{\frac{\partial^2 \sum_{i=1}^n \xi_i}{\partial^2 (\beta, \beta_0, \xi)}}_0 \\ &= \frac{1}{2} \cdot \frac{\partial^2 \|\beta\|_2^2}{\partial^2 (\beta, \beta_0, \xi)} \\ &= \frac{1}{2} \cdot \frac{\partial^2 \sum_{i=1}^n \beta_i^2}{\partial^2 (\beta, \beta_0, \xi)} \\ &= \dots \end{aligned}$$

- האיבר  $\sum_{i=1}^n \xi_i$  שורד גזירה לפי  $\xi$  רק פעם אחת, בגזירה השנייה הוא מתאפס.
- נבחין תחילתה כי **אין איברים מוחוץ לאלכסון**, כי לכל איבר גזoor אותו לפי שני אלמנטים שונים (לדוגמא לפי  $\beta_1$  ו- $\beta$  ו- $\xi$  נקבל 0). מכאן נובע כי **ההסיאן** היא מטריצה **אלכסונית**.
- לאחר שני גזירות קיבל רק קבועים. ככלומר  $\nabla^2 f(\beta, \beta_0, \xi)$  היא מטריצה של קבועים. (הוא לא משתנה בין נקודה אחת אחרת) כי פונ' המטריה היא ריבועית (ולא יותר מזה) ולכן 2 גזירות קיבל רק מספרים קבועים.

• נסמן  $x = (\beta, \beta_0, \xi)$

• ולכן

$$\nabla^2 f(\mathbf{x}) = \begin{pmatrix} \frac{\partial^2 f}{\partial \beta_1^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_1 \partial \beta_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \beta_1 \partial \beta_n}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_1 \partial \beta_0}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_1 \partial \xi_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \beta_1 \partial \xi_p}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial \beta_2 \partial \beta_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_2^2}(\mathbf{x}) & \cdots & \vdots & \frac{\partial^2 f}{\partial \beta_2 \partial \beta_0}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_2 \partial \xi_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \beta_2 \partial \xi_p}(\mathbf{x}) \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial \beta_n \partial \beta_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_n \partial \beta_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \beta_n^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_n \partial \beta_0}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_n \partial \xi_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \beta_n \partial \xi_p}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial \beta_0 \partial \beta_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_0 \partial \beta_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \beta_0 \partial \beta_n}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_0^2}(\mathbf{x}) & \frac{\partial^2 f}{\partial \beta_0 \partial \xi_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \beta_0 \partial \xi_p}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial \xi_1 \partial \beta_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_1 \partial \beta_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \xi_1 \partial \beta_n}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_1 \partial \beta_0}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_1 \partial \xi_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \xi_1 \partial \xi_p}(\mathbf{x}) \\ \frac{\partial^2 f}{\partial \xi_2 \partial \beta_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_2 \partial \beta_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \xi_2 \partial \beta_n}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_2 \partial \beta_0}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_2 \partial \beta_1}(\mathbf{x}) & \cdots & \vdots \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial \xi_p \partial \beta_1}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_p \partial \beta_2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \xi_p \partial \beta_n}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_p \partial \beta_0}(\mathbf{x}) & \frac{\partial^2 f}{\partial \xi_p \partial \xi_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial \xi_p \partial \xi_p}(\mathbf{x}) \end{pmatrix}$$

כלומר:

$$\nabla^2 f(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi}) = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \cdots & 0 & 0 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & 0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

מטרית ההסיאן היא אלכסונית  $\nabla^2 f(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi})$  (ולכן הע"ע שלה נמצאים על איברי האלכסון) ולכן יש לה ע"ע שווה ממש ל-0 ולכן  $\nabla^2 f(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi})$  היא לא positive definite. הינה לא קמורה ממש ולכן לא נוכל לקבוע האם יש לה או אין לה פתרון ייחיד.

עבור פונקציית המטרה אחרת  $g(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi}) = \frac{1}{2} \|\boldsymbol{\beta}\|_2^2 + \frac{1}{2} \beta_0^2 + C \cdot \sum_{i=1}^n \xi_i^{1.01}$  נקבל כי ההסיאן הוא

$$\nabla^2 g(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi}) = \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & 1 & 0 & 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 & 1 & 0 & 0 & \cdots & 0 \\ 0 & 0 & \cdots & 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 0 & \cdots & 0 & 0 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 0 & 0 & 0 & 0 & 0 & \frac{1}{\xi_1^{0.99}} \end{pmatrix}$$

• אנו יודעים שה-0  $\xi_i \geq 0 \forall i \in \{1, 2, \dots, n\}$  ו- $\nabla^2 g(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi})$  הוא מיטר (ולכן חיוויים). כל איברי האלכסון (=הע"ע של המיטר) הם חיוביים. ולכן  $\nabla^2 g(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi})$  הוא מיטר האופטימאלית שפוני המטרה שלה היא  $g(\boldsymbol{\beta}, \beta_0, \boldsymbol{\xi})$  (היא פונ' מטריה קמורה ממש) ולכן עבור פונ' מטריה זו, קיים פתרון ייחיד.

### 3.1.3 תכונות ואפיון מסדר ראשון של פתרונות אופטימליים

#### 3.1.4 תנאי אופטימליות תחת אילוצים

**סימון 17.3** ניסוח שקול לביעית אופטימאלית קמורה:

$$\begin{aligned} & \arg \min f(\mathbf{x}) \\ \text{s.t. } & \forall i \in \{1, \dots, m\} : g_i(\mathbf{x}) \leq 0, \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

כולה להיות מנוסחת באופן הבא

$$\min_{\mathbf{x}} f(\mathbf{x}) \quad \text{s.t. } \mathbf{x} \in C$$

כאשר  $\{x \mid \forall i \in \{1, \dots, m\} : g_i(x) \leq 0, \mathbf{A}\mathbf{x} = \mathbf{b}\}$  feasible points. כלומר  $C$  היא קבוצת כל הנקודות הפיאבוליות

**משפט 18.3** **תנאי מסדר ראשון לפתרון אופטימי** עבור בעיית האופטימציה הבאה:  $\min_{\mathbf{x}} f(\mathbf{x})$  s.t.  $\mathbf{x} \in C$  (כאשר  $C$  היא קבוצת כל הנקודות אשר מקיימות את האילוצים כלומר  $C$ , מוגדרת כמו קודם) ו  $f$  גזירה. אז נקודה פיאבולית  $x \in C$  הינה אופטימלית אם ורק אם


$$\forall y \in C : \nabla f(x)^T (y - x) \geq 0$$

התוכנה הבאה נקראת **תנאי מסדר ראשון לפתרון אופטימי**.


במילים: כל כיוון שנבחר שמתחל בנקודה  $x$  ומגיע לנקודה  $y$  אחרת בתחום  $C$  יהיה עם קורולציה חיובית לכיוון הגרדיאנט ( $\nabla f(x)$ ). כלומר, יהיה בכיוון העליה. (כלומר כל כיוון שמתחל בנקודה  $x$  ומגיע לנקודה  $y$  אחרת בתחום  $C$  הפונקציה  $f$  תהיה עולה (לא יורדת) בכיוון זהה כלומר זה יהיה **כיוון עלייה** של  $f$ ).

**דוגמה 19.3** שרטוטים לדוגמא:

שרטוט מהספר (פחות טוב):



שרטוט מההרצאה (שממחמיש את יותר טוב):



**הערה 20.3** אם  $C = \mathbb{R}^n$  (כלומר בעיית האופטימציה היא **לא אילוצים**) אז התנאי לאופטימליות הוא הופך להיות פשוט יותר: נקודה פיאבולית  $x \in C = \mathbb{R}^n$  היא אופטימלית אם ורק אם

$$\forall y \in C = \mathbb{R}^n : \nabla f(x)^T (y - x) = 0$$

הנקודה $x \in C$ היא אופטימלית אם ורק אם :	יש או אין אילוצים?	
$\forall y \in C : \nabla f(x)^T (y - x) \geq 0$	האילוץ $C \neq \mathbb{R}^n$ (=יש אילוצים):	תנאי מסדר ראשון
$\forall y \in C = \mathbb{R}^n : \nabla f(x)^T = 0$	האילוץ $C = \mathbb{R}^n$ (=אין אילוצים):	לפתרון אופטימלי עבור:

### 3.1.5 תרגיל לדוגמא : quadratic minimization

( נזכיר כי עבור פונ' ריבועית מהצורה  $f(x) = \frac{1}{2}x^T Qx + b^T x + c$  היא פונ' קמורה  $\nabla f(x) = \frac{1}{2}x^T Qx + b^T x + c$  כאשר  $Q \succeq 0$  )  
 נניח שפונ' המטרה שלנו היא  $f(x) = \frac{1}{2}x^T Qx + b^T x + c$  כאשר  $Q \succeq 0$ .  
 אז  $f(x)$  היא פונ' קמורה. ושביעית האופטימציה שלנו היא לא מושלמת כלומר בעית האופטימציה שלנו היא

$$\min_{x \in \mathbb{R}^n} f(x)$$

אז התנאי מסדר ראשון לפתרון אופטימי קבוע כि הפתרון האופטימי של הבעיה  $x$  מקיים  $\nabla f(x) = 0$ . כלומר

$$\begin{aligned} \nabla f(x) &= \nabla \left( \frac{1}{2}x^T Qx + b^T x + c \right) \\ &= \nabla \left( \frac{1}{2}x^T Qx + b^T x \right) \\ &= \frac{1}{2} \nabla (x^T Qx) + \nabla (b^T x) \\ &= \frac{1}{2} (Q^T + Q)x + b \\ &\stackrel{Q \succeq 0}{\Rightarrow} Q^T = Q \\ &\stackrel{\text{def}}{=} \frac{1}{2} (2Q)x + b \\ &= Qx + b \\ &= 0 \end{aligned}$$

כלומר הפתרון האופטימי של הבעיה  $x$  מקיים  $Qx + b = 0$ . כלומר שקיימים  $Qx = -b$ . איך ממשיכים מכאן?

$Q \succeq 0$  ולכן  $Q$  היא מט' אלכסונית ולכן לפי משפט הפירוק הספקטורי קיימות מטריצה אלכסונית  $\Lambda$  ומטריצה אוניטרית  $U$  (כלומר  $U^T U = I$ ) כך שמתקיים

$$Q = U\Lambda U^T$$

כאשר  $(\lambda_1, \lambda_2, \dots, \lambda_n)_{i=1}^n$  ו-  $\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$  היא קבוצת הע"ע של  $Q$ .  
 נסמן את הע"ע לפי גודלם כך ש  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ .

• אם  $Q$  הפיכה:

אז  $0 > \lambda_n, \lambda_1, \dots, \lambda_2$  (כלומר על הע"ע של  $Q$  חיוبيים ממש) אז  $Q \succ 0$  (כי  $Q$  היא הפיכה, ראינו את זה בתרגיל בית 1) ולכן הפתרון הוא  $x = -Q^{-1}b$ .

$$Q^{-1} = (U\Lambda U^T)^{-1} = (U^T)^{-1} (\Lambda)^{-1} (U)^{-1} = U\Lambda^{-1}U^T$$

$x = -Q^{-1}b = -U\Lambda^{-1}U^T b = -U\Lambda^{-1}b$ . לסייע במצב זה קיים פתרון יחיד והוא  $b$ .

• אחרת  $Q$  סינגולרית (=לא הפיכה):

$Q$  סינגולרית ולכן  $\exists i \in \{1, \dots, n\} : \lambda_i = 0$ . לפי הסימנונים מעלה 0. (ואולי יש עוד ע"ע עם ערך אפס).

$Q = \begin{pmatrix} | & | & & | \\ Q_1 & Q_1 & \cdots & Q_n \\ | & | & & | \end{pmatrix}$ .  
 נסמן את עמודות  $Q$ , באופן הבא: העמודה ה-  $i$  של  $Q$  תסומן  $Q_i$ . כלומר  $Q_i$  היא העמודה ה-  $i$  של  $Q$ .

נבחן כי לכל וקטור  $x \in \mathbb{R}^n$  מתקיים ש

$$Qx = \begin{pmatrix} & & & \\ | & Q_1 & Q_1 & \cdots & Q_n \\ | & & & & | \\ & & & & \\ & x_1 & & & \\ \vdots & & & & \\ & x_n & & & \end{pmatrix} = \sum_{i=1}^n x_i Q_i$$

לכל וקטור  $x \in \mathbb{R}^n$  קלומר ניתן לרשום את  $x$  כצירוף לינארי של העמודות של  $Q$ . קלומר  $x = \sum_{i=1}^n x_i Q_i$  נוצר שמתקיים ש שמיים  $b = -Qx$  נושא השאלת האם קיים צירוף לינארי של העמודות של  $Q$  (של  $b \in \text{span}(\underbrace{Q_1, Q_2, \dots, Q_n}_{\text{?}})$  כך שהוא שווה ל  $b$ ). קלומר האם  $b$  שייך למרחב הנפרש על ידי  $\{Q_i\}_{i=1}^n$  קלומר, האם  $b = -Qx$  – אם  $b \notin \text{span}(Q_1, Q_2, \dots, Q_n)$  קלומר אין  $x$  שמיים את המשוואה  $-Qx = b$  במקורה הזה אפשר להראות ש  $\min_x f(x) = -\infty$  (קלומר המינימום הוא אינו חסום). **חישוב מדויק?** (נמחיש מדויק עם תרגיל) – אחרת  $b \in \text{span}(Q_1, Q_2, \dots, Q_n)$  קלומר  $x$  פתרונות למשוואה  $-Qx = b$ . במקורה זה **קיימים אינסוף פתרונות**.

**דוגמא לפתרון זה:**  $b = -Q^\dagger Q$ , כאשר  $Q$  היא הפסאדו אינברס של  $Q$ .

\* מה זה ראיינו כי  $Q^\dagger$  pseudo-inverse של  $Q$ ?

$$\Lambda = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n) = \begin{pmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_n \end{pmatrix}$$

משפט הפירוק הספקטורי ראיינו כי  $Q = U\Lambda U^T$  וגם כי

$$\Lambda = \text{diag}\left(\underbrace{\lambda_1, \lambda_2, \dots, \lambda_k}_{\text{elements}}, \underbrace{0, 0, \dots, 0}_{(n-k) \text{ elements}}\right) = \exists k \in \{0, 1, \dots, n-1\} \text{ כך שכל } i < k \text{ מתקיים } \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_k, 0, 0, \dots, 0)$$

$$\begin{aligned} Q^\dagger &\triangleq U \text{diag} \left( \underbrace{\lambda_1^{-1}, \lambda_2^{-1}, \dots, \lambda_k^{-1}}_{k \text{ elements}}, \underbrace{0, 0, \dots, 0}_{(n-k) \text{ elements}} \right) U^T \\ &= U \text{diag}(\lambda_1^{-1}, \lambda_2^{-1}, \dots, \lambda_k^{-1}, 0, 0, \dots, 0) U^T \end{aligned}$$

קלומר הפסאדו אינורס הופכת את הע"ע שונים מאפס על האלכסון ואת שאר האפסים על האלכסון משאייה ללא שניי.

\* קלומר כל הפתרונות הם מהצורה

$$x = -Q^\dagger b + z, z \in \text{null}(Q) = \{z \mid Qz = 0\}$$

כאשר  $z \in \text{null}(Q)$  הכוונה היא לאוסף הווקטורים שעבורם  $Qz = 0$  (קיימים אינסוף כאלה כי העמודות של  $Q$  תלויות כי  $Q$  היפה).

\* לעיתים מסמנים  $\text{null}(Q) = \ker(Q)$  קלומר, הגרעין של מטריצה  $Q$ .

תרגיל למחשה :  
הנחנו כי  $b \in \text{span}(\mathbf{Q}_1, \mathbf{Q}_2)$  לא הפיכה ומצאו  $b$  כך שמתקיים

- מקרה 1 (כלומר מתקיים ש  $b \in \text{span}(\mathbf{Q}_1, \mathbf{Q}_2)$ )  
**תשובה:**  $b \in \text{span}(\mathbf{Q}_1, \mathbf{Q}_2)$  כלומר  $b = 1 \cdot \mathbf{Q}_1 + 0 \cdot \mathbf{Q}_2$  ולכן  $b = 1 \cdot \mathbf{Q}_1 + 0 \cdot \mathbf{Q}_2$  כי  $\mathbf{Q}_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ ,  $\mathbf{Q}_2 = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$  ו  $b = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$ . במקרה כזה יש אינסוף פתרונות : והם

$$Qx = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} 1 \\ a \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \end{pmatrix} = b$$

כפי שניתן לראות זו קבוצת פתרונות אינסופית.

- מקרה 2 (כלומר מתקיים ש  $b \notin \text{span}(\mathbf{Q}_1, \mathbf{Q}_2)$ )  
**תשובה:**  $b \notin \text{span}(\mathbf{Q}_1, \mathbf{Q}_2)$  כלומר  $b = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$  מתקיים  $\forall \mathbf{x} \in \mathbb{R}^2 : \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \mathbf{x} = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} x_1 \\ 0 \end{pmatrix} \neq \begin{pmatrix} 0 \\ 1 \end{pmatrix} = b$ .  
כלומר לא קיימים פתרונות במקרה זה.

### 3.2 תרגול 3

**משפט 21.3** אם  $f, g$  קמורות , ו  $\lambda f + \mu g$  אזי  $\lambda f + \mu g$  היא פונ' קמורה

**הערה 22.3** כלומר סכום של פונ' קמורות עם מקדים חיוביים הוא פונ' קמורה.

**מסקנה 23.3** אם  $f(x)$  קמורה  $\Leftrightarrow$  אזי  $f(y) = y \cdot f\left(\frac{1}{y} \cdot x\right)$  קמורה (בהינתן  $y > 0$ )

### 4 הרצאה 4


#### 4.1 הרצאה

#### המשך מצגת 3

**4.1.1 תרגיל לדוגמא: הטלה של נקודה לתוך קמור** **projection onto a convex set**  
תへא קבוצה קמורה  $C \subseteq \mathbb{R}^n$ . נניח שיש לנו נקודה  $a \notin C$  ונקצתה להטיל אותה לנקודה בתוך הקבוצה  $C$ .  
כלומר

$$\min_{\mathbf{x}} \|\mathbf{a} - \mathbf{x}\|_2^2 \text{ subject to } \mathbf{x} \in C \subseteq \mathbb{R}^n$$

ציור להמחשה:



**תנאי מסדר ראשון לפתרון אופטמלי** עבור בעיית האופטימציה קובע כי

$$\forall \mathbf{y} \in C : \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) \geq 0$$

נחשב את הגרדיאנט(נזכר בכלל הגיאירה הווקטורית) נקבל:

$$\begin{aligned}\nabla f(\mathbf{x}) &= \|\mathbf{a} - \mathbf{x}\|_2^2 \\ &= \nabla [(\mathbf{a} - \mathbf{x})^T (\mathbf{a} - \mathbf{x})] \\ &= \nabla [(\mathbf{a}^T - \mathbf{x}^T)(\mathbf{a} - \mathbf{x})] \\ &= \nabla [\mathbf{a}^T \mathbf{a} - \mathbf{a}^T \mathbf{x} - \mathbf{x}^T \mathbf{a} + \mathbf{x}^T \mathbf{x}] \\ &= \nabla [\mathbf{a}^T \mathbf{a}] - \nabla [\mathbf{a}^T \mathbf{x}] - \nabla [\mathbf{x}^T \mathbf{a}] + \nabla [\mathbf{x}^T \mathbf{x}] \\ &= 0 - \nabla [\mathbf{a}^T \mathbf{x}] - \nabla [\mathbf{x}^T \mathbf{a}] + \nabla [\mathbf{x}^T I \mathbf{x}] \\ &= -\mathbf{a} - \mathbf{a} + (I^T + I)\mathbf{x} \\ &= -2\mathbf{a} + (2I)\mathbf{x} \\ &= -2\mathbf{a} + 2\mathbf{x} \\ &= 2(\mathbf{x} - \mathbf{a})\end{aligned}$$

נציב  $(\mathbf{x} - \mathbf{a})$  בתנאי מסדר ראשון לפתרון אופטמלי ונקבל כי :

$$\begin{aligned}\forall \mathbf{y} \in C : \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) &\geq 0 \\ \iff \forall \mathbf{y} \in C : (2(\mathbf{x} - \mathbf{a}))^T (\mathbf{y} - \mathbf{x}) &\geq 0 \\ \iff \forall \mathbf{y} \in C : (\mathbf{x} - \mathbf{a})^T (\mathbf{y} - \mathbf{x}) &\geq 0\end{aligned}$$

ممליץ להסתכל שוב על להמחשה יחד עם התנאי  $\forall \mathbf{y} \in C : (\mathbf{x} - \mathbf{a})^T (\mathbf{y} - \mathbf{x}) \geq 0$  (אינטואציה (שליל, לא רשמית): במקרה הדו מימידי אפשר לחשב על זה בטור הזווית שנוצרת בין הווקטור  $x \rightarrow a$  לווקטור  $y \rightarrow x$  כאשר שמים את זנבות הווקטוריים לגוף אחד בשני, אז משמעות התנאי  $(\mathbf{x} - \mathbf{a})^T (\mathbf{y} - \mathbf{x}) \geq 0$  היא שהזווית שנוצרת תהיה עם קוסינוס חיובי (כלומר שouser זווית קטנה מ-90 מעלות לכל  $y$  שנבחר)

$$\min_{\mathbf{x}} \|\mathbf{a} - \mathbf{x}\|_2^2 = 0 \text{ ו } \mathbf{x} = \mathbf{a} \in C$$

## מיפויים/טרנספורמציות שניתן לבצע מביעות אופטימיזציות אל בעיות שקולות

4.1.2 (פעולה משמרת בעיות אופטימיזציה קמורה) אופטימיזציה חלקית ( / מינימיזציה חלקית )

**תזכורת :**

$$\text{נגיד} \quad g(x) = \min_{y \in C} f(x, y)$$

אם  $f$  היא פונ' קמורה ב  $(x, y)$  ו  $C$  הוא תחום קמור אז הבועה של מציאת מינימום ל  $(x)$  היא בעית אופטימיזציה קמורה ב  $x$  (כלומר  $(x)$  היא פונ' קמורה).

כלומר מיד ניתן לבצע אופטימיזציה חלקית לבעיה קמורה והבעה המתקבלת תשמר קמורה.

(כלומר אופטימיזציה חלקית משמרת קמירות)

**הכללה:**

יהא  $x = (x_1, x_2) \in \mathbb{R}^{n_1+n_2}$  כך שניתן להביא את  $x$  באופן הבא:

$$\text{נסמן } \tilde{f}(x_1) = \min_{x_2} f(x_1, x_2) \text{ אזי מתקיים :}$$

$$\begin{aligned} & \min_{x_1, x_2} f(x_1, x_2) \\ & \text{s.t. } g_1(x_1) \leq 0 \quad \iff \quad \min_{x_1} \tilde{f}(x_1) \\ & g_2(x_2) \leq 0 \end{aligned}$$

כלומר :

הבעה הימנית היא בעית אופטימיזציה קמורה  $\iff$  הבעה השמאלית היא בעית אופטימיזציה קמורה .

TCPונה זו מאד שימושית

נדגיםikut מודע

## 4.1.3 שימוש לאופטימיזציה חלקית: כתיבת בעית SVM בניסוח צרי hinge form of SVM

叙事 בבעיה של SVM שראינו בהרצאה הקודמת

בהתנן  $y \in \{-1, 1\}$  ו  $X \in \mathbb{R}^{n \times p}$  עם שורות  $x_1, \dots, x_n$  ויהא  $C \geq 0$ . נגיד את בעית ה-SVM או ה support vector machine (בעית הווקטורים התומכים) באופן הבא :

$$\begin{aligned} & \min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}, \xi \in \mathbb{R}^n} \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i \\ & \text{subject to } \xi_i \geq 0, i = 1, \dots, n \\ & y_i (x_i^T \beta + \beta_0) \geq 1 - \xi_i, i = 1, 2, \dots, n \end{aligned}$$

ראינו בהרצאה 3 כי בעית SVM היא בעית אופטימיזציה קמורה.

$$\begin{aligned} & \text{נספח את האילוצים} \\ & \text{subject to } \xi_i \geq 0, i = 1, \dots, n \\ & y_i (x_i^T \beta + \beta_0) \geq 1 - \xi_i, i = 1, 2, \dots, n \end{aligned}$$

$$\begin{aligned} & \left[ \begin{array}{l} \min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}, \xi \in \mathbb{R}^n} \dots \text{subject to } \xi_i \geq 0, i = 1, \dots, n \\ y_i (x_i^T \beta + \beta_0) \geq 1 - \xi_i, i = 1, 2, \dots, n \end{array} \right] \\ \iff & \left[ \begin{array}{l} \min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}, \xi \in \mathbb{R}^n} \dots \text{subject to } \xi_i \geq 0, i = 1, \dots, n \\ -y_i (x_i^T \beta + \beta_0) \leq \xi_i - 1, i = 1, 2, \dots, n \end{array} \right] \\ \iff & \left[ \begin{array}{l} \min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}, \xi \in \mathbb{R}^n} \dots \text{subject to } 0 \leq \xi_i, i = 1, \dots, n \\ 1 - y_i (x_i^T \beta + \beta_0) \leq \xi_i, i = 1, 2, \dots, n \end{array} \right] \\ \iff & \left[ \begin{array}{l} \min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}} \dots \text{subject to} \\ \max \{0, 1 - y_i (x_i^T \beta + \beta_0)\} \leq \xi_i, i = 1, 2, \dots, n \end{array} \right] \end{aligned}$$

כלומר קיבלנו אילוצים חדשים :

$$\max \{0, 1 - y_i (x_i^T \beta + \beta_0)\} = [1 - y_i (x_i^T \beta + \beta_0)]_+ \leq \xi_i, i = 1, 2, \dots, n$$

נסמן את הפונ'  $a_+$  במקורה זהה  $\xi_i$  המינימלים שמקיימים את התנאי  $\text{asm}$  כאשר השוויון מתקיים ככלומר

$$\max \{0, 1 - y_i (x_i^T \beta + \beta_0)\} = [1 - y_i (x_i^T \beta + \beta_0)]_+ = \xi_i, i = 1, 2, \dots, n$$

וכעת נציב בחזרה את את  $\xi_i = [1 - y_i (x_i^T \beta + \beta_0)]_+$  ונקבל את **הניסוח הצרי של בעיית SVM**:

$$\boxed{\min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}} \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n [1 - y_i (x_i^T \beta + \beta_0)]_+}$$

כלומר עצת ניסחנו את בעיית SVM **ללא אילוץ על  $\xi$** . (כלומר ביצענו כבר את המינימזציה של המשתנים של  $\xi$  לכל  $i \in \{1, \dots, n\}$ ) על פי המשפט שראינו (על מינימזציה חלקית) נובע כי הניסוח ה"נ" של הבעיה הוא בעיית אופטימזיה קמורה. כלומר כי בעיית SVM בניסוח צרי היא בעית מינימזיה רק של המשתנים  $\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}$ . בעית **SVMבניסוח הצרי** היא בעית מינימזיה רק של המשתנים  $\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}$ . בניסוח זה הוא הדרך נוספת לפולרית להסתכל על בעית SVM נחזר אליה בהמשך הקורס.

#### 4.1.4 החלפת משתנים trasformation and change of variables

**משפט 2.4** תהא  $\mathbb{R} \rightarrow h : \text{פונ' מונוטונית עולה איז}$

$$\begin{aligned} \min_x f(x) \text{ subject to } x \in C \\ \iff \\ \min_x h(f(x)) \text{ subject to } x \in C \end{aligned}$$

**הערה 3.4** כלומר הפתרון האופטימלי של הבעיה הוא זהה עבור  $f(x)$  ועבור  $(f(x))$ . באופן דומה ניתן להפעיל פונ' מונוטונית עולה על אילוצי השוויון/אי שוויון וקירות הבעיה ת變. יכול לעזור לנו להראות כי הבעיה שקיבלו היא קמורה.

**משפט 4.4** יהא תחום קמור  $C \subseteq \mathbb{R}^m$  תהא  $\phi : \mathbb{R}^n \rightarrow \mathbb{R}^m$  כמפורט לעיל פונ' שמקיימת שני תנאים:

1.  $\phi$  היא פונ' חד חד ערכית
2. התמונה של  $\phi$  על  $\mathbb{R}^n$  (כלומר על כל הע'ים) מכילה את התחום  $C$ . בעצם אנו רוצים להיות מסוגלים לבטא כל  $x$  בתחום  $C$  על ידי  $\phi$ .

$$\forall x \in C \subseteq \mathbb{R}^m, \exists y \in \mathbb{R}^n : \phi(y) = x$$

$$\begin{aligned} \min_x f(x) \text{ subject to } x \in C \\ \iff \\ \min_y f(\phi(y)) \text{ subject to } \phi(y) \in C \end{aligned}$$

את אומרת הבעיה ה"נ" לסקולות כלומר אם אני מוצא  $y$  שמאוצר את הבעיה  $\min_y f(\phi(x))$  subject to  $\phi(y) \in C$  אז מażער את הבעיה  $\min_x f(x)$  subject to  $x \in C$  **ולהפ'**.

#### 4.1.5 דוגמא: תוכנות גאומטרי geometric programming

תזכורת: הקבוצה  $\mathbb{R}_{++}^n = \{(x_1, x_2, \dots, x_n)^T \mid x_1, x_2, \dots, x_n > 0\}$

**הגדרה 5.4 מונום monomial** היא פונ'  $f : \mathbb{R}_{++}^n \rightarrow \mathbb{R}$  מהצורה  $f(x) = \gamma x_1^{a_1} x_2^{a_2} \cdots x_n^{a_n}$  כאשר  $\gamma > 0$  ובנוסף  $a_1, \dots, a_n \in \mathbb{R}$ .

**הגדרה 6.4 פושינומייאל posynomial** היא פונ'  $f : \mathbb{R}_{++}^n \rightarrow \mathbb{R}$  שמהווה סכום של מונומים. כלומר

$$f(x) = \sum_{k=1}^p \gamma_k \cdots x_1^{a_{k1}} x_2^{a_{k2}} \cdots x_n^{a_{kn}}$$

(כאשר לכל  $k \in \{1, \dots, p\}$   $a_{k1}, \dots, a_{kn} \in \mathbb{R}$  ובנוסף  $\gamma_k > 0$ ).

#### הגדרה 7.4 בעיית תכנות גאומטרי geometric program היא מהצורה

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ & \text{s.t.} \\ & \forall i \in \{1, \dots, m\} : g_i(\mathbf{x}) \leq 1 \\ & \forall j \in \{1, \dots, r\} : h_j(\mathbf{x}) = 1 \end{aligned}$$

כאשר  $f, g_i$  ו-  $h_j$  הם **פונקציונליים posynomial** ו- **הם מונומיאליים monomials**.

**הערה 8.4** נבחין כי בעית התכנות הגאומטרי אינה בעיה קמורה. (לודגמאן, ניתן לבדוק כי האיליצים לא קמורים) אבל אפשר להפעיל עליה את הפעולות התאימות בשביל להעביר אותה להיות בעיה קונבקטית.

- עבור כל **מונום monom**  $\forall i \in \{1, \dots, n\} : y_i = \log x_i = f(\mathbf{x}) = \gamma \cdot x_1^{a_1} x_2^{a_2} \cdots x_n^{a_n}$  נציין את החלפת המשתנים הבא:  $\phi(\mathbf{y}) = \phi((y_1 \ y_2 \ \dots \ y_n)) = \phi : \mathbb{R}_{++}^n \rightarrow \mathbb{R}_{++}^n \subseteq \mathbb{R}^n$  מקיימת  $\forall i \in \{1, \dots, n\} : e^{y_i} = x_i$  או **אי נגידיר**  $(e^{y_1} \ e^{y_2} \ \dots \ e^{y_n}) = (x_1 \ x_2 \ \dots \ x_n) = \mathbf{x}$

$$\mathbf{a} = (a_1 \ a_2 \ \dots \ a_n), \mathbf{y} = (y_1 \ y_2 \ \dots \ y_n)$$

$$\text{ובנוסף נסמן } e^b = \gamma \text{ או } b = \log(\gamma)$$

$$\begin{aligned} f(\mathbf{x}) &= \gamma x_1^{a_1} x_2^{a_2} \cdots x_n^{a_n} \\ &= \gamma (e^{y_1})^{a_1} (e^{y_2})^{a_2} \cdots (e^{y_n})^{a_n} \\ &= \gamma (e^{y_1 a_1}) (e^{y_2 a_2}) \cdots (e^{y_n a_n}) \\ &= \gamma (e^{y_1 a_1 + y_2 a_2 + \dots + y_n a_n}) \\ &= \gamma (e^{\mathbf{a}^T \mathbf{y}}) \\ &= e^b (e^{\mathbf{a}^T \mathbf{y}}) \\ &= e^{\mathbf{a}^T \mathbf{y} + b} \end{aligned}$$

- באוף דומה עבור כל **פונמייאל polynomial** ניתן לכתוב באוף הבא  $f(\mathbf{x}) = \sum_{k=1}^p e^{\mathbf{a}_k^T \mathbf{y} + b_k}$

- נבחין כי ההתמרה המוצעת  $\phi(\mathbf{y}) = \phi((y_1 \ y_2 \ \dots \ y_n)) = (e^{y_1} \ e^{y_2} \ \dots \ e^{y_n}) = (x_1 \ x_2 \ \dots \ x_n) = \mathbf{x}$

– היא פונ' חד חד ערכית. (כי העלה באקספוננט היא פונ' חד חד ערכית)

– ואכן מתקיים  $\forall \mathbf{x} \in C \subseteq \mathbb{R}_{++}^n, \exists \mathbf{y} \in \mathbb{R}_{++}^n : \phi(\mathbf{y}) = \mathbf{x}$

$$\forall \mathbf{x} = (x_1 \ x_2 \ \dots \ x_n) \in C \subseteq \mathbb{R}_{++}^n, \exists \mathbf{y} = (\log x_1 \ \log x_2 \ \dots \ \log x_n) \in \mathbb{R}_{++}^n : \phi(\mathbf{y}) = \mathbf{x}$$

– ולכן החלפת המשתנים היא קבילה.

אנו לפיה המשפט על החלפת משתנים המוצעת ( $\approx$ ) ולפי המשפט על שימוש קmirות של פונ' מונוטונית עולה ( $\gg$ ) ( $\gg$  היא פונ' מונוטונית עולה) נובע כי

בעיית התכונות הגאומטרי שකולה :

$$\begin{aligned}
 & \left[ \begin{array}{l} \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{s.t.:} \\ \forall i \in \{1, \dots, m\} : g_i(\mathbf{x}) \leq 1 \\ \forall j \in \{1, \dots, r\} : h_j(\mathbf{x}) = 1 \end{array} \right] \\
 \xleftarrow{(\otimes)} & \left[ \begin{array}{l} \min_{\mathbf{x}} \log(f(\mathbf{x})) \\ \text{s.t.:} \\ \forall i \in \{1, \dots, m\} : \log(g_i(\mathbf{x})) \leq \log(1) \\ \forall j \in \{1, \dots, r\} : \log(h_j(\mathbf{x})) = \log(1) \end{array} \right] \\
 \iff & \left[ \begin{array}{l} \min_{\mathbf{x}} \log(f(\mathbf{x})) \\ \text{s.t.:} \\ \forall i \in \{1, \dots, m\} : \log(g_i(\mathbf{x})) \leq 0 \\ \forall j \in \{1, \dots, r\} : \log(h_j(\mathbf{x})) = 0 \end{array} \right] \\
 \xleftarrow{(\mathcal{C})} & \left[ \begin{array}{l} \min_{\mathbf{y}} \log\left(\sum_{k=1}^p e^{\mathbf{a}_k^T \mathbf{y} + b_k}\right) \\ \text{s.t.:} \\ \forall i \in \{1, \dots, m\} : \log\left(\sum_{k=1}^p e^{\mathbf{a}_k^T \mathbf{y} + b_k}\right) \leq 0 \\ \forall j \in \{1, \dots, r\} : \log\left(e^{\mathbf{a}^T \mathbf{y} + b}\right) = 0 \end{array} \right] \\
 \iff & \left[ \begin{array}{l} \min_{\mathbf{y}} \log\left(\sum_{k=1}^p e^{\mathbf{a}_k^T \mathbf{y} + b_k}\right) \\ \text{s.t.:} \\ \forall i \in \{1, \dots, m\} : \log\left(\sum_{k=1}^p e^{\mathbf{a}_k^T \mathbf{y} + b_k}\right) \leq 0 \\ \forall j \in \{1, \dots, r\} : \mathbf{a}^T \mathbf{y} + b = 0 \end{array} \right]
 \end{aligned}$$

נתבונן בבעיה השקולה שהתקבלה:


$$\begin{aligned}
 & \min_{\mathbf{y}} \log\left(\sum_{k=1}^p e^{\mathbf{a}_k^T \mathbf{y} + b_k}\right) \\
 & \text{s.t.:} \\
 & \forall i \in \{1, \dots, m\} : \log\left(\sum_{k=1}^p e^{\mathbf{a}_k^T \mathbf{y} + b_k}\right) \leq 0 \\
 & \forall j \in \{1, \dots, r\} : \mathbf{a}^T \mathbf{y} + b = 0
 \end{aligned}$$

- **אלילוצי השווין 0**  $\forall j \in \{1, \dots, r\} : \mathbf{a}^T \mathbf{y} + b = 0$  הם לינאריים ולכון הם קמורים.
  - **פונ' המטריה ואילילוצי אי השווין זה** לוג של סכום של אספוננטים הוכחנו בתרגול שהפונ' מהצורה הזה הן פונ' קמורים.
- כלומר**, עברנו מבעה שאינה קמורה (בעיית התכונות הגאומטרי) אל בעיה שהיא קמורה.

#### 4.1.6 relaxation ("הרגעה")

בהתנן בעית אופטימיזציה  $\min_{\mathbf{x}} f(\mathbf{x})$  s.t to  $\mathbf{x} \in C$  שקיימים  $C \subseteq \tilde{C}$  תמיד נוכל לחתך תחום מורחב ("מקל") בעיה שנוצרת  $\min_{\mathbf{x}} f(\mathbf{x})$  s.t to  $\mathbf{x} \in \tilde{C}$ . לפעולה של הרחבת האילוצים הזה אנו קוראים **רלקסציה relaxation** והערך האופטמלי שמתתקבל בעיה זו הוא קטן או שווה לערך האופטמלי שמתתקבל בעבור הבעיה המקורית. ככלומר רק יכול לשפר את הפתרון האופטמלי.

ציוויל להמחשה:



האילוץ הירוק מכיל את האילוץ האדום ואכן הפתרון האופטימלי תחת האילוץ הירוק טוב יותר מאשר הפתרון האופטימלי תחת האילוץ האדום.

#### הערה 9.4 פועלות הרלקסציה מאוד שימושית במדעי המחשב.

**דוגמה 10.4 דוגמא חשובה :** ראיינו שבעיה אופטימזית עם אילוצי שווין מהצורה  $\forall j \in \{1, \dots, r\} : h_j(x) = 0$  אז הבעה תהיה קמורה בתנאי ש  $\forall j \in \{1, \dots, r\} : h_j(x)$  פונ' לינאריות (כלומר הם אפינים) כלומר מתקיים ש  $\exists a_j \in \mathbb{R}^n, \exists b \in \mathbb{R} : h_j(x) = a_j^T x + b$  אם ( $\forall j \in \{1, \dots, r\} : h_j(x) = 0$ ) אין אלה הם פונ' קמורות אבל לא לינאריות אז הבעה עם אילוצי שווין מהצורה 0 אינה בעיה קמורה.

אם  $\{x_j\}_{j=1}^r$  ( $x_j$  היא פונ' קמורה(אבל לא אפינית(כלומר לא לינארית)) אפשר לבצע רלקסציה (להרחיב את התחום) ולאחר מכן אי שווין מהצורה  $0 \leq \sum_{j=1}^r h_j(x) \leq 0$  וזה אילוץ קמור. כלומר:

התחלנו עם אילוץ לא קומר, ביצענו רלקסציה וקיבלנו אילוץ קמור.

#### הערה 11.4 מושתמשים בדוגמה זו המונ'

הערה 12.4 ההפסד כאן הוא שאנו לא מקיים יותר את האילוצים המקוריים של הבעה.

#### מצגת 4 צורות קונוניות של בעיות אופטימזציה


נדבר על בעיות אופטימזיה מפורסומות. יש עוד בעיות אופטימזיה אבל הדוגמאות שנדרב עליהם נחרכו המון והם נחשות מאוד חשובות.

רוב הבעיות האופטימזיה אינם קמורות. בעיות אופטימזיה הן תק קבוצה של בעיות אופטימזיה. מה שמיוחד בעיות קמורות שיש תוארה מפותחת מאוד לפתרון שלהם ולשאר הבעיות (אלא אם כן יש בעיות האלו קיים מבנה אחר מיוחד) מציאת פתרון היא משימה מאוד מורכבת.

נדבר על הבעיות הבאות:

- **תכנות לינארי LPs Linear programs**
- **תכנות ריבועי QPs Quadratic programs**
- **תכנות "חוובי מוגדר" SDPs Semidefinite programs**
- **תכנות קווני Cone programs**

היררכיה של בעיות אופטימזציה:



**הערה 13.4** קיימות צורות נוספות של בעיות אופטימיזציה קמורות שאינם אף אחת מ-4 סוגים הביעות שמוארכות מעלה.

#### 4.1.7 תכונות לינארדי LPs Linear programs

**הגדרה 14.4** בעיית **תכונות לינארדי** LPs Linear programs היא בעיית אופטימיזציה מהצורה

$$\begin{aligned} & \min_x c^T x \\ \text{subject to: } & Dx \leq d, Ax = b \end{aligned}$$

נבחין כי בעיה זו אילוצי השווון וailוצי אי השווון כולם לינאריים.

נבחין כי בעיית **תכונות לינארדי** היא תמיד בעיה קמורה.

כלומר לכל וקטורים  $c, b, d$ , ומטריצות  $A, D$  הבעיה תהיה קמורה.

**הערה 15.4** האלגוריתם לפתרון בעיות כאלה הוא אלגוריתם **הסימפלקס**. הוא שונה מאוד מהאלגוריתם **הסימפלקס**. מיחודה במיוחד לביעיות לינאריות. קיימות שיטות טובות יותר שנלמדו עליהם לאחר סוף הקורס, ושיטות אלו נחבות יותר ואפשר להכליל אותם על סוגים רבים יותר של בעיות.

**הערה 16.4** קיימים קורסים בתעוי"ג שמתעסקים רק בפתרון בעיות מהסוג זהה. בעיות אלה בשימוש נרחב במדעי המחשב.

**דוגמה 17.4** בעיית **תכונות לינארדי** לדוגמא:

**בעיית הדיאטה diet problem:**

מצאת השילוב הזול ביותר של מזונות שמספקים מגבלות תזונתיות מסוימות:

כלומר

$$\begin{aligned} & \min_x c^T x \\ \text{subject to: } & Dx \leq d, x \geq 0 \end{aligned}$$

כאשר

- $c_j$  הוא המחיר של מזון  $j$
- $d_i$  הוא הכמות המינימלית של הויטמין  $i$  שצרכי לקרחת ביום
- $D_{ij}$  הוא הכמות של הויטמין  $i$  ליחדית מזון  $j$
- $x_j$  הוא כמות ייחודית המזון ממזון  $j$  בדיאטה

**הערה 18.4** יש את האילוץ  $0 \geq x$  למניעת צריכה שלילית של מזון. כלומר אסור להקיא מזון החוצה!

**הערה 19.4** השתמשו בעיה ה"ל על מנת לספק תצרוכת של צבאות, לדוגמא של הצבא הרוסי.

**דוגמה 20.4** בעיית **תכונות לינארדי** לדוגמא:

### ב夷ית basis pursuit

נניח שיש לנו מטריצה נתונה  $X \in \mathbb{R}^{n \times p}$  (כלומר  $n$  שורות ו  $p$  עמודות) ונניח שיש לנו  $y \in \mathbb{R}^p$  ושמתקיים  $n > p$ . ונניח שאנו רוצים למצוא את הפתרון **הدليل ביותר** למערכת המשוואות הילינארית  $y = X\beta$ .

$$X = \begin{pmatrix} \leftarrow & \rightarrow \\ \uparrow & \downarrow \\ -\beta_1 & -\beta_2 & \vdots & -\beta_p \end{pmatrix}$$

אפשר לבטא את הב夷יה כ夷יה לא קמורה באופן הבא:

$$\begin{aligned} \min_{\beta \in \mathbb{R}^p} & \|\beta\|_0 \\ \text{s.t. } & X\beta = y \end{aligned}$$

כאשר הסימן  $\|\beta\|_0$  מסמן  $\{\beta_j \neq 0\}$  (כאשר  $\mathbb{I}$  היא פונ' אינדיקטור) (נבהיר כי צורה זו מכונה "נורמת  $l_0$ " למרות שהיא אינה נורמה, לא מקיימת את הגדרת נורמה). ככלומר הסימן  $\|\beta\|_0$  הוא מנתה של מספר הריבבים בוקטור  $\beta$  שאינם אפס. נציג שוב  $l_0$  זה לא באמת נורמה! זה רק מסומן כמו נורמה.).

כלומר השאיפה שלנו היא למצוא  $\beta$  שקיימים את האילוץ  $y = X\beta$  עם הכלי פחות "כניות מולדקוט" כלומר שהוקטור  $\beta$  יהיה הכל דليل שאפשר.

- האילוץ  $y = X\beta$  הוא אילוץ לינארי אבל פונ' המטריה  $\|\beta\|_0$  אינה קמורה. (שוב נזכיר,  $l_0$  אינה נורמה).
- ולכן הב夷יה הנ"ל אינה夷יה קמורה.

**בשביל לפטור את הב夷יה** לעיטם מבצעים **קירוב** שנקרא **קירוב  $l_1$** , ולעתים נקרא **basis pursuit** ננסה לפטור את הב夷יה הבהא:

$$\begin{aligned} \min_{\beta \in \mathbb{R}^p} & \|\beta\|_1 \\ \text{s.t. } & X\beta = y \end{aligned}$$

וז夷יה קמורה. (האלוצים קמורים ופונ' המטריה קמורה, כי פונ' המטריה היא נורמה ולכן היא קמורה). הב夷יה basis pursuit לא נוראית כמו夷יה תכונות לינארית (LP) האלוצים אומנס לינארים אבל פונ' המטריה  $\|\beta\|_1$  אינה לינארית.

ניתן להציג את הב夷יה basis pursuit באמצעות夷יה תכונות לינאר. **איך עושים זאת?**  
על ידי הוספת משתנים חדשים  $z = (z_1 \ z_2 \ \dots \ z_p)^T$

$$\forall i \in \{1, \dots, p\} : z_i = |\beta_i|$$

ו אז:

$$\|\beta\|_1 = \sum_{i=1}^p |\beta_i| = \sum_{i=1}^p z_i = \begin{pmatrix} 1 & 1 & \dots & 1 \end{pmatrix} \begin{pmatrix} z_1 \\ z_2 \\ \vdots \\ z_p \end{pmatrix} = \mathbf{1}^T z$$

$$\forall i \in \{1, \dots, p\} : z_i = |\beta_i| \Rightarrow z_i \geq \beta_i \text{ and } z_i \geq -\beta_i$$

ונראה איך夷יה החדשנה נראה:

$$\min_{\beta, z} \mathbf{1}^T z$$

אך:

$$\forall i \in \{1, \dots, p\} : z_i \geq \beta_i$$

$$\forall i \in \{1, \dots, p\} : z_i \geq -\beta_i$$

$$X\beta = y$$

**21.4 רלקסציה לבעה לדוגמא:**

**Dantzig selector**

רלקסציה אפשרית לבעה pursuit שראינו קודם : נאפשר במקרה את האילוץ של  $y = X\beta$  את האילוץ של  $y \approx X\beta$  (לא דורשים שוויון מפורש) איי בעית ה Dantzig selector מוגדרת כך

$$\min_{\beta \in \mathbb{R}^p} \|\beta\|_1 \\ \text{s.t.: } \left\| \mathbf{X}^T (\mathbf{y} - \mathbf{X}\beta) \right\|_\infty \leq \lambda$$

עבור  $0 \geq \lambda$  שזה הוא פרמטר שאנו שולטים בו ודרכו קובעים את "הרזולוציה" של השווין. ככל λ קטן יותר כך  $X\beta$  "ייתקרב יותר" ל  $y$ . בעיה זו אינה בעית תכונות לינארית, אבל לבעה זו קיים ניסוח של בעית תכונות לינארית.

**הערה 22.4** האילוץ  $\lambda$  s.t:  $\left\| \mathbf{X}^T (\mathbf{y} - \mathbf{X}\beta) \right\|_\infty \leq \lambda$  משמעו שהמקסימום של כל איבר בוקטור קטן מ.λ.(חסום על ידי λ)

אנו יודעים כי עבור האילוץ מתקיים (לפי חוקי גזירה וקטורית):  
(נזכר בכלל הגזירה והקטורית  $\underline{A}^T \underline{A}x = (\underline{A}^T + \underline{A})\underline{x} = (\underline{A}^T \underline{x}) + \underline{A}\underline{x} = \underline{A}^T \underline{x}$ )

$$\begin{aligned} & \min_{\beta \in \mathbb{R}^p, \star} \|\mathbf{X}\beta - \mathbf{y}\|_2^2 \\ \iff & \nabla \|\mathbf{X}\beta - \mathbf{y}\|_2^2 = 0 \\ \iff & \nabla (\mathbf{X}\beta - \mathbf{y})^T (\mathbf{X}\beta - \mathbf{y}) = 0 \\ \iff & \nabla (\beta^T \mathbf{X}^T - \mathbf{y}^T) (\mathbf{X}\beta - \mathbf{y}) = 0 \\ \iff & \nabla (\beta^T \mathbf{X}^T \mathbf{X}\beta - \beta^T \mathbf{X}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\beta - \mathbf{y}^T \mathbf{y}) = 0 \\ \iff & \nabla (\beta^T \mathbf{X}^T \mathbf{X}\beta - \beta^T \mathbf{X}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\beta - \mathbf{y}^T \mathbf{y}) = 0 \\ \iff & \nabla (\beta^T \mathbf{X}^T \mathbf{X}\beta - \beta^T \mathbf{X}^T \mathbf{y} - \mathbf{y}^T \mathbf{X}\beta) = 0 \\ \iff & \left( (\mathbf{X}^T \mathbf{X})^T + (\mathbf{X}^T \mathbf{X}) \right) \beta - \mathbf{X}^T \mathbf{y} - (\mathbf{y}^T \mathbf{X})^T = 0 \\ \iff & 2(\mathbf{X}^T \mathbf{X})\beta - 2\mathbf{X}^T \mathbf{y} = 0 \\ \iff & 2\mathbf{X}^T (\mathbf{X}\beta - \mathbf{y}) = 0 \end{aligned}$$

כלומר

$$\min_{\beta} \|\mathbf{X}\beta - \mathbf{y}\|_2^2 \iff 2\mathbf{X}^T (\mathbf{X}\beta - \mathbf{y}) = 0$$

• לפि תנאי אופטימליות מסדר ראשון כשיין מגבלה על המרחב הפתרון האופטימלי הוא התאפסות הגרדיינט .

**הערה 23.4** לא הורחב הרבה על הבעה הנ"ל

#### 4.1.8 צורה סנדրית של LP

**זיכרון :** בעיית תכנות לינארית היא מהצורה:

$$\begin{aligned} & \min_{\boldsymbol{x}} \boldsymbol{c}^T \boldsymbol{x} \\ \text{subject to: } & \boldsymbol{D}\boldsymbol{x} \leq \boldsymbol{d}, \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} \end{aligned}$$

**הגדלה 24.4** נאמר שבעייה תכנות לניארי היא מהצורה הסטנדרטית standard form אם ניתן לכתוב אותה כך:

$$\begin{aligned} & \min_{\boldsymbol{x}} \boldsymbol{c}^T \boldsymbol{x} \\ \text{subject to: } & \boldsymbol{x} \geq 0, \boldsymbol{A}\boldsymbol{x} = \boldsymbol{b} \end{aligned}$$

**הערה 25.4** הבעיה הזאת שוכבת כי מוחהו קלטו לאלא' הסימפלקס לפרטרו בעיות תכונות ליאנרי. (כלומר בשביל לפטור כל בעיית תכונות ליאנרי ציריך קודם להביא אותה לצורה סטנדרטיבית ורק אז להפעיל על הצורה הסטנדרטיבית שלה את אל' הסימפלקס.

**נבחן כי כל בעיית תכנות לנארוי קיים ניסוח שקול בצורה הסנדטרית.**  
**למה?**

הבדל בין הצורה הסנטרלית לצורה הרגילה של LP יש הבדל רק באילוצים.

- אילוצי הבעה המקורית subject to:  $Dx \leq d$ ,  $Ax = b$
  - אילוצי הצורה הסטנדרטיבית subject to:  $x \geq 0$ ,  $Ax = b$

נוסף משתנים שנקראים slack variables נגדיր משתנים חדשים  $s = d - Dx$  הallow

$$Dx < d \iff 0 < d - Dx \iff 0 < s \text{ and } s = d - Dx$$

כלומר האילוץ  $Dx$  שkol לאילוצים  $0 \leq s$  and  $s = d - Dx$  ו-  $\exists$  בעית האופטימזציה תראה כך:

$$\min_{\mathbf{x}} \mathbf{c}^T \mathbf{x}$$

**הערה 26.4** ממשמעות הסימון  $s \leq 0$  כלומר כל רכיב בוקטור  $\vec{e}_C$  יהיה גדול או שווה מאפס.

תבניות ריבועי Quadratic programs 4.1.9 QPs

**הגדלה 27.4** בעיית **תכננות ריבועי** QPs Quadratic programs היא בעית אופטימיזציה מהצורה

$$\begin{aligned} & \min_{\boldsymbol{x}} \boldsymbol{c}^T \boldsymbol{x} + \frac{1}{2} \boldsymbol{x}^T \boldsymbol{Q} \boldsymbol{x} \\ \text{subject to: } & \boldsymbol{D} \boldsymbol{x} \leq \boldsymbol{d}, \boldsymbol{A} \boldsymbol{x} = \boldsymbol{b} \end{aligned}$$

כאשר  $0 \in Q$ , קלומר  $Q$  היא מטריצה אי שלילית מוגדרת.

**הערה 28.4** נבהיר כי QP מואוד דומה ל LP רק שהפעם לפונ' המטריה הוספנו את האיבר  $\frac{1}{2}x^T Q x$ . (רכיב ריבועי)

**הערה 29.4** נבחן כי הבעיה אינה קמורה כאשר  $0 \neq Q$ .

**הערה 30.4** מעתה נניח באופן סטטי שכל פעם שנאמר שבעיה היא QP, מתקיים ש  $0 \subseteq Q$  (והבעיה קמורה). במידה וזה לא מתקיים, נזכיר זאת בምורש.

**דוגמיה 31.4** בעיית תכנות ריבועי לדוגמא:

**בעיית** porfolio optimiztion

Example: portfolio optimization

Construct a financial portfolio, trading off performance and risk:

$$\begin{aligned} \max_x \quad & \mu^T x - \frac{\gamma}{2} x^T Q x \\ \text{subject to} \quad & 1^T x = 1 \\ & x \geq 0 \end{aligned}$$

Interpretation:

- $\mu$ : expected assets' returns
- $Q$ : covariance matrix of assets' returns
- $\gamma$ : risk aversion
- $x$ : portfolio holdings (percentages)

נבחן כי כאן יש לנו בעית מקסימציה קעורה, ולכן היא שולחה בעית מינימציה קמורה. (על ידי הוצאת מינוס בפונ' המטרה)

**דוגמיה 32.4** בעיית תכנות ריבועי לדוגמא : SVM

Example: support vector machines

Given  $y \in \{-1, 1\}^n$ ,  $X \in \mathbb{R}^{n \times p}$  having rows  $x_1, \dots, x_n$ , recall the support vector machine or SVM problem:

$$\begin{aligned} \min_{\beta, \beta_0, \xi} \quad & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i \\ \text{subject to} \quad & \xi_i \geq 0, i = 1, \dots, n \\ & y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i, i = 1, \dots, n \end{aligned}$$

This is a quadratic program

הערה 33.4 דילגו בהרצאות על Lasso

**4.1.10** הזרה הסנדրית של בעית QP

תזכורות : בעית תכנות הריבועי היא מהזרה :

$$\begin{aligned} \min_x \quad & c^T x + \frac{1}{2} x^T Q x \\ \text{subject to:} \quad & Dx \leq d, Ax = b \end{aligned}$$

הגדרה 34.4 נאמר שבעית תכנות ריבועי היא מהזרה הסטנדרטיבית standard form אם ניתן לכתוב אותה כך:

$$\begin{aligned} \min_x \quad & c^T x + \frac{1}{2} x^T Q x \\ \text{subject to:} \quad & x \geq 0, Ax = b \end{aligned}$$

נבחן כי כל בעית תכנות ריבועי קיים ניסוח שקול בΖורתה הסנדרטית. (הסביר זהה לזה כמו במקרה של תכנות לינארית)

**4.1.11** SMs semidefinite programs

מבוא תזכורות : בעית תכנות לינארית היא מהזרה :

$$\begin{aligned} \min_x \quad & c^T x \\ \text{subject to:} \quad & Dx \leq d, Ax = b \end{aligned}$$

הבעיה הנ"ל יכולה להיות מוגבלת על ידי הכללה של הסימון  $\leq$  לSIMON  $\preceq$ .  
 SM היא בעצם הכללה של LP, הפעם  $x$  במקופ וקטור יהיה עתיד להיות מטריצה.  
 נזכיר בסימונים הבאים:

**סימון 35.4** קבוצת כל המטריצות הסמטריות מסדר  $n$  מסומן  $\mathbb{S}^n$  כלומר

**סימון 36.4** קבוצת כל המטריצות שליליות מסדר  $n$  מסומן  $\mathbb{S}_+^n$  כלומר

**סימון 37.4** קבוצת כל המטריצות החזויות מוגדרות מסדר  $n$  מסומן  $\mathbb{S}_{++}^n$  כלומר

ומתקיים  $\mathbb{S}_{++}^n \subseteq \mathbb{S}_+^n \subseteq \mathbb{S}^n$ .

**חשיבותם של אלגברת לינארית:**

נסמן את הערכים העצמיים של המטריצה  $X$  באופן הבא:

$$\lambda(X) = (\lambda_1(X), \lambda_2(X), \dots, \lambda_n(X))$$

אזי

$$\begin{aligned} X \in \mathbb{S}^n &\iff \lambda(X) \in \mathbb{R}^n \\ X \in \mathbb{S}_+^n &\iff \lambda(X) \in \mathbb{R}_+^n \\ X \in \mathbb{S}_{++}^n &\iff \lambda(X) \in \mathbb{R}_{++}^n \end{aligned}$$

**הגדרה 38.4** נגדיר מכפלה פנימית מעלה  $\mathbb{S}^n$ , בהינתן  $X, Y \in \mathbb{S}^n$ , נגדיר

$$\langle X, Y \rangle = X \bullet Y = \text{tr}(XY) = \sum_{i=1}^n (XY)_{i,i} = \sum_{i=1}^n \sum_{j=1}^n X_{i,j} \cdot Y_{i,j}$$

**הגדרה 39.4** נגדיר סדר מעלה  $\mathbb{S}^n$ , בהינתן  $X, Y \in \mathbb{S}^n$ , נגדיר

$$X \succeq Y \iff (X - Y) \in \mathbb{S}_+^n$$

**הערה 40.4** לכל  $y \in \mathbb{R}^n$ ,  $x$  מתקיים ש  $x \geq y$   $\iff$   $\text{diag}(x) \succeq \text{diag}(y)$ : לכל כניסה בוקטור  $x$  הוא גדול יותר מכל כניסה זהה בוקטור  $y$

**בעיית ה-SMps semidefinite programs**

**הגדלת ה-SMps semidefinite programs**

**הגדרה 41.4** (שcoleה) בעיית SMps semidefinite programs היא בעית אופטימיזציה מוחזרה

$$\begin{aligned} \min_x c^T x \\ \text{subject to: } &x_1 F_1 + \dots + x_n F_n \preceq F_0 \\ &Ax = b \end{aligned}$$

כאשר אכן  $F_j \in \mathbb{S}^d$  לכל  $j \in \{1, \dots, n\}$  ו  $b \in \mathbb{R}^m$  ו  $c \in \mathbb{R}^n$  ו  $A \in \mathbb{R}^{m \times n}$  ונבחן כי זו בעית אופטימיזציה קמורה **תמיד**.  
 (לכל  $(F_1, \dots, F_n, A, c, b)$ )  
 בנוסח, כל בעיה LP היא גם בעיה SP. אפשר לבדוק זאת, כנראה עבור מימד אחד

**הערה 42.4** כל בעית SMps semidefinite programs ניתן לכתוב בצורה סטנדרטיבית וזה הצורה הסטנדרטיבית שלה.

**הגדירה 43.4** הצורה הסנדրטית של בעיית SMps semidefinite programs היא בעיית אופטימיזציה מהצורה

$$\begin{aligned} & \min_{\mathbf{X}} \mathbf{C} \bullet \mathbf{X} \\ \text{subject to: } & A_i \bullet X = b_i, i \in \{1, \dots, m\} \\ & \mathbf{X} \succeq 0 \end{aligned}$$

**דוגמה 44.4** דוגמא לבעיית SMs

Example: theta function

Let  $G = (N, E)$  be an undirected graph,  $N = \{1, \dots, n\}$ , and

- $\omega(G)$  : clique number of  $G$
- $\chi(G)$  : chromatic number of  $G$

The Lovasz theta function:<sup>2</sup>

$$\begin{aligned} \vartheta(G) &= \max_{\mathbf{X}} \quad \mathbf{1}\mathbf{1}^T \bullet \mathbf{X} \\ \text{subject to} \quad & I \bullet \mathbf{X} = 1 \\ & X_{ij} = 0, (i, j) \notin E \\ & \mathbf{X} \succeq 0 \end{aligned}$$

The Lovasz sandwich theorem:  $\omega(G) \leq \vartheta(\bar{G}) \leq \chi(G)$ , where  $\bar{G}$  is the complement graph of  $G$

<sup>2</sup>Lovasz (1979), "On the Shannon capacity of a graph"

הטענה 45.4  $\vartheta(G)$  הוא מט' בגודל  $n \times n$  שכל רכיביה הם 1.  $\mathbf{1}\mathbf{1}^T \bullet \mathbf{X}$  הוא למעשה סכום רכיבי כל האיברים במט'  $X$ . הבטווי 1  $I \bullet \mathbf{X} = 1$  הוא אילוץ שסכום כל איברי האלכסון של  $X$  יהיו שווים לאחד.

**הערה 45.4** זו בעיה שקשורה לתורת הגרפים

**הערה 46.4** לא כל כך נדוע בבעיות כ אלה בקובץ

#### 4.1.12 Cone programs

**הגדירה 47.4** אמר שביעית **תכנות קווני Cone programs** אם ניתן לכתוב אותה כך:

$$\begin{aligned} & \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x} \\ \text{subject to: } & D(\mathbf{x}) + d \in K, \mathbf{A}\mathbf{x} = \mathbf{b} \end{aligned}$$

כאשר

$$\mathbf{A} \in \mathbb{R}^{m \times n}, \mathbf{b} \in \mathbb{R}^m \text{ ו } \mathbf{x}, \mathbf{c} \in \mathbb{R}^n \quad •$$

$$D : \mathbb{R}^n \longrightarrow Y \quad •$$

ו  $K \subseteq Y$  הוא מפוי לינארי (פומי' לנארו),  $d \in Y$  במרחב אוקלידי.

ומקיימים ש  $K$  הוא חרוף קמור. (כלומר  $K$  הוא חרוט(קוונוס) וגם  $K$  קבוצה סגורה).

נבחן כי LPs ו SDPs הם מקרים מיוחדים של תכנות קווני. עבור LP נבחן כי  $K = \mathbb{R}_+^n$  ועבור SDPs מתקיים לא נראה את זה בצורה מסודרת בקורס.

**הערה 48.4** לא הוכח על הדבר הזה יותר מדי

## 4.2 תרגול 4 - בעיות אופטימיזציה קמורות ואלגוריתמים

### 4.2.1 בעיות אופטימיזציה קמורות

**הערה 49.4** בתרגול זהה נגדיר שוב את אותם ההגדרות שראינו בהרצאות. הפעם בניסוח טיפה אחר.

**הגדרה 50.4** הביעית האופטימיזציה קמורה אם מתקיימים שני התנאים הבאים:

1. פונ' המטריה  $f$  היא פונ' קמורה

2. תחום האילוץ  $C$  קמור.

**תנאי מספיק לביעיות קמורות:** נתובן בבעיית האופטימיזציה הבאה מעל  $\mathbb{R}^n$  כאשר אנו מניחים כי כל הפונקציות מוגדרות בכל נקודה וואלי מתקבלת בה את הערך  $(\infty)$ :

$$\min_x \{f(x) \mid g_i(x) \leq 0, h_j(x) = 0, \forall i \in \{1, \dots, m\}, \forall j \in \{1, \dots, p\}\}$$

או ברישום החלופי

$$\begin{aligned} & \min_x f(x) \\ \text{s.t. } & g_i(x) \leq 0, \forall i \in \{1, \dots, m\} \\ & h_j(x) = 0, \forall j \in \{1, \dots, p\} \end{aligned}$$

**הערה 51.4** אז, אם הפונ'  $f$  קמורה, הפונ'  $g_i(x) \leq 0, \forall i \in \{1, \dots, m\}$  קמורות והפונ'  $h_j(x) = 0, \forall j \in \{1, \dots, p\}$  אפייניות (כלומר מהצורה  $h_j(x) = c_j^T x - d$ ) אז הבעה קמורה.

**הערה 52.4** נשים לב שהתנאי הנ'ל הוא **תנאי מספיק אך לא הכרחי** לקיימות של בעיות אופטימיזציה. למשל בעיית האופטימיזציה (החד מימדי) הבהא:  $\min_x \{x \mid -x^2 = 0\}$  פונ' המטריה לינארית ולכן קמורה, אבל קיים אילוץ שווין שאינו פונ' אפיינית ( $x^2$  אינו פונ' אפיינית) ובכל זאת  $C = \{x \mid -x^2 = 0\} = \{0\}$  תחום זה קמור.

**הגדרה 53.4** בעית אופטימיזציה נקראת **פייזibilitט (בת-השגה)** אם קיימת נקודה  $x_0 \in C$  בתחום האילוץ כלומר  $x_0$  במקרה זה נאמר שהנקודה  $x_0$  היא **פתרון פייזילי**.

**הגדרה 54.4** נקודה פייזibilitט  $x^* \in C$  נקראת **מינימום מקומי של  $f$  ב- $C$**  אם קיימים  $0 < r > 0$  כך שלכל  $x \in B(x^*; r) \cap C$  מתקיים  $f(x) \leq f(x^*)$ . (נזכיר כי משמעות הסימן  $r$  ב- $B(c; r)$  סביב נקודה  $c$ )

**הערה 55.4** החיתוך עם קבוצה  $C$  בהגדירה "לכל  $x \in B(x^*; r) \cap C$ " נובע מהשיקול בו במידה והערך האופטימלי מתקבל בקטה של התחום  $C$  נרצה שהגדרה של מינימום מקומי תכלול אותו. אולי לא היה את ה- $C$  אז במידה והדרישה הייתה שלכל  $x \in B(x^*; r)$  מתקיים  $f(x) \leq f(x^*)$  ו- $x$  הוא נקודת שפה (אינו נקודת פנים)  $f$  לא בהכרח מוגדרת על כל כדור ב- $x^*$  ואז ההגדירה למינימון מקומי לא תכלול את  $x^*$  שהוא מצב לא רצוי)

**הגדרה 56.4** נקודה פייזibilitט  $x^* \in C$  נקראת **מינימום גלובלי של  $f$  ב- $C$**  אם לכל  $x \in C$  מתקיים  $f(x) \leq f(x^*)$ .

**הגדרה 57.4** נקודה פייזibilitט  $x^* \in C$  נקראת **מינימום גלובלי ממש של  $f$  ב- $C$**  אם לכל  $x \in C$  מתקיים  $f(x) < f(x^*)$ .

**הערה 58.4** נקודת מינימום גלובלי  $x^*$  נקראת לעתים גם **פתרון אופטימלי** של הבעה. הערך  $(x^*) f$  שיסומן לעתים על ידי **נקרא הערך האופטימלי** (או הערך המינמלי) של הבעה

**משפט 59.4** כל נקודת מינימום של בעית אופטימיזציה היא **מינימום גלובלי**.

במילים אחרות עבור בעיית אופטימיזציה קמורה, מינימום מקומי הוא גם גלובלי. המשפט ליעיל אינו אומר כי בעיית אופטימיזציה קמורה קיימת נקודת מינימום יחידה, לדוגמא עבור הבעיה הקמורה  $\min_x f(x) = \{f(x)\}$ ,  $f(x) = 0$  כל נקודת  $x$  היא מינימום גלובלי של הבעיה.

#### הוכחת המשפט:

תהא  $x^*$  היא נקודת מינימום מקומי.  
נניח בsvilleה ש $x^*$  אינה מינימום גלובלי.

- $x^*$  אינה מינימום גלובלי  $\Leftrightarrow \exists y \in C : f(y) < f(x^*)$ . נסמן טענה זו ב $\heartsuit$ .
- $x^*$  היא נקודת מינימום מקומי  $\Leftrightarrow \exists r \in \mathbb{R}, \forall x \in B(x^*; r) \cap C : f(x^*) \leq f(x)$ . ובווסף  $x^* \in C$ . נסמן טענה זו ב $\heartsuit$ .
- בעיית אופטימיזציה היא קמורה ולכן  $C$  תחום קמור. מכיוון ש  $y$  נובע כי לכל מתקיים  $t \in [0, 1]$  ו  $x^* \in C$  וגם  $y \in C$  ו  $f(z) = f(ty + (1-t)x^*) \leq tf(y) + (1-t)f(x^*)$ .
- בפרט, עבור  $t = \frac{r}{2\|y-x^*\|} \in (0, 1)$  מתקיים  $(ty + (1-t)x^*) \in C$ .
- בעיית אופטימיזציה היא קמורה ולכן  $f$  קמורה ומכאן נובע כי

$$f(z) = f(ty + (1-t)x^*) \leq tf(y) + (1-t)f(x^*) \overset{\heartsuit}{<} tf(x^*) + (1-t)f(x^*) = f(x^*)$$


- **מצד אחד:** בפרט  $f(z) < f(x^*)$ .
- **מצד אחר:** נבחן כי  $f(x^*) \leq f(z)$  ולכן לפי טענה  $\heartsuit$  ראיינו כי  $f(z) = f(x^*)$ .

סתירה!

$$\Leftrightarrow x^* \text{ מינימום גלובלי.}$$

**הסבר נספ על מדו**  $t = \frac{r}{2\|y-x^*\|} \in (0, 1)$

Theorem 1 – cont.




כאשר חילקו נבזבז בזבז לא להתעסק עם ניסאנסים של כדור סגור או פתוח.

**הערה 60.4** זה משפט חזק מאוד כי רוב האלגוריתם הבסיסיים הטעונים למינימום מקומי. ולכן כאשר הבעיה קמורה אז המינימום המקומי הוא המינימום הגלובלי.

**הגדרה 61.4** הנקודה  $x$  נקראת  $\epsilon$ -תת אופטימלית (sub optimal) אם  $f(x) - f^* \leq \epsilon$ .

$\epsilon$ -suboptimality



**משפט 62.4** תנאי מסדר ראשון לאופטימליות יהא  $f : C \rightarrow \mathbb{R}^n$  תחום קמורה ותהא  $f$  פונ' קמורה וגזרה בריצפות. אז:

הנקודה  $x^*$  היא פתרון אופטימלי עבור הבעה  $\min_x \{f(x) | x \in C\}$

#### 4.2.2 מבוא לאלגוריתמי אופטימיזציה

בהתאם בעיה אופטימזציה כללית כשלעצמה  $\min_x \{f(x) | x \in C\}$  לרוב לא תמיד אפשר לפתרות את הבעיה באופן אנליטי ולכן משתמשים באלו נומריים שמאפשרים למצוא פתרון **מקרוב** לבעה. באופן כללי אלגוריתמי האופטימזציה מתחילה מניחוש כשלוח  $x_0$  ומפיקים סדרת פתרונות פיזיבליים  $x_1, x_2, \dots$  בדומה **אייטרטיביות**. מכיוון שההמטר היא למצוא פתרון מקרוב לבעה אופטימזציה, ככל שתתבצענה יותר אייטרציות ערך פונ' המטרה ישאך לערך האופטימלי. ככלומר

$$\lim_{t \rightarrow \infty} f(x_t) = f^*$$

**הגדרה 63.4** נאמר כי **קצב ההתקנסות convergence rate** של אלג' אופטימזציה הוא  $O(g(t))$  אם לפחות התחלתי  $x_0$  קיים קבוע אי שלילי  $c \in \mathbb{R}$  (כלומר הקבוע  $c$  תלוי ב  $x_0$ ) עבורו מתקיים  $f(x_t) - f^* \leq c(x_0) \cdot g(t)$ .

**הערה 64.4** במקרה רבים הקבוע  $c$  תלוי בפרמטרים נוספים של הפונ' (שאינם תלויים ב  $t$ )

**דוגמא 65.4** על מנת להמחיש את חשיבות קצב ההתקנסות עבור אלג' אופטימזציה נתיעין בשאלת הבאה: מה הוא **מספר האיטרציות הדרוש על מנת לקבל פתרון שהוא ε תחת אופטימי** עבור אלגוריתמי אופטימזציה שונים? לשם כך נדרש  $|f(x_t) - f^*| \leq c(x_0) \cdot g(t) \leq \epsilon$ .

- במקרים נפוצים הקבוע המתקבל הינו  $c = \|x_0 - x^*\|_2^2$ . אנו נתעניין במקרה ספציפי אף יותר שבו הקבוע זהה הוא 1 (למשל כאשר בעיה האופטימזציה היא  $\min_x \|x\|_2^2$  והניחוש התחלתי הוא על מעגל היחידה).
- נניח כי ברצונו להגיע לפתרון  $\epsilon$  תחת אופטימי עבור  $\epsilon = 10^{-4}$ .

– עבור קצב של  $O(\frac{1}{t})$ :

$$\frac{1}{t} \leq \epsilon \Rightarrow \frac{1}{\epsilon} \leq t \Rightarrow \frac{1}{10^{-4}} \leq t \Rightarrow 10^4 \leq t$$

כלומר נדרש  $10^4$  איטרציות של האלג' על מנת להבטיח את המרחק הדרוש האופטימי.

– עבור קצת של  $O(\frac{1}{\sqrt{t}})$ :

$$\frac{1}{\sqrt{t}} \leq \epsilon \Rightarrow \frac{1}{\epsilon} \leq \sqrt{t} \Rightarrow \frac{1}{10^{-4}} \leq \sqrt{t} \Rightarrow 10^4 \leq \sqrt{t} \Rightarrow 10^8 \leq t$$

כלומר נדרש  $10^8$  איטרציות של האלג' על מנת להבטיח את המרחק הדרוש האופטימי.

– עבור קצת של  $O(e^{-t})$ :

$$e^{-t} \leq \epsilon \Rightarrow -t \leq \ln(\epsilon) \Rightarrow t \geq -\ln(\epsilon) \Rightarrow \ln\left(\frac{1}{\epsilon}\right) \leq t \Rightarrow 9.21 \approx \ln\left(\frac{1}{10^4}\right) \leq t$$

כלומר נזדקק סה"כ ל 10 איטרציות בלבד על מנת להבטיח את המרחק הדרוש מהאופטימום.

## חלק II שיטות ואלגוריתמים מסדר ראשון

### 5 הרצאה 5 ותרגול 5

#### 5.1 הרצאה 5 התחלתה של הנושא Gradient descent

בהרצה נראתה למצער פונ' קמורה  $f$  חלקה ולא אילוצים. כלומר נרצה לפתור את בעיה האופטימזציה  $\min_x f(x)$ .

כלומר  $f$  פונ' קמורה וגירה בתחום הגרהה  $\mathbb{R}^n$ .  
 $\text{dom}(f) = \mathbb{R}^n$   
נסמן את הערך האופטמלי  $(x)$   $f^* = \min_x f$  ואת הפתרון האופטמלי  $x^*$ .  
בשיעור זהה נשתמש בגרדיינט של הפונ' בתור כל מרכיבי לניתוח של הפונ' במטרה למצאה את המינום שלה. שיטות כלליות נקראות שיטות מסדר ראשון. קיצור לשיטות מסדר ראשון הם GD (Gradient descent) = משפחת האל' מסדר ראשון). שיטות אלו הן שיטות איטרטיביות שימושות בגרדיינט של  $f$  כדי לעדכן את הערך  $x$  מאיוטריה אחת לאחרת.  
**למה שיטות מסדר ראשון חשובות כל כך?**

- **תמונה ראשונה: עלות חישובית נמוכה.** בהשוואה לשיטות מסדר שני (שיטות איטרטיביות שימושות בגרדיינט + האסיאן לצורך בצע ערך עדכו) הן **עלות חישובית נמוכה יותר**.

**דוגמה 1.5** אם לבעה שלנו יש מיד  $= n$  או עלות חישוב הגרדיינט היא מסדר  $(n)$ . מצד שני עלות חישוב ההאסיאן היא מסדר  $(n^2)$ . וכך שיטות מסדר ראשון הם בסיבוכיות  $(n)$  לעומת שיטות מסדר שני שהם בסיבוכיות  $= (n^2 + n)$ . לעומת שיטות מסדר שני במינדים גבוהים הם לא לעיתים קרובות מעשיות כי העלות החישובית שלהם היא כמעט מואוד.

- **תמונה שנייה: חסינות לרעש** השיטות משפחת GD מסוגלות להתמודד באופן יפה עם רעש בעיה. לשיטות מסדר שני אין התמונה זו של התמודדות עם רעש בהצלחה.

### 5.1.1 GD-Gradient descent

כלט:


- **פונ'**  $f : \mathbb{R}^d \longrightarrow$  קמורה, גירה ובעל מינום גלובלי  $x^*$ .
- **תנאי עצירה**  $\epsilon < 0$ .
- כלומר, כמה קרוב אנו רוצים להיות לפתרון?
- **גודל צעד(=קצב הלימוד)**  $\eta < 0$ .

— בחירה הפרמטר הזה הוא **קריטי** אם נדע לבחור את גודל הצעד בצורה נכונה, זה יכול להיות ההבדל המשמעותי בין ההצלחה של האל' לכשלון.

**הערה 2.5** ניתן גם לבחור את **נקודות ההתחלת**  $x_0$  אם יש לנו מידע מוקדים על הפתרון האופטמלי נרצה לבחור נקודת ההתחלת שקרובה אליו.


**מטרה/פלט:** מצא  $x \in \mathbb{R}^d$  כך  $\epsilon \leq f(x^*) - f(x)$ . למעשה, מספיק לנו למצאו **פתרון מקובל** לפתרון האופטמלי. זה מספיק במקרים האמתיים לכל צורך פרקטני.

**הערה 3.5** שים לב שיתכנו כמה נקודות  $x_1^*, x_2^*$  עבורם  $f(x_1^*) = f(x_2^*)$  כעדון:  $x_{t+1} = x_t + \eta \nabla f(x_t)$  איטרציה  $t \in \{0, 1, \dots\}$ .  
**אינטואיציה:** נזכר שראינו בהרצאה 2 את **המסקנה מי שווין הגרדיינט**: לכל פונ' קמורה  $0 \geq (-\nabla f(x))^T (x^* - x)$ .  
כלומר ראיינו כי אם  $f$  פונ' קמורה אז להליכה בכיוון ירידת הגרדיינט **תמיד תהיה קוולוציה אי שלילית** עם הכיוון שבו עליינו לכלת על מנת להגיע למינום הגלובלי.




כלומר התקדמות בכיוון ( $\nabla f(x)$ ) – תקדם אוטי לעבר הפתרון האופטמלי. הרעיון הוא שנו מתחילה בנקודת שירורתייה כלשהו  $x_0$  ובכל צעד הולכים בכיוון השיליי של הגרדיאנט של הפתרון שאנו נמצאים בוCut.

**איור לדוגמא:**




הערה 4.5 (באיור הנקודה הראשונה היא  $x_1$ )

**דוגמה 5.5** איור נוסף להתכנסות האלג' GD עבור אתחולים שונים (בצבעים שונים)



שים לב שעבור פונ' קמורה (הפונ' באיזור מעלה) לא משנה מאיפה אתחלנו (موقع בעיגול) את האלג': הגענו לאותו הפתרון האופטמלי.

עבור פונ' לא קמורות המצב שונה:



כעת אתחלנו את האלג' מנקודות שונות (העיגולים בצבעים) והגענו למקומות שונים: ההסבר הוא שהפונ' באיזור הנ"ל אינו קמור. ככלומר אם  $f$  קמורה מובחנת התכנסות למינימום הגלובלי, אם  $f$  אינה קמורה, יכולה להתקיים התכנסות, אבל לא בהכרח למינימום גלובלי (אלא למינימום מקומי) או אפילו יותר גורע: יש התכנסות למינימום בהם הגרדיאנט מתואפס (לדוגמא: נקודות אוכף) ונקודות אלה אפילו לא מהוות נקודות מינימום.

**פרשנות (אינרפטציה) לאלג' GD-Gradient descent** נניח שיש לנו פונ' ( $y$ ) או ראיינו שנייתן לעשות לה **קירוב מסדר ראשון** סיבוב נקודה  $x$  באופן הבא:

$$f(y) \approx f(x) + \nabla f(x)^T (y - x)$$

אנו יודעים כי הקירוב הנ"ל תקין רק **בשבביה קרובה** של הנקודה  $x$  כלומר, ככל שנתרחק מהנקודה  $x$  כהה הקירוב מסדר ראשון יהיה ופחות "יכג לנו נאמנה את  $f$ ".


ולכן גישה אחת בתבוננות על בעיית GD היא **ميزור של הקירוב מסדר ראשון** של  $f$ , תוך מתן **קנס** (אייבר מהצורה  $\frac{1}{2\eta} \cdot \|y - x\|_2^2$ ) הוא אייבר שמכריה אותנו להשאר קרובים לנוקודה  $x$  שהתחלו ממנה את האיטרציה (כל שאנו מתרחקים מנוקודה  $x$ . מתמטית ניתן להראות זאת באופן הבא. באיטרציה  $t$ , נרצה לieżור את  $x_t$  כלומר נחשף **בسبביה הקובבה** של  $x$  שמקיים:

$$\min_y f(x_t) + \nabla f(x_t)^T (y - x_t) + \frac{1}{2\eta} \cdot \|y - x_t\|_2^2$$

משמעותו שם אנו עושים זאת, קיבל כלל עדכון **שקלול** לכל העדכון הבא:

$$x_{t+1} = x_t - \eta \cdot \nabla f(x_t)$$

**איור:**



Blue point is  $x$ , red point is

$$x^+ = \underset{y}{\operatorname{argmin}} f(x) + \nabla f(x)^T (y - x) + \frac{1}{2\eta} \|y - x\|_2^2$$

- בעצם מה שקרה כאן: יש את הפונ'  $f$  (הקו הרציף)
- והקירוב הlienari שלה+גורם ריבועי  $\frac{1}{2\eta} \cdot \|y - x\|_2^2$  (הקו המוקוּוֹ).
  - הגורם הליניארי מקרבב את הפונ' בسبביה של הנוקודה  $x$ .
  - הגורם הריבועי מטאpecץ' כל שטmarksים מ- $f$  (הנקודה הכהולה).
  - שני הגורמים מרכיבים את הפרבולת שאנו רואים בשרטוט.
- הנקודה הכהולה היא נקודת ההתחלה ( $x_t$ )
- הנקודה האדומת היא הנקודה של המינימום של הקירוב הליניארי שלה+גורם ריבועי  $x$ . שימושו לב שיכל שנתרחק מהנקודה הכהולה כך הגורם הריבועי יידל (=הקירוב הליניארי לא יהיה תקף והבטוי יגדל).
- הנקודה הבאה שניקח תהיה  $f(x_{t+1})$  (את  $x_{t+1}$ ) או הנקודה האדומת.

**מה נעשה בשאר השיעור?**

- איך בוחרים את  $\eta$  קצב הלימוד
- הוכחת התכונות של האלג' עברו בחירה נcona של  $\eta$  ודיון על קצב ההתכנסות
- דיון עברו תוכנות ההתכנסות של האלג' עברו פול' שאין קמורות.

**קצבי התוכניות**

### תוצאה טיפוסית לגבי קצב ההתקנסות:

**דוגמה 6.5** אם מריםים GD למשך  $t$  איטרציות (=סיבובים/עדכונים) אז מקבלים את הפתרון  $x_t$  כך ש :

$$f(x_t) - f(x^*) \leq \frac{C}{t} \quad , C \text{ is Const such that } C > 0$$

- **המשמעות**, ככל שלוקחים יותר יותר איטרציות, ככה הפתרון נעשה יותר מדויק הערך שלו נעשה קרובה יותר לערך האופטמלי הקבוע  $C$  בד"כ הקשור לאותו המינימום ההתחלה היא  $x^* = 0$  אז  $\frac{C}{t}$  לדוגמא. כאמור נקראת **הבטחת קצב**. בדוגמא פה קצב ההתקנסות הוא  $\frac{C}{t^2}$ . כלומר בדוגמא דומה שלנו הפתרון משיפור כמו  $\frac{C}{t}$ .

- **ניתן להתבונן על אי השווון מזוינת אחרת:** אם אני רוצה למצוא פתרון  $\epsilon$  אופטמלי (קרוב לפתרון האופטמלי בכל הפחות  $\epsilon$ ), כמו איטרציות אני צריך על מנת להגיע לפתרון זהה. כאמור, אם רוצים להבטיח כי  $f(x_t) - f(x^*) < \epsilon$ ,  $C$  is Const such that  $\epsilon > 0$  כמה איטרציות  $t$  אנו צריכים?
- ראינו כי אחרי  $t$  איטרציות הפתרון יהיה  $\frac{C}{t}$  אופטמלי (רחוק מהפתרון האופטמלי בכלל יותר  $\frac{C}{t}$ ) ולכן על מנת למצוא את  $t$  נחוץ אותו מהמשווה  $\frac{C}{t} \geq \epsilon$  כלומר  $t \geq \frac{C}{\epsilon}$ .

$$f(x_t) - f(x^*) \leq \frac{C}{t} \leq \epsilon \Rightarrow t \geq \frac{C}{\epsilon}$$

כלומר עליינו ללחשת  $\lceil \frac{C}{\epsilon} \rceil$  צעדים על מנת להגיע לפתרון  $\epsilon$  אופטמלי.

כלומר שני דרכי ההסתכלות על קצב התקנסות הם :

1. **הലכת  $t$  איטרציות ?**  $\Leftarrow$  כמה הפתרון שנקבל קרוב לאופטמלי ?

- **תת אופטAMILיות כפונ' של מספר האיטרציות.**

2. **רוצים למצוא פתרון קרוב לפתרון האופטמלי בכל הפחות  $\epsilon$  (בדיקה של  $\epsilon$ )**  $\Leftarrow$  כמה איטרציות נזדקק ?

- **מספר האיטרציות הנדרשות כפונ' של אפסילון.**

זה מה שחשוב לזכור.

- אנליזה ראשונית** איך חוסמים את  $f(x_t) - f(x^*)$ ? כאמור למצוא חסם עליון לאחר  $T$  צעדים (=תת אופטAMILיות כפונ' של מספר האיטרציות  $T$ ) נסמן  $g_t \equiv \nabla f(x_t)$  ולכן עד העדכון של אלג' הגרדיינט  $x_{t+1} = x_t - \eta \cdot \nabla f(x_t)$  מוגדר להיות כתת הסימון החדש

$$\forall t \in \{0, 1, 2, \dots, T-1\} : x_{t+1} = x_t - \eta \cdot g_t$$

**משפט 7.5** אם פונ' קמורה איז אלגי GD מבטיח כי  $f : \mathbb{R}^d \longrightarrow \mathbb{R}$

$$\frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot \|x_0 - x^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|g_t\|_2^2 \right]$$

**ניתוח המשפט:**

- השגיאה באיטרציה ה $t$  נתונה על ידי  $(f(x_t) - f(x^*))$ , סכום כל השגיאות לאורך כל  $T$  האיטרציות נתון על ידי  $\frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*))$ . ניקח את הבטיי ב  $T$  נקבל את הבטיי  $\frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \frac{1}{T} \sum_{t=0}^{T-1} \|g_t\|_2^2$  המשמעות של האלג' במהלך  $T$  האיטרציות שלו.

- **איז השגיאה הממוצעת של האלג' לאחר  $T$  איטרציות קטנה או שווה (חסומה)** על ידי אנפ' ימין. (כלומר חסומה על ידי  $\frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot \|x_0 - x^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|g_t\|_2^2 \right]$ )

**ההבטחה** זה היא נcona לכל  $0 > \eta$ . מתי ההבטחה זו ממשוערת? כלומר מתי שהשגיאה ממוצעת הולכת ופחותה עם הגודל כמות האיטרציות?

- משמעות האיבר  $\|x^*\|_2^2 - \|x_0\|_2^2 - \frac{1}{2\eta} \cdot \text{רלוונטי לתנאי התחלה. אם } \eta \text{ נקודה התחלתי } x \text{ קרוב לפתרון האופטמלי } x^* \text{ אז הערך שלה איבר זהה הולך להיות נמוך (ואם רוחק מ-} x^* \text{ יהיה נבוהה).}$

- משמעות האיבר :  $\sum_{t=0}^{T-1} \|g_t\|_2^2 \cdot \frac{1}{2}$  אם הגרדיינטס לאורץ הפתרון מאוד גדולים אז האיבר הזה יהיה גדול אם הם קטנים לאורץ הפתרון אז האיבר קטן והשגיאה הולכת להיות נמוכה.

**נוכיח את המשפט** ונראה שקיים בירהה של קצב לימוד  $0 < \eta < \frac{1}{\sum_{t=0}^{T-1} \|g_t\|_2^2}$  כך שהבטי היומי (האיבר הולך וקטן ונמצא את  $\eta$  עבורו הבטי הנ"ל יהיה אופטמלי (=הקטן ביותר)).

**למה מסתכלים על השגיאה המוצעת?** לא מובטח לנו מכל סיבוב לכל סיבוב  $f(x_t) - f(x^*)$  יקטן, יש סיבובים בה השגיאה עלולה לגדול (כלומר, יש איטרציות עבורם  $f(x_t) - f(x^*) > f(x_{t+1}) - f(x^*)$ ) אבל במקרה, השגיאה הולכת לפחות מסיבוב לשיבוב.

**הנition (הוכחת המשפט)** הבא של האלגוריתם לחזור על עצמו כל הקרים כמעט לכל האלגוריתם. אז חשוב להבין אותו.  
הוכחת המשפט:

1. נזכר באי שווין הגרדיאנט  $\mathbb{R} \longrightarrow \mathbb{R}^n$  וקמורה ולכון תנאי מתקיים ולכון :

$$\forall x, y \in \text{dom}(f) : f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

ולכון :

$$\forall x, y \in \text{dom}(f) : f(y) - f(x) \geq +\nabla f(x)^T (y - x)$$

ולכון :

$$\forall x, y \in \text{dom}(f) : f(x) - f(y) \leq \nabla f(x)^T (x - y)$$

בפרט עבור  $f(x_t) - f(x^*) \leq \nabla f(x_t)^T (x_t - x^*)$  מתקיים  $x_t = x, x^* = y \in \text{dom}(f)$ . נסמן  $g_t \equiv \nabla f(x_t) - f(x^*)$  כדי כי השגדרנו קודם קודם ולכון קיבל כי מתקיים

$$f(x_t) - f(x^*) \leq g_t^T (x_t - x^*)$$

אי השוויון הנ"ל נכון לכל  $t$  ולכון גם יהיה נכון על הסכום של כל  $t$ -ים:

$$(\diamond) : \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \sum_{t=1}^{T-1} [g_t^T (x_t - x^*)]$$

(א) נתבונן בשני האיטרציות הראשונות:

$$\begin{array}{c|c} t=0 & 2\eta \cdot g_0^T (x_0 - x^*) \leq \|(x_0 - x^*)\|_2^2 - \|x_1 - x^*\|_2^2 + \eta^2 \cdot \|g_0\|_2^2 \\ t=1 & 2\eta \cdot g_1^T (x_1 - x^*) \leq \|(x_1 - x^*)\|_2^2 - \|x_2 - x^*\|_2^2 + \eta^2 \cdot \|g_1\|_2^2 \end{array}$$

נחבר את שני המשוואות האיברים הבאים יתבטלו

$$\begin{array}{c|c} t=0 & 2\eta \cdot g_0^T (x_0 - x^*) \leq \|(x_0 - x^*)\|_2^2 - \|x_1 - x^*\|_2^2 + \eta^2 \cdot \|g_0\|_2^2 \\ t=1 & 2\eta \cdot g_1^T (x_1 - x^*) \leq \|(x_1 - x^*)\|_2^2 - \|x_2 - x^*\|_2^2 + \eta^2 \cdot \|g_1\|_2^2 \end{array}$$

זה נקרא סכום טלקופי זה יקרה עבור כל שני אי שוויונות עוקבים. וכך נסכום את כל  $T$ -ים נשאר עם האיבר הראשון והאיבר האחרון. המחסנו את זה עבור  $t=0, t=1, t=2, \dots, T-1$ . אזי אם נסכום על פני כל הסיבובים נקבל:

$$\sum_{t=0}^{T-1} 2\eta \cdot g_t^T (x_t - x^*) \leq \sum_{t=0}^{T-1} (\|(x_t - x^*)\|_2^2 - \|x_{t+1} - x^*\|_2^2 + \eta^2 \cdot \|g_t\|_2^2)$$

ומהתקנות של הטור הטלסקופי נשאר עם

$$\sum_{t=0}^{T-1} 2\eta \cdot \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 - \|\mathbf{x}_{(T-1)+1} - \mathbf{x}^*\|_2^2 + \eta^2 \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2$$

כולם

$$\sum_{t=0}^{T-1} 2\eta \cdot \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 - \|\mathbf{x}_T - \mathbf{x}^*\|_2^2 + \eta^2 \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2$$

מתוכנות הנורמה האיבר  $\|\mathbf{x}_T - \mathbf{x}^*\|_2^2$  אי שלילי ולכן ניתן לנצל להשmitt אותו ולהגדיל את אי השוויון ולקבל

$$\begin{aligned} \sum_{t=0}^{T-1} 2\eta \cdot \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) &\leq \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 - \|\mathbf{x}_T - \mathbf{x}^*\|_2^2 + \eta^2 \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2 \\ &\leq \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 + \eta^2 \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2 \end{aligned}$$

כולם קיבלנו את אי השוויון

$$\sum_{t=0}^{T-1} 2\eta \cdot \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 + \eta^2 \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2$$

נחלק ב  $2\eta$  ונקבל

$$\diamond : \sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \frac{1}{2\eta} \cdot \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2$$

2. נזכיר בכלל העדכו של האלג  $\|\mathbf{x}_{t+1} - \mathbf{x}^*\|_2^2$  וננתח את הבטו  $\forall t \in \{0, 1, 2, \dots, T-1\} : \mathbf{x}_{t+1} = \mathbf{x}_t - \eta \cdot \mathbf{g}_t$

$$\begin{aligned} \|\mathbf{x}_{t+1} - \mathbf{x}^*\|_2^2 &= \|(\mathbf{x}_t - \eta \cdot \mathbf{g}_t) - \mathbf{x}^*\|_2^2 \\ &= \|(\mathbf{x}_t - \mathbf{x}^*) - \eta \cdot \mathbf{g}_t\|_2^2 \\ &= \|(\mathbf{x}_t - \mathbf{x}^*)\|_2^2 - 2\eta \cdot \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) + \eta^2 \cdot \|\mathbf{g}_t\|_2^2 \end{aligned}$$

$$\Rightarrow \|\mathbf{x}_{t+1} - \mathbf{x}^*\|_2^2 = \|(\mathbf{x}_t - \mathbf{x}^*)\|_2^2 - 2\eta \cdot \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) + \eta^2 \cdot \|\mathbf{g}_t\|_2^2$$

נבצע העברת אגפים ונקבל

$$2\eta \cdot \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \|(\mathbf{x}_t - \mathbf{x}^*)\|_2^2 - \|\mathbf{x}_{t+1} - \mathbf{x}^*\|_2^2 + \eta^2 \cdot \|\mathbf{g}_t\|_2^2$$

(א) נשרש את אי השוויון  $\diamond$  ונקבל

$$\sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \stackrel{\diamond}{\leq} \sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \stackrel{\diamond}{\leq} \frac{1}{2\eta} \cdot \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2$$

ובפרט

$$\sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{1}{2\eta} \cdot \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2$$

נחלק את אי השוויון הנ"ל ב  $T$  ונקבל

$$\frac{1}{T} \cdot \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right] \leq \frac{1}{T} \left[ \frac{1}{2\eta} \cdot \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|\mathbf{g}_t\|_2^2 \right]$$

שזה מה שרצינו להוכיח ולכון, סיום.

■

**המשך בניתו של המשפט** נתבונן בנקודת  $\mathbf{x}_t$  היא מהויה צירוף קמור של  $\mathbf{x}_t$  ים לאורך כל  $T$  האיטרציות (כל המקדמים  $\lambda_i = \frac{1}{T}$  אי שליליים והסכום של כולם הוא 1). מאי שווין ינסן 69.2 נובע כי

$$f(\bar{\mathbf{x}}_T) = f\left(\frac{1}{T} \cdot \sum_{t=0}^{T-1} \mathbf{x}_t\right) = f\left(\sum_{t=0}^{T-1} \frac{1}{T} \mathbf{x}_t\right) \stackrel{\text{Jensen's inequality}}{\leq} \sum_{t=0}^{T-1} \frac{1}{T} f(\mathbf{x}_t) = \frac{1}{T} \sum_{t=0}^{T-1} f(\mathbf{x}_t)$$

כלומר

$$f(\bar{\mathbf{x}}_T) \leq \frac{1}{T} \sum_{t=0}^{T-1} f(\mathbf{x}_t)$$

חסיר  $f(\mathbf{x}^*)$  משני האגפים ונקבל

$$\begin{aligned} f(\bar{\mathbf{x}}_T) - f(\mathbf{x}^*) &\leq \left[ \frac{1}{T} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t)) \right] \right] - f(\mathbf{x}^*) = \left[ \frac{1}{T} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t)) \right] - Tf(\mathbf{x}^*) \right] \\ &= \left[ \frac{1}{T} \left[ \sum_{t=0}^{T-1} \left( f(\mathbf{x}_t) - T \cdot \frac{1}{T} f(\mathbf{x}^*) \right) \right] \right] = \left[ \frac{1}{T} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right] \right] \end{aligned}$$

בפרט  $f(\bar{\mathbf{x}}_T) - f(\mathbf{x}^*) \leq \left[ \frac{1}{T} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right] \right]$

$$f(\bar{\mathbf{x}}_T) - f(\mathbf{x}^*) \leq \left[ \frac{1}{T} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right] \right] \leq \frac{1}{T} \left[ \frac{1}{2\eta} \cdot \|(\mathbf{x}_0 - \mathbf{x}^*)\|_2^2 + \frac{\eta}{2} \cdot \sum_{i=1}^{T-1} \|\mathbf{g}_t\|_2^2 \right]$$

לא רק שהשגיאה ממוצעת לאורך כל האיטרציות  $\left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right]$  הולכת וקטנה ככל שעושים יותר סיבובים ( $T$  גדול).

אלא שמש אפשר לבחור נקודה אחת מסוימת בסוף התהליך של האופטימציה של האגף  $\bar{\mathbf{x}}_T = \frac{1}{T} \cdot \sum_{t=0}^{T-1} \mathbf{x}_t$  שהשגיאה שלה תהיה נמוכה (נומבה ממש נקודה מסוימת) ככלום:

- **כלומר מסובב לסיבוב לא מובטח שיפור**, ככלום, עלול להתקיים ש( $f(\mathbf{x}_{t+1}) - f(\mathbf{x}^*) > f(\mathbf{x}_t) - f(\mathbf{x}^*)$ ) (השגיאה גדולה מאייטרציה מסוימת לאיטרציה העוקבת)

• **אבל בסוף תהליכי האופטימציה** אפשר לבחור את הנקודה  $\bar{\mathbf{x}}_T = \frac{1}{T} \cdot \sum_{t=0}^{T-1} \mathbf{x}_t$  עבורה יתקיים  $f(\bar{\mathbf{x}}_T) - f(\mathbf{x}^*) \leq \frac{1}{T} \cdot \sum_{t=0}^{T-1} \mathbf{x}_t$ . עבור נקודה זו, מתקיים **頓時** שככל ש- $T$  גדול יותר, (עשינו יותר איטרציות) ככה השגיאה שלה תהיה נמוכה יותר ויותר, וזה באופן וודאי.

**מסקנה 8.5** מסקנה חשובה ככלום, מסובב לסיבוב לא מובטח שיפור בתת האופטימליות של השגיאה (ייתכנו  $f(\mathbf{x}_{t+1}) - f(\mathbf{x}^*) > f(\mathbf{x}_t) - f(\mathbf{x}^*)$ ). אבל **עד הפעם נקודה שהיא המוצע  $\bar{\mathbf{x}}_t$** , תמיד ישטרפ מסובב לסיבוב ככלום –  $f(\bar{\mathbf{x}}_{t+1}) - f(\mathbf{x}^*) \leq f(\bar{\mathbf{x}}_t) - f(\mathbf{x}^*)$  **תמיד**. ככלום האיכות של הפתרון (=תת אופטימי עבור מספר קטן יותר) של הנקודה  $\bar{\mathbf{x}}_t$  הולכת ומשפרת **תמיד** ככל שגדדים את מספר האיטרציות.

הגדירה 9.5 פונ'  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  תקרא **B לפשיצית אם קיים**  $\forall x, y \in \mathbb{R}^n : \|f(x) - f(y)\| \leq B \cdot \|x - y\|$  :

הערה 10.5 **תנאי שקול לפונ'**  $f$  להיות **B לפשיצית** היא שכל הגרדיינטים שלhab חסומים על ידי קבוע  $B$ . כלומר:  $\forall x \in \mathbb{R}^n : \|\nabla f(x)\| \leq B$ .

נרצה לראות متى לחסם מוחמפט הבודם שקיבנו יש שימושות. אנו הולכים להניח שני הנחות נוספות על הפונ'  $f$ :

1. אנו מניחים שהפונ'  $f$  היא **לייפשיצית**. (כלומר שכל הגרדיינטים שלhab חסומים על ידי קבוע  $B$ ).

2. בנוסך אנו מניחים שקיים  $R$  עבורו נקודת האתחול של האלג' שלו מקיים  $R \geq \|x^* - x_0\|$ .

הערה 11.5 בוקפדייה, עבור פונ' קמורה לייפשיצית מכל תחום במידה לכל טווח במידה כלשהו, תנאי לייפשיציות יכול להיות מוגדר עם כל שני מרחבי נורמות שהם (אחת שמוגדרת בתחום ואחת שמוגדרת לטווח):

### Definitions [edit]

Given two metric spaces  $(X, d_X)$  and  $(Y, d_Y)$ , where  $d_X$  denotes the metric on the set  $X$  and  $d_Y$  is the metric on set  $Y$ , a function  $f : X \rightarrow Y$  is called **Lipschitz continuous** if there exists a real constant  $K \geq 0$  such that, for all  $x_1$  and  $x_2$  in  $X$ ,

$$d_Y(f(x_1), f(x_2)) \leq K d_X(x_1, x_2). \quad [3]$$

אזי אם נבצע את הנחות הנוספות האלו על  $f$ , נקבל את המוחמפט הבא:

משפט 12.5 תהא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  קמורה, גיירה, עם נקודת מינימום גלובלית שננסמה  $x^*$ . **בנוסך נניח כי:**  $\exists R, \forall x \in \mathbb{R}^n : \|\nabla f(x)\| \leq B$  ומי  $\|x - x^*\| \leq R$  אז  $\exists \eta$  נבחר את גודל הצעד  $\eta$  באופן הבא:

$$\eta := \frac{R}{B\sqrt{T}}$$

אזי **אלגוריתם הגרדיינט GD** יניב את התואנה הבאה:

$$\frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \frac{RB}{\sqrt{T}}$$

הערה 13.5 נבחן כי  $\eta$  הוא פורפרוציוני למרחק האתחול  $R \geq \|x_0 - x^*\|$  ופורפרוציוני הפוך לחסם על הגרדיינטים  $B$ .

הערה 14.5 ככלומר השגיאה ממוצעת  $(f(x_t) - f(x^*))$  או שווה  $\frac{RB}{\sqrt{T}}$ . ככלומר השגיאה ממוצעת הולכת וקטנה ככל  $T$  הולך וגדל. ככלומר השגיאה ממוצעת הולכת וקטנה כפונ' של  $\frac{1}{\sqrt{T}}$ .

הערה 15.5 נבחן כי המוחמפט **דורש לדעת מראש** מה היא כמות האיטרציות שאנו הולכים לבצע,  $T$ .

הערה 16.5 אזי, כדי לקבל  $\epsilon$  אופטימליות, כמה איטרציות  $T$  נצטרץ? החישוב נראה כך  $\epsilon = \frac{RB}{\sqrt{T}}$  נרצה לבטא את  $T$  כפונ' של  $\epsilon$ : נקבל

$$\frac{RB}{\sqrt{T}} \leq \epsilon \iff \frac{RB}{\epsilon} \leq \sqrt{T} \iff \left(\frac{RB}{\epsilon}\right)^2 \leq T$$

“ $\epsilon$  נצטרץ לפחות  $\left(\frac{RB}{\epsilon}\right)^2$  איטרציות (אם המספר לא שלם ניקח ערך שלם עליון) בשביל לקביל פתרון  $\epsilon$  אופטימלי. במיללים אחרות, כדי לקבל  $\epsilon$  אופטימליות (שנראה של כל היותר  $\epsilon$ ) נצטרץ לפחות מספר צעדים שפורפרוציוני ל  $\frac{1}{\epsilon^2}$ . ככלומר הקצב הוא הוא  $\mathcal{O}\left(\frac{1}{\epsilon^2}\right)$ .

**הערה 17.5** ראיינו קודם כי עבור הנקודה  $\bar{x}_T = \frac{1}{T} \cdot \sum_{t=0}^{T-1} x_t$  יתקיים  $f(\bar{x}_T) - f(x^*) \leq \frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*))$  ולכן נוכל לשדרש אותו למשפט שראיינו ולקבל את אי השוויין

$$f(\bar{x}_T) - f(x^*) \leq \frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \frac{RB}{\sqrt{T}}$$

**הוכחת המשפט:** ראיינו לפי המשפט הקודם כי

$$\frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot \|x_0 - x^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|g_t\|_2^2 \right]$$

כעת נגדיל את אי השוויין על ידי וכי  $\exists R, \forall x \in \mathbb{R}^n : \|x_0 - x^*\| \leq R$  ונקבל

$$\begin{aligned} \frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) &\leq \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot \|x_0 - x^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|g_t\|_2^2 \right] \\ &\leq \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot R^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} B^2 \right] \\ &= \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot R^2 + \frac{\eta}{2} \cdot TB^2 \right] \end{aligned}$$

כלומר מתקבל כי

$$\frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot R^2 + \frac{\eta}{2} \cdot TB^2 \right]$$

כלומר קיבלנו בטווי של השגיאה ממוצעת (אגף שמאל) שחסומה על ידי פונ' של  $\eta$  (אגף ימין).. נרצה **למצוא את החסם ההדוק ביותר**, כלומר את השגיאה הממוצעת הקטנה ביותר.

ולכן, נסמן  $q(\eta) = \frac{1}{2\eta} \cdot R^2 + \frac{\eta}{2} \cdot TB^2$  ונרצה לבחור  $\eta$  עבורו נקבל ש  $q(\eta)$  מקבל מינימום. נגזר את  $q$  לפי  $\eta$  ונקבל

$$q'(\eta) = -\frac{1}{\eta^2} \left[ \frac{1}{2} \cdot R^2 \right] + \frac{1}{2} \cdot TB^2 = 0 \Rightarrow \frac{1}{2} \cdot TB^2 = \frac{1}{\eta^2} \left[ \frac{1}{2} \cdot R^2 \right] \Rightarrow \frac{\frac{1}{2} \cdot TB^2}{\frac{1}{2} \cdot R^2} = \frac{1}{\eta^2} \Rightarrow \frac{\frac{1}{2} \cdot R^2}{\frac{1}{2} \cdot TB^2} = \eta^2 \Rightarrow \boxed{\frac{R}{\sqrt{TB}} = \eta}$$

נבחן כי  $\eta = \frac{R}{\sqrt{TB}}$  הוא הערך עבורו מתקבל המינימום של הפונ'. (ניתן לגוזר פעמיים נוספת ולחזורות שנגזרת חיובית ולכן זו אכן נקודת מינימום:  $q''(\eta) = \frac{1}{\eta^3} \left[ \frac{1}{2} \cdot R^2 \right] > 0$ ) because  $\eta > 0$

ולכן קיבלנו כי עבור  $\eta$  קצב הלימוד מתקבל כי  $\frac{R}{\sqrt{TB}} = \eta$

$$\begin{aligned}
 \frac{1}{T} \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) &\leq \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot R^2 + \frac{\eta}{2} \cdot TB^2 \right] \\
 &= \frac{1}{T} \cdot \left[ \frac{1}{2 \left( \frac{R}{\sqrt{TB}} \right)} \cdot R^2 + \frac{\left( \frac{R}{\sqrt{TB}} \right)}{2} \cdot TB^2 \right] \\
 &= \frac{1}{T} \cdot \left[ \frac{\sqrt{TB} \cdot R}{2} + \left( \frac{R}{\sqrt{TB}} \right) \frac{TB^2}{2} \right] \\
 &= \frac{1}{T} \cdot \left[ \frac{\sqrt{TB} \cdot R}{2} + \frac{\sqrt{TB} R}{2} \right] \\
 &= \frac{1}{T} \cdot [\sqrt{TB} \cdot R] \\
 &= \frac{BR}{\sqrt{T}}
 \end{aligned}$$

כלומר עבור  $\eta$  (ה  $\eta$  האופטמלי) מתקבל כי  $\frac{BR}{\sqrt{T}} = \frac{R}{\sqrt{TB}}$

■

**הערה 18.5 הערכה חשובה:** קיבלנו את התוצאה שעבור  $\frac{1}{T} \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{BR}{\sqrt{T}}$  מתקיים  $\eta$  מתקיים ש  $\frac{R}{\sqrt{TB}} = \eta$  כלומר **תוצואה היא איננה תלויות במייד של הבעה!** ככלור החסם על השגיאה הממוצעת איינו תלוי במייד של הבעה. קיימים הרבה מקרים שבהם הקבועים  $R, B$  אינם תלויים במייד. **למה זה חשוב?** יש שיטות (שללא נלמד בקורס: cutting plae, epilipsoid, ...) שזו סבוכיות גדולה מאוד (לדוגמא  $O(n^3)$ ) ומשי לביעות מעשיות. **ולכן חשוב להעריך את התכונה הזו.**

**הערה 19.5 הערכה חשובה 2:** קיבלנו את התוצאה שעבור  $\frac{1}{T} \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{BR}{\sqrt{T}}$  מתקיים  $\eta$  מתקיים ש  $\frac{R}{\sqrt{TB}} = \eta$ . ראיינו כי מתקיים כבר  $f(\bar{\mathbf{x}}_T) - f(\mathbf{x}^*) \leq \frac{BR}{\sqrt{T}}$  ולכן החסם מלמעלה גם את השגיאה זו ( $f(\mathbf{x}^*) - f(\bar{\mathbf{x}}_T) \leq \frac{BR}{\sqrt{T}}$ ). וגם חסם מלמעלה את האיטרנט סעל השגיאה הכי נמוכה ( $f(\bar{\mathbf{x}}_T) - f(\mathbf{x}^*) \leq \min_{t \in \{0, 1, \dots, T-1\}} \{f(\mathbf{x}_t) - f(\mathbf{x}^*)\}$ ). מתקיים עבור האיטרנט הכי טוב שהוא חסום מלמעלה על ידי אותו חסם,  $f(\mathbf{x}_{t^*}) - f(\mathbf{x}^*) \leq \frac{BR}{\sqrt{T}}$  ככלור לסייעו

$$\begin{aligned}
 f(\bar{\mathbf{x}}_T) - f(\mathbf{x}^*) &\leq \frac{BR}{\sqrt{T}}, \quad \bar{\mathbf{x}}_T = \frac{1}{T} \cdot \sum_{t=0}^{T-1} \mathbf{x}_t \\
 f(\mathbf{x}_{t^*}) - f(\mathbf{x}^*) &\leq \frac{BR}{\sqrt{T}}, \quad t^* = \arg \min_{t \in \{0, 1, \dots, T-1\}} \{f(\mathbf{x}_t) - f(\mathbf{x}^*)\}
 \end{aligned}$$

**הבעיה** היא שלא תמיד אנו יודעים את  $R$  ו/או את  $B$  למעשה הרבה לא נדע אותם. קיימות שיטות (אחד מהם נלמד בתרגול) שמנסה ללמידה את הפרמטרים הללו תוך כדי הרצת אל' האופטימיזציה (נקראת adagrad) שיטה שהיא אדפטטיבית לנורמות של הגרדיאנטים (לא צריכה לדעת את  $B$  מראש).

### 5.1.2 פונ' חלקות

אנו הולכים להגביל את הדיוון שלנו כתעט לפונ' קמורות שם בנוסף גם **חלקות**.  
נתחיל בהגדרת פונ' חלקות

**הגדירה 20.5** הגדרה ראשונה: פונ'  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  **L-smooth** (עבור פרמטר  $0 \leq L$ ) אם היא גזירה ברציפות ובנוסף  $\|y - x\| \leq L \cdot \|\nabla f(x) - \nabla f(y)\| \forall x, y \in \mathbb{R}^d$ . (שקלל להגדרה שהגרדיינט הוא  $L$  ליפשייך, ראה הערכה) השימוש בהגדרה זהו בד"כ נעשה מוחץ להקשר של אופטימציה. עבור אופטימציה נהוג להשתמש בהגדרה השנייה (שנובעת מההגדרה מספר 1).

**הערה 21.5** ההגדרה זו אינה דורשת קמירות (יהי לנו שימושי בהמשך). עבור פונ' קמורות ההגדרה הראשונה והשנייה, שקולות.

**הערה 22.5** (הגדירה שקופה, של התרגול) פונ'  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  תהיה בעלת גרדיינט ליפשייך עם קבוע  $L$  אם  $\|\nabla f(x) - \nabla f(y)\| \leq L \cdot \|x - y\| \forall x, y \in \mathbb{R}^d$ , מתקייםgradient

**הערה 23.5** נוכל לומר על פונ' לינארית (הגרדיינטים שלה מתאפסים) שהיא **0 - חלקה**. (זה כי חלק שיכל להיות).

**הגדירה 24.5** הגדרה שנייה: פונ'  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  **L-smooth** (עבור פרמטר  $0 \leq L$ ) אם היא **קמורה, גזירה וبنוסף**  $\forall x, y \in \mathbb{R}^d : f(y) \leq f(x) + \nabla f(x)^T (y - x) + \frac{L}{2} \cdot \|x - y\|^2$ .

**הערה 25.5** כמובן, לפי ההערכה הקודמת אם **קמורה וגזירה ברציפות**:

$$\begin{aligned} \forall x, y \in \mathbb{R}^d : \|\nabla f(x) - \nabla f(y)\| &\leq L \cdot \|x - y\| \\ \iff \forall x, y \in \mathbb{R}^d : f(y) &\leq f(x) + \nabla f(x)^T (y - x) + \frac{L}{2} \cdot \|x - y\|^2 \end{aligned}$$

כלומר אם פונ'  $f$  קמורה וגזירה ברציפות אז:  $f$  בעלת גרדיינט ליפשייך עם קבוע  $L$   $\iff$   $f$  חלקה  $\iff$  היא  $L$  חלקה.

**משפט 26.5** (מתוך הרצאה 5) **תhea פונ'  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  אם  $f$  גזירה פעמיים ובנוסף  $f$  היא פונ' קמורה, אז  $f$  חלקה אם  $\forall x \in \mathbb{R}^d : \lambda_{\max}(\nabla^2 f(x)) \leq L$  (הע"ע הגדל ביותר של מט' ההאסיאן של  $f$ , קטן מ  $L$  בכל מקום) אז  $f$  היא  $L$  חלקה.**

**משפט 27.5** (מתוך הרצאה 5) **תhea פונ'  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  אם  $f$  גזירה פעמיים (כאן אין דרישת על קמירות  $f$ ). נסמן את מט' ההאסיאן  $(x)$   $\nabla^2 f(x)$  ואת קבועת הע"ע שלה  $\{\lambda_i\}_{i=1}^d$ , אז כל הע"ע שלה חסומים מקיימים**

$$\forall i \in \{1, 2, \dots, d\} : |\lambda_i| \leq L$$


אז  $f$  היא  $L$  חלקה.

**דוגמה 28.5** איזור מתוך הרצאה שמנסה להציגים זאת:

### Smooth functions: $\mathcal{O}(1/\varepsilon)$ steps



**Smoothness:** For any  $x$ , the graph of  $f$  is below a not-too-steep tangential paraboloid at  $(x, f(x))$ :



כלומר אם הפונ'  $f$  קמורה וחלקה, אז לכל נקודה  $x$ , הפונ' תמצא בمعنى "סנדביץ" מעל הפונ' יהיה המשיק + האיבר האיבועי (שגדל ככל שמתրחקים מ $x$ )  $f(x) + \nabla f(x)^T(y - x) + \frac{L}{2} \|y - x\|^2$


if  $f$  is convex and smooth :

$$\forall x, y \in \mathbb{R}^d :$$

$$f(x) + \nabla f(x)^T(y - x) \leq f(y) \leq f(x) + \nabla f(x)^T(y - x) + \frac{L}{2} \cdot \|x - y\|^2$$

אייר נוסף לסנדביץ, מתוך התרגול:

Illustration



• בשchor זו הפונ' הקמורה והחלקה.

• ובאודום זה הבטו של החלקות (אם האודום מעלה השטור לכל נקודה אז הפונ'  $f$  חלקה)

• ובחולז המשיך לפונ' (ראינו שעבור פונ' קמורות הוא יהיה תמיד מתחת לפונ')

• בירוק זה בטו שמתואר פונ' קמורה ממש. (פונ' קמורה ממש אם תחסיר ממנה איבר ריבועי מסוימים ותקבל עדיין פונ' קמורה).

אנחנו הוליכם להראות שאם יש פונ' שהוא איז אפשר לקבל קצב עbor GD שהוא טוב יותר מהקצב שראינו. קודם שקדם ראיינו שהקצב היה  $\mathcal{O}\left(\frac{1}{\epsilon^2}\right)$  (=בשביל לקביל פתרון  $\epsilon$  הינו צריים לכלת סדר גודל של  $\frac{1}{\epsilon^2}$  צעדים) אזicut נראה שבקצב עבור  $f$  קמורה וגם חלקה יהיה טוב יותר כלומר שהקצב היה  $\mathcal{O}\left(\frac{1}{\epsilon}\right)$  (=בשביל לקביל שהקצב היה  $\mathcal{O}\left(\frac{1}{\epsilon^2}\right)$  הינו צריים לכלת סדר גודל של  $\frac{1}{\epsilon}$  צעדים) ולכן זה שיפור מאוד ניקר.

**משפט 29.5** פונ' שטח ריבועיות Quadratic functions הן פונ' חלקות.

**פעולות משמרות חלקות:**

**משפט 30.5** יהיו  $f_1, f_2, \dots, f_m$  פונ' קמורות שחלקות עברו פרמטרים  $L_1, L_2, \dots, L_m$  בהתאם. יהיו  $\lambda_1, \lambda_2, \dots, \lambda_m \in \mathbb{R}_+$  (כלומר  $\lambda_i$  אי שלילית לכל  $i$ ). אז הפונ' הבאה:  $f \triangleq \sum_{i=1}^m \lambda_i f_i$  היא הקמורה (לפי משפט אחר) וחלקה עם פרמטר חלקות  $\lambda_i L_i$ .

**משפט 31.5** תהא  $f \circ g = f(g(x))$  פונ' קמורה ו  $L$  חלקה. נגיד  $A \in \mathbb{R}^{d \times n}, b \in \mathbb{R}^d$  עבור  $g(x) = Ax + b$  אז הפונ'  $f$  היא

קמורה (לפי משפט אחר) וחלוקת עם פרמטר חלוקת  $L \|\mathbf{A}\|^2$  כאשר

$$\|\mathbf{A}\| = \max_{\mathbf{x} \neq 0} \frac{\|\mathbf{Ax}\|}{\|\mathbf{x}\|} = \sqrt{\lambda_{\max} \cdot (\mathbf{A}^T \mathbf{A})}$$

כלומר,  $\|\mathbf{A}\|$  היא הנורמה norm – 2. (מכונה גם הנקמה הספקטרלית) של  $\mathbf{A}$ .

**קימיות אל מול פשיטות:**

**הערה 32.5** ראיינו כי

• הגרדיאנטים חסומים  $\nabla f$  הינה  $L$  פשיטית.

• הפ' חלקה  $\nabla f$  עם הפ'  $f$  הינה פשיטית.

**משפט 33.5** (ראינו אותו מעלה) תהא  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  קמורה וגורירה איזי:  $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^d : \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \cdot \|\mathbf{x} - \mathbf{y}\| \iff f$  הינה חלקה עם פרמטר חלוקות  $L$ .

הוכחה של GD עבור פונ' חלוקות.

**лемה 34.5** sufficient decrease תהא  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  גירה וחולקה עם פרמטר חלוקות  $L$ . איז עבור צעד הלימוד  $\eta = \frac{1}{L}$  הGD מבטיח

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) - \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2 \quad .t \geq 0$$

הערה 35.5 נבחן שאי השוויון הזה מתקיים אם  $L$  חולקה עם פרמטר  $L$  עבור הקו המחבר בין הנקודות  $\mathbf{x}_{t+1}, \mathbf{x}_t$ .

הערה 36.5 נזכור שפרמטר חלוקות מוגדר עbor 0  $L \geq 0$ .

**מסקנה 37.5 מסקנה ראשונה** ככלומר ההבטחה כאן היא שבין כל שני אינטרנטים קיים שיפור.

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) - \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2 \iff f(\mathbf{x}_{t+1}) - f(\mathbf{x}_t) \leq -\overbrace{\frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2}^{\text{not negative}}$$

$$\Rightarrow f(\mathbf{x}_{t+1}) - f(\mathbf{x}_t) \leq 0 \Rightarrow \boxed{f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t)}$$

כלומר **בניגוד** לקרה הכללי בקרה זה **תמיד** יש שיפור בין **כל שני צעדים** של האלג', עbor פונ' חולקה וגודל צעד הבא  $\eta = \frac{1}{L}$ , בכל  $f(\mathbf{x}_t) - \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2$  הולך וקטן. מתקרבים למינימום השיפור הנ"ל פורפוציוני לגרדיאנט בנקודה זו.

כלומר ככל שהגדリアנט גדול נקבל שיפור מושעתי יותר וככל שהגדリアנט קטן נקבל שיפור קטן יותר.

כלומר ראיינו כי  $f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t)$  לכל  $t$  בפרט עבור האינטרנט האחרון מתקיים

$$\forall t \in \{0, 1, \dots, T-1, T\} : f(\mathbf{x}_T) \leq f(\mathbf{x}_t)$$

**מסקנה 38.5 מסקנה שנייה** (נובעת מהעברת אגפים) אנו יכולים לחסום את  $\|\nabla f(\mathbf{x}_t)\|^2$  (ריבוע הנורמה של הגרדיאנט בנקודה  $\mathbf{x}_t$ ) על ידי

$$\boxed{\frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2 \leq f(\mathbf{x}_t) - f(\mathbf{x}_{t+1})}$$

למה זה חשוב? ראיינו בחוכחה הקודמת כי היה בטוי מהצורה  $\|\nabla f(\mathbf{x}_t)\|^2$ , כתע יש לנו חסם נוסף על הגודל הזה. וכך נוכל להשתמש בו בחוכחה הקודמת עבור פונ' חלוקות.

**הוכחת הלמה:** נזכיר בהגדרת החלוקות (הגדרה 2) וובפרט עבור  $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^d : f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{L}{2} \cdot \|\mathbf{x} - \mathbf{y}\|^2$  וכן  $\mathbf{x} = \mathbf{x}_t, \mathbf{y} = \mathbf{x}_{t+1}$

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) + \nabla f(\mathbf{x}_t)^T (\mathbf{x}_{t+1} - \mathbf{x}_t) + \frac{L}{2} \cdot \|\mathbf{x}_t - \mathbf{x}_{t+1}\|^2$$

נזכור כי  $x_{t+1} = x_t - \eta \nabla f(\mathbf{x}_t)$  ונציב אותו ונקבל

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) + \nabla f(\mathbf{x}_t)^T (\mathbf{x}_t - \eta \nabla f(\mathbf{x}_t) - \mathbf{x}_t) + \frac{L}{2} \cdot \|\mathbf{x}_t - \mathbf{x}_t - \eta \nabla f(\mathbf{x}_t)\|^2$$

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) - \eta \nabla f(\mathbf{x}_t)^T (\nabla f(\mathbf{x}_t)) + \frac{L}{2} \cdot \|\eta \nabla f(\mathbf{x}_t)\|^2$$

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) - \eta \nabla f(\mathbf{x}_t)^T (\nabla f(\mathbf{x}_t)) + \frac{L}{2} \cdot |\eta|^2 \|\nabla f(\mathbf{x}_t)\|^2$$

$$\Downarrow \eta = \frac{1}{L}$$

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) - \frac{1}{L} \cdot \|\nabla f(\mathbf{x}_t)\|^2 + \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2$$

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) - \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2$$

■

### המשפט **GD** עבור פונ' חלוקות

**משפט 39.5** תהא  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  פונ' קמורה גיירה בעלת נקודות מינימום שנסמנה  $\mathbf{x}^*$ . בנוסף נניח כי  $f$  חלקה עם פרמטר חלוקות  $L$ . אזי, עבור גודל הצעד  $\eta = \frac{1}{L}$  **GD** מיביא:

$$f(\mathbf{x}_T) - f(\mathbf{x}^*) \leq \frac{L}{2T} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|^2 \quad , T > 0$$

**הערה 40.5** הדבר הזה משמעותי כי המשמעות שלו היא שכך כל ש  $T$  גדול השגיאה של האיטרציה האחורונה ( $f(\mathbf{x}_T) - f(\mathbf{x}^*)$ ) הולכת וקטנה. (בניגוד למקודם, שהוא לנו משפט שדיבר על "השגיאה המומוצעת") כאן אנו מדברים על האיטרציה האחורונה.

**הערה 41.5** במשפט אפסילון על מנת להגיע לשגיאה קטנה לפחות כמוה  $\epsilon$  (פתרון  $\epsilon$  תת אופטמלי), علينا שיתקיים  $\frac{L}{2T} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|^2 \leq \epsilon$ . כלומר עלינו לבצע  $T \geq \frac{\|\mathbf{x}_0 - \mathbf{x}^*\|^2}{\frac{L}{2\epsilon}} = \frac{2\epsilon}{L}$  איטרציות. ככלומר מושגים שלנו ממקודם, במרקחה כזה של פונ' חלקה וגודל צעד  $= \eta$  מתקיים שקצב הלימוד הוא  $\mathcal{O}(\frac{1}{\epsilon})$ . ככלומר, אם נסמן  $R^2 = \|\mathbf{x}_0 - \mathbf{x}^*\|^2$ , קיבל כי כדי לקבל פתרון  $\epsilon$  תת אופטמלי  $\frac{L}{2\epsilon} \cdot R^2 \leq T$  איטרציות.

**הערה 42.5** מה קורה אם אנו לא יודעים את קבוע החלוקות  $L$ ? מעשית יש הרבה דרכים לחזות אותו. קיימות כל מנין שיטות לא לדעת אותו בדיקות ועדיין להשתמש באלו:

Line search • נראית אותה בתרגול

Polyak step size • נראית בתרגילים בית

adaptive methods •

— אחת השיטות של ה **adagrad** היא adaptive methods ונראית אותה בתרגול

$$f(\mathbf{x}_T) - f(\mathbf{x}^*) \leq \frac{L}{2T} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|^2 \quad , T > 0$$

נזכור כי  $\eta = \frac{L}{2}$   
ראינו והוכיחנו בעבר כי :

$$\frac{1}{T} \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{1}{T} \cdot \left[ \frac{1}{2\eta} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|g_t\|_2^2 \right]$$

נכפיל את  $T$  בשני האגפים :

$$\diamondsuit : \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{1}{2\eta} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|g_t\|_2^2$$

בנוסח  $f$  חלקה ולכן לפי הлемה  $\frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2 \leq f(\mathbf{x}_t) - f(\mathbf{x}_{t+1})$  על כל המקרים של  $T$ :

$$\frac{1}{2L} \cdot \sum_{t=0}^{T-1} \|\nabla f(\mathbf{x}_t)\|^2 \stackrel{\text{sufficient decrease}}{\leq} \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}_{t+1}))$$

ראינו כי אך ימין הוא סכום טלסובי שמקיים ולכן מתקיים

$$\heartsuit : \frac{1}{2L} \cdot \sum_{t=0}^{T-1} \|\nabla f(\mathbf{x}_t)\|^2 \leq f(\mathbf{x}_0) - f(\mathbf{x}_T)$$

נזכור כי  $\nabla f(\mathbf{x}_t) \equiv g_t$  לפי היסימונים ולכן לפי  $\diamondsuit$  ושרשור האי שווין מעלה נקבל:

$$\begin{aligned} \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) &\stackrel{\diamondsuit}{\leq} \frac{1}{2\eta} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|g_t\|_2^2 \\ &\stackrel{\nabla f(\mathbf{x}_t) \equiv g_t}{=} \frac{1}{2\eta} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + \frac{\eta}{2} \cdot \sum_{t=0}^{T-1} \|\nabla f(\mathbf{x}_t)\|_2^2 \\ &= \frac{1}{2\eta} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + \eta \cdot L \cdot \frac{1}{2L} \cdot \sum_{t=0}^{T-1} \|\nabla f(\mathbf{x}_t)\|_2^2 \\ &\stackrel{\heartsuit}{\leq} \frac{1}{2\eta} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + \eta \cdot L \cdot [f(\mathbf{x}_0) - f(\mathbf{x}_T)] \\ &\stackrel{\eta=\frac{L}{2}}{=} \frac{L}{2} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + f(\mathbf{x}_0) - f(\mathbf{x}_T) \end{aligned}$$

בפרט  $f(\mathbf{x}_0) - f(\mathbf{x}_T) \leq \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{L}{2} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + f(\mathbf{x}_0) - f(\mathbf{x}_T)$  ונקבל

$$\sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{L}{2} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2 + f(\mathbf{x}_0) - f(\mathbf{x}_T)$$

$$\sum_{t=1}^T (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{L}{2} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2$$

מהלמה sufficient decrease ראיינו שהארט האחרון הכי טוב, ככלומר ראיינו כי מתקיים  $f(\mathbf{x}_T) \leq \sum_{t=1}^T (f(\mathbf{x}_t) - f(\mathbf{x}^*))$  ולכן מתקיים  $f(\mathbf{x})$

$$T[f(\mathbf{x}_T) - f(\mathbf{x}^*)] \leq \sum_{t=1}^T (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \frac{L}{2} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2$$

נמצאים ב  $T$  (נזכור ש  $T > 0$ ), ונקבל כי מתקיים

$$f(\mathbf{x}_t) - f(\mathbf{x}^*) \leq \frac{L}{2T} \cdot \|\mathbf{x}_0 - \mathbf{x}^*\|_2^2$$

זה מה שרצינו להוכיח ■

ההוכחה הנ"ל הייתה דומה להוכחה הראשונה תוך שימוש בחוקות ובלמת sufficient decrease.

### 5.1.3 תרגול 5

הוגדר בתחילת התרגול ההגדרות הבאות (שראיינו בהרצאה):

**הערה 43.5 פונ' גראדיינט ליפשייצי עם קבוע**  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  גזירה בריצפות. נאמר כי הפונ'  $f$  **בעלת גראדיינט ליפשייצי עם קבוע** אם  $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\|_2 \leq L \cdot \|\mathbf{x} - \mathbf{y}\|_2$

**הגדרה 44.5 הגדרה שנייה:** פונ'  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  גזירה בריצפות. תקרא **פונ'  $L$ -חלקה** (עבור פרמטר  $L \geq 0$ ) אם  $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^d : f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{L}{2} \cdot \|\mathbf{x} - \mathbf{y}\|^2$

**למה 45.5** אם פונ'  $f$  קמורה וגזירה בריצפות אז:  $f$  **בעלת גראדיינט ליפשייצי עם קבוע  $L$**   $\iff$  היא  $L$  חלקה

נתובן בביטחון האופטימיזציה הלא מאולצת הבארה  $\min_{\mathbf{x}} f(\mathbf{x})$ . כאשר  $f$  היא פונ' קמורה ו  $L$ -חלקה. אלג' **GD** (אלג' **גרדיינט**) הוא אלג' איטרטיבי בו כל העדוכן הוא מהצורה  $\mathbf{x}_t = \mathbf{x}_{t-1} - \eta_t \nabla f(\mathbf{x}_{t-1})$ . ראיינו בתרגילים בית 1 כי ( $d = -\nabla f(\mathbf{x})$  הוא כיוון ירידת  $f$  ב  $\mathbf{x}$  אם  $d \neq 0$ ). ולכן (מהגדרת כיון ירידת) עבור גודל צעד  $\eta_t > 0$  קטן מספיק, מתקיים  $f(\mathbf{x}_t) < f(\mathbf{x}_{t-1})$  כאשר  $\nabla f(\mathbf{x}_{t-1}) \neq 0$ .

### אלגוריתם 1 אלג' הגרדיינט (GD) - תרגול 5

**Data:** Initial guess,  $\mathbf{x}_0$ , tolerance parameter  $0 < \epsilon \ll 1$

for  $t = 1, 2, \dots$  do

```

 $\eta_t \leftarrow \text{ComputeStepSize}(\mathbf{x}_{t-1}, \nabla f(\mathbf{x}_{t-1}))$ 
 $\mathbf{x}_t \leftarrow \mathbf{x}_{t-1} - \eta_t \nabla f(\mathbf{x}_{t-1})$ 
if  $\|\nabla f(\mathbf{x}_t)\| < \epsilon$  then
    return  $\mathbf{x}_t$ 
end
end

```

end

**אלג' הגרדיינט:** בנק' המינימום הגרדיינט מטאפס. ולכן תנאי העצירה מבטיח כי אנו קרובים מספיק לנקודת המינימום, בה  $\nabla f(\mathbf{x}) = 0$ . קיימות גישות שונות לבחירת גודל הצעד:

1. **גודל צעד קבוע** בכל איטרציות  $\eta \equiv \eta_t : \forall t$  כלומר בכל האיטרציות נתקדם תמיד באותו גודל צעד.
2. **גודל צעד מדויק** בגישה זו נבצע מנימציה על כל גגלי הצעד במטרה למתוא את הגודל שיביא לירידה המקסימלית בערך פון' המטריה, כלומר לכל  $t$  נבצע את החישוב הבא:

$$\forall t : \eta_t = \arg \min_{\eta \geq 0} f(\mathbf{x}_{t-1} - \eta \nabla f(\mathbf{x}_{t-1}))$$

(א) גישה זו לרוב לא נפוצה מעשית ובעיקר בדיון של קבילת אנשי האופטימציה הטהורה (נשמע סוג של כת)

3. **גודל צעד דועך** גישה זו היא בחירת גודל צעד דועך-כלומר ככל ש  $t$  גדל גודל הצעד, קטן. לבחירת קבוע הלימוד  $\eta$  חשיבות מכרעת על ביצועי האלג' (בחירה לא טובה של  $\eta$  עלולה להוביל שהאלג' לא יתכנס או לחולפני שיתכנס לאחר הרבה מאוד זמן).

**משפט 46.5** אי שוויון קנטורובי' Kantorovich נסמן את  $M \in \mathbb{R}^{n \times n}$  הגדל ביותר של  $Q$  ו-  $m$  הע"ע הקטן ביותר של  $Q$ . אין מתקיים: עבור  $0 < \kappa \leq Q$  נסמן את  $M$  הע"ע הגדל ביותר של  $Q$  ו-  $m$  הע"ע הקטן ביותר של  $Q$ .

$$\frac{\mathbf{x}^T Q \mathbf{x} \cdot \mathbf{x}^T Q^{-1} \mathbf{x}}{(\mathbf{x}^T \mathbf{x})^2} \leq \frac{(M+m)^2}{4Mm}, \forall \mathbf{x} \neq 0$$

**הגדירה 47.5** תהא  $0 < \kappa \leq Q$  נסמן את  $M$  הע"ע הגדל ביותר של  $Q$  ו-  $m$  הע"ע הקטן ביותר של  $Q$ . **נדיר** את  $\kappa$  number של  $Q$  להיות  $\kappa \triangleq \frac{M}{m}$

**מסקנה 48.5** (מסקנה (למעשה, הכללה) של תרגיל 2 בתרגול 5) זה שעבור אלג' הגרדיאנט עם גודל צעד מדויק מתקיים עבור עיה ריבועית כי

$$f(\mathbf{x}_t) - f(\mathbf{x}) \leq \left( \frac{\kappa - 1}{\kappa + 1} \right)^{2t} (f(\mathbf{x}_0) - f(\mathbf{x}^*))$$

כלומר יש לנו קצב התכנסות **אקספוננציאלי**. ככל שמדוברים באיטרציות אנו מקטינים את המרחק פי הקבוע  $\frac{\kappa - 1}{\kappa + 1}$  שקטן מ-1. (בספרות לעיתים קרואים לזה התכנסות לינארית כי המינוח לינארית מקשר בין ערך הפונ' באינטרנט הנוכחי ובאיטרנט הקודם, והקשר בינהם הוא קבוע  $\frac{\kappa - 1}{\kappa + 1}$ . קבוע לינארי ולכן מכאן מינוח של "התכנסות לינארית" בפועל זו התכנסות אקספוננציאלית (בכל צעד מכפלים קטן מ-1 )


- אם  $1 = \kappa$  (ע"ע מינימלי ו-  $\kappa$  מקסימלי), אין אחריו צעד 1 נגיעה לערך האופטימי.
- אם  $1 \approx \kappa$  הה收敛ות תהיה מהירה.
- ככל שא' גודל , הקבוע  $\frac{\kappa - 1}{\kappa + 1}$  יותר ויותר קרוב ל-1, וכך התכנסות אומנם אקספונציאלית אבל הקבוע שיש לנו בסיס מאוד קרוב לנו. ולכן עבור  $0 \gg \kappa$  הה收敛ות תהיה איטית יותר.
- **הכללה של הטענה לפונ'  $f$**  קומות המקיים  $L$ -חלוקת ו-  $\mu$ -התכנסות חזק  $\kappa$  מתקיים  $\kappa \leq \frac{L}{\mu}$  גנדיר את  $\kappa$  condition number.

$$k \triangleq \frac{1}{\gamma} = \frac{L}{\mu}$$

- משתמשים המונם condition number זה דבר נפוץ.
- ככל ש  $\kappa$  conditonal number גדול יותר ככה התכנסות איטית יותר. בד"כ הקשר של זה למציאות הוא שלמעשה השכלל ש-  $\kappa$  conditonal number גדול יותר ככה הזרים השונים (המימדים השונים) לא נמצאים באותה הסקלאה (לדוגמא, מימד ראשון  $x_1$  מודד בקילומטרים ומימד שני  $x_2$  מודד בנטומטרים ) במקרה כזה הבעה תראה יותר "פחוסה" (ראה איך הימני יותר מותק סדרת האיורים שלמטה בדוגמא) ובמקרה זהה האלג' יתכנס לפחות יותר עבור גודל צעד אופטימי. (ולכן גם יתכנס לפחות יותר עבור כל גודל צעד אחר)

## Condition Number

Example:  $\mathbf{x} \in \mathbb{R}^2, f(\mathbf{x}) = \frac{1}{2}\mathbf{x}^T Q \mathbf{x}, Q$  is diagonal.



**השיטה אלג'ריתם Backtracking search:** בגישה זו מתחילה עם גודל צעד נתון ומקטינגים אותו עד אשר מובטחת ירידת "מספקת" שיטתה זו מוגדרת על ידי שני פרמטרים  $\alpha \in (0, 0.5)$  ו  $\beta \in (0, 1)$ . פרמטרים אלו נקבעים לפני הначלה האלג'ר, ואינם משתנים במהלך ריצתו.

בכל איטרציה מתחילה עם גודל צעד התחלתי כלשהו למשל  $\eta = 1$  וכל עוד מתקיים

$$f(\mathbf{x} - \eta \nabla f(\mathbf{x})) > f(\mathbf{x}) - \alpha \eta \|\nabla f(\mathbf{x})\|_2^2$$

נקטין את גודל הצעד פי  $\beta$ :  $\eta \leftarrow \beta \eta$ . הiytron בגישה זו הוא שהוא פשוטה ולעתים רבות מאפשרת לקבל ביצועים טובים בבעיות מעשיות.

backtraking line search

### אלגוריתם 2

**Data:** Current guess  $\mathbf{x}$ , Current gradient  $\nabla f(\mathbf{x})$ , parameters  $\alpha \in (0, 0.5)$ ,  $\beta \in (0, 1)$

**Result:** Step size  $\eta$

```

 $\eta \leftarrow 1$ 
 $\mathbf{y} \leftarrow \mathbf{x} - \eta \nabla f(\mathbf{x})$ 
while  $f(\mathbf{y}) - f(\mathbf{x}) > -\alpha \eta \|\nabla f(\mathbf{x})\|_2^2$  do
     $\eta \leftarrow \beta \eta$ 
     $\mathbf{y} \leftarrow \mathbf{x} - \eta \nabla f(\mathbf{x})$ 
end
return  $\eta$ 

```

## 6 הרצאה 6 ותרגול 6

### 6.1 הרצאה 6

#### 6.1.1 קצבי לימוד : הדוגמה על בעיה ריבועית

נצרה למשער את הפונ'  $f(\mathbf{x}) = \frac{10x_1^2 + x_2^2}{2}$  או בעיה ריבועית  $\mathbb{R}^2 \rightarrow \mathbb{R}$  דו מימדית בשימוש באlg' GD עם גודל צעד קבוע  $\eta_k = \eta$   $\forall k \in \{1, \dots, T\}$ . ניתן להבחן בклות (מיהתבוננות ב  $f(\mathbf{x})$ ) כי האופטימום שלה הוא בנקודה  $(0, 0)$  נבחן את פועלות האlg' GD עבור גודל צעד קבוע, עברור מספק גגלי צעד אפשררים. בנוספ' ניתן להראות כי  $f$  היא פונ' חלקה עם פרמטר חלקות  $L = 10$ .

**נעם במשפט שאומר** שאם  $f$  גירה פעמיים וקמורה, אז  $f$  חלקה אם  $\lambda_{\max}(\nabla^2 f(\mathbf{x})) \leq L$  (הע"ע הגדול ביותר של מטי ההאסיאן של  $f$ , קטן מ  $L$ ) אז **היא  $L$  חלקה.**  
אז

$$\begin{aligned}\nabla^2 f(\mathbf{x}) &= \begin{bmatrix} \frac{\partial}{\partial x_1} \frac{\partial}{\partial x_2} f(\mathbf{x}) & \frac{\partial}{\partial x_1} \frac{\partial}{\partial x_2} f(\mathbf{x}) \\ \frac{\partial}{\partial x_2} \frac{\partial}{\partial x_1} f(\mathbf{x}) & \frac{\partial}{\partial x_2} \frac{\partial}{\partial x_2} f(\mathbf{x}) \end{bmatrix} \\ &= \begin{bmatrix} 10 & 0 \\ 0 & 1 \end{bmatrix}\end{aligned}$$

חיבית מוגדר כי שני הע"ע שלה גדולים ממש ולכן  $f$  קמורה. במת' אלכסונית הע"ע שלה הם ערכי האלכסון. ולכן  $\lambda_{\max}(\nabla^2 f(\mathbf{x})) = 10 \leq L = 10$ .  
המסקנה היא ש  $f$  חלקה. ראיינו בשיעור קודם כוונח חלוקות עם פרמטר חלוקות  $L$ , אל' GD מתכנס רק עם  $\eta \leq \frac{1}{L}$  במקרה שלנו  $\eta \leq \frac{1}{10}$ .


היא  $f$  חלקה ולכן ככלומר האל' GD יתכנס עבור  $f(\mathbf{x}) = \frac{10x_1^2 + x_2^2}{2}$  רק עם גודל צעד  $\eta \leq \frac{1}{L} = \frac{1}{10}$ .

התבדרות

נבחן כי במקרה עבורו  $\eta = 1$  (כלומר, פי עשר מהקצב המקסימלי שmbטיח התכונות) נקבל **התבדרות** של האל':

### Fixed step size

Simply take  $\eta_k = \eta$  for all  $k = 1, 2, 3, \dots$ , can **diverge** if  $\eta$  is too big.  
Consider  $f(\mathbf{x}) = (10x_1^2 + x_2^2)/2$ , gradient descent after 8 steps:




\* f(x here is L-smooth with L=10

בתמונה אנו רואים 8 צעדים של האל'  
בתמונה רואים קצב לימוד שהוא פי 10 מהאופטמלי (האל' מתבתרד)  
התכונות:

נבחן כי במקרה עבורו  $\frac{1}{L} \ll \eta$  במקרה זה האלג' עדין מתכנס, אבל קצב ההתכנסות יהיה מאד איטי.

Can be slow if  $\eta$  is too small. Same example, gradient descent after 100 steps:




בתמונה上看 100 צעדים של האלג' רואים קצב לימוד שהוא קטן מהאופטמלי (האלג' מתכנס אבל מאוד לאט) במקרה זה  $\eta = \frac{1}{10L} = \frac{1}{100}$ .

התכנסות מתאימה של האלג':

נבחן כי במקרה עבורו  $\frac{1}{L} = \eta$  במקרה זה האלג' מתכנס באופן יפה:

Converges nicely when  $\eta$  is "just right". Same example, 40 steps:



נבחן כי בדוגמה הנ"ל י闪闪 40 איטרציות.

## 6.1.2 החסם של נדרוב

הראנו בשיעור קודם כי עבור פונ'  $L$  חלקות, כדי לקבל  $\epsilon$  שגייה אנו צריכים  $\frac{1}{\epsilon}$  איטרציות (במינוחי אפסילון) נשאלת השאלה האם ניתן להשיג **ביצועים טובים** יותר עבור פונ'  $L$  חלקות והතשובה היא **שכן. אבל, אכן אפשר** להשיג תוצאה שהיא **משמעותית טובה** יותר מאשר שכבר השנו.

זכיר כי **ההגדרה של שיטות מסזר ראשון**, הן שיטות של אלג' איטריטיביים המעדכנות את  $x$  בכל צעדי על ידי הגרדיאנטים שלו, ככלומר,

First order methods :

$$\forall t = 1, 2, \dots : x_t \in \{x_0 + \text{span}\{\nabla f(x_0), \nabla f(x_1), \nabla f(x_2), \dots, \nabla f(x_t), \dots\}\}$$

כלומר שיטות מסדר ראשון הן שיטות שבהם כל צעד בהם הוא קומבינציה לינארית של נקודת ההתחלה  $x_0$  והградיאנטים שהאלג' חישב עד כה. משפט נדרוב נותן חסם מלמטה על אלגוריתמים מהסוג זה (ובפרט עבור GD).

נדגים מדוע GD הוא ממשחתת האלג' הנ"ל ? מכיוון שאפשר לרשום את האxis'ים השונים שבאלג' באופן הבא(ק"ל של הגרדיאנטים שהאלג' פוגש עד רגע  $t$ ):

$$\forall t \in \{0, 1, \dots\} : x_t = \begin{cases} x_0 & t = 0 \\ x_0 - \left(\sum_{i=1}^t \eta_i \nabla f(x_i)\right) & \text{else} \end{cases}$$

**משפט 1.6 משפט נדסטרוב** לכל אלג' מסדר ראשון , (ובפרט לאלגוריתמים מהמשפחה של GD ) , ולכל  $t \leq \frac{n-1}{2}$  ולכל תנאי התחלה  $x_0$  , לכל בעיה עם פונ'  $f$  קמורה  $L$  חלקה. מתקיים:

$$f(x_t) - f^* \geq \frac{3L \cdot \|x_0 - x^*\|_2^2}{32(t+1)^2}$$

כלומר, כל שיטה של GD חסומה מלמטה על ידי  $\frac{3L \cdot \|x_0 - x^*\|_2^2}{32(t+1)^2}$  . זה הוא חסם מלמטה על התת אופטימליות של האlg' .

**הערה 2.6** המשמעות של  $t \leq \frac{n-1}{2}$  היא שהמייד של הבעיה  $n$  (כלומר  $\mathbb{R}^n \rightarrow \mathbb{R}$  :  $f$ ) כלומר שמספר הצעדים קטן מהמייד חלקים שתיים בערך. המריצה אמר שהוא חשב ש"הוכיחו את המשפט כבר ללא הנחה הזאת". ההנחה שהמייד מאד גדול ביחס לכמות הצעדים באlg' היא הנחה סבירה לרוב, בעיקר בעיות בתחום ה- bigdata.

**מסקנה 3.6** לא נצליח להגיע לקצב שהוא טוב יותר מ  $(\frac{1}{t^2})O$  (או בלשון אפסילון  $(\frac{1}{\sqrt{\epsilon}})O$ ) על ידי שימוש באלגוריתמים מסדר ראשון. כלומר, לאחר  $t$  איטציות, (כאשר האתול אין על נקודת המינימום) לא נצליח להגיע לשגיאה שקטנה יותר מ  $\frac{1}{t^2}$  כפול קבוע חיובי מסוים שתלו依 בנקודת התחלה.

**הערה 4.6** קיימת שיטה יותר מתוכמת GD שושברת את החסם הזה ואולי אנו נדבר עליה בהמשך.

**הערה 5.6** הקצב שמציע נסטורוב  $(\frac{1}{t^2})O$  (שיכולת להיות מובטאת על ידי החסם של  $\frac{3L \cdot \|x_0 - x^*\|_2^2}{32(t+1)^2}$ ) על שיטות מסדר ראשון הוא קצב טוב יותר מוקצב של GD שראינו עבור פונ' חלקות (שראינו שהקצב שלהם הוא  $(\frac{1}{t})O$ ). כלומר קיים פער מפתיע בין הקצב הטוב ביותר לבין שאולני נוכל להציג אליו בין הקצב שאנו כבר מגעים אליו בGD ולכון , לאחר שנסטרו השוויה את החסם התחthon ה- n , נסטרו ואיש חכם נוספים זכר את שמו הראו כי קיימת שיטה מסדר ראשון שאנו מצליחה להציג להחסם האופטימי הזה. (כלומר, שיטה מסדר ראשון יותר טובה מGD). לא נדבר בהרחבה על השיטה הזאת ששםה accelerated gradeint decent.

### 6.1.3 אנליזה של אלג' של GD עבור פונ' שאינו קמורות

נאמר שלצרכים מעשיים בתחוםים שונים משתמשים באlg' GD גם על פונ' שאינו קמורות ומקסלים תוצאות מוצלחות. קיימות מספרbettחות שיש כאשר משתמשים באlg' GD עבור פונ' לא קמורות. לעיתם למצוא נקודת אופטימלית היא מושמה קשה מדי , אנו יכולים להסתפק ב "  $\epsilon$  סטציונריות " קרי: שהנורמה של הגרדיאנט שלהם היא אפסילון קטנה ככלומר  $\epsilon \leq \|\nabla f(x_t)\|_2$ . הנה אחת מהם:

**משפט 6.6** אם פונ' המטרה היא  $L$  חלקה (כלומר , הגרדיאנטיים שלה הם לפישרים) ומפעלים את ה- GD עם קצב לימוד קבוע  $\eta = \frac{1}{L}$  גם אם  $f$  אינה קמורה אז

$$\min_{t=1,2,\dots,T} \|\nabla f(x_t)\|_2 \leq \sqrt{\frac{2L}{T} \cdot (f(x_1) - f^*)}$$

וקצב זה אינו יכול להשתפר.

**הערה 7.6** כלומר, אם תנאי המשפט מתקיימים : אז אחרי  $T$  צעדים , אז הנורמה של הגרדיאנט  $\|\nabla f(x_t)\|_2$  הולכת וקטנה. כלומר,  $L$ -חלקות שאין קמורות מזקירות נקודות  $\epsilon$  סטציונריות " כלומר: שהנורמה של הגרדיאנט שלהם  $\|\nabla f(x_t)\|_2$  היא אפסילון קטנה ככלומר  $\epsilon \leq \|\nabla f(x_t)\|_2 \leq \min_{t=1,2,\dots,T} \|\nabla f(x_t)\|_2$ . כלומר, לאחר  $T$  איטציות , אז הנורמה של הגרדיאנט הכי קטנה שחישבנו מותך כל הגרדיאנטיים שחישבנו בתהיליך , תהיה קטנה יותר מוחסם  $\sqrt{\frac{2L}{T} \cdot (f(x_1) - f^*)}$  כלומר, היא הולכת וקטנה כמו  $\frac{1}{\sqrt{T}}$ .

**הערה 8.6** נראה את החלק הזה של המשפט ה- n ל בתרגיל הבית.

**הערה 9.6** קצב הלימוד הקבוע  $\eta = \frac{1}{L}$  הוא זהה לזה שהוכחנו עבורו חלק מהפתרונות בפונ' קמורות.

- צעד עדכון של אלג' GD הוא מהצורה  $x_{t+1} = x_t - \eta \nabla f(x_t)$ .
  - אם  $(\cdot)$  היא פונ' קמורה וזרה  $\Leftarrow$  אלג' GD מתכנס.
  - אם  $(\cdot)$  היא פונ' B ליפשיצית וגם  $\|x - x^*\| \leq R$  ומסמנים  $\bar{x}_T = \frac{1}{T} \sum_{t=0}^{T-1} x_t$  אז הפעלת GD עם גודל הצעד הקבוע  $\eta$  מוגדרת כ  $f(\bar{x}_T) - f(x^*) \leq \frac{BR}{\sqrt{T}} = \frac{R}{B\sqrt{T}}$
  - אם  $(\cdot)$  היא  $L$ -חלקה וגם  $R = \frac{1}{L} \|x - x^*\| \leq R$  אז הפעלת GD עם גודל הצעד הקבוע  $\eta$  מוגדרת כ  $f(x_T) - f(x^*) \leq \frac{LR^2}{T}$
- מה יקרה כאשר  $(\cdot)$  לא גזרה? נгла בדעת. (אני בטוח שאתם במתח)

**6.1.5 אנדיזה של פונקציות קמורות שאין גזירות**

- במקרה הזה נגידר גודל שנקרא subgradient במקום גרדיאנט ושתמש בגודל זהה של subgradient עם אלג' הגרדיינט ונראה שאנו מקבלים את אותה התוצאה
- פונ' שאין דיפרנציביליות, לא חלוקות (אי אפשר לדבר על הגרדיינטים שלו)

**subgradient 6.1.6**

נגידר את הגודל subgradient באופן הבא:


**הגדרה 10.6** וקטור  $g \in \mathbb{R}^d$  נקרא סאב-גרדיינט (=תת גרדיאנט/subgradient) של  $f$  בנקודה  $x$  אם  $\forall y \in \text{dom}(f) : f(y) \geq f(x) + g^T(y - x)$

**הערה 11.6** ככלומר, הסאב-גרדיינט הוא שיפור של קו לינארי שעובר בנקודה  $\{x_i, f(x_i)\}$  וنمצא מתחת לפונ'. ככלומר, התת-גרדיינט הוא השיפור של הישר  $f(x_i) + g_i^T(x - x_i)$  ובנוסך הוא עובר מתחת לפונ'  $f$  בכל נקודה בתחום הגדotta.

**הערה 12.6** הגודל subgradient הוא גרדיאנט עבור פונ' חלוקות וקמורות. (אפשר להוכיח את זה כי אם הסאב-גרדיינט צריך לקיים את אי שוויון הגרדיינט ואת אי השוויון).

**סימונו 13.6** מסמנים  $\partial f(x) \subseteq \mathbb{R}^d$  את הסאב-דיפרנציאל subdifferential להיות קבוצת התת-גרדיינטים של  $f$  בנקודה  $x$ .


**דוגמה 14.6** אייר לדוגמה:




**הערה 15.6** בנקודה  $x$  הפונקציה  $f$  גיירה ולכן הסaab גרדיאנט  $g$ , מתלפי עם הגרדיינט. ככלומר הסaab-גרדיינט הוא בעצם הגרדיינט. כמובן, קבוצת הסaab דיפרנציאלי של  $f$  בנקודה  $x$  היא בז'וק האיבר היחיד שהוא הגרדיינט של  $f$  בנקודה  $x$ . זה נכון כי **שוויון הגרדיינט** First-order characterization של  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  גיירה וקמורה, מתקיים ש:

dom( $f$ ) היא תחום קמור ובנוסף  $\forall x, y \in \text{dom}(f) : f(y) \geq f(x) + \nabla f(x)^T(y - x)$ . ככלומר הגרדיינט ( $x$ ) מקיים את השוויון בכל  $y \in \text{dom}(f)$  ובפרט בנקודה  $x_1$  (לדוגמא) ולכן מקיימים את הדרת התת-גרדיינט ולכן אם  $f$  גיירה בנקודה  $x$  אז הגרדיינט של  $f$  בנקודה מהוות תת-גרדיינט של  $f$  בנקודה  $x$ .

**הערה 16.6** בנקודה  $x_2$ , שני השיירים הבאים  $g_2, g_3$  הם subgradientים: כי שניהם עוברים בנקודה  $x_2$ . נציג כי הפונקציה אינה חלקה בנקודה זו (הנגזרת מימין ומשמאלה שונות):



למעשה, קיימים אינסוף subgradientים בנקודה  $x_2$ ähoo. לדוגמא:



**מסקנה 17.6** עבור פונקצייתם קמורות. אם  $(\cdot)$   $f$  גיירות בנקודה  $x$ : הסaab גרדיאנט ב $x$  הוא פשוט הגרדיינט, עבור שאין גיירות באיש אוסף אינסופי סaab גרדיאנטיים שעוניים על ההגדירה.

**מסקנה 18.6** נבחן כי כל סaab גרדיאנט לפי ההגדירה מקיים את אי השוויון  $f(y) \geq f(x) + g^T(y - x)$   $\forall y \in \text{dom}(f)$ . שזה שוויון שמצויר מאוד את אי השוויון הגרדיינט, כפי שהגדינו בעבר עבור פונקצייתם קמורות.

**דוגמה 19.6** נתבונן בפונקציית  $f : \mathbb{R} \rightarrow \mathbb{R}$  הבאה:  $f(x) = |x|$ . עבורה בכל מקום הנגזרת קיימת פרט לנקודה  $0$ , בה הפונקצייתם גיירה. לפי המסקנה הקודמת,  $\forall x \in \mathbb{R} \setminus \{0\}$  הסaab-גרדיינט של  $f$  בכל נקודה כזו הוא פשוט הגרדיינט שלו. במקרה  $x = 0$  הסaab גרדיאנט יכול להיות כל ישר שעובר בראשית עם שיפוע קטן מ-1 או גדול מ-1. ככלומר


$$x = 0 : f(y) \geq f(0) + g(y - 0) = |0| + gy = gy \Rightarrow x = 0 : |y| \geq gy \Rightarrow x = 0 : \frac{|y|}{y} \geq g$$

$$\Rightarrow x = 0 : \text{sign}(y) \geq g$$

ולכן במקרה זהה הסאב דיפרנציאלי של  $f$  בנקודה 0 המסומן  $(0)$  מקיים  $\partial f(0) = [-1, 1]$ . כלומר  $\partial f(0) = \{g \mid g \in [0, 1]\}$ . כלומר הופטנציאלי של  $f$  בנקודה  $x$  מקיים:

$$\forall x \in \mathbb{R} : \partial f(x) = \begin{cases} \{-1\} & x < 0 \\ [-1, 1] & x = 0 \\ \{+1\} & x > 0 \end{cases}$$


איור לדוגמא שמחיש את הפונ' :



למה זה מעניין?


- באלג' ריבים ב machine learning ובתחומים נוספים, נהוג לעתים להוסיף לפונ' מטריה איבר שאינו גזר בכל מקום שהוא מהצורה  $\|x\|_1 = \sum_{i=1}^d |x_i|$  (=איבר גולרזיציה מסוג גולרזיציה  $l_1$ ) הינו רוצים עדין למצוא לפונ' המטריה מינימום אפילו שהיא מכילה איבר שאינו גזר בכל המרחב. כלומר הינו רוצים למצוא מינימום לפונ' מהצורה הבאה  $f(x) = f_0(x) + \lambda \|x\|_1$ .
- לעתים רבות אנו נתקלים בפונ' מהצורה הבאה  $f(x) = \sum_{i=1}^n \max \{\theta_i b_i - a_i^T x\}$  כלומר  $f$  היא אוסף של פונ' שאינן גזירות (max אינה גירה בכל מקום). אבל כל אחת מהפונ'  $\{\theta_i b_i - a_i^T x\}_{i=1}^n$  היא קמורה כקומברנצייה אפינית שלם. הינו רוצים למצוא להם מינימום. לבעה ז' קראים SVM ורוצים למצוא להם פתרון אופטמלי, אפילו ש  $f$  אינה גירה.

**הערה 20.6** המושג של סaab גרדיאנט שימושי בעיקר עבור פונ' שהם קמורות. עבור פונ' כללית אם  $f : \text{dom}(f) \rightarrow \mathbb{R}$  היא פונ' גירה בנקודת  $x \in \text{dom}(f)$  אז מתקיים כי  $\{\nabla f(x)\} \subseteq \{\nabla f(x) + \nabla f(x)^T(y-x)\}$ . וויתכנו שני מקרים או  $\partial f(x) = \nabla f(x) + \nabla f(x)^T(y-x)$  (תמיד המקרה אם הפונ' קמורה) או ש  $\partial f(x) = \emptyset$  (אם הפונ' לא קמורה זה עלול לקרות).



משפט אפיון לפונ' קמורות , דרך הגדרת הסaab גרדיאנטיים:

**משפט 21.6** תחא פונ'  $f : \text{dom}(f) \rightarrow \mathbb{R}$  איזי.  $\forall x \in \text{dom}(f) : \partial f(x) \neq \emptyset$  הוא תחום קמור וגם  $\text{dom}(f) \iff f$  פונ' קמורה



**הערה 22.6** ניתן לזכור את המשפט הזה על ידי האמרה "קמורות=סאב-גרדיינטים בכל מקום".

הקשר "קמורה ולפישיות = סאב גרדיאנטים חסומים"

**משפט 23.6** תהא פונ'  $f : \text{dom}(f) \rightarrow \mathbb{R}_{++}$  קמורה, התחום  $\text{dom}(f)$  פתוח ו- **אזי** התנאים הבאים שקולים: **(קיימים בינםים יחס אמי"מ)**

$$\forall x \in \text{dom}(f), \forall g \in \partial f(x) : \|g\|_2 \leq B .1$$

$$\forall x, y \in \text{dom}(f) : |f(x) - f(y)| \leq B \cdot \|x - y\|_2 .2$$

**הערה 24.6** ההגדרה של לפשיות בהקשר זהה היא עבור עבור הנורמות  $\|\cdot\|_2$  ו-  $\|\cdot\|$  ייחד, בהגדרה מוקפdea של לפשיות, זה מסתדר (ראה הגדרה של לפשיות בזוקפdea האנגלית)

**הערה 25.6** נשים לב שימוש הפונ' גזירות וגם עבור פונ' שאין גזירות (כי יש התייחסות ל" $x$ "  $\forall g \in \partial f(x)$ ) כלומר לכל התת-גרדיינטים בנקודה מסוימת)

**הערה 26.6** אנחנו נראה שלצורך אופטימיזציה בהפעלה של אל' GD על פונ' שאין גזירות, כל סאב גרדיאנט שנבחר יהיה טוב לצרכי האופטימיזציה. עבור כל בחירה שלנו

### תכונות של סאב-גרדיינטים


**משפט 27.6** יהיו  $f(\cdot)$  ו-  $h(\cdot)$  אשר עבורם  $\partial f(\cdot) \neq \emptyset, \partial h(\cdot) \neq \emptyset$ . אזי הסאב גרדיאנט של הפונ'  $(f+h)(\cdot)$  בנקודה  $x$  הוא :

$$\partial(f+h)(x) = \{g_1 + g_2 \mid g_1 \in \partial f(x), g_2 \in \partial h(x)\}$$

### דוגמאות של סאב-גרדיינטים של פונקציות לא גזירות

עבור הפונ'  $f(x) = \|x\|_1 = \sum_{i=1}^n |x_i|$  נוכל להראות כי דוגמא לסאב-גרדיינט של  $f$  לכל  $x$  הוא  $g = (\text{sign}(x_1) \quad \text{sign}(x_2) \quad \dots \quad \text{sign}(x_n))$  כאשר  $\text{sign}(\alpha) = \begin{cases} -1 & \alpha < 1 \\ 0 & \alpha = 0 \\ 1 & \alpha > 1 \end{cases}$ .

קל יותר להבין את הבטו' הזה עבור חד מימד. נניח כי  $f : \mathbb{R} \rightarrow \mathbb{R}$  נבחן כי  $g = 0$  (הקו הכהול האירור מטה) הוא סאב גרדיאנט עבור רכיב שמתאפס כי הוא מתחת לגרף בכל נקודה וועבר בנקודה  $(0,0)$ , קל לראות את זה במקרה הבהיר מימד ה-1:



נראה על התוכונה הזו של מה קורה כאשר  $x \in \partial f(x)$  כמו כאן, בлемה/משפט הבא:

#### תכונות של סאב-גרדיינטס

**лемה 29.6** תהא  $f : \mathbb{R} \rightarrow \mathbb{R}$  ותהא נקודת  $x \in \text{dom}(f)$  מתקיים כי  $0 \in \partial f(x)$  אם ורק אם  $x$  היא נקודת מינימום גלובלי.

הוכחה:

ההוכחה נובעת ישירות מההוכחה של סאב-גרדיינט. נתון כי  $0 \in \partial f(x)$  ולכן נוכל להציג את הנקודה  $0 = g$  בהגדרת המינימום הגלובלי

$$\forall y \in \text{dom}(f) : f(y) \geq f(x) + g^T(y - x)$$

ולקובל :

$$\forall y \in \text{dom}(f) : f(y) \geq f(x)$$

כלומר,  $x$  היא נקודת מינימום גלובלי, לפי הגדרה. ■

■

#### 6.1.7 אלגוריתם הסאב-גרדיינט subgradient descent

כעת הבעה היא ללא אילוצים המטריה שלנו היא למייער את הפונ'  $f$ , כלומר

$$\min_x f(x)$$

האלג' מחשב את הסאב גרדיאנטים ומתקדם במודדים, יתכן שייהיו מספר סאב-גרדיינטים ובכל צעד זה לא משנה איזה סאב-גרדיינטאים אנו בוחרים בשביל להתקדם.  
עקרון האלגוריתם הסאב-גרדיינט:

---

#### אלגוריתם 3 אלג' הסאב-גרדיינט

1. בחר  $x_0 \in \mathbb{R}^d$

2. לכל  $t = 0, 1, 2, \dots$  ועבור צעדי  $\eta \geq 0$

(א) חשב  $g_t \in \partial f(x_t)$  (אם יש כמה, מצא אחד מהם באופן שירורי)

$$(b) בצע צעד עדכון  $x_{t+1} = x_t - \eta g_t$$$

---

באופן עקרוני זו יכול להשתנות מאייטרציה אחת לאחרת, אבל בניתוח האלג' שנציג כאן ננתה את האלג' עברו זו שהוא קבוע לכל האיטרציות.

אלג' הסאב גרדיאנט עבור פון' קמורה לפשכית נוון קצב של  $\mathcal{O}(\frac{1}{\epsilon^2})$

הערה 30.6 המשפט הבא תקף לפון' שAIN בהכרח גירות כי הוא משתמש באלג' subgradient descent.

**משפט 31.6** תהא  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  פון' קמורה ו- $B$ -לפשכית, רציפה עם מינימום גלובלי  $x^*$ . בנוסף נניח כי  $R = \|x_0 - x^*\| \leq \eta = \frac{R}{B\sqrt{T}}$  גודל הצעד subgradient descent עם את התוצאה הבאה:

$$f(\bar{x}_T) - f(x^*) \leq \frac{1}{T} \sum_{t=0}^{T-1} [f(x_t) - f(x^*)] \leq \frac{RB}{\sqrt{T}}$$

הערה 32.6 נבחן כי

- משמעות אי השווין:  $\frac{1}{T} \sum_{t=0}^{T-1} [f(x_t) - f(x^*)] \leq \frac{RB}{\sqrt{T}}$
- מפון' קמורות (ומאי שווין ינסן) נובע כי  $f(\bar{x}_T) - f(x^*) \leq \frac{1}{T} \sum_{t=0}^{T-1} [f(x_t) - f(x^*)]$  כלומר קיימת נקודה  $\bar{x}_T = \frac{1}{T} \sum_{i=1}^T x_i$  (מוצע של כל הנקודות שראינו עד עכשו) שהשgiaה שלה קטנה או שווה לשgiaה המומוצעת שראינו עד עכשו.
- מרשור אי השווינות מתקבלים  $f(\bar{x}_T) - f(x^*) \leq \frac{RB}{\sqrt{T}}$  כלומר השgiaה של הנקודה  $x_i$  הולכת וקטנה כמו  $\frac{1}{\sqrt{T}}$ . כלומר ככל שנעשה יותר איטרציות השgiaה זו תהיה קטנה יותר.
- בשפת אפסילון (כמו סיבובים אנו נצרך לעשות כדי לקבל פתרון  $\epsilon$  אופטימי, כלומר ש  $\epsilon \leq f(\bar{x}_T) - f(x^*)$ ) איי

$$f(\bar{x}_T) - f(x^*) \leq \frac{RB}{\sqrt{T}} \leq \epsilon \Rightarrow \frac{RB}{\sqrt{T}} \leq \epsilon \Rightarrow \frac{RB}{\epsilon} \leq \sqrt{T} \Rightarrow \frac{(RB)^2}{\epsilon^2} \leq T \Rightarrow \mathcal{O}\left(\frac{1}{\epsilon^2}\right)$$

כלומר קצב הלימוד במקרה זה הוא  $\mathcal{O}\left(\frac{1}{\epsilon^2}\right)$  (או בהסתכלות אחרת)

**משפט 33.6 ההוכחה:**

ההוכחה זהה להלוטין להוכחה עבור המשפט gradient descent המקורי (והמסקנה זהה לחלווטין) עבור פון' קמורות אבל לא כלות, עד כדי השינויים הבאים:

- $f$  היא קמורה ולכן  $\text{dom}(f)$  תחום קמור ו  $\emptyset \neq \text{dom}(f) \subset \text{dom}(f)$  (כלומר, יש לה סאב גרדיאנטים בכל מקום (=בכל נקודה שמקיימת  $x \in \text{dom}(f)$ ))
- מבוקם  $\nabla f(x_t) = g_t$  נבחר  $g_t \in \partial f(x_t)$  (נחליף את הגרדיאנט בסאב גרדיאנט כתשחו)
- אי השווין ( $x - x^* \geq g_t^T(x_t - x^*)$  :  $\forall t$  כעת נובע ישירות מהגדלת הסאב גרדיאנט (במקום Mai שווין הגרדיאנט (משפט אפיון מסדר ראשון לפון' קמורות)))


### 6.1.8 אופטימיזציה עם אילוצים

נעשה רגע הפסקה מבעיות אופטימיזציה לא גירות.Cutת נראה כיצד פתרים בעיות אופטימיזציה גירות עם אילוצים. עד כה פתרנו בעיות אופטימיזציה לא מאולצות.

נשתמש בשיטות מסדר ראשון עם אלג' gradient descent עבור בעיות עם אילוצים. כלומר נראה לפטור את הבעיה הבאה:

$$\begin{aligned} & \min f(x) \\ & \text{s.t } x \in X, X \subseteq \mathbb{R}^d \end{aligned}$$

כאשר  $X$  היא קבוצה קומפקטיבית וסגורהץ  
אייר למחשה:




קיימות דרכי פתרון שונות לפתרון בעיות אופטימזציה עם אילוצים. בקורס נראה שני גישות:

1. להשתמש באלג' Projected Gradient Descent (את זה נראה היום)


2. להפוך את הביעה לבעה שינה מואולצת (ללא אילוצים, נראה בהמשך הקורס, קרואת סוף הקורס)

קיימים 2 מקרים עיקריים עבורם אנו רוצים לפתור בעיות אופטימזציה עם אילוצים:

1. המקרה בו המינימום הגלובלי (=הפתרון האופטימי הגלובלי) שייך לתוך האילוץ  $X \in \mathbb{R}^d$ . במקרה כזה הרצאה של אלג' GD הרגיל תניב לנו תוצאה שתיהה בתחום  $X$  לאחר מספיק איטרציות.




2. המקרה בו המינימום הגלובלי (=הפתרון האופטימי הגלובלי) לא שייך לתוך האילוץ  $X^* \notin X$ .



כאן הנקודה האדומה (האופטימיום הגלובלי) מחוץ לתוך האילוץ והרצאת GD הרגיל יניב לנו אותה, אבל אנו לא רוצים אותה כי היא לא מקיימת את האילוצים ולכן נרצה למצוא אלג' שייניב לנו את הנקודה היחולה: נקודת מינימום של הפונ' מתוך כל הנקודות שנמצאות בתחום האילוץ. ככלمر נרצה נקודה בתחום האילוץ שמניבת ערך מינימלי על  $f$ .

### 6.1.9 אלג' projected gradient descent

**רעיון:** בכל צעד נטיל את תוצאה צעד של האלג' (צעד בכיוון מורד הרגדיאנט) על התחום  $X$ . כמוואר באירור הבא:



**סימון 34.6** יהא תחום  $X \subseteq \mathbb{R}^d$  ונקודה  $y \in \mathbb{R}^d$ , את מסמנים את הטלה של נקודה  $y$  על התחום  $X$  באופן הבא  $\Pi_X(y) \triangleq \arg \min_{x \in X} \|x - y\|$

**הערה 35.6** לדוגמא, אם  $y \in X$  אז  $y = y$  על התמונה של  $y$  על התמונה  $X$  היא נקודת אחרת (הנקודה הקורובה ביותר אל  $y$  שנמצאת בתחום  $X$ ). נראה דוגמאות להטלות בהמשך.

המשך רعيון האלג': ככלומר, במקורה של האלג' צעד העדכו יהיה עקורי האלגוריתם projected gradient descent:

## אלגוריתם 4 אלג' הסאברדרידיאנט

$x_0 \in \mathbb{R}^d$  בחר .1

2. לכל  $t = 0, 1, 2, \dots$  ועבור צעד  $\eta \geq 0$

- (א) חשב את הגרדיאנט בנקודת  $x_t$

$$g_t = \nabla f(x_t)$$

(ב) בצע צעד עדכון  $x_{t+1} = \Pi_X(x_t - \eta g_t)$

**הערה 36.6** לאחר החזרונות של שיטת projected gradient descent היא שטה לא תמיד מוחשבת כמשימה פשוטה, לעיתים מציאות הטלה היא שלעצמה בעיית אופטימיזציה שצורך לפתור, אבל בהרבה מקרים עבור תחומים מסוימים הטענה היא יחסית פשוטה. נציג מספר דוגמאות (ללא הוכחות) להטלות אלו. חשוב מאד להכיר את הדוגמאות להטלת **(ככה המרצה אמר, בגראה שיש לו סיבה טובה לומר דבר שכזה)**.

**הערה 37.6** בהרבה מהמקרים נניח כי חישוב הettela הוא משימה פשוטה יחסית שנitin לחשב בעילות (זה נכון עבור תחומים פשוטים כמו קביה כדור או סימפלקס כמו שנראה בהמשך). פחותת נטמקד בתחומים אקזוטיים יותר שהettela שלהם מוכבת.

6.1.10 דוגמאות להטלה

**דוגמה 38.6** קטע ישר במילוי אחד נניח שהבעה שלנו היא חד מימדיות (על הישר  $\mathbb{R}$ ) והתחום שלנו הוא  $X = [-1, 1]$ .



-1 1

תהי נקודה  $\mathbb{R} \in y$  כלשהיא ונרצה לחשב את הנטלה שלה.

ו-  $y \in X$  •



$$-1 \qquad \qquad y \qquad 1$$

$$\Pi_X(y) = y$$

אם  $y > 1$  •



$$-1 \qquad \qquad \qquad 1 \qquad \qquad y$$

$$\Pi_X(y) = 1$$

או  $y < -1$  •



$$y \quad -1 \quad 1$$

$$\text{כלומר } \Pi_X(y) = -1$$

ולכן ההטלה של  $y$  היא:

$$\Pi_X(y) = \begin{cases} -1 & y < -1 \\ 0 & y \in [-1, 1] \\ 1 & y > 1 \end{cases} = X$$

במקרה הזה ההטלה קלה יחסית ואיינטואטיבית.

**דוגמה 39.6 קובייה  $d$  מימדית** נניח שהביצה שלנו היא רב מימדי (במרחב  $\mathbb{R}^d$  מימדי) והתחום שלנו הוא  $X = [-1, 1]^d$  (קובייתה במרחב  $d$  מימדי/cדור היחידה בגורמת  $\infty$ , שניתן לסמן כך  $\mathcal{B}_\infty = \{\mathbf{y} \in \mathbb{R}^n \mid \|\mathbf{y}\|_\infty \leq 1\} = \{\mathbf{y} \in \mathbb{R}^n \mid \max_{i=1,2,3,\dots,n} |y_i| \leq 1\}$ ) ווגדר באופן הבא (כמו לעיל) תהא  $\Pi_X(\mathbf{y})_i \in \mathbb{R}^d$  אזי הרכיב  $i$  של ההטלה יסומן  $(\Pi_X(\mathbf{y}))_i = (y_1, y_2, \dots, y_d)$

$$(\Pi_X(\mathbf{y}))_i = \begin{cases} -1 & y_i < -1 \\ 0 & y_i \in [-1, 1] \\ 1 & y_i > 1 \end{cases}$$


כלומר ההטלה תראה

$$\Pi_X(\mathbf{y}) = (\Pi_X(\mathbf{y}))_1 \quad (\Pi_X(\mathbf{y}))_2 \quad \dots \quad (\Pi_X(\mathbf{y}))_d$$

וכל איבר בה הוגדר מעלה.


**דוגמה 40.6 כדור אוקלידי** נניח שהביצה שלנו היא רב מימדי (במרחב  $d$  מימדי) והתחום שלנו הוא  $X = \{\mathbf{x} \in \mathbb{R}^d \mid \|\mathbf{x}\|_2 \leq 1\}$  (הכדור האוקלידי) תהא  $\Pi_X(\mathbf{y})_i \in \mathbb{R}^d$  אזי הרכיב  $i$  של ההטלה יסומן  $(\Pi_X(\mathbf{y}))_i = (y_1, y_2, \dots, y_d)$  ווגדר באופן הבא (כמו לעיל).

$$\bullet \text{ אם } y \in X \text{ (כלומר } \|y\|_2 \leq 1 \text{ אזי}$$



ומתקיים כי  $\Pi_X(\mathbf{y}) = \mathbf{y}$ .

כאשר  $\mathbf{y} \notin X$  ( $\text{כלומר } \|y\|_2 > 1$ ) אזי נתבונן על הישר ממרכזו הכדור ל  $y$ , איינטואטיבית הנקודה שהכי קרובה לכדור אל  $y$  היא הישר ממרכזו כדור ל  $y$  חלקי הנורמה של אותו הישר. (נמצאת בדיק על שפת הכדור).




כלומר

$$\Pi_X(\mathbf{y}) = \begin{cases} \mathbf{y} & \mathbf{y} \in X \text{ (in that case } \|\mathbf{y}\|_2 \leq 1) \\ \frac{\mathbf{y}}{\|\mathbf{y}\|_2} & \mathbf{y} \notin X \text{ (in that case } \|\mathbf{y}\|_2 > 1) \end{cases}$$

**הערה 41.6** לסימפלקס קיימות כמה הגדרות, נבחר כעת באחת מהם (שונה אולי מההגדרה שראינו בהרצאה 2). ראיינו בהרצאה 2 הגדרה פופולרית לסימפלקס  $X = \left\{ x \in \mathbb{R}^d \mid \forall i : x_i \geq 0 \text{ and } \sum_{i=1}^d x_i = 1 \right\}$  אבל אנו משתמש בהגדרה דומה וקצת אחרת לסימפלקס  $X = \left\{ x \in \mathbb{R}^d \mid \forall i : x_i \geq 0 \text{ and } \sum_{i=1}^d x_i \leq 1 \right\}$

**הערה 42.6** הסימפלקס זה אילוץ שמתמשים בו בתחוםים רבים : בתורת האינפורמציה / תורת הקידוד ובעמ' machine learning. נראה את שני הטלות על שני סוגים הסימפלקס)

**דוגמה 43.6 הסימפלקס Simplex** נניח שהביצה שלנו היא רב מימדי (במישור  $d$  מימדי  $\mathbb{R}^d$ ) והתחום שלנו הוא  $X = \left\{ x \in \mathbb{R}^d \mid \forall i : x_i \geq 0 \text{ and } \sum_{i=1}^d x_i \leq 1 \right\}$ .



$$\text{תחא } \mathbf{y} = (y_1, y_2, \dots, y_d) \in \mathbb{R}^d$$

- אם  $\mathbf{y} \in X$  אז  $\mathbf{y} \in \Pi_X(\mathbf{y})$  כי שראינו.
- אם  $\mathbf{y} \notin X$  :

נניח ש  $y_d \geq \dots \geq y_2 \geq y_1$  (אם זה לא המצב נוכל "למיין" את הווקטור לצורכי נוחות על מנת שזה יתקיים) כלומר הרכיבים של  $\mathbf{y}$  ממוינים מהגדול לקטן (או מציגים זאת לצורכי נוחות הצגת הטלחה) עבור הטלחה של הווקטור הלא ממויין נוכל למיין את  $\mathbf{y}$  להטיל ולהחזיר את כל איבר בטלחה למקוםו המקורי לפני המיוון. אזי


אזי כל ריכיב בטלחה של  $\mathbf{y}$  על הסימפלקס היא :

$$(\Pi_X(\mathbf{y}))_i = \max \{0, y_i - \lambda\}$$

כך ש  $\sum_{i=1}^d (\Pi_X(\mathbf{y}))_i \leq 1$  (זה האילוץ דרכו בוחרים את  $\lambda$  וזה בעצם האילוץ שקובע כי  $\mathbf{y} \in X$ ). אזי כלומר הטלחה תראה

$$\Pi_X(\mathbf{y}) = ( (\Pi_X(\mathbf{y}))_1 \quad (\Pi_X(\mathbf{y}))_2 \quad \dots \quad (\Pi_X(\mathbf{y}))_d ) = ( y_1 - \lambda \quad y_2 - \lambda \quad \dots \quad y_k - \lambda \quad 0 \quad \dots \quad 0 )$$

**הערה 44.6** עברו הגדרת הסימפלקס מצורה ייראה באופן הבא:



אזי הטלחה תראה כך אם  $\mathbf{y} \in X$  אז  $\mathbf{y} \in \Pi_X(\mathbf{y})$  כי שראינו אם  $\mathbf{y} \notin X$  (אותו רעיון של המיוון מנקודת מבוקד) אזי ל ריכיב בטלחה של  $\mathbf{y}$  על הסימפלקס היא  $(\Pi_X(\mathbf{y}))_i = \max \{0, y_i - \lambda\}$ : כל ש  $\sum_{i=1}^d (\Pi_X(\mathbf{y}))_i = 1$  וזה האילוץ דרכו בוחרים את  $\lambda$  וזה בעצם האילוץ שקובע כי  $\mathbf{y} \in X$ . אזי כלומר הטלחה תראה


$$\Pi_X(\mathbf{y}) = ( (\Pi_X(\mathbf{y}))_1 \quad (\Pi_X(\mathbf{y}))_2 \quad \dots \quad (\Pi_X(\mathbf{y}))_d ) = ( y_1 - \lambda \quad y_2 - \lambda \quad \dots \quad y_k - \lambda \quad 0 \quad \dots \quad 0 )$$

## תבונות של הטלה

**משפט 45.6** קיימות להטלה על תחום תכונות רבות. התכונה הכى חשובה לנו לצרכי אופטימיזציה דרך אלג' GD היא התכונה הבאה:

יהא  $X \subseteq \mathbb{R}^d$  תחום סגור חסום וקמור (=קומפקטי) ויהיו  $z \in X$  ו-  $\mathbf{y} \in \mathbb{R}^d$ . אז

$$\|\Pi_X(\mathbf{y}) - z\|_2 \leq \|\mathbf{y} - z\|_2$$



כלומר, לכל נקודה במרחב  $\mathbb{R}^d$  מתקיים שהמרחק בין כל נקודה בתחום  $X$  לנטלה  $\Pi_X(\mathbf{y})$  הוא קטן או שווה מהמרחק של הנקודה  $X \in z$  לנקודה  $y$  המקורי. במלים אחרות **הטלה מקצרת את המרחקים** בין כל  $y$  לבין כל נקודה בתחום  $X$ . (כלומר שימוש בטלה לא יגדיל את המרחק)

**הערה 46.6** המשפט מדבר רק על הנורמה האוקלידית (כומר רק לנורמת  $l_2$  שמשמעות  $\|\cdot\|_2$ )

הוכחה:

- **תזכורת:** נניח שרוצים למזער את  $f(\cdot)$  שמוגדרת בתחום קמור  $\text{dom}(f)$  קמור תחת אילוצים  $X$ .

וראינו כי:  $\forall x \in X : \nabla f(x^*)^T (x - x^*) \geq 0 \iff x^* = \arg \min_{x \in X \subseteq \text{dom}(f)} f(x)$

- הטלה היא פתרון אופטמלי של בעיית אופטימיזציה קמורה. וכך נוכל להשתמש בתזכורת (נסמן  $\|z - y\| = f(z)$  הפונ' הזו היא בתחום קמור בז כפונ' קמורה  $z$  فهو קבוע מרכיבת על נורמה) שהיא פונ' קמורה) ונקבל כי:

$$\begin{aligned} & \forall z \in X, \forall y \in \mathbb{R}^d : \Pi_X(\mathbf{y}) \triangleq \arg \min_{z \in X} \|z - y\| \\ & \iff \forall z \in X, \forall y \in \mathbb{R}^d : \nabla f(\Pi_X(\mathbf{y}))^T (z - \Pi_X(\mathbf{y})) \geq 0 \\ & \iff \dots \end{aligned}$$

$$\begin{aligned}
\nabla f(\Pi_X(\mathbf{y}))^T &= \nabla f(\mathbf{z})^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{\partial}{\partial \mathbf{z}} \|\mathbf{z} - \mathbf{y}\|_2 \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{\partial \|\mathbf{z} - \mathbf{y}\|_2}{\partial (\mathbf{z} - \mathbf{y})} \cdot \frac{\partial (\mathbf{z} - \mathbf{y})}{\partial \mathbf{z}} \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{\partial \sqrt{(\mathbf{z} - \mathbf{y})^T (\mathbf{z} - \mathbf{y})}}{\partial (\mathbf{z} - \mathbf{y})} \cdot 1 \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{\partial \sqrt{(\mathbf{z} - \mathbf{y})^T (\mathbf{z} - \mathbf{y})}}{\partial (\mathbf{z} - \mathbf{y})} \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{\partial \sqrt{(\mathbf{z} - \mathbf{y})^T (\mathbf{z} - \mathbf{y})}}{\partial (\mathbf{z} - \mathbf{y})^T (\mathbf{z} - \mathbf{y})} \cdot \frac{\partial (\mathbf{z} - \mathbf{y})^T (\mathbf{z} - \mathbf{y})}{\partial (\mathbf{z} - \mathbf{y})} \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{1}{2\sqrt{(\mathbf{z} - \mathbf{y})^T (\mathbf{z} - \mathbf{y})}} \cdot \frac{\partial (\mathbf{z} - \mathbf{y})^T I(\mathbf{z} - \mathbf{y})}{\partial (\mathbf{z} - \mathbf{y})} \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&\stackrel{\frac{\partial \underline{\mathbf{a}}^T \underline{\mathbf{A}} \underline{\mathbf{a}}}{\partial \underline{\mathbf{a}}} = (\underline{\mathbf{A}}^T + \underline{\mathbf{A}}) \underline{\mathbf{a}}}{=} \left( \frac{1}{2\sqrt{(\mathbf{z} - \mathbf{y})^T (\mathbf{z} - \mathbf{y})}} \cdot (I^T + I)(\mathbf{z} - \mathbf{y}) \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{1}{2\|(\mathbf{z} - \mathbf{y})\|_2} \cdot 2(\mathbf{z} - \mathbf{y}) \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{\mathbf{z} - \mathbf{y}}{\|(\mathbf{z} - \mathbf{y})\|_2} \right)^T \Big|_{\mathbf{z}=\Pi_X(\mathbf{y})} \\
&= \left( \frac{\Pi_X(\mathbf{y}) - \mathbf{y}}{\|(\Pi_X(\mathbf{y}) - \mathbf{y})\|_2} \right)^T \\
&= \frac{(\Pi_X(\mathbf{y}) - \mathbf{y})^T}{\|(\Pi_X(\mathbf{y}) - \mathbf{y})\|_2}
\end{aligned}$$

נជיב ונקבל

$$\begin{aligned}
&\forall \mathbf{z} \in X, \forall \mathbf{y} \in \mathbb{R}^d : \Pi_X(\mathbf{y}) \triangleq \arg \min_{\mathbf{z} \in X} \|\mathbf{z} - \mathbf{y}\| \\
&\iff \forall \mathbf{z} \in X, \forall \mathbf{y} \in \mathbb{R}^d : \nabla f(\Pi_X(\mathbf{y}))^T (\mathbf{z} - \Pi_X(\mathbf{y})) \geq 0 \\
&\iff \forall \mathbf{z} \in X, \forall \mathbf{y} \in \mathbb{R}^d : \frac{(\Pi_X(\mathbf{y}) - \mathbf{y})^T}{\|(\Pi_X(\mathbf{y}) - \mathbf{y})\|_2} (\mathbf{z} - \Pi_X(\mathbf{y})) \geq 0 \\
&\stackrel{\|\cdot\|_2 \geq 0}{\iff} \forall \mathbf{z} \in X, \forall \mathbf{y} \in \mathbb{R}^d : (\Pi_X(\mathbf{y}) - \mathbf{y})^T (\mathbf{z} - \Pi_X(\mathbf{y})) \geq 0
\end{aligned}$$

כלומר הראנו כי

$$\forall \mathbf{z} \in X, \forall \mathbf{y} \in \mathbb{R}^d : (\Pi_X(\mathbf{y}) - \mathbf{y})^T (\mathbf{z} - \Pi_X(\mathbf{y})) \geq 0$$

$$\forall z \in X, \forall y \in \mathbb{R}^d : (z - \Pi_X(y))^T (\Pi_X(y) - y) \geq 0$$

ולכן גם

$$\diamondsuit : \forall z \in X, \forall y \in \mathbb{R}^d : 2(z - \Pi_X(y))^T (\Pi_X(y) - y) \geq 0$$

כעת,

$$\begin{aligned} \|z - y\|_2^2 &= \left\| \overbrace{z - \Pi_X(y) + \Pi_X(y)}^{=0} - y \right\|_2^2 \\ &= \|(z - \Pi_X(y)) + (\Pi_X(y) - y)\|_2^2 \\ &\stackrel{\diamondsuit}{\geq} 0 \quad \|\cdot\| \geq 0 \\ &= \|z - \Pi_X(y)\|_2^2 + \overbrace{2(z - \Pi_X(y))^T (\Pi_X(y) - y)}^{\geq 0} + \overbrace{\|\Pi_X(y) - y\|_2^2}^{\geq 0} \\ &\geq \|z - \Pi_X(y)\|_2^2 \end{aligned}$$

ולכן מתקיים

$$\|z - y\|_2^2 \geq \|z - \Pi_X(y)\|_2^2$$

זה מה שרצינו להוכיח.

■

## 6.2 תרגול 6

**הערה 47.6** ההגדרות בתרגול הוצגו גם בהצראה, אני מנסה אוטם שוב בלשון התרגול לצורך שלמות המסמך

### 6.2.1 תת-גרדיינטים

**הגדרה 48.6** תהא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  פונ' כלשהיא. ווקטור  $\mathbf{g} \in \mathbb{R}^n$  נקרא **תת-גרדיינט** של  $f$  בנקודה  $x$  אם מתקיים:

$$\forall y \in \mathbb{R}^n : f(y) \geq f(x) + \mathbf{g}^T (y - x)$$

**הערה 49.6** עבור  $f$  קמורה ונזרה ברצייפות בנקודה  $x$  אי השוויון הנ"ל מתקיים אך ורק עבור  $\mathbf{g} = \nabla f(x)$

**הגדרה 50.6 התת-דיפרנציאלי** sub-differential של  $f$  בנקודה  $x$  הוא קבוצת כל התת-גרדיינטים באוטה הנקודה

$$\partial f(x) = \{ \mathbf{g} \in \mathbb{R}^n \mid \forall y \in \mathbb{R}^n : f(y) \geq f(x) + \mathbf{g}^T (y - x) \}$$

### משפט 51.6 תכונות של תת-דיפרנציאלי:

$$\forall a \in \mathbb{R}, a > 0 : \partial(af(x)) = a\partial(f(x)) .1$$

$$\partial(f_1(x) + f_2(x)) = \{g_1 + g_2 \mid g_1 \in \partial f(x), g_2 \in \partial h(x)\} .2$$

## 6.2.2 הטלה על קבוצה קמורה

הגדירה 52.6 תהא  $C \subseteq \mathbb{R}^n$  קבוצה קמורה וקומפקטיבית (=סגורה וחסומה) נגדיר את **הטלה projection** של הנקודה  $x \in \mathbb{R}^n$  על הקבוצה  $C$  פתרו פתרון בעיית האופטימוציה הבאה

$$(P) : \begin{array}{ll} \min_{\mathbf{y}} & \|\mathbf{y} - \mathbf{x}\|_2 \\ \text{s.t.:} & \mathbf{y} \in C \end{array}$$

כמעט תמיד נתענין בנוינה האוקלידית (נורמת  $\ell_2$ ) כלומר  $\|\cdot\|_2$  נסמן את הטלה של  $x$  על  $C$  על ידי  $P_C(x)$ . נשים לב כי בעיית האופטימוציה  $(P)$  היא בעית אופטימוציה קמורה מכיוון ש פונ' המורה קמורה וכך גם התחים  $C$ .

**משפט 53.6** קיים פתרון ייחד לבעיה  $(P)$  כלומר **היטל הינו יחיד**.

**משפט 54.6** תחת הנורמה האוקלידית  $(P_C(x))$  מתקיים  $\mathbf{z} \in C \iff \mathbf{y}^* = P_C(\mathbf{x})$  לכל  $\mathbf{y}^* = P_C(\mathbf{x})$

**הערה 55.6** המשמעות הגאומטרית היא שקיים הזווית בין הווקטור  $\mathbf{z} - \mathbf{y}^*$ ,  $\mathbf{y}^* - \mathbf{x}$  גדול או שווה ל $90^\circ$ . משמעות גאומטרית נוספת היא שככל מקהה כזה של הטלה, קיים **מישור שימוש** בתחום הקמור  $C$  בנקודה  $P_C(x)$ .

## 6.2.3 אלגוריתם הגרדיינט המוטל

נתובן בעית אופטימוציה המאולצת הבאה

$$(Q) : \begin{array}{ll} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{s.t.:} & \mathbf{x} \in C \end{array}$$

כאשר  $f$  פונ' קמורה ו  $C$  קבוצה קמורה וקompקטית. אלג' הגרדיינט המוטל מבצע עדכון באופן הבא:

$$\mathbf{x}_{t+1} = P_c(\mathbf{x}_t - \eta_t \mathbf{g}_t)$$

כאשר  $\mathbf{g}_t$  הוא תח גראדיינט כלשהו ב  $\mathbf{x}_t$  דהיינו  $\mathbf{g}_t \in \partial f(\mathbf{x}_t)$  כלומר רישת מתבצע עדכון ת-גרדיינט ולאחר מכן מתבצעת הטלה חוזרת על הקבוצה  $C$ .

**הגדרה 56.6** הפונ'  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  נקראת **רציפה ליפשיץ Lipschitz continuous** אם קבוע  $G$  לכל  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$  מתקיים

$$|f(\mathbf{x}) - f(\mathbf{y})| \leq G \cdot \|\mathbf{x} - \mathbf{y}\|_2$$

**лемה 57.6** עבור פונקציה קמורה  $f$  התכונות הבאות שקולות

1.  $f$  רציפה לישפץ עם קבוע  $G$ .

2. לכל  $\mathbf{x} \in \mathbb{R}^n$  כל התח גראדיינטים של  $f$  חסומים בנורמה על ידי  $\|\mathbf{g}\|_2 \leq G, \forall \mathbf{g} \in \partial f(\mathbf{x})$ .

**הגדרה 58.6** תהא  $C \subset \mathbb{R}^n$  קבוצה קומפקטיבית (=סגורה וחסומה). הקוטר  $\text{diam } C$  של  $C$  המסומן על ידי  $\text{diam } C$  מוגדר על ידי

$$\text{diam } C \triangleq \sup_{\mathbf{x}, \mathbf{y} \in C} \|\mathbf{x} - \mathbf{y}\|_2$$

## 7 הרצתה 7 ותרגול 7

### 7.1 הרצתה 7

בשיעור שעבר למדנו על הנושא של אופטימוציה עם אילוצים ועל אלג' הגרדיינט המוטל

### 7.1.1 אלג' הגרדיינט המוטל projected gradient descent המשך

כמעט כל תוכזהה שהוכחנו עבור אלג' הגרדיינט הרגיל תקפה גם על אלג' הגרדיינט המוטל:

1. התכנסות של פונ' קמורה ולפנצית (לאו דווקא חלקה) מעל תחום  $X$  לוקחת ( $\frac{1}{\epsilon^2}$ )  $\mathcal{O}$  צעדים.

2. התכנסות של פונ' קמורה וחלקה(הגרדיינטים לפצחים עבור  $L$  קבוע כלשהו) מעל תחום  $X$  לוקחת ( $\frac{1}{\epsilon}$ )  $\mathcal{O}$  צעדים.

3. התכנסות של פונ' קמורה חזק strongly convex וחלקות מעל תחום  $X$  לוקחת ( $\log(\frac{1}{\epsilon})$ )  $\mathcal{O}$  צעדים.(נדבר על המקרה הזה בהרצאה זו עבור אלג' הגרדיינט הרגיל וגם על אלג' הגרדיינט המוטל).

(א) ( $\log(\frac{1}{\epsilon})$ )  $\mathcal{O}$  צעדים נחשב כקב מחריר מאוד.

**אבל** לאלג' הגרדיינט המוטל **יש עולות נוספת**:

- בכל צעד נאלץ לבצע הטלה לתחום  $X$  (זה לא תמיד שימושה פשוטה! הטלה עלולה להיות מסובכת חישובית ואלג' הגרדיינט המוטל לא מותאים לשימוש במרקרים אלו, אבל יש להזיו פתרונות אחרים שנראתה בשבע הבא ובסוף הקורס).

- יכול להיות לא יעיל (קיים המקרים שהאלג' אכן יעיל ראיינו בשיעור שעבור מקרים שהטלת היא פשוטה)

כלומר אם התחום  $X$  מספיק פשוט האלג' הנ' למאוד אטרקטיבי וברוב המקרים האילוצים פשוטים מספיק והאלג' הגרדיינט המוטל מאוד שימושי.

**התכנסות עבור פונ' קמורה ולפנצית מעל  $X$  בסדר גודל של ( $\frac{1}{\epsilon^2}$ )  $\mathcal{O}$  צעדים הנחות:**

1. התחום  $X$  הוא תחום קמור וסגור (=הילוצים בעיה הם קמורים וסגורים). (אחרת הבעיה אינה בעית אופטימציה קמורה)

2. כל הגרדיינטים של  $f$  חסומים על ידי קבוע  $B$  מעל  $X$ . כלומר  $\forall x \in X : \|\nabla f(x)\| \leq B$ .

**הערות:**

(א) ראיינו שההנחה הנ' הוא תנאי שקול לאמירה ש $f$  היא לפנצית מעל  $X$ .

(ב) קיימים פונ' מעניינות קבועות שהם לפנציות מעל אילוצים מסוימים (כלומר קיימות פונ'  $f$  רבות עבורם קיים תחום  $X$  שהפונ'  $f$  היא לפנצית בהם)

**משפט 1.7 אלג' הגרדיינט המוטל עבור המקרה שבו הפונ' קמורה ולפנצית מעל  $X$**   
 תהא  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  פונ' קמורה גירה. יהא  $X \subseteq \mathbb{R}^d$  תחום קמור וסגור. תהא  $x^*$  נקודת מינימום של  $f$  מעל  $X$ . בנוסף נניח כי  $\eta = \frac{R}{B\sqrt{T}}$  אז עבור גודל הצעד  $\eta$  הפעלת אלגוריתם הגרדיינט המוטל תניב לאחר  $T$  סיבובים:

$$f(\bar{x}_T) - f(x^*) \leq \frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*)) \leq \frac{RB}{\sqrt{T}}$$

### 2.7 העשרה

1. כרגיל מסמנים  $\bar{x}_T = \frac{1}{T} \sum_{t=0}^{T-1} f(x_t)$

2. תזכורת המשמעות של הבטווי ( $\frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*))$  היא השגיאה הממוצעת.


3. לכן כמו שראינו כרגיל,  $\frac{RB}{\sqrt{T}}$  ככל שמספר הצעדים עולה, השגיאה הממוצעת הולכת וקטנה. במנוחה " כדי להשגיאה שגיאה קטנה או שווה מאפסילון נציגך  $\epsilon$ " כדי  $\frac{RB}{\sqrt{T}} \leq \frac{RB}{\epsilon^2} \leq T \Leftrightarrow \frac{RB}{\sqrt{T}} \leq \frac{\mathcal{O}(\frac{1}{\epsilon^2})}{\epsilon^2}$  כולם סדר גודל של ( $\frac{1}{\epsilon^2}$ )  $\mathcal{O}$  צעדים.

4. המשפט הנ' זהה למשפט של האלג' הלא מוטל אבל שימושי יותר, ועובד גם עבור subgradients. ככלומר אם פונ' המטרה אינה גירה בכל נקודה אז אם נשתמש באלג' הגרדיינט המוטל אבל עם טבר-גרדיינטים במקומות עם גודינייטים קיבל את אותו הקצב של התכנסות עבור אלג' הגרדיינט המוטל (כלומר נקבל את אותו הקצב עבור אלג' הסaab גדריאנט המוטל).

- לפני הוכחת המשפט נזכיר במשפט משיעור קודם (שהוכחנו בסוף הרצאה 6) על התכונה של ההטלה:

**משפט (תכונה של הטלה** (property of projection): יהא  $X \subseteq \mathbb{R}^d$  תחום סגור חסום וקמור (=קומפקטי) ויהי  $z \in X$  ו-  $y \in \mathbb{R}^d$  נקודה במרחב. אז  $\|\Pi_X(y) - z\|_2 \leq \|y - z\|_2$

$$\|\Pi_X(y) - z\|_2 \leq \|y - z\|_2$$



כלומר, לכל נקודה  $y \in \mathbb{R}^d$  מתקיים שהמרחק בין כל נקודה בתחום  $X \subseteq \mathbb{R}^d$  להטלה  $\Pi_X(y)$  הוא קטן או שווה מהמרחק של הנקודה  $X \in \mathbb{R}^d$  לנקודה  $y$  המקורי. כלומר, המרחק בין כל  $y$  לבין כל נקודה בתחום  $X$  (כלומר שימוש בהטלה לא יגדיל את המרחק) הוכחנו את המשפט בשיעור קודם (בסוף הרצאה 6).

#### הוכחת המשפט:

- כמו קודם, הוכחת אי השוויון  $f(\bar{x}_T) - f(x^*) \leq \frac{1}{T} \sum_{t=0}^{T-1} (f(x_t) - f(x^*))$  נעשת דרך אי שוויון ינסן

בדיק כמו בהוכחות קודמות נתבונן במרחקים בין האיטרנטים השונים מהנקודה האופטימלית. נזכיר כי עדכון הוא  $x_{t+1} = \Pi_X(x_t - \eta g_t)$  ולכן מתקיים:

$$\|x_{t+1} - x^*\|^2 = \|\Pi_X(x_t - \eta g_t) - x^*\|^2 \stackrel{\text{property of projection}}{\leq} \|x_t - \eta g_t - x^*\|^2$$

כלומר

$$\begin{aligned} \|x_{t+1} - x^*\|^2 &\leq \|x_t - \eta g_t - x^*\|^2 \\ &= \|(x_t - x^*) - \eta g_t\|^2 \\ &= \|(x_t - x^*)\|^2 - 2\eta g_t^T (x_t - x^*) + \eta^2 \|g_t\|^2 \end{aligned}$$

כלומר

$$\|x_{t+1} - x^*\|^2 \leq \|(x_t - x^*)\|^2 - 2\eta g_t^T (x_t - x^*) + \eta^2 \|g_t\|^2$$

מהנקודה זו הוכחה היא בדיק כמו הוכחה הרגילה של המשפט שכבר רأינו.  
לאחר העברת האגפים קיבל כי

$$2\eta g_t^T (x_t - x^*) \leq \|(x_t - x^*)\|^2 + \eta^2 \|g_t\|^2 - \|x_{t+1} - x^*\|^2$$

אי השווין נכון לכל  $t \in \{0, 1, \dots, T-1\}$  על שני האגפים ולקבל

$$\sum_{t=0}^{T-1} 2\eta \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \sum_{t=0}^{T-1} \left( \|(\mathbf{x}_t - \mathbf{x}^*)\|^2 + \eta^2 \|\mathbf{g}_t\|^2 - \|\mathbf{x}_{t+1} - \mathbf{x}^*\|^2 \right)$$

מתכונות של טור טלסקופי מותקמים

$$\sum_{t=0}^{T-1} 2\eta \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \left( \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + \eta^2 \sum_{t=0}^{T-1} \|\mathbf{g}_t\|^2 - \|\mathbf{x}_T - \mathbf{x}^*\|^2 \right)$$

מתכונות הנורמה האיבר  $\|\mathbf{x}_T - \mathbf{x}^*\|_2^2$  – אי חיובי ולכון האיבר  $\|\mathbf{x}_T - \mathbf{x}^*\|_2^2$  אי שלילי ולכון נוכן להשミニט אותו ולהגדיל את אי השווין ולקבל

$$\sum_{t=0}^{T-1} 2\eta \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + \eta^2 \sum_{t=0}^{T-1} \|\mathbf{g}_t\|^2$$

נחלק ב $2\eta$  ונקבל

$$\sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \frac{1}{2\eta} \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + \frac{\eta}{2} \sum_{t=0}^{T-1} \|\mathbf{g}_t\|^2$$

כלומר

$$\begin{aligned} \sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) &\leq \frac{1}{2\eta} \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + \frac{\eta}{2} \sum_{t=0}^{T-1} \|\mathbf{g}_t\|^2 \\ &\stackrel{\|\mathbf{x}_0 - \mathbf{x}^*\| \leq R}{\leq} \frac{1}{2\eta} R^2 + \frac{\eta}{2} \sum_{t=0}^{T-1} B^2 \\ &= \frac{1}{2\eta} R^2 + \frac{\eta}{2} TB^2 \\ &\stackrel{\eta = \frac{R}{B\sqrt{T}}}{=} \frac{1}{2 \left( \frac{R}{B\sqrt{T}} \right)} R^2 + \frac{\left( \frac{R}{B\sqrt{T}} \right)}{2} TB^2 \\ &= \frac{B\sqrt{T}}{2} R + \frac{R}{2} \sqrt{T} B \\ &= RB\sqrt{T} \end{aligned}$$

לכל  $t \in \{0, \dots, T-1\}$  Mai שווין הגדרינט עבר  $\mathbf{g}_t \equiv \nabla f(\mathbf{x}_t)$  ומאי שווין הגרדינאט (הסאב גרדיאנט במקורה שורצים להוכיח שהמשפט נכון עבור פונ' לא גירה) מותקמים

$$f(\mathbf{x}_t) - f(\mathbf{x}^*) \leq \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)$$

נשרשר את אי השווונות

$$\sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq RB\sqrt{T}$$

$$\frac{1}{T} \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \frac{RB}{\sqrt{T}}$$

ולכן הוכחנו את אי השוויון השני.  
בזה הסתיימה הוכחת המשפט.  
**געצ'ור** את הנושא של אלג' הגרדיינט המוטל כדי להתקדם לנושא הבא.

### 7.1.2 אלג' הגרדיינט: קצב התכנסות מהירים יותר.

נזכיר לנו שאם אלג' הגרדיינט ללא אילוצים. ראיינו שיכל שאנו מבצעים הנחות חזקות יותר על  $f$  כהה נוכל להבטיח קצב התכנסות מהירים יותר.

ראיינו כי קצב התכנסות מקיים:

1. עבור פונ' קמורה  $(\frac{1}{\epsilon^2}) \mathcal{O}$ .

2. עבור פונ' קמורה וחלקה  $(\frac{1}{\epsilon}) \mathcal{O}$ .

עכשו נראה שנייה לקל קצב מהיר בהרבה מאשר חזקה יותר מallow.  
**אינטואציה**

- עבור הפונ' החד מימדית  $x^2 = f(x)$  וגודל צעד  $\frac{1}{2} = \gamma$ . נזכיר כי המינימום שלה מתקיים ב-0.
- מתקיים עבור הפונ' הזו וגודל הצעד הזה:

$$x_{t+1} = x_t - \gamma \nabla f(x_t) = x_t - \frac{1}{2}(2x_t) = 0 = x^*$$

כלומר קיבלנו התכנסות בצעד אחד.

**הערות:**

– נזכיר כי המינימום של הפונ'  $x^2 = f(x)$  מתקיים ב-0.

– (נזכיר כי  $f$  היא 2 חלקה כי לפי הגדרת  $L$  חלקה מתקיים  $\|\nabla f(x) - \nabla f(y)\| \leq L \cdot \|x - y\|$   $\forall x, y \in \mathbb{R}^d$ :  $\|\nabla f(x) - \nabla f(y)\| \leq L \cdot \|x - y\|$   $\forall x, y \in \mathbb{R}^d$ :  $\|2x - 2y\| \leq L \cdot \|x - y\|$   $\forall x, y \in \mathbb{R}^d$ :  $\|2x - 2y\| \leq L \cdot \|x - y\|$   $\forall x, y \in \mathbb{R}^d$  מקיים את המשוואה ולכן הפונ' היא 2 חלקה).

– דרך נוספת לראות את זה: ראיינו שפונ' שאם הערך העצמי של ההאסין בכל מקום (כלומר לכל  $x \in \mathbb{R}^n \nabla^2 f(x)$ ) חסום על ידי  $L$  ככלומר  $\|\nabla^2 f(x)\| \leq L$ . איז' הפונ' היא  $L$  חלקה. ההאסיאן של  $f(x)$  הוא  $\nabla^2 f(x) = 2 \in \mathbb{R}^{1,1}$  והוא ע"ש. וכך הפונ' היא 2 חלקה.

– זה נכון גם עבור הפונ' הרוב ממדית  $\|x\|_2^2 = f(x) = x^T x = \|x\|_2^2$ , ניתן להראות שוב בשתי האופנים (או דרך הגדרה או דרך משפט על ההאסיאן) לדוגמה עבור המפט על ההאסיאן

$$\forall x \in \mathbb{R}^n : \nabla^2 f(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}(x) & \frac{\partial^2 f}{\partial x_1 \partial x_2}(x) & \dots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(x) \\ \frac{\partial^2 f}{\partial x_2 \partial x_1}(x) & \frac{\partial^2 f}{\partial x_2^2}(x) & \dots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(x) & \frac{\partial^2 f}{\partial x_n \partial x_2}(x) & \dots & \frac{\partial^2 f}{\partial x_n^2}(x) \end{pmatrix} = \begin{pmatrix} 2 & 0 & \dots & 0 \\ 0 & 2 & \dots & \vdots \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 2 \end{pmatrix}$$

המיט' היא אלכסונית ולכן הע"ש מופיע על האלכסון, הערך הכספי גדול הוא 2 ולכן הפונ'  $\|x\|_2^2$  היא 2 חלקה.

– זה מקרה מיוחד מאוד עבור הפונ' הנו' וטוב מדי להיות מוכפל למקרה הכללי. נתבונן על גודל צעד אחר.

- עבור הפונ' החד מימדית  $x^2 = f(x)$  (כמו קודם) וגודל צעד  $\frac{1}{4} = \gamma$ . (נבחן כי מכיוון שהפונ' היא 2 חלקה, אז לכל מההגדירה נובע שכל  $n$  שגודל מג הפונ' יהיה גם  $n$  חלקה, ובפרט הפונ' 4 חלקה).

מתוקים עבור הפונ' הזו וגודל הצעד הזה:

$$x_{t+1} = x_t - \gamma \nabla f(x_t) = x_t - \frac{1}{4}(2x_t) = \frac{1}{2}x_t$$

כלומר בכל צעד אנו ממצאים את הערך שקיבלו בחצי כלומר  $x_t$  בכל איטרציה קטן בפקטור חצי, כלומר

$$x_t = \frac{1}{2^t} \cdot x_0$$

$$f(x_t) = f\left(\frac{1}{2^t} \cdot x_0\right) = \left(\frac{1}{2^t} \cdot x_0\right)^2 = \frac{1}{2^{2t}} \cdot x_0^2 = \left(\frac{1}{4}\right)^t \cdot x_0^2$$

משמעות היא קצב התכנסות התכנסות אקספוננציאלית ב- $t$ .

כלומר עבור המקרה של  $f(x) = x^2$  עם גודל צעד  $\gamma = \frac{1}{4}$  הראנו שהפונ' קטנה בכל איטרנט בקצב אקספוננציאלי ב- $t$ .

נדיר את המקרה הכללי. נניח בcontra מוחחת את ההגדרה של פונ' קמורה חזק.

**הגדרה: פונ' קמורה חזק**  
איןטואציה לפונ' קמורה ממש = "לא יותר מדי שטוחה"

**הגדרה 3.7** תהא  $\mathbb{R} \rightarrow f$  פונ' גזירה. הा תחום  $f : \text{dom}(f) \subseteq X$  פונ' קמורה והוא  $\mu \in \mathbb{R}_+$  (כלומר  $0 > \mu$ ) (אזי פונ'  $f$  **תקרא קמורה ממש** עם פרמטר  $\mu$  (" $\mu$  קמורה ממש")) מעלה תחום  $X$  אם

$$\forall \mathbf{x}, \mathbf{y} \in X : f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$$

**הערה 4.7** שימושי יותר במקרים עוברים  $f$  אינה גזירה פעמיים.

**משפט 5.7** (נאמר בעל פה) **תאה**  $\mathbb{R} \rightarrow f$  אם  $f$  גזירה פעמיים, אזי  $f$  תקרא  $\mu$  קמורה ממש  $\Leftrightarrow$  פונקציה  $\mu$  קמורה ממש.

**הערה 6.7** שימושי יותר במקרים עוברים  $f$  גזירה פעמיים.

**הערה 7.7** נזכר כיניתן להראות ש: פונקציה קמורה חזק  $\Leftrightarrow$  פונקציה קמורה ממש  $\Leftrightarrow$  פונקציה קמורה.  
(כלומר  $\text{strongly convex} \Rightarrow \text{strictly convex} \Rightarrow \text{convex}$  ו↳  $\text{convex} \Rightarrow \text{strongly convex}$  כיוון נקודת מינימום יחידה).

**ט 8.7** אם ( $\cdot$ )  $f$  היא  $\mu$  קמורה חזק וגזרה איז עבור אלג' GD עם גודל צעד  $\mu$  מתוקים  $h_t \equiv (f(\mathbf{x}_t) - f(\mathbf{x}^*))$   $\leq 2\mu(f(\mathbf{x}_t) - f(\mathbf{x}^*))$   $\leq 2\mu h_t$   $\Rightarrow$  מוגדרת קמירות חזק  $\mu$ .

יהיו  $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$ , כלשהם. איז מהגדרת הקמירות ממש מתקיים כי

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|_2^2 \equiv g(\mathbf{x}) = \dots$$

הפונ'  $g(\mathbf{y}) \equiv f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|_2^2$  הינו קמורה:

נחשב את הגדירינט שלו

$$\begin{aligned}
\nabla g(\mathbf{y}) &= \frac{\partial}{\partial \mathbf{y}} g(\mathbf{y}) \\
&= \frac{\partial}{\partial \mathbf{y}} \left[ f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 \right] \\
&= \frac{\partial}{\partial \mathbf{y}} \left[ \nabla f(\mathbf{x})^T \mathbf{y} + \frac{\mu}{2} \|\mathbf{y} - \mathbf{x}\|_2^2 \right] \\
&\stackrel{\frac{\partial}{\partial \underline{x}}(\underline{a}^T \underline{x}) = \frac{\partial}{\partial \underline{x}}(\underline{x}^T \underline{a}) = \underline{a}}{=} \nabla f(\mathbf{x}) + \frac{\mu}{2} \frac{\partial}{\partial \mathbf{y}} \|\mathbf{y} - \mathbf{x}\|_2^2 \\
&= \nabla f(\mathbf{x}) + \frac{\mu}{2} \frac{\partial}{\partial \mathbf{y}} \left[ (\mathbf{I}\mathbf{y} - \mathbf{x})^T (\mathbf{I}\mathbf{y} - \mathbf{x}) \right] \\
&= \nabla f(\mathbf{x}) + \frac{\mu}{2} [2\mathbf{I}^T (\mathbf{I}\mathbf{y} - \mathbf{x})] \\
&= \nabla f(\mathbf{x}) + \mu(\mathbf{y} - \mathbf{x})
\end{aligned}$$

ואת ההאיסיאן שלו

$$\nabla^2 g(\mathbf{y}) = \frac{\partial}{\partial \mathbf{y}} \frac{\partial}{\partial \mathbf{y}^T} g(\mathbf{y}) = \mu \mathbf{I} > 0$$

ולכן  $\mu > 0$  היא חיובית מוגדרת ולכן  $g$  היא פונ' קמורה. וכך אם  $\mathbf{y}$  יש נקודה בה הגרדיינט מותאפס אז נקודת מינימום גלובלי, ככלומר

$$\nabla g(\mathbf{y}) = \nabla f(\mathbf{x}) + \mu(\mathbf{y} - \mathbf{x})$$

$$\begin{aligned}
&[\nabla g(\mathbf{z})]_{\mathbf{z}=\mathbf{z}^*} = 0 \\
&\iff [\nabla f(\mathbf{x}) + \mu(\mathbf{z} - \mathbf{x})]_{\mathbf{z}=\mathbf{z}^*} = 0 \\
&\iff \nabla f(\mathbf{x}) + \mu(\mathbf{z}^* - \mathbf{x}) = 0 \\
&\iff \nabla f(\mathbf{x}) + \mu \mathbf{z}^* - \mu \mathbf{x} = 0 \\
&\iff \mu \mathbf{z}^* = \mu \mathbf{x} - \nabla f(\mathbf{x})
\end{aligned}$$

$$\mathbf{z}^* = \mathbf{x} - \frac{1}{\mu} \nabla f(\mathbf{x})$$

כโลמר  $\mathbf{z}^*$  היה מינימום גלובלי של  $g$  כלומר

$$\forall \mathbf{z} \in \mathbb{R}^n : g(\mathbf{z}) \geq g(\mathbf{z}^*)$$

וגם עבור  $\mathbf{y}$  מתקיימים

$$\star : g(\mathbf{y}) \geq g(\mathbf{z}^*)$$

נמשיך ונפתח את אי השוויון מתחילה הוכחחה:

$$\begin{aligned}
\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : f(\mathbf{y}) &\geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|_2^2 \\
&= g(\mathbf{y}) \\
&\geq (z^*) \\
&= f(\mathbf{x}) + \nabla f(\mathbf{x})^T (z^* - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{x} - z^*\|_2^2 \\
&= f(\mathbf{x}) + \nabla f(\mathbf{x})^T \left( \left( \mathbf{x} - \frac{1}{\mu} \nabla f(\mathbf{x}) \right) - \mathbf{x} \right) + \frac{\mu}{2} \left\| \mathbf{x} - \left( \mathbf{x} - \frac{1}{\mu} \nabla f(\mathbf{x}) \right) \right\|_2^2 \\
&= f(\mathbf{x}) - \nabla f(\mathbf{x})^T \frac{1}{\mu} \nabla f(\mathbf{x}) + \frac{\mu}{2} \left\| -\frac{1}{\mu} \nabla f(\mathbf{x}) \right\|_2^2 \\
&= f(\mathbf{x}) - \frac{1}{\mu} \|\nabla f(\mathbf{x})\|_2^2 + \frac{1}{2\mu} \|\nabla f(\mathbf{x})\|_2^2 \\
&= f(\mathbf{x}) - \frac{1}{2\mu} \|\nabla f(\mathbf{x})\|_2^2
\end{aligned}$$

כלומר

$$\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^n : f(\mathbf{y}) = f(\mathbf{x}) - \frac{1}{2\mu} \|\nabla f(\mathbf{x})\|_2^2$$

נבחר  $\mathbf{x} = \mathbf{x}_t$  ו  $\mathbf{y} = \mathbf{x}^*$  ונקבל כי  $f(\mathbf{x}^*) \geq f(\mathbf{x}_t) - \frac{1}{2\mu} \|\nabla f(\mathbf{x}_t)\|_2^2$  נמשיך  
ונקבל  $2\mu(f(\mathbf{x}_t) - f(\mathbf{x}^*)) \leq \|\nabla f(\mathbf{x}_t)\|_2^2$  כלומר קיבלנו

$$\|\nabla f(\mathbf{x}_t)\|_2^2 \geq 2\mu(f(\mathbf{x}_t) - f(\mathbf{x}^*)) \stackrel{h_t \equiv (f(\mathbf{x}_t) - f(\mathbf{x}^*))}{=} 2\mu h_t$$

זה מה שרצינו להוכיח.

**הערה 9.7** ראיינו שאם  $f$  קמורה וגיירה ברציפות אזי:  $f$  בעלת גרדיאנט ליפשיצי עם קבוע  $L$ . ומכאן ייבוא  
כי

$$\begin{aligned}
\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^d : \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| &\leq L \cdot \|\mathbf{x} - \mathbf{y}\| \\
\iff \forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^d : f(\mathbf{y}) &\leq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{L}{2} \cdot \|\mathbf{x} - \mathbf{y}\|^2
\end{aligned}$$

**הערה 10.7** כלומר עבור פונקציה  $f$  גזירה ברציפות שהיא גם  $\mu$  קמורה חזק  $L$  וגם  $\mu$  חלקה  $L$  מתקיים כי


$$\begin{aligned}
\forall \mathbf{x}, \mathbf{y} : f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{L}{2} \cdot \|\mathbf{x} - \mathbf{y}\|^2 \\
\overbrace{\geq}^{L \text{ smooth}} f(\mathbf{y}) \\
\overbrace{\geq}^{\mu \text{ strongly convex}} f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{\mu}{2} \|\mathbf{x} - \mathbf{y}\|_2^2
\end{aligned}$$

נבחן כי מי השוויון נובע גם כי  $\mu \geq L$ . (מקדם הקמיירות ממש  $\mu$  תמיד קטן או שווה למקדם החלוקות  $L$ )

**איור:** (פונקציית  $f$  קמורה חזק  $L$  ו**גם  $\mu$  קמורה חזק  $L$** )

## Strongly convex functions II

**Strong convexity:** For any  $\mathbf{x}$ , the graph of  $f$  is above a not too flat tangential paraboloid at  $(\mathbf{x}, f(\mathbf{x}))$ :



EPFL Machine Learning and Optimization Laboratory

5/34

נבחן שבכל נקודה יש לנו מעין "סנדביץ'" שמלמטה נוצר מההגדלה של  $\mu$  קמורה ממש ומעל נוצר מההגדלה של  $L$  חלקה. כלומר במקרה זה

$$\forall \mathbf{x}, \mathbf{y} : f(\mathbf{x}) + \|\nabla f(\mathbf{x}) - \nabla f(\mathbf{y})\| \leq L \cdot \|\mathbf{x} - \mathbf{y}\|$$

נזכיר את צעד האלג' בGD:  $\mathbf{g}_t = \nabla f(\mathbf{x}_t)$   $\mathbf{x}_{t+1} = \mathbf{x}_t - \eta \mathbf{g}_t$

**משפט 11.7** תהא  $f(\cdot)$  פונ'  $\mu$  קמורה חזק  $\mu \geq \frac{1}{L}$  ו גם  $L$  חלקה  $\mu$  strongly convex. אז על ידי גודל צעד  $\eta = \frac{\mu}{L}$  שימוש באלג' GD מבטיח כי

$$f(\mathbf{x}_t) - f(\mathbf{x}^*) \leq (f(\mathbf{x}_0) - f(\mathbf{x}^*)) e^{-\frac{\mu}{L} \cdot t}$$

הערה 12.7 המשמעות היא שהשגיאה דועכת אקספוננציאלית במספר הצעדים.

הערה 13.7 נבחן כי ראיינו ש  $\mu \geq L$  ולכן תמיד מתקיים  $1 \leq \frac{\mu}{L}$ . לוגדל  $\frac{\mu}{L}$  יש שם מיוחד, הוא נקרא Condition number והוא נקרא Condition number מה אומר הגדול הזה?  $\equiv \frac{\mu}{L}$

- נזכיר כי השגיאה במשפט היא לפחות  $e^{-\frac{\mu}{L} \cdot t}$  כלומר, ככל ש Condition number קטן יותר ככה השגיאה היא איטית יותר.
- ראיינו קודם כיוון  $x^2$  חלקה 2 (פונ' 2 קמורה ממש) Condition number 2 Condition number 2 הוא בדיקת 1 Condition number 1 Condition number 1 הוא  $\frac{\mu}{L} = \frac{2}{2} = 1$  כלומר לפונ' זו יש את ה Condition number Condition number 1 הוא אפסי. ולכן במקרה זה (עבור הפעלת אלג' GD עם  $\eta = \frac{1}{L} = \frac{1}{2}$ ) ראיינו ההתקנסות היא תוך איטרציה בודדת (=כלומר התקנסות מהירה).

הערה 14.7 ראיינו את השימוש בגודל הצעד של  $\eta = \frac{1}{L}$  גם במקרה ש  $f$  היא רק חלקה.

**הערה 15.7** בשביל להגעה לפתרון  $\epsilon$  אופטמלי נזדקק ל  $t$  איטרציות כך שיתקיים נמצא את  $t$ :

$$\begin{aligned} & (f(\mathbf{x}_0) - f(\mathbf{x}^*)) e^{-\frac{\mu}{L} \cdot t} \leq \epsilon \\ \iff & e^{-\frac{\mu}{L} \cdot t} \leq \frac{1}{(f(\mathbf{x}_0) - f(\mathbf{x}^*))} \cdot \epsilon \\ \iff & -\frac{\mu}{L} \cdot t \leq \ln \left( \frac{1}{(f(\mathbf{x}_0) - f(\mathbf{x}^*))} \cdot \epsilon \right) \\ \iff & -t \leq \frac{L}{\mu} \ln \left( \frac{1}{(f(\mathbf{x}_0) - f(\mathbf{x}^*))} \cdot \epsilon \right) \\ \iff & t \geq \frac{L}{\mu} \ln \left( \frac{(f(\mathbf{x}_0) - f(\mathbf{x}^*))}{\epsilon} \right) \end{aligned}$$

כלומר התוכניות הולכת כמו  $\mathcal{O}(\ln(\frac{1}{\epsilon}))$ .

#### הוכחת המשפט

נווכיח את קצב התוכניות של המשפט:

נסמן  $h_t = f(\mathbf{x}_t) - f(\mathbf{x}^*)$  את השגיאה של האינטרנט  $t$ . נזכיר במשפטים הבאים:

1. אם  $f(\cdot)$  היא פונ' גזירה וחלקה איזי לפי הלמה sufficient decrease עבור צעד הלימוד  $\eta = \frac{1}{L}$  אל' GD מבטיח

$$f(\mathbf{x}_{t+1}) \leq f(\mathbf{x}_t) - \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2 \quad .t \geq 0$$

(א) ראיינו את אי השוויון הזה בהרצאות קודמות)

(ב) כלומר אם נחסיר  $f(\mathbf{x}^*)$  משני האגפים קיבל

$$\star : h_{t+1} \leq h_t - \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2$$

2. אם  $f(\cdot)$  היא פונ'  $\mu$  קמורה ממש איזי :

$$\star\star : \|\nabla f(\mathbf{x}_t)\|^2 \geq 2\mu(f(\mathbf{x}_t) - f(\mathbf{x}^*)) = 2\mu h_t$$

(א)

3. אי שוויון שימושי Condition number  $= \frac{\mu}{L} \leq \forall x \geq 0 : (1-x) \leq e^{-x}$  ולכן קיבל את :

$$\star\star\star : \left[1 - \frac{\mu}{L}\right] \leq e^{-\frac{\mu}{L}}$$

ולכן:

$$h_{t+1} \stackrel{*}{\leq} h_t - \frac{1}{2L} \cdot \|\nabla f(\mathbf{x}_t)\|^2 \stackrel{\star\star}{\leq} h_t - \frac{1}{2L} \cdot (2\mu h_t) = h_t \left[1 - \frac{\mu}{L}\right] \stackrel{\star\star\star}{\leq} h_t \cdot e^{-\frac{\mu}{L}}$$

כלומר

$$h_{t+1} \leq h_t \cdot e^{-\frac{\mu}{L}}$$

נשתמש באופן רקורסיבי באי השווין ונקבל

$$h_{t+1} \leq h_t \cdot e^{-\frac{\mu}{L}} \leq h_{t-1} \cdot e^{-\frac{\mu}{L}} \cdot e^{-\frac{\mu}{L}} \leq h_{t-2} \cdot e^{-\frac{\mu}{L}} \cdot e^{-\frac{\mu}{L}} \cdot e^{-\frac{\mu}{L}} \leq \dots \leq h_0 \cdot e^{-\frac{\mu}{L} \cdot (t+1)}$$

כלומר עבור  $\tilde{t} = t + 1$  נקבל

$$h_t \leq h_0 \cdot e^{-\frac{\mu}{L} \cdot t}$$

$$\begin{aligned} \text{נציב בחזרה את } (\mathbf{x}_t) - f(\mathbf{x}^*) &= f(\mathbf{x}_t) - f(\mathbf{x}^*) \text{ ונקבל} \\ f(\mathbf{x}_t) - f(\mathbf{x}^*) &\leq (f(\mathbf{x}_0) - f(\mathbf{x}^*)) e^{-\frac{\mu}{L} \cdot t} \end{aligned}$$

וקיבלנו את מה שרצינו להוכיח ■.

### 7.1.3 אלגוריתם הגרדיינט הסטטיסטי SGD

עד עכשיו דיברנו על המקרה שבו הינה לנו פונ' ידוע ואנו מסוגלים לחשב את הגרדיינטם שלה ואת הערכיהם שלה במדויק. הרבה פעמים בעולם זה לא המצב. יש לנו גישה רק לחלק מהמیدע על ( $x$ )  $f$  (פונ' שנרצה למשער) לדוגמא מייצג שלה אין לנו גישה לכל הפונ' ובאמצעות המדגם מייצג אנו רוצים למצאו נקודות המינימום של כל הפונ'. האלג' שנסלמוד שימושי מאוד בעקבות של למידה, בקרה, תורת האינפורמציה. פונ' מטריה רבות הטעינה של סכום כלומר מהצורה:

$$f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$$

לדוגמא,  $f_i$  היא פונ' המחר עבור האיטרציה  $i$  שנ마다 עבור סט האימון, בתהליך של אימון רשות שמקיל  $n$  איטרציות. באופן כללי בשביל לחפש את ( $\mathbf{x}$ )  $\nabla f$ : הגרדיינט של סכום הפונ'  $f_i$  יכול להיות תחילה יקר חישובית (לסכום  $n$  גרדיאנטים של  $n$  פונ' (שיכולות להיות שונות אבל לא בהכרח)).

**הערה 16.7**  $n$  יכול להיות מספר מאד גדול בעקבות מעשיות, בסדר גודל של מיליוןים ואפילו מיליארדים.

**דוגמה 17.7** לדוגמא, ( $\mathbf{x}$ )  $f$  הוא פונ' ממוחשב דגימות הדם של בנדאם לתחזית האם הבנדאם שמננו נלקחו הדגימות הדם יחלו בקורסנה או שלא. כלומר  $\mathbf{x}$  הוא בדיקות הדם (ווקטור פרמטרים (=ווקטור פיצרים): באחת הנסיבות שלו: רמת סוכרدم ובכניתה אחרת שלו: רמת גליקוזدم וכיו...)) ו( $\mathbf{x}$ ) זה החזוי (=שערוך) האם האדם יחל בקורסנה או שלא. יש לנו גישה רק לחלק מהאנשים כלומר אנו ידעים רק  $M$  זוגות של אנשים  $\{x_i, f(x_i)\}_{i=1}^M$  =תוגים והינו רוצים לדעת מה השערוך שיניב את השגיאה המינימלית עבור כל האנשים בעולם (לדוגמא יש  $n$  אנשים בעולם)  $\{x_i, f(x_i)\}_{i=1}^n$ . במקרה הזה לחשב את הגרדיינט יכול להיות מאוד יקר ודורש מיליון או מיליארדי חישובים, שזה דבר שאינו מעשי.

**דוגמה 18.7 רגרסיה לוגיסטיבית**  
בהתנון דוגמאות מותיגות  $\{y_i\}_{i=1}^n$ ,  $y_i \in \{0, 1\}$ ,  $i \in \{1, \dots, n\}$ , נזכיר בעיית הרגרסיה הלוגיסטיבית:

$$\min_{\beta} \frac{1}{n} \sum_{i=1}^n \left( \underbrace{-y_i x_i^T \beta + \log(1 + \exp(x_i^T \beta))}_{f_i(\beta)} \right)$$

הчисוב של הגרדיינט  $f_i(\beta)$  הוא מעשי כאשר  $n$  הוא צנוע אבל כאשר  $n$  גדול מאוד אז החישוב שלו אינו מעשה.

$$\nabla f(\beta) = \frac{1}{n} \sum_{i=1}^n (y_i - p_i(\beta)) x_i$$

השוואה בין האלג' הגרדיינט הרגיל (=גרדיינט מלא/batch gradient) אל מול הגרדיינט הסטטיסטי stochastic gradient/batch gradient (full gradeint/batch gradient) :

- מעבר על הbatch ועדכו פונ' המחר פעם אחת עולה ( $np$ )  $\mathcal{O}$ .
  - מעבר על חלק מסט האימון ועדכו פונ' המחר (=עדכו סטטיסטי) פעם אחת עולה ( $p$ )  $\mathcal{O}$ .
- לכן כה גדול מספיק נועד לשימוש באלו הגרדיינט הסטטיסטי.

**מבנה האלגוריתם:** פונ' המטרה שאנו רוצים מזעර ( $f(\mathbf{x})$ )

$$\min_{\mathbf{x}} f(\mathbf{x}) = \min_{\mathbf{x}} \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$$

- בחר  $\mathbf{x}_0 \in \mathbb{R}^d$

- לכל  $t = 0, 1, \dots$  ועבור צעד  $\eta_t \geq 0$

– דגום את  $i_t$  באופן אקראי מתוך הקבוצה  $\{1, 2, \dots, n\}$  עם פונ' פילוג יוניפורמייה איחידה.

– בצע את העדכון  $\mathbf{x}_{t+1} = \mathbf{x}_t - \eta_t \mathbf{g}_t$  כאשר  $\mathbf{g}_t = \nabla f_{i_t}(\mathbf{x}_t)$

- באלו' הגרדיינט זהה העדכון מתבצע לפ'  $\mathbf{g}_t$  הגרדיינט בנקודה  $\mathbf{x}_t$  על הפונ'  $f_{i_t}$  בלבד: הפונ' שדגמוני בסיבוב זהה. באלו' הגרדיינט המלא ביצענו את חישוב הגרדיינט לפי הפונ'  $f$  והדוללה. (כלומר לפי  $\frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$ ).

- ככלומר בכל סיבוב בוחרים מינימ' אחד  $i_t$  מתוך  $n$  הפונ'  $\{f_i\}_{i=1}^n$  שמתארות את ( $\mathbf{x}$ )  $f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$  ומוחשים עליו את הגרדיינט וمعدכני רק לפי כיוונו.

- נציג כי בכל סיבוב אנו מגירלים פונ' חדש לא בהכרח אותה פונ' כמו בסיבוב הקודם. ככלומר **"יתכנו דגימות שונות שייגרלו פונ' שוונות."**

- ככלומר מעדכנים את הגרדיינט בכל פעם רק עם  $i_t$  אחות במקומות להשתמש בעדכון הגרדיינט המלא. וכך כל איטרציה היא "זולה" יותר **יחסטיבית** פי  $n$  מאשר עדכון הגרדיינט **full gradient** ( $O(d)$  במקום  $O(nd)$ ) כה גדול מאוד זה הבדל משמעותית! הווקטור ( $\mathbf{g}_t = \nabla f_{i_t}(\mathbf{x}_t)$ ) נקרא **גרדיינט סטוכסטי stochastic gradient**. הוא למעשה למשעה ווקטור של  $d$  משתנים אראים (כלומר ווקטור אקראי) אבל לצורך נוחות נקראה לו "משתנה אקראי".

- האלו' נקרא **אלג' הגרדיינט הסטוכסטי** מכיוון שיש כאן בתהיליך זהה **אקרואיות (=סטוכסיטיות)** בתהיליך (כל סיבוב מבצעים דגימה אקראית).

– ככלומר גם  $\mathbf{x}_t$  וגם  $\mathbf{g}_t$  הם למעשה ווקטורים אקראיים.

- מطبع הדברים האלו' סטוכסטי ותלי' במשתנים אקראיים (ויתכן שאפילו לא דגמוני את כל הפונ' ב- $\{f_i\}_{i=1}^n$ ) וכך לא נוכל לומר שהוא יתכנס בהתאם 1 למשהו, אלא נוכל לומר **שבסתברות גבוהה** קיים תופעת התכנסות רצiosa או **שתווחת השגיאה** היא קטנה.

#### • סימונים:


- האות  $d$  והאות  $p$  מסמנות את אותו הדבר, מימד הקלט (לעתים מסומנים ככח ולעתים מסומנים ככח) זה המימד של

$$f : \mathbb{R}^d \xrightarrow{p \equiv d} \mathbb{R}^p$$

- $n$  משמעו כמהות הפונ' שבסכום של הפונ' המלא ( $\mathbf{x}$ )

$$\min_{\mathbf{x}} f(\mathbf{x}) = \min_{\mathbf{x}} \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$$

**דוגמה 19.7** ניתן לראות שהאלג' הסטוכסטי מתכנס בצורה יותר רועשת מהאלג' fullgradient אבל בכל זאת מתכנס. לדוגמא:



**איינטואטיבית:** אפשר לחוש על האלו' הגרדיינט הסטוכסטי מנוקודת המבט הבא:

בכל סיבוב אפשר לחוש על האלו' הגרדיינט הסטוכסטי בתור אלג' הגרדיינט הרגיל האמתי, מוסף לו קצת(או הרבה) מבעץ את העדכון. ככלומר הוא מעין גרסה של האלו' הגרדיינט המלא רק שבכל פעם מתווסף לנו רעש לצעד העדכון. ככלומר אם האלו' הגרדיינט המלא (הכחול) עוקב אחרי הגרדיינטים, אז גם האלו' הגרדיינט הסטוכסטי עוקב אחרי הגרדיינטים (האדום עוקב אחרי הכחול) אבל באופן יותר רועש. אבל עדין אם הגרדיינט גדול מספיק, אז עדין יש התקדמות ("סחיפת") בכיוון הגרדיינט.

- באופן כללי הביצועים של אלגוריתמים סטטיסטיים:
- כאשרנו בנקודת מינימום (וזה הגראדיאנט מאוד חזק) נוכל לモר שהאלג' הסטטיסטיים **מתכנסים מאוד מהר**. (מהר אפילו כמו full gradient) אפלו שהעלות החישובית שלהם היא הרבה יותר נמוכה.
- כאשרנו בנקודת מינימום (וזה הגראדיאנט הוא מוקט חסיט) ואז האלג' נוכל לモר שהאלג' הסטטיסטיים מתכנסים נאוד לאט. כי במקרה זה הילוק מקרי. (כשבעצם לעומת זאת full gradient יעשה הילוק מקרי). י Mishik ווישתפר כי תמיד יתקדם לכיוון ההפוך לגרדיינט האמתי).

- לכן האלג' הנ"ל מצליח עברו דיקונים לא גדולים מדי.
- בדרך כלל בleraning כמעט ולא מספיק לנו מפתרונות מאוד מדויקים, ולכן האלג' הסטטיסטי ייתן ביצועים טובים יותר ובעלות חישובית זולה יותר ולעתים קרובות נעדר אוטו על פניו האלג' full gradient .
- לדוגמה אלג' שמתכוון למסלול נסיעה בויז ואומר לנו מה הזמן שנגע לעד. אם השגיאה היא  $1 \pm \text{דקota}$  אז אנחנו בסדר עם שגיאה כזו וזה לא כל כך נורא. לא תעוני אותנו רזולוציה (של הגעה לעד) בבדיקה של מיקרו שניות. (כלומר אנו בסדר לקבל פתרון שאינו מדויק מאוד) וגם שגיאה של דקה יכולה להסביר לנו. וכך שימוש באלג' הסטטיסטי ייתאים לצרכינו.

**השערון הלא מותה unbaisedness**  
ראינו כי בהוכחות הקודומות של התכונות השתמשנו באישווין הגראדיאנט עבור פונקונבקסיות:

$$f(\mathbf{x}_t) - f(\mathbf{x}^*) \leq \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)$$

אבל מכיוון שהפעם באלג' הנוכחי  $\mathbf{g}_t = \nabla f_{i_t}(\mathbf{x}_t)$  הוא לא הגראדיאנט שלנו, אלא **הגראדיאנט הסטטיסטי**:  $\mathbf{g}_t = \nabla f_{i_t}(\mathbf{x}_t)$  לא נוכל להשתמש באישווין הנ"ל. (הוא לא בהכרח נכון) מה שכן נוכל להראות היא שחייבנו אכן נכוון עברו תוחלת.  
עבור זה נתחל בהגדלה,

- נבחין כי  $\mathbf{g}_t$  הוא משתנה אקראי:  $P\{\mathbf{g}_t = \nabla f_{i_t}(\mathbf{x}_t) \mid i_t \in \{1, 2, \dots, n\}\} = \frac{1}{n}$ . עם פונ' פילוג מהצורה  $\mathbf{g}_t = \nabla f_{i_t}$  מוגדרת על ידי  $\theta$  ולכן bias  $(\theta, \hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$ . ולכן מכאן נובע כי:

**הגדלה 20.7** תזכורת, הטיה של משערץ  $\hat{\theta}$  לפרמטר  $\theta$  מוגדרת על ידי  $\mathbb{E}(\hat{\theta}) - \theta$ . כלומר העדרץ בלתי מותה unbaised estimate לא מושט/לא מותה של  $\nabla f(\mathbf{x}_t)$  כי לפי ההגדלה של המשתנה האקראי  $\mathbf{g}_t$  הוא משערץ בלתי מותה unbaised estimate לא מושט/לא מותה של  $\nabla f(\mathbf{x}_t)$  כי לפי ההגדלה של תוחלת:

$$\mathbb{E}[\mathbf{g}_t \mid \mathbf{x}_t = \mathbf{x}] = \frac{1}{n} \sum_{i=1}^n \nabla f_i(\mathbf{x}_t) = \nabla f(\mathbf{x}_t) \quad , \mathbf{x} \in \mathbb{R}^d$$

כלומר

$$\text{bias}(\nabla f(\mathbf{x}_t), (\mathbf{g}_t \mid \mathbf{x}_t = \mathbf{x})) = \mathbb{E}[\mathbf{g}_t \mid \mathbf{x}_t = \mathbf{x}] - \nabla f(\mathbf{x}_t) = \nabla f(\mathbf{x}_t) - \nabla f(\mathbf{x}_t) = 0$$

כלומר

$$\text{bias}(\nabla f(\mathbf{x}_t), (\mathbf{g}_t \mid \mathbf{x}_t = \mathbf{x})) = 0$$

ולכן  $\mathbf{g}_t$  הוא משערץ בלתי מותה.

**מסקנה 21.7** והמשמעות היא: בפועל הדרך הנקונה לחושב על  $\mathbf{g}_t$  הוא כגודל שווה לגרדיינט המדויק בנקודת  $\nabla f(\mathbf{x}_t)$  + רעש, שהתוחלת שלו היא אפס.

נוכחים שוויון הגראדיאנט (sum of squares)  $f(\mathbf{x}_t) - f(\mathbf{x}^*) \leq \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)$  נכוון עברו **התוחלת** כלומר נובח כי  $\mathbb{E}[f(\mathbf{x}_t) - f(\mathbf{x}^*)] \leq \mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)]$

**משפט 22.7** מתקיים  $\mathbb{E}[f(\mathbf{x}_t) - f(\mathbf{x}^*)] \leq \mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)]$  convexity in expectation:

כלומר זה הוא אישווין הגראדיאנט הסטטיסטי (sum of squares רק בתוחלת)  
הוכחה:

- $\star : \mathbb{E}[f(\mathbf{x}_t) - f(\mathbf{x}^*)] \leq f(\mathbf{x}_t) - f(\mathbf{x}^*) \leq \nabla f(\mathbf{x}_t)^T (\mathbf{x}_t - \mathbf{x}^*)$ . קלומר  $\mathbb{E}\left[\nabla f(\mathbf{x}_t)^T (\mathbf{x}_t - \mathbf{x}^*)\right]$

- נאcir כי ראיינו מעלה כי מתקיים  $\star$ :  $\mathbb{E}[\mathbf{g}_t | \mathbf{x}_t = \mathbf{x}] = \nabla f(\mathbf{x}_t)$

- ממשפט החלוקת נובע כי

$$\begin{aligned}\mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)] &= \mathbb{E}[\mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) | \mathbf{x}_t]] \\ &= \mathbb{E}[\mathbb{E}[\mathbf{g}_t^T | \mathbf{x}_t] (\mathbf{x}_t - \mathbf{x}^*)] \\ &= \mathbb{E}\left[(\mathbb{E}[\mathbf{g}_t | \mathbf{x}_t])^T (\mathbf{x}_t - \mathbf{x}^*)\right] \\ &\stackrel{\star}{=} \mathbb{E}\left[\nabla f(\mathbf{x}_t)^T (\mathbf{x}_t - \mathbf{x}^*)\right]\end{aligned}$$

קלומר

$$\star\star : \mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)] = \mathbb{E}\left[\nabla f(\mathbf{x}_t)^T (\mathbf{x}_t - \mathbf{x}^*)\right]$$

- נשרר את  $\star$  ואת  $\star\star$  ונקבל

$$\begin{aligned}\mathbb{E}[f(\mathbf{x}_t) - f(\mathbf{x}^*)] &\leq \mathbb{E}\left[\nabla f(\mathbf{x}_t)^T (\mathbf{x}_t - \mathbf{x}^*)\right] = \mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)] \\ &\quad . \mathbb{E}[f(\mathbf{x}_t) - f(\mathbf{x}^*)] \leq \mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)]\end{aligned}$$

■

**הערה 23.7** נבחין כי אם לא היו מגדירים פונ' חדשה בOPEN-YOPOORMI בכל סביבות המעבר  $(\mathbb{E}[\mathbf{g}_t | \mathbf{x}_t])^T = \nabla f(\mathbf{x}_t)^T$  לא היה מוצדק.

**bounded stochastic gradient descent:**  $\mathcal{O}\left(\frac{1}{\epsilon^2}\right)$  steps

**משפט 24.7** תהא  $f : \mathbb{R}^d \rightarrow \mathbb{R}$  פונ' קוונקטיות וגיירה ותהי  $\mathbf{x}^*$  נקודת מינימום גלובלית של  $f$ . בנוסף נניח כי  $R$  ו-  $\|\mathbf{x}_0 - \mathbf{x}\| \leq f$  כ- SGD עליה גודל הצעד  $\eta = \frac{R}{B\sqrt{T}}$  :

$$\mathbb{E}[f(\bar{\mathbf{x}}_t) - f(\mathbf{x}^*)] \leq \frac{1}{T} \sum_{t=0}^{T-1} (\mathbb{E}[f(\mathbf{x}_t)] - f(\mathbf{x}^*)) \leq \frac{RB}{\sqrt{T}}$$

**הוכחת המשפט** בדיק כפי שראינו בעבר (מספר פעמים) רק שהפעם:

1. שוב גם כאן  $\bar{\mathbf{x}}_t = \frac{1}{T} \sum_{t=0}^{T-1} \mathbf{x}_t$ .

2. נבחין כי הפעם  $\mathbf{x}_t$  לכל  $t$  הוא משתנה מקרי ולכן לא ניתן להבטיח עבור  $\mathbf{x}_t$  בהתחשבות אחת יקרה משווה מסויים כי  $\mathbf{x}_t$  תלוי בהגרלות שלנו על פנ' כל סיבוב ולכן אי השוויונות וכל המשתנים הסטוכסטיים (המשתנים האקראיים) חיים בתוך תוחלת.

3. מניחים שהגראדיינטים חסומים **בתוכלת**  $\mathbb{E}(\|\mathbf{g}_t\|^2) \leq B^2$

4. השגיאה בממוצע חסומה **בתוכלת**  $\mathbb{E}[f(\bar{\mathbf{x}}_t) - f(\mathbf{x}^*)] \leq \frac{1}{T} \sum_{t=0}^{T-1} (\mathbb{E}[f(\mathbf{x}_t)] - f(\mathbf{x}^*))$  קלומר תוחלת השגיאה על פנ' כל הסיבוביים  $(\mathbf{x}^*) - f(\mathbf{x}^*)$  היא קטנה או שווה מ  $\frac{RB}{\sqrt{T}}$ . ככל שמספר הסיבוביים  $T$  גדול ככל תוחלת השגיאה על פנ' כל הסיבוביים הולכת וקטנה.

**הוכחה:**

החלק הראשון של אי השוויון הראשון מבוצע בגלל אי שוויון י่น על  $f$  כי  $f$  פונ' קמורה ולקיחת תוחלת של התוצאה

$$\mathbb{E}[f(\bar{\mathbf{x}}_t) - f(\mathbf{x}^*)] \leq \frac{1}{T} \sum_{t=0}^{T-1} (\mathbb{E}[f(\mathbf{x}_t)] - f(\mathbf{x}^*))$$

מאוד מזכיר את ההוכחות הקודמות. נזכיר כי עד הרגע הוא  
כפי שראינו בעבר (כמו פעמים)  
מתוקים

$$\begin{aligned} \|\mathbf{x}_{t+1} - \mathbf{x}^*\|^2 &\leq \|\mathbf{x}_t - \eta \mathbf{g}_t - \mathbf{x}^*\|^2 \\ &= \|(\mathbf{x}_t - \mathbf{x}^*) - \eta \mathbf{g}_t\|^2 \\ &= \|(\mathbf{x}_t - \mathbf{x}^*)\|^2 - 2\eta \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) + \eta^2 \|\mathbf{g}_t\|^2 \end{aligned}$$

העברה אגפים תניב

$$2\eta \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \|(\mathbf{x}_t - \mathbf{x}^*)\|^2 - \|\mathbf{x}_{t+1} - \mathbf{x}^*\|^2 + \eta^2 \|\mathbf{g}_t\|^2$$

נסכום על פני  $t \in \{0, 1, \dots, T-1\}$  ונקבל סכום טלסקופי

$$\begin{aligned} \sum_{t=0}^{T-1} 2\eta \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) &\leq \sum_{t=0}^{T-1} \left( \|(\mathbf{x}_t - \mathbf{x}^*)\|^2 + \eta^2 \|\mathbf{g}_t\|^2 - \|\mathbf{x}_{t+1} - \mathbf{x}^*\|^2 \right) \\ &= \left( \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + T\eta^2 \|\mathbf{g}_t\|^2 - \underbrace{\|\mathbf{x}_T - \mathbf{x}^*\|^2}_{>0} \right) \\ &\leq \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + T\eta^2 \|\mathbf{g}_t\|^2 \end{aligned}$$

נמצם ב  $\eta^2$  ונקבל

$$\star : \sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \leq \frac{1}{2\eta} \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + \frac{\eta}{2} T \|\mathbf{g}_t\|^2$$

עד השלב הזה אי השוויונות נכונים בהסתברות אחת. אי השוויון תמיד מתוקים.

כעת נתחל לחשוף בתוחלות.  
ראינו לפיה המשפט הקודם הקודם כי מתוקים  $\mathbb{E}[f(\mathbf{x}_t) - f(\mathbf{x}^*)] \leq \mathbb{E}[\mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*)]$  ולכן

$$\begin{aligned}
& \mathbb{E} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right] \stackrel{\star}{\leq} \mathbb{E} \left[ \sum_{t=0}^{T-1} \mathbf{g}_t^T (\mathbf{x}_t - \mathbf{x}^*) \right] \\
& \stackrel{\star}{\leq} \mathbb{E} \left[ \frac{1}{2\eta} \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + T \frac{\eta}{2} \|\mathbf{g}_t\|^2 \right] \\
& \xrightarrow{\mathbf{x}_0 \text{ is deterministic}} \frac{1}{2\eta} \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + T \frac{\eta}{2} \mathbb{E} [\|\mathbf{g}_t\|^2] \\
& \mathbb{E} (\|\mathbf{g}_t\|^2) \leq B^2 \\
& \|\mathbf{x}_0 - \mathbf{x}\| \leq R \\
& \stackrel{\star}{=} \frac{1}{2\eta} R^2 + \frac{\eta}{2} TB^2 \\
& \stackrel{\eta = \frac{R}{B\sqrt{T}}}{=} \frac{1}{2 \left( \frac{R}{B\sqrt{T}} \right)} R^2 + \frac{\left( \frac{R}{B\sqrt{T}} \right)}{2} TB^2 \\
& = \frac{B\sqrt{T}}{2} R + \frac{R}{2} \sqrt{T} B \\
& = BR\sqrt{T}
\end{aligned}$$

כלומר  $\mathbb{E} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right] \leq BR\sqrt{T}$

$$\frac{1}{T} \sum_{t=0}^{T-1} (\mathbb{E}[f(\mathbf{x}_t)] - f(\mathbf{x}^*)) \leq \frac{RB}{\sqrt{T}}$$


סיימנו.

**הערה 25.7** נבחן שבמהלך הפתרון מקבלים שהשגיאה הממוצעת בתוחלת מקיימת  $\mathbb{E} \left[ \sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*)) \right] \leq \frac{1}{2\eta} \|(\mathbf{x}_0 - \mathbf{x}^*)\|^2 + \frac{\eta}{2} \sum_{t=0}^{T-1} \mathbb{E} [\|\mathbf{g}_t\|^2]$  וראינו שניינו לחושב על  $\mathbf{g}_t$  את  $\nabla f(\mathbf{x}_t)$  (הградיאנט המדויק) + רעש עם תוחלת אפס. וכן על  $\|\mathbf{g}_t\|^2$  לחושב בתור משחו שקשור למומנט השני של  $\mathbf{g}_t$  מכיוון שהתוחלת היא אפס נכון שכך שהמומנט השני (כלומר כרך השווארים) יותר קטן מכמה התוכניות יותר מהירה (סכום השגיאות  $\sum_{t=0}^{T-1} (f(\mathbf{x}_t) - f(\mathbf{x}^*))$  חסום מלמעלה על ידי  $\|\mathbf{g}_t\|^2$ ) ועוד איבר קבוע) כלומר סכום שהשגיאות חסום על ידי סכום הווהרים שולב המשיערים של  $\nabla f(\mathbf{x}_t)$ .

בתרגול נראה דרך להקטין את המומנטים השניים (=הווהרים) במרקחה (של תוחלת אפס) על  $\|\mathbf{g}_t\|^2$  ולקבל אלג' עם קצב התוכניות משופר. לא תמיד אפשר לעשות את זה ובתרגול נלמד דרך "חצ' פרקטית" כדי לעשות זאת.


**דוגמה 26.7** כאן  $n = 10,000$  פונ' אחד מימד 20  $= p$  כלומר  $f_i : \mathbb{R}^{20} \rightarrow \mathbb{R}$  דוגמא לække התוכניות של האלג' הגרדיינט הסטטיסטי אלג' הרגדיינט המלא ואלגורתמי mini-batch (דוגמה של מספר פון' מותוק הקבוצה, מעיין פשרת בין אלג' גראדיאנט סטטיסטי ואלג' גראדיאנט מלא)

Example with  $n = 10,000$ ,  $p = 20$ , all methods use fixed step sizes:



ניתן לראות שאלאג' הגרדיינט המלא מתכנס הכיב מהר ואלאג' הגרדיינט הסטוכסטי הכיב לאט, האלאג' של mini-batch למיניהם נותרנים תוצאה ביניים. אבל זה לא כל התמונה, הנה התמונה של העלות החישובית ביחס למתכנסות.

What's happening? Now let's parametrize by flops:




הפעם במקום איטרציות ציר  $X$  הוא כמות החישובים שהתבצעה (כמויות flop count - floating point operations counts) חישובים בטיפוס נקודה צפה). רואים כאן שהאלג' הגרדיינט המלא מתכנס לשגיאה יותר נמוכה אבל העלות החישובית שלו היא בסדרי גודל משמעותיים יותר. העלות החישובית שלו היא הרבה יותר גבוהה. בזמנן שהאלג' הגרדיינט המלא עשה צעד אחד (הנקודה הראשונה בגרף השחור) שלקח לחשב אותו סדר גדול של  $10^5$  חישובים של פעולות נקודה צפה. האלאג' הסטוכסטי הספיק כבר לעשות הרבה יותר ולහגיה לשגיאה שאינה טרואלית (שגיאה נמוכה) בהרבה פחות חישובים. ואלאג' minibatchhn גם קיבל תוצאה יפה בעלות חישובית גדולה מהאלג' הסטוכסטי וקטנה מהאלג' full gradeint.

**יש כאן מעשה trade off :**

- כאשרנו לוקחים מעט דוגמאות מכל סיבוב מסויף החישובים הוא יותר נמוך וכבר במעט חישובים אפשר לקבל שגיאה שהיא לא טרואלית.
- ככל שנאננו לוקחים יותר דוגמאות מכל סיבוב (כל שגודל batch גדל) (בגרף מ 10, ל 100 ול full) העלות החישובים הולכת ועולה אבל השגיאה שמתכנסים אליה היא יותר נמוכה.

בסוף נסתכל על השגיאה:

Finally, looking at suboptimality gap (on log scale):



כמו שניתן לראות האלאג' full gradeint descent מגיע לשגיאות מאוד קטנות, האלגוריתמים הסטוכסטיים (הרועשים) לא מסוגלים להגיא לשגיאות כל כך קטנות. קלומר אם יש לנו בעיה שבה חשוב לנו מאוד שגיאה מאוד שימוש באלגוריתמים

**סטטיסטיים הוא רעיון לא טוב** במקרה זה. ושוב כפי שאמרנו בד"כ בבעיות פרקטיות של machine learning להגעה לשגיאות כל כך קטנות בסדרי גודל של  $10^{-12}$  זה לא מעניין, ולא משמעותי. (כפי שהסביר עם הדוגמא על הוויז).

## 7.2 תרגול 7

**תזכורת מהסתברות:**

**הגדה 27.7** יהא  $X$  משתנה אקראי RV-random variable עם פונ' פילוג הסתברות  $(\cdot) p$  מעל הקבוצה  $\mathcal{X}$ . (כלומר המ"א  $X$  מקבל ערכים מותך הקבוצה  $\mathcal{X}$  כאשר ההסתברות לקבל כל ערך מהקבוצה  $\mathcal{X}$  מוגדרת על ידי פונ' ההסתברות  $(\cdot) p$ )

- **התוחלת**  $\mathbb{E}[X] \triangleq \sum_{x \in \mathcal{X}} x \cdot p(x)$

- **המומנט השני**  $\mathbb{E}[X^2] \triangleq \sum_{x \in \mathcal{X}} x^2 \cdot p(x)$

- **שונות**:  $\text{var}(X) \triangleq \mathbb{E}[(X - \mathbb{E}(X))^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2$

**משפט החלקה:** יהא  $X$  מ"א והוא  $Y$  מ"א אחר. רצ'

$$\mathbb{E}_X[X] = \mathbb{E}_Y \left[ \underbrace{\mathbb{E}_X[X | Y]}_{\substack{\text{it's an RV:} \\ \text{(function of Y)}}} \right]$$

**הערה 29.7** על ידי משפט החלקה נוכל לחשב תוחלת של משתנים אקראיים.

**מבוא קצר לתורת השערות:**

- יהא  $\theta$  משתנה דטרמיניסטי.

- נניח שאנו מקבלים גישה למשתנה אקראי  $X$  כך שהוא קשור באופן כללי לשונו  $\theta$ , לדוגמה  $(\theta, \sigma^2) \sim \mathcal{N}$ . (כלומר יש גישה ל $X$  ול $X$  יש קשר לשונו  $\theta$ )

- אנו רוצים לשערך את  $\theta$  על  $X$ . (על סמך המדידה/המדידות של  $X$ )

- במקרה אחרות אנו רוצים למצוא פונ'  $f(X) \equiv \hat{\theta}$  כך שverbora מתקיים  $\theta \approx \hat{\theta}$ .

- \* נבחין כי  $X$  הוא משתנה אקראי ולכן  $f(X)$  משתנה אקראי כלומר  $\hat{\theta}$  הוא משתנה אקראי.

- \* נבחין כי  $\hat{\theta}$  הוא משתנה דטרמיניסטי. כלומר  $\hat{\theta} \approx \theta$

- אנו רוצים למצוא שערך **לא מוטה** של  $\theta$  על סמך  $X$ . ככלומר רוצים ש  $\hat{\theta}$  יהיה שערך לא מוטה של  $\theta$ .

- ככלומר רוצים ש  $\hat{\theta} = \mathbb{E}[\hat{\theta}]$  (כלומר שבתוחלת המשערך  $\hat{\theta}$  יהיה שווה לפרמטר  $\theta$  שאנו מנסים לשערך)

כלומר, שבעמוצע, המשערך שלנו טוב.

### 7.2.1 אופטימציה סטטיסטית

**הגדרת הבעה:** רוצים למצער על פני  $a$  את הפונ' הבאה

$$\min_a \mathbb{E}_{a \sim \mathcal{D}} [f(x, a)]$$

כאשר הווקטור  $a$  הוא וקטור אקראי עם פונ' פילוג הסתברות  $\mathcal{D}$ .

**הערה 30.7**  $f(x, a)$  הוא אקראי גם הוא (בגלל ש  $a$  הוא אקראי ו  $f(x, a)$  הינו גם פונ' של  $a$ )

**סימון 31.7** הסימון [ $\cdot$ ]  $\mathbb{E}_{\mathbf{a} \sim \mathcal{D}}$  משמעו "חשב את התוחלת על מה שבפניהם [ $\cdot$ ] לפי משתנה  $a$  שمفולג לפי  $\mathcal{D}$ ".

**הערה 32.7** אנו מנסים למצוא מינימום לתוחלת. נציג כי התוחלת של המשתנה זהה היא דטרמינסטית. (כלומר  $f(\mathbf{a}, a)$  אקראי אבל התוחלת שלו דטרמינסטית התוחלת היא פונ' של  $a$  בלבד (אנו מבצעים תוחלת על  $a$ ) וזה מספר דטרמינסטי).

**הערה 33.7** לא ניתן לבצע אופטימיזציה על מה שהוא אקראי, כי אין לה משמעות. וכך הוכחים את הבעה לדטרמינסטית כמסתכלים על התוחלת שלה.

### Finte sum/FRM

- התוחלת  $\mathcal{D}$  היא באפן כללי לא תמיד ידועה. (אנחנו לא תמיד יודעים את הפילוג  $\mathcal{D}$ , לפעמים זה דברים שקשורים לטבע/דברים שאנו פשוט לא יודעים).

- מה שכן אנו יודעים אלו דוגמאות  $\mathcal{D} \sim \{\mathbf{a}_1, \dots, \mathbf{a}_m\}$  שנציגו מותן הפילוג  $\mathcal{D}$ . נציג כי לכל  $i \in \{1, \dots, m\}$  מותקים ש  $\mathbf{a}_i = (w_1^{(i)} \ w_2^{(i)} \ \dots \ w_d^{(i)} \ y_i)$  הוא וקטור מהצורה  $\{-1, 1\}$

– כאשר  $y_i$  הוא תיוג label (מספר סקלארי מהקבוצה  $\{-1, 1\}$ )

– ולכל כל  $j \in \{1, \dots, d\}$  מותקים ש  $w_j^{(i)}$  הוא סאלקר. מסמנים ש מאפיינים. (עם  $d$  מאפיינים).

$$\mathbf{a}_i = \left( \underbrace{w_1^{(i)}, w_2^{(i)}, \dots, w_d^{(i)}}_{\text{d features}}, \underbrace{y_i}_{\text{label} \in \{0, 1\}} \right) \quad \text{כלומר}$$

**דוגמה 34.7**  $\mathbf{a}_i$  יכול להיות מדידה של האדם  $\text{ה}_i$  (מדידה של  $d$  מאפיינים בתיק רפואי שלו : מעשן/לא מעשן לחץ דם / רמת גליקוז (סה"כ  $d$  מאפיינים) והתיות  $y_i$  הוא האם הבנדאם חולה בקונה. אנו לננו את המדגם המלא  $\mathcal{D}$  של כל האנשים בעולם אבל יש לנו מספר סופי של מדידות מותן התיוג זהה (מה שנמצא base database של קופת החוליםים למשל).

במקרה הזה אין לנו גישה לתוחלת המלאה  $\mathbb{E}_{\mathbf{a} \sim \mathcal{D}} [f(\mathbf{x}, \mathbf{a})]$  שבבטווי מהצורה  $\min_{\mathbf{x}} \mathbb{E}_{\mathbf{a} \sim \mathcal{D}} [f(\mathbf{x}, \mathbf{a})]$  כי אין לנו את הפילוג  $\mathcal{D}$ , אז במקומם נמצא את  $\mathbb{E}_{\mathbf{a} \sim \mathcal{D}} [f(\mathbf{x}, \mathbf{a})]$  נסתכל על הבוטי הבא

$$(P) \quad : \min_{\mathbf{x}} F(\mathbf{x}) = \frac{1}{m} \sum_{i=1}^m f_i(\mathbf{x})$$

מיעור התוחלת האמפירית תוחלת אמפירית). כאשר מסמנים ( $f_i(\mathbf{x}) \equiv f(\mathbf{x}, \mathbf{a}_i)$ )

הנחה:

לכל  $i \in \{1, \dots, m\}$  אז  $f_i$  היא פונ' קמורה ו  $L$  - חלקה.

ניסי לוב:

$$\min_{\mathbf{x}} \mathbb{E}_{\mathbf{a} \sim \mathcal{D}} [f(\mathbf{x}, \mathbf{a})] \xrightarrow{\text{we don't have } \mathcal{D} \text{ so}} \min_{\mathbf{x}} \frac{1}{m} \sum_{i=1}^m f_i(\mathbf{x}) = \min_{\mathbf{x}} \mathbb{E}_{\mathbf{a}_i \sim \text{Uni}} [f(\mathbf{x}, \mathbf{a}_i)]$$

כי המוצע האמפירי הינו "ל"  $(\mathbf{x}) = \mathbb{E}_{\mathbf{a}_i \sim \text{Uni}} [f(\mathbf{x}, \mathbf{a}_i)] = \frac{1}{m} \sum_{i=1}^m f_i(\mathbf{x}) = \frac{1}{m} \sum_{i=1}^m \mathbb{E}_{\mathbf{a}_i \sim \text{Uni}} [f(\mathbf{x}, \mathbf{a}_i)]$  קלומר הממוצע האמפירי Skoł (לפי הדרת התוחלת) לנוחות של הנולה אקראית יוניפורמי מותן הקבוצה  $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_m\}$ . כלומר :  $\forall i \in \{1, \dots, m\} : \mathbb{E}_{\mathbf{a}_i \sim \text{Uni}} [f(\mathbf{x}, \mathbf{a}_i)] = \frac{1}{m} \sum_{i=1}^m f_i(\mathbf{x})$ . כלומר במקומות להתייחס למוגם  $\mathcal{D}$  אנו מבצעים הנחה שהמודגם שיש לנו  $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_m\}$  הוא המדגם המלא האמיטי והקירוב ל  $\mathcal{D}$  שאנו מבצעים הוא ההגלה האקראית היוניפורמי בכל פעם מותן הקבוצה  $\{\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_m\}$ . וכן  $\frac{1}{m} \sum_{i=1}^m f_i(\mathbf{x}) = \mathbb{E}_{\mathbf{a}_i \sim \text{Uni}} [f(\mathbf{x}, \mathbf{a}_i)]$ .

## 7.2.2 אלג' הגרדיינט הסטטיסטי

- נרצה לסייע את

$$(P) \quad : \min_{\mathbf{x}} F(\mathbf{x}) = \frac{1}{m} \sum_{i=1}^m f_i(\mathbf{x})$$

- צעד ערך עבור אלג' הגרדיינט המקורי המלא בהקשר לבעה  $(P)$

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \eta_t \cdot \frac{1}{m} \sum_{i=1}^m \nabla f_i(\mathbf{x}_{t-1})$$

- צעד ערך עבור אלג' הגרדיינט הסטטיסטי בהקשר לבעה  $(P)$

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \eta_t \cdot \mathbf{g}_{t-1}$$

כאשר  $\mathbf{g}_{t-1}$  הוא המשערץ **בלתי מוטה** של  $(\cdot)$  בנקודה  $\mathbf{x}_{t-1}$  כלומר

$$\mathbb{E}[\mathbf{g}_{t-1}] = \nabla F(\mathbf{x}_{t-1})$$

כלומר  $\mathbf{g}_{t-1}$  הוא משתנה אקראי שבתוחלת שלו משווה ל  $\nabla F(\mathbf{x}_{t-1})$  (כלומר ל $\nabla F$  בנקודה  $\mathbf{x}_{t-1}$ ).  
כלומר צעד הערך הוא

unbiased gradient  
estimator

$$\mathbf{x}_t = \mathbf{x}_{t-1} - \eta_t \cdot \widehat{\mathbf{g}_{t-1}}$$


רוב המשערדים הנפוצים ל $\nabla F$  מושגים על ידי **דגם אקראי**

$$\mathbf{g} = \nabla f_i(\mathbf{x}) \quad , i \sim \text{uniform}(\{1, 2, \dots, m\})$$

כלומר דוגמים באיחוזות אינדקס  $i$  מתוך הקבוצה  $\{1, 2, \dots, m\}$  ומשתמשים בגרדיינט של  $f_i$  כמשערץ לגראינט של  $F$ . נראה שמשערץ זה אכן בלתי מוטה

$$\mathbb{E}[\mathbf{g}] = \sum_{i=1}^m \frac{1}{m} \cdot \nabla f_i(\mathbf{x}) = \nabla \left( \sum_{i=1}^m \frac{1}{m} \cdot f_i(\mathbf{x}) \right) = \nabla F(\mathbf{x})$$

$$\mathbf{g} = \nabla f_i(\mathbf{x}), \quad i \sim \text{Uniform}(\{1, \dots, m\})$$



נבחן כי לא מובטח שבכל צעד אנו נתקדם בכיוון הכלול של מינום של  $\nabla F$  כמו באlg' הגרדיינט המקורי (כלומר יתכו סיבובים בהם נתרחק מנקודת המינימום) אבל **בתוחלת אנו נקרב לשם**.

- בחירה נפוצה נוספת נקראת mini-batch. דוגמיה באיחודת תת קבוצה  $I$  בגודל  $b$  (כאשר  $m < b$ ) מותוך  $\{1, \dots, m\}$  וממציעים את הגרדיינט של  $\{f_i\}_{i \in I}$  לקבלת המשערץ

$$\mathbf{g} = \frac{1}{b} \sum_{i \in I} \nabla f_i(\mathbf{x})$$

- ניתן לוודא שגם משערץ גרדיאנט זה הינו בלתי מוטה.
- לבחור mini-batch מקטין את השונות של המשערץ שלו. לעומת זאת בבחירה של דוגמיה בודדת בכל סיבוב (שבעלת שונות גודלה יותר).
- זו הגשיה הפרקטית ביותר שראינו עד כה.
- ככל הווarians קטן כי לוקחים יותר דוגמאות ומצד שני חישוב כל גרדיאנט יהיה יקר יותר חישובית ( $(b)\mathcal{O}$ ). ולכן זה מעין tradeoff.

**אלגוריתם 5** אלג' הגרדיינט הסטוכסטי (SGD) - תרגול 7

**Data:** Initial guess,  $\mathbf{x}_0$ , set of step sizes  $\{\eta_t\}_{t \geq 1}$

**for**  $t = 1, 2, \dots$  **do**

**g** $_t \leftarrow$  UnbiasedGradientEstimate( $\mathbf{x}_{t-1}$ )

**x** $_t \leftarrow \mathbf{x}_{t-1} - \eta_t \mathbf{g}_t$

**end**

**אלג' הגרדיינט הסטוכסטי: הנחת Realizability** לעיטים (לא תמיד ולא בכל הנסיבות) ניתן להניח כי המינימום הגלובלי של  $F(\mathbf{x}) = \frac{1}{m} \sum_{i=1}^m f_i(\mathbf{x})$  הוא גם המינימום הגלובלי של כל  $f_i$  בנפרד ככלומר קיים  $\mathbf{x}^* \in \mathbb{R}^n$  המקיים

$$\forall i \in \{1, \dots, m\} : \nabla f_i(\mathbf{x}^*) = 0$$

עבור ההנחה הנ"ל, קצב ההתכנסות של אלג' הגרדיינט הסטוכסטי הינו  $\mathcal{O}\left(\frac{1}{t}\right)$ .

**лемה 35.7** תהא  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  פונ'  $L$  חלקה ובעל מינימום גלובלי המתקיים בנקודה  $\mathbf{x}^*$ . אזי לכל  $\mathbf{x} \in \mathbb{R}^n$  מתקיים

$$\|\nabla f(\mathbf{x})\|_2^2 \leq 2L(f(\mathbf{x}) - f(\mathbf{x}^*))$$

## 8 הרצאה 8 ותרגול 8

### 8.1 הרצאה 8

**תקציר השיעור הקודם:**

בשיעור הקודם דיברנו על אלג' SGD-stochastic gradeint descent ובערך סיימנו לדבר עליו. ריאנו כי הוא מתאים לפתרון כאשר פונ' המטרה היא סכום של הרבה פונ'  $f(\mathbf{x}) = \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$ . אמרנו שניתן להפעיל את אלג' full gradeint (כלומר אלג'

גרדנט הנקורי) אבל זה יהיה מאוד יקר חישובית והיא תהיה פורפורציונית ל- $n$ . בבעיות פרקטיות  $n$  הוא מספר גדול במיוחד (למשל מיליאדים) ולכן גודל הבחירה הינה מוגבל על ידי  $n$  הבחירה בין כל סיבוב אפשרי. לכן נשתמש באלגוריתם הנקרא SGD (Full gradient descent) שמבצע סיבוב אחד בכל איטeration. בדוגמה הבאה נסביר כיצד מושגנו את הגרדנט  $\nabla f_i(x_t)$  בזאת ש- $x_{t+1} = x_t - \eta_t g_t$ , כלומר  $\nabla f_i(x_{t+1}) = \nabla f_i(x_t) + \nabla f_i(x_t) - \eta_t \nabla f_i(x_t)$ .

ראיינו בנוספֿה:

- אלי SGD לא מסוגל לפתורו את אופטימליים קטנים מאוד מאד. (לדוגמא  $\epsilon = 10^{-12}$  כת אופטימלי). כל צורך מעשי בmachine learninganno נזדקק לפתורו את אופטימליים סבירים יותר (מוגנים יותר) (לדוגמא  $\epsilon = 10^{-3}$  כת אופטימלי) ועבור מקרים אלו אלי SGD יכול להתכנס לפתרונות אלו בסבוכיות חישובית קטנה יותר מאשר במקרה הגרדיינט המלא.
  - ראיינו שהבטחת ההתכנסות היא על צעד לימוד דועץ מהצורה  $\frac{R}{B\sqrt{T}}$  (כל שורצים להריץ את האלג' למשך  $T$  צעדים אז קצב הלימוד דועץ). בוגיון לתאוריה הקלאסית שפתחנו בהרצאה הקודמת, מה שעשווים באופן מעשי עברו קביעת קצב הלימוד  $\eta$  באלאי SGD:

1. דבר אחד שמקובל לעשות זה **לקבוע קצב לימוד גודל צעד** (*ה*) **קבוע** ובעצם לכוון מראש את הקצב הקבוע הזה על ידי בחינה של הביצועים של האלגוריתם על תות קבוצה קטנה מספק של dataset (זה מעין תהליכי של וולדיציה-מיון של היפר פרמטר: גודל הצעד) ורק לאחר מכן לאחר שמצאנו קצב לימוד שמספק תוצאות טובות אנו משתמשים בו לבחינה של כל dataset.

2. דבר אחר שמקובל לעשות שימוש בקצב לימוד אדפטיבי לדוגמא על ידי אלגוריתם adagrad

3. יש המונח טריקים פופולריות שימושיים בהם בפועל בעלי שיש מאחריהם תאויריה אנלטית מוצקה, לדוגמא שיטות של

### (א) מומנטום Momentum

### (ב) תאוצה Acceleration

(ג) **מייצוג** (averaging) מושג מאוד חשוב בפתרון בעיות אופטימיזציה רגילהות ובעיות אופטימיזציה סטוכסטיות-חישוב אחד יותר, עוזר להפחית את הרעש של הפתרון

4. אלגוריתמים של SGD הם מודרניים גם בפרטן של בעיות large-scale, continuous, nonconvex optimization (רכיפות לא קמורות ובמידות גבוהה) מפעילים את השיטות בשביל לפתרון במקרה והם עובדות בצורה די טובת, אבל עדין קיימות המנו שאלות פתוחות בקשר לשימוש בשיטה זו לבעיות כלליות (אחת השאלות החשובות לדוגמא שעוננה פتوוחה היא בקשר לimplicit regularization (implcit regularization (imp))) כולםanno לא מבינים מדוע השיטות הללו עובדות בפועל עבור בעיות מחסוגים הללו. זה נחשב נושא מחקר מאוד פעל.

## התחלת השיעור הנוכחי:

. SGD נזכר על גרסאות נוספות לאלג' ה

נזכיר כי עדיןanno רוצים לפרט את בעיית האופטימיזציה מהצורה

$$\min_{\boldsymbol{x}} f(\boldsymbol{x}) = \min_{\boldsymbol{x}} \frac{1}{n} \sum_{i=1}^n f_i(\boldsymbol{x})$$

### 8.1.1 הרכבה אפשרית ראשונה לאלאג' ה SGD: אלגוריתם ה SGD

במוקם להשתמש בפונ'  $f_i$  אחת  $f_i$  (מתוך  $n$  הפונ')  $\{f_i\}_{i=1}^n$  לצורך חישוב הנגזרת  $g_t$  בנקודה  $x$ . בשיטות של SGD מושתמשים **במייצוע** על פני כמה מהן.

כלומר צעד העדכון באgal' מסווג זה המה策ורה:

$$\tilde{\mathbf{g}}^t = \frac{1}{m} \sum_{j=1}^m \mathbf{g}_t^j$$

אפשר לנתח את חישוב הגרדייאנט  $\hat{g}$  כולל העדכון שבמוצע על ידי Mini-batch SGD באופן הבא:

1. לכל איטרציה  $t = 0, 1, 2, \dots$

- (א) בחר  $m$  פול' באקראי מתוך  $\{f_1, f_2, \dots, f_t^m\}$ . תהא הבחירה  $f_i$  המתקבלת עבור האיטרציה  $t$ .
- (ונסמן)  $\forall j \in \{1, 2, \dots, m\} : g_t^j = \nabla f_t^j(x)$
- (ב) חשב  $\tilde{g}_t = \frac{1}{m} \sum_{j=1}^m g_t^j = \frac{1}{m} \sum_{j=1}^m \nabla f_t^j(x)$
- (ג) עדכן  $x_{t+1} = x_t - \eta_t \tilde{g}_t$

**הערה 1.8** נשים לב למקרי הקיצור:

- אם  $1 = m$  אז אנו מבצעים שימוש רק בפונ' אחת  $f_i$  לצורך חישוב הגרדיינט  $\tilde{g}$  ולכון עבור מקרה זה האל' המתתקבל שקול לאל' SGD.

- אם  $n = m$  אז אנו משתמשים בכל הפונ'  $\{f_i\}_{i=1}^n$  לצורך חישוב הגרדיינט  $\tilde{g}$  ולכון עבור מקרה זה האל' המתתקבל שקול לאל' full gradient. ואז היעילות החישובית של האל' נפגעת מאוד (היא כמו full gradient כלומר היא לא יעילה ממשיכי-השוויה כי היא בסדר גודל של  $(O)$  ולכון  $m$  הוא בדרך כלל קטן בסדרי גודל מ- $n$ ).

**הערה 2.8** יתרון של אל' ה- Mini-batch SGD הוא שחישוב הגרדיינטים באופן טבעי יכול להיות מוחושב **באופן מקביל**.

**הערה 3.8** בעולם האמיתי מואוד מקובל להשתמש באל' Mini-batch SGD ולבחר  $m$  כלשהו כאשר  $1 < m < n$ . מסתבר שמתהボנותם בוגר של השגיאה כפונ' של מספר החישובים מתרבר שהדבר הממולץ לעשות לקחת  $m$  שהוא טיפה יותר גדול מ- $n$  והגדלים הפולוריים הם  $m \in \{32, 64, 128\}$ .

### 8.1.2 החרבה אפשרית שנייה לאל' ה SGD: אלגוריתם ה Stochastic subgradient Descent

$$\min_{\mathbf{x}} f(\mathbf{x}) = \min_{\mathbf{x}} \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$$

כעת יכולות להיות פול' בקבוצה  $\{f_i\}_{i=1}^n$  שאין בהכרח גירות. ככלומר גם  $f$  אינה בהכרח פול' גירה. עבור בעיות שאינן בהכרח גירות, נציג שני קל באל' SGD כך שיישתמש בסאב-גרדיינטים של  $f_i$  בכל איטרציה (בתחילה לגרדיינטים שלה).

אפשר לנתח את חישוב הגרדיינט  $\tilde{g}$  כולל העדכו שבסוצע על ידי Stochastic subgradient Descent באופן הבא:

Stochastic subgradient Descent

$t = 0, 1, 2, \dots$ דגום $i \in \{1, 2, \dots, n\}$ מתוך פילוג אחד. סמן $g_t \in \partial f_i(\mathbf{x}_t)$ עדכו $\mathbf{x}_{t+1} = \mathbf{x}_t - \eta_t g_t$
--

במילים אחרות, אנו משתמשים **במשערך הבלתי** מוטה של הסאב-גרדיינט בכל נקודה

$$\mathbb{E}[g_t | \mathbf{x}_t] \in \partial f(\mathbf{x}_t)$$

האל' מתכנס בקצב של  $(\frac{1}{\epsilon^2})$ . כדי לקבל פתרון  $\epsilon$  תת אופטימלי נצרך סדק גודל של  $\frac{1}{\epsilon^2}$  סיבוביים, גם כאן השיך של התוכניות הוא **בתחולות** השגיאה (האל' סטטיסטי). ניתן להראות את ההוכחה התוכניות על ידי שימוש בתחילת ההוכחה בהגדרת הסאב-גרדיינט (הגדרת הסאב-גרדיינט: אי שוויון הסאב-גרדיינט, שדומה מאוד לאי שוויון הגרדיינט) במקומות אוי שוויון הגרדיינט שהיהה בשימוש בהוכחה המקורית של SGD. זאת אומרת שהאל' Stochastic subgradient Descent פועל בביטויים שווים לאל' Stochastic gradient Descent.

### 8.1.3 החרבה אפשרית שלישיית לאל' ה SGD. בעיה מאולצת :Constrained optimization

projected SGD projected Stochastic gradient Descent כלומר projected SGD כולם ריצה לפטור בעיה מצורה

$$\min_{\mathbf{x} \in \mathcal{X}} f(\mathbf{x}) = \min_{\mathbf{x} \in \mathcal{X}} \frac{1}{n} \sum_{i=1}^n f_i(\mathbf{x})$$

כלומר בעיה זו,  $\mathbf{x}$  חייב להיות שייך לקבוצה  $\mathcal{X}$  כלומר תחום האילוץ הוא הקבוצה  $\mathcal{X}$ , כאשר  $\mathcal{X}$  היא קבוצה קמורה וקומפקטיבית (כלומר קמורה, סגורה וחסומה).

- ראיינו בעבר כי גישה אחת לפטור בעית מאולצות עם אלג' איטרטיבים היא לבצע אלג' גרדיאנט ולאחר כל צעד לבצע הטלה חזרה לתוך האילוץ. (=צעד הטלה בכל סיבוב) לאלאג' שמבצע זאת קראנו projected gradient descent משאו מקביל:

על מנת להשתמש בReLU של אלגוריתם SGD עבור בעיה עם אילוצים, נוכל לבצע משאו מקביל:

1. בכל סיבוב מחשבים את הגרדיינט לפונ' אחת שנבחרת באקראי.

2. מביצאים את עדכון הגרדיינט לפי הכלל של SGD.

3. מביצאים הטלה של הנקודה שהתקבלת לתוך האילוץ.

**כלומר:**

projected SGD

$t = 0, 1, 2, \dots$

(א) דוגם  $\{n\}_{i=1}^{\infty}$  מותך פילוג אחד.

(ב) סמן  $\mathbf{g}_t = \nabla f_i(\mathbf{x}_t)$

(ג) עדכון  $\mathbf{x}_{t+1} = \prod_X (\mathbf{x}_t - \eta_t \mathbf{g}_t)$

אם כן האלג' מתכנס בקצב של  $(\frac{1}{\epsilon^2})$ . (כדי לקבל פתרון  $\epsilon$  תת אופטימלי נטריך סדק גודל של  $\frac{1}{\epsilon^2}$  סיבובים), גם כן השיכ שhttcnostot הוו **בתחולת השגיאה** (האלג' סטוכסטי). זאת אומרת שהאלג' projected SGD פועל בביטויים שווים לאלאג' SGD.

ובזאת מסתיים הדיון על SGD ועל הנסיבות השונות למש אותו.

#### 8.1.4 מוטבציה לאלגוריתם Frank Wolfe

אלגוריתם שפותח בשנות החמישים אבל בשנים האחרונות צובר הרבה פופולריות.


לפנ' שני שיעורים דיברנו על בעיות אופטימיזה עם אילוצים:

כלומר אלו בעיות מהצורה הבאה:

$$\begin{aligned} & \min f(\mathbf{x}) \\ & \text{s.t } \mathbf{x} \in X, X \subseteq \mathbb{R}^d \end{aligned}$$


כאשר  $X$  היא קבוצה קומפקטיבית (=סגורה וחסומה) קמורה.

**איור למחשה:**



אחד הרעיונות שהרנו על מנת לפטור את הבעיה זו היא להשתמש באלאג' projected GD כלומר להשתמש באלאג' הגרדיינט בעיצוע הטלה על תחום האילוץ  $X$  לאחר הליכה לכיוון הגרדיינט לאחר כל איטרציה.

**צעד עדכון לדוגמא:**



חלק מהשימוש באלג' projected GD, מה שהיינו צריכים לחשב בכל צעד זה את **ההטלה** של של  $x_t - \eta g_t$  על התחום  $X$ . באופן כללי בעית הטליה (=הנקודה הקרובה ביחס לתחום  $X$  לנקודה  $x_t - \eta g_t$ ) **היא בעית אופטימיציה בפני עצמה**. ראיינו שישנם מקרים שיחסוב ההטלה אינו מסובך ויכול להתבצע ביעילות אבל גם גילינו שישנם בעיות רבות שבהם  $X$  אינם בהכרח תחום שלבצע את חישוב ההטלה עליו הוא משימה קלה. עבור בעיות אלו הפעלת אלג' projected gradeint descentה.

#### • נזכיר את בעית הטליה projection

בעית הטליה כאמור היא בעית אופטימיציה בפני עצמה. לדוגמה, **בעית הטליה של  $y$  על התחום  $X$**  נתונה על ידי  $\min_{x \in X} \|y - x\|_2^2$ . כלומר בכל סיבובו של projected gradeint descent علينا לחשב את הטליה  $\min_{x \in X} \|(x_t - \eta g_t) - x\|_2^2$ . מכאן נובע **שבעית הטליה היא בעית אופטימיציה ריבועית**.

#### • נזכיר את בעית הקירוב הלינארי Linear opt.problem

פתרון בעית אופטימיציה לינארית  $x = \arg \min_{x \in X} g^T x$

• **אלג' פרנק וולף** מカリ בעובדה שיחסוב בעית הטליה (אמור, בעית אופטימיציה ריבועית) נחשבת קשה ומציע פתרון של בעיה מסווג אחר : בעיתת הקירוב הלינארי. הם שאלו את עצם האם נתן לפטור את הבעיה של אופטימיציה עם אילוצים על ידי שימוש בפתרונות של **בעיתת הקירוב הלינארי  $x_t = \arg \min_{x \in X} g_t^T x$**  (אלו יותר חישובית) ולעתות בו שימוש על מנת לעדכן את הפתרון בכל איטרציה. במקרים שימוש בפתרונות של בעית הטליה(קירוטות יותר חישובית) (כמו projected gradient descent) והם מצאו דרך לעשות זאת.

– **בכל איטרציה באלג' פרנק וולף**

\* נתבונן בגרדיינט (=על מישור) של הפונ' בנקודה  $x_t$  (נקרא גם **"הקירוב הלינארי של הפונ' בנקודה  $x_t$ "**)


\* נמצא את הנקודה הפיזיבלית (=בתחום האילוץ) על העל מישור (=הגרדיינט) עבורה העל מישור עצמו מקבל את הערך הכי נמוך ונסמך נקודה זו  $s_t$ (כלומר  $s_t = \arg \min_{x \in X} g_t^T x$ ) היא פתרון של בעיתת האופטימיציה  $\min_{x \in X} g_t^T x$  (=נתן להראות שמכיוון שהעל מישור (=הגרדיינט) הוא מישור קבוע, המינימום של הפונ' **תמיד מתקיים בקצוות התחום  $X$** ), כלומר  $s_t$  היא הנקודה שבה העל מישור מקבל את הערך הכי נמוך בתחום  $X$  (זה פתרון של בעית אופטימיציה קמורה). (לא נכון זאת).

.  $s_t$  יהיה תמיד על הגבול/השפה של התחום שעליו אנו מבצעים אופטימיציה  $X$ .

\* נתקדם מנקודה  $x_t$  אל עבר הכוון של  $s_t$  על ידי גודל צעד מסוימים.(באופן בו גודל הצעד משאיר אותנו פיזיבליים, כלומר  $s_t = \frac{2}{t+1}(x_t - \gamma_t)$  וכן נעשה בכל איטרציה  $x_{t+1} = x_t + \gamma s_t$  (התוצאות  $x_t$  ייה שווה למעין סוג של ממוצע בין הנקודה  $x_t$  לנקודת  $s_t$ ).

כלומר בכל איטרציה לוקחים את הנקודה שנמצאים בה, מבצעים לינאריזציה של הפונ' (=כלומר, נתייחס רק לגרידנט של הפונ') ונבדוק על איזה נקודה הגרדיינט הכי נמוך בתחום  $X$  ונתקדם בצעד  $\eta$  לכיוון זה.

– את הפתרון של בעיתת האופטימיציה  $x_t = s_t = \arg \min_{x \in X} g_t^T x$  ניתן למצוא בצהורה עיליה.



#### 8.1.5 אלגוריתם Frank Wolfe/conditonal gradient

נניח שיש לנו אלג' שכבר פוטר את בעיתת **בעיתת הקירוב הלינארי Linear opt.problem** באופן יעיל. אזי האלגוריתם הזה יקרא "פותר solver ויסומן ויקרא גם:

**סימון 4.8**  $LMO(g) \equiv \arg \min_{s \in X} \langle s, g \rangle = \arg \min_{s \in X} g^T s$  **נדיר Linear Minimization Oracle**

## אלגוריתם 6 אלגוריתם פרנק וולף

1. לכל איטרציה  $t = 0, 1, 2, \dots$

$$(a) \quad s_t = \text{LMO}(\nabla f(x_t))$$

$$(b) \quad x_{t+1} = (1 - \gamma_t)x_t + \gamma s_t$$

$$\cdot \gamma_t = \frac{2}{t+2}$$

**הערה 5.8** בהרצאה נאמר שהמשקל הוא  $\frac{2}{t+1} \gamma_t$ . ולדעתי אם זה המשקל אליו צעד העדכון צריך להיות  $x_{t+1} = (1 - \gamma_{t+1})x_t + \gamma_{t+1}s_t$ . (אחרת  $\gamma_t$  עלול להיות גדול מ-1 באיטרציה הראשונה) תגבות המרצה: "בוא נניח שמתחלים מאטרציה  $t=1$ " ככלומר עבור המקרה הזה, האלג' הוא:


1. לכל איטרציה  $t = 1, 2, \dots$

$$(a) \quad s_t = \text{LMO}(\nabla f(x_t))$$

$$(b) \quad x_{t+1} = (1 - \gamma_t)x_t + \gamma s_t$$

$$\cdot \gamma_t = \frac{2}{t+1}$$

איור לדוגמא:



(יש הסבר מוצלח על האיור הנ"ל בתרגול 8)

**הערה 6.8** אם הפונ' המקורית היא בעצמה לינארית, אז אלג' פרנק וולף יתכנס בצעד אחד מכיוון שהקירוב הlienארי לפונ' הוא בעצם הפונקציה עצמה.(במקרה זה עבור גודל צעד של גודל צעד 0).( $0 < \gamma_t = \frac{2}{t+2} < 0$ )

$$\begin{aligned} x_1 &= [(1 - \gamma)x_t + \gamma s_t]_{t=0} \\ &= [(1 - 1)x_t + 1 \cdot s_t]_{t=0} \\ &= s_0 \\ &= \text{LMO}(\nabla f(x_t)) \\ &= \text{LMO}(f(x_t)) \end{aligned}$$

ולכן זו ההתקנסות.

**הערה 7.8** בכל צעד נישאר פיאבוליליס נראה זאת באינדוקציה על  $t$ :  
כלומר נוכח כי  $\{ \dots \} \forall t \in \{0, 1, \dots\}$  מתקיים ש  $x_t \in X$ .

- **בסיס**  $X \in x_0$  נקודת התחלה, חייב להיות פיזבלית כי ככה בוחרים אותה מראש.
- **הנחה**  $X \in x_t$  היא נקודת פיזבלית.
- **צעד** נוכח כי  $x_{t+1} \in X$ .

– אנו יודעים כי  $X \in x_t$  לפי הנחת האינדוקציה.

–  $s = \text{LMO}(\nabla f(x_t)) = \arg \min_{s \in X} [\nabla f(x_t)]^T s$  כלומר  $s$  הוא פתרון של בעית אופטימיזיה מואלצת בתחום  $X$  ולבן  $s \in X$ .

–  $X$  תחום קמור ולבן לכל  $k \in [0, 1]$  ולכל  $x, y, z \in X$  מתקיים  $(1 - k)y + zk \in X$  ובפרט עבור  $s, x \in X$  ועבור  $\gamma_t \in [0, 1]$  מתקיים  $(1 - \gamma_t)s_t + x_t\gamma_t \in X$  ולבן  $x_{t+1} = ((1 - \gamma_t)s_t + x_t\gamma_t) \in X$


**הערה 8.8** כלומר הנקודה  $x_{t+1}$  תהיה בתחום האילוץ. מכיוון שהאלג תמיד לוקח צירופים קמורים של נקודות בתחום האילוץ  $X$ . ולבן כל הנקודות באלאג' יהיו בתחום.

**הערה 9.8** כלומר הנקודה  $x_{t+1}$  תהיה בתחום האילוץ. מכיוון שהאלג תמיד לוקח צירופים קמורים של נקודות בתחום האילוץ  $X$ . ולבן כל הנקודות באלאג' יהיו בתחום.

**תכונות של אלג' פרנק-וולף:**

1. **האלג' מפיק נקודות פיזוביליות לכל אורךו :**  $x_t \in X, x_1, \dots, x_0, x$ . (כיוון ש  $x_{t+1}$  על הקוד המחבר בין  $[s, x_t]$  עברו  $\gamma_t \in [0, 1]$  כל הנקודות הם תמיד בתחום).
2. **יעילות חישובית:** בכל סיבוב האלאג' פותר בעיות LP במקומות אלג' שפתר בעיות ריבועיות (=לא בעיות ליניאריות) (בעיות הטלה).
3. **האלג' לא מחשב הטלות כלל** (בגלל 1)
4. **האייטרציות של האלאג' הן דليلות** sparse iterates
  - (א) נזכר בתחום אילוצים ליניארי, פאונים (נקרא גם "בעיות של פוליטופים") :
  - . מה זה פוליטופ (מצולע רב מימדי) ? זה אוסף של אילוצים ליניארים.
  - ii. **תזכורת:** פאון Polyhedron (פוליהדרון) הוא קבוצה  $\{x | Ax \leq b\}$  כאשר  $A \in \mathbb{R}^{n \times n}, x, b \in \mathbb{R}^n$  וכאשר בהקשר זה הסימן  $\leq$  מוחשב לכל שורה בנפרד.
  - כלומר פאון היא הקבוצה המוגדרת על ידי אוסף  $x$ -ים המהווים פתרונות למערכת המשוואות הלינארית (מערכת  $A, C \in \mathbb{R}^{n \times n}, x, b, d$ ,  $\{x | Ax \leq b, Cx = d\}$  כאשר  $C, d \in \mathbb{R}^{m \times n}$ )

$\mathbb{R}^n$  :



iii. כ启发ורים בעיות עם פוליטופים הפתرون תמיד יהיה אחד מהקודקודים. זאת אומרת  $x_t$ -ים תמיד יהיו קודקודים של תחומי האילוץ.

ו. תחום אילוץ לינארי שצהה, מכיל הרבה פעמים המון קודקודים, שיכולים להיות אפילו אקספוננציאליים במרחב היביר  $n$ .

(ב) נבחן כי לכל  $T$  ניתן לבטא את  $x$  באופן הבא:

$$\begin{aligned} x_t &= \sum_{t=1}^{T-1} \alpha_t s_t + \alpha_0 x_0 \\ \alpha_0 + \sum_{t=1}^{T-1} \alpha_t &= 1 \\ \forall t \in \{0, 1, \dots, T-1\} : \alpha_t &\geq 0 \end{aligned}$$

כלומר  $x$  הוא צירוף קמור של  $x_0$  ושל כל הקודקודים שראינו במהלך הבעיה  $\{s_t\}_{t=1}^{T-1}$ .

(ג) הכוונה sparse בהנタン בעיות שהאילוץ בו הוא לינארי (פוליטוף עם המון המון קודקודים), אףלו מספר הקודקודים יכול להיות אקספוננציאלי במרחב היביר  $n$  (זה יכול לקרות די הרבה, למשל במקרה של מושגים קומביורואטים). אם נרים את האל' למשך  $T$  איטרציות  $\alpha_0 x_0 + \sum_{t=1}^{T-1} \alpha_t s_t$  אליו הנקודה  $x$  תקבע רק על ידי  $T$  קודקודים, ולא מעבר לה. (כלומר האל' נקרא "דלי" כי לא משתמש בתחומי האילוץ אלא בכל איטרציה מתחשב רק בחשבונו רך עוד קודקוד אחד נוסף). לרבות האיטרציות  $T$  הוא קטן יותר בסדיי נודל מכמהות כל הקודקודים שבתחום האילוץ. (לדוגמא, בסדר גודל של אלפיים או מאות, ומספר הקודקודים הוא  $2^{100}$  או  $2^{1000}$ ) איזו נאמר שהיצוג של  $x$  הוא דלי במספר הקודקודים.


. כולם דليل הכוונה דليل במספר הקודקודים שמייצנים את  $x$  ביחס לכמות הקודקודים הכוללת בתחום האילוץ.

**דוגמא: בעית לאסו** נתבונן בעיית האופטימציה הבאה


$$\begin{aligned} \min_x \|Ax - b\|_2^2 \\ \text{s.t } \|x\|_1 \leq 1 \end{aligned}$$

נבחן כי פונ' המטרה  $\|Ax - b\|_2^2$  היא פונ' ריבועית. **תוצאות:** נורמת  $\|x\|_1$  היא מהצורה  $\sum_{i=1}^n |x_i|$  (בכום הערכים המוחלטים של כל הרכיבים בווקטור  $x$ ). כלומר האילוץ הוא כדור נורמה סביב הראשית ברדיוס 1. אפשר גם לומר שהוא שטח Convex hull שנמצא על ידי וקטורי היחידה כלומר  $X = \{x \mid \|x\|_1 \leq 1\} = \text{conv}(\pm e_1, \pm e_2, \dots, \pm e_n)$

**דוגמיה 10.8** כדור  $\|x\|_1 \leq 1$  ברדיויס 1 בדוח מימד:



**דוגמיה 11.8** כדור  $\|x\|_1 \leq 1$  בשלושה מימדים:



דוגמאות לחיתוך חלק מתחום האילוץ של כדור  $\|x\|_1 \leq 1$  ברדיויס 2. (כלומר האירור הוא חלק מהאילוץ 1  $\|x\|_1 \leq 1$ )

או בעצם יש לנו בעיית אופטימציה קונבקטית  $\min_{\|x\|_1 \leq 1} \|Ax - b\|_2^2$  עם תחום האילוץ של הפוליטוף (=פאון) הזה הפוליטוף הוא כדור נורמה סביב הראשית ברדיויס 1 כלומר:  $\|x\|_1 \leq 1$ . נרצה לראות כיצד נראים העדכונים של פרנק וולף עבור האלג'זה.

$$\nabla f(x) = g = A^T(Ax - b)$$

$$\text{LMO}(g) = -\text{sign}(g_i) e_i \quad , \text{with } i = \arg \max_{i \in \{1,2,3,\dots,n\}} |g_i|$$

נבחן כי הפתרון של  $\text{LMO}(g)$  פשוט בהרבה מביצוע ההטלה על כדור נורמת  $\|x\|_1$ . כלומר לחישוב ה  $\text{LMO}(g)$  בסה"כ עוברים על הווקטור פעמי אחת ומוצאים בו את הרכיב הגדול ביותר. (סבירות כגודל ממד הבעה: המימד של  $\text{LMO}(g)$  במקורה הזה הפתרון של  $\text{LMO}(g)$  הוא קל ולכן אילוצי  $\|x\|_1$  זה בעיה קלאסית לפתרון עם אלג' פרנק וולף).

נבחן מדוע הפתרון  $\text{LMO}(g) = -\text{sign}(g_i) e_i \quad , \text{with } i = \arg \max_{i \in \{1,2,3,\dots,n\}} |g_i|$  של בעיית המינימזציה?

$$\text{LMO}(\mathbf{g}) = \min_{\|\mathbf{x}\|_1 \leq 1} \mathbf{g}^T \mathbf{x} = \sum_{i=1}^n g_i x_i$$

בנוספַּח אנו יודעים כי  $X \in \mathbb{R}^n$  ולקו  $\|\mathbf{x}\|_1 \leq 1$  כלומר  $\sum_{i=1}^n |x_i| \leq 1$  כלומר מכאן נובע שאפשר לחשב על כל  $x$ -ים כמעין משקלים שהsuccם שלהם בערך מוחלט מניב מספר שהוא לכל היותר 1. אז מה שיביא למיינמוס את הבעה יהיה למצוא את  $g_i$  שבערכו המוחלט הוא הגדול ביותר ולתת לו את כל המשקל (משקל אחד) תוך סימן מתאים. (סימן שייחס את המכפלה לשילנית). וכן התוצאה של בעית האופטימציה היא:

$$\text{LMO}(\mathbf{g}) = -\text{sign}(\mathbf{g}_i) e_i \quad , \text{with } i = \arg \max_{i \in \{1, 2, 3, \dots, n\}} |g_i|$$

**דוגמה (1) שתמכייש מדויע הפתרון נכון:**

$$\min_{\text{s.t.: } |x_1| + |x_2| \leq 1} 2x_1 - 3x_2$$

נרצה לחשב איך אנחנו מחלקים את וקטור המשקלים שלנו  $\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$  כך שפונ' המטרה  $(2x_1 - 3x_2)$  תהיה הקטנה ביותר תוך שהנקודה שנבחר תשאיר פיזibilitה  $|x_1| + |x_2| \leq 1$ . ניתן להשתכנע שהפתרון באופטמלי במקרה זה הוא

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

**דוגמה (2) שתמכייש מדויע הפתרון נכון:**

$$\min_{\text{s.t.: } |x_1| + |x_2| \leq 1} 2x_1 - x_2$$

במקרה הזה הפתרון באופטמלי במקרה זה הוא

$$\mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = \begin{pmatrix} 0 \\ -1 \end{pmatrix}$$

**במקרה הכללי:**

$$\text{LMO}(\mathbf{g}) = -\text{sign}(\mathbf{g}_i) e_i \quad , \text{with } i = \arg \max_{i \in \{1, 2, 3, \dots, n\}} |g_i|$$


כאשר  $e_i$  הוא וקטור היחידה בכיוון  $i$ .

**מושג ה Duality Gap** נניח שיש לנו פונ' לינארית, לדוגמא פונ' לינארית שונרת ככה  $\mathbf{x}^T \nabla f(\mathbf{x}_t)$  (=הקרוב הלינארי לפונ' סביר  $f$ ) נזכיר שבסירוק ולפ',  $s_t = \arg \min_{\mathbf{x} \in X} \nabla f(\mathbf{x}_t)^T \mathbf{x}$  הוא המינימר של הפונ' הלינארית זהו בתחום האילוץ כלומר  $\mathbf{x}_t$  הנקודה  $\mathbf{x}_t$  מוגדר באופן הבא הגודל שנקרא Duality Gap

$$\begin{aligned} g(\mathbf{x}) &\triangleq \langle \mathbf{x} - s, \nabla f(\mathbf{x}) \rangle \\ &= (\mathbf{x} - s)^T \nabla f(\mathbf{x}) \\ &= \mathbf{x}^T \nabla f(\mathbf{x}) - s^T \nabla f(\mathbf{x}) \\ &= \nabla f(\mathbf{x})^T \mathbf{x} - \nabla f(\mathbf{x})^T s \end{aligned}$$

המשמעות של הגודל זה הוא **תת אופטימליות** של הנקודה  $x$  עבור הקירוב הילינארי שסיביב  $x$ . ככלומר המשמעות של הגודל זה היא  
כמה ערך הקירוב הילינארי בנקודה  $x$  שנตอน על ידי  $x^T \nabla f(x)$  רחוק מערך עבורו הקירוב הילינארי מקבל את המינימום  $f(x)$ .  
כלומר, כמו  $x$  הוא פתרון תת אופטימי של הקירוב הילינארי  $f(x) = x^T \nabla f(x)$ .

איור לדוגמא:



אפשר להראות את עם הגודל Duality Gap את הדבר הבא:

- אם הערך קטן (כלומר עם  $\langle g(x) - f(x), \nabla f(x) \rangle \triangleq \langle x - s, \nabla f(x) \rangle$  הוא קטן) אז גם הscalar אופטימליות של  $x$  יחסית לפונקציה **המטרה המקורית**  $f$  היא קטנה יותר.

• נראה זאת בנוסחה,

זכור כי:

$$x^* = \arg \min_{x \in X} f(x) \text{ מסומנת של } f$$

$$2. \text{ נזכיר כי } s_t = \arg \min_{s \in X} [\nabla f(x_t)]^T s \text{ ולכן}$$

$$\star : (-s_t) = \arg \max_{s \in X} [\nabla f(x_t)]^T s$$

ולכן

$$\begin{aligned} \star\star : \max_{s \in X} ([\nabla f(x_t)]^T x_t - [\nabla f(x_t)]^T s) &\Rightarrow \\ \left[ [\nabla f(x_t)]^T x_t - [\nabla f(x_t)]^T s \right]_{s=x^*} &\leq \max_{s \in X} ([\nabla f(x_t)]^T x_t - [\nabla f(x_t)]^T s) \end{aligned}$$

$$3. \text{ נזכיר כי } \langle a, b \rangle = a^T b = b^T a.$$

4. נזכיר באישווין הגרדיאנט  $f: \text{dom}(f) \rightarrow \mathbb{R}$  הינה פונקציה קמורה ו**בנוסף** :

$$f(y) \geq f(x) + \nabla f(x)^T (y - x)$$

$$\forall x, y \in \text{dom}(f) : f(y) - f(x) \geq +\nabla f(x)^T (y - x)$$

בפרט עבור  $x = x_t, y = x^*$  מתקיים:

$$f(x^*) - f(x_t) \geq +\nabla f(x_t)^T (x^* - x_t)$$

נכפיל במינוס 1 בשני האגפים ונקבל

$$\star\star\star : \forall x, y \in \text{dom}(f) : f(x_t) - f(x^*) \leq \nabla f(x_t)^T (x_t - x^*)$$

$$\begin{aligned}
g(\mathbf{x}_t) &= \langle \mathbf{x}_t - \mathbf{s}_t, \nabla f(\mathbf{x}_t) \rangle \\
&\stackrel{\star\star}{=} \nabla f(\mathbf{x}_t)^T (\mathbf{x}_t - \mathbf{s}_t) \\
&= \nabla f(\mathbf{x}_t)^T \mathbf{x}_t - \nabla f(\mathbf{x}_t)^T \mathbf{s}_t \\
&\stackrel{\star}{=} \nabla f(\mathbf{x}_t)^T \mathbf{x}_t - \min_{\mathbf{s} \in X} ([\nabla f(\mathbf{x}_t)]^T \mathbf{s}) \\
&\stackrel{\star}{=} \max_{\mathbf{s} \in X} ([\nabla f(\mathbf{x}_t)]^T \mathbf{x}_t - [\nabla f(\mathbf{x}_t)]^T \mathbf{s}) \\
&\stackrel{\star\star}{\geq} \left[ [\nabla f(\mathbf{x}_t)]^T \mathbf{x}_t - [\nabla f(\mathbf{x}_t)]^T \mathbf{s} \right]_{\mathbf{s}=\mathbf{x}^*} \\
&= [\nabla f(\mathbf{x}_t)]^T \mathbf{x}_t - [\nabla f(\mathbf{x}_t)]^T \mathbf{x}^* \\
&= [\nabla f(\mathbf{x}_t)]^T (\mathbf{x}_t - \mathbf{x}^*) \\
&\stackrel{\star\star\star}{\geq} f(\mathbf{x}_t) - f(\mathbf{x}^*)
\end{aligned}$$

כלומר

$$g(\mathbf{x}_t) \geq f(\mathbf{x}_t) - f(\mathbf{x}^*)$$

כלומר החסם עליהן על השגיאה באיטרציה  $t$ . ככל ש Duality Gap קטן יותר כהה גם הסאב אופטימליות של  $\mathbf{x}$  יחסית לפונקציית המטריה המקורית  $f$  היא קטנה יותר.

כלומר, הסאב אופטימליות של הנקודה  $\mathbf{x}_t$  ביחס לפונ' המקורית  $f$ , קטנה או שווה מהGap בנקודה  $\mathbf{x}_t$ . (כלומר, מהאוסף אופטימליות שלה בהתחשב בקירוב הליניארי של הפונ' סביב הנקודה  $\mathbf{x}_t$ )

- פיתחנו את המשקנה הזה על ידי הגדרת קמירות (על ידי אי שוויון הגרדינט) ועל ידי הגדרת ה Gap .
- העובדה הזאת תשמש אותנו בהוכחה של פרנקל וולף.

- נבחין כי  $(\mathbf{x}^* - f(\mathbf{x}_t))$  אינו גודל שניינו לחישוב כי איןנו יודעים את  $\mathbf{x}^*$  אבל הadol  $(\mathbf{x}_t)$  הוא גודל שניינו לחישוב כי כל הפרמטרים שלו ידועים (חישוב הגרדיינט,  $t$  (על ידי solver) ו-  $\mathbf{x}_t$  שגם הוא ידוע, את כל אלה אנו יודעים לחשב). ככלומר אנו לא יודעים את השגיאה עצמה אבל אנו כן מסוגלים לחשב חסם עליון עליה. וכך את  $(\mathbf{x}_t)$  ( $f(\mathbf{x}_t) - f(\mathbf{x}^*)$ ) אפשר לחשב בכל סיבוב.

**קביעת גודל הצעד  $\gamma_t$**  קיימות כל מני דרכים:

גודל צעד דועך		$\gamma_t = \frac{2}{t+1}$
Line search	יש קו ישר בין $\mathbf{x}_t$ אל $\mathbf{x}$ . נמצא $\gamma$ שמייצער את הפונ' לאורץ הקו היישר.	$\gamma_t = \arg \min_{\gamma \in [0,1]} f((1-\gamma)\mathbf{x}_t + \gamma\mathbf{s}_t)$
Gap-based	$L$ -חלוקת הפונ' $g(\mathbf{x}_t)$ ה-Duality Gap בנקודה $\mathbf{x}_t$ לא נפרט על זה	$\gamma_t = \min \left\{ \frac{g(\mathbf{x}_t)}{L\ \mathbf{s}_t - \mathbf{x}_t\ ^2}, 1 \right\}$

אלו שלושת גדי הצעד הפופולריים. ככלום יש את אותו קצב התכנסות.

בהרצתה זו ננתח את גודל הצעד  $\gamma_t = \frac{2}{t+1}$ .

**הערה 12.8** **אלגוריתם frank-wolfe לא מתכנס לפונ'** **שאינו חלקות!** (gradient descent) לעומת זאת, מתקנס לפונ' שאינו חלקות על ידי אל' sub-gradient descent (gradient descent but with a sub-gradient instead of a gradient). כלומר על אל' frank-wolfe **כמעט ולא מבטיח** כלום **במקרה**  $f$  **אינה חלקה.**  $\Leftarrow$  **אל'** frank-wolfe **עובד רק לפונ'** **שהן גם קמורות ו גם חלקות.**

## קצב התכונות לאלגוריתם פרנק וולף

**משפט 13.8** משפט התכונות לאלג' (FW frank-wolfe) (נسمן  $f$  פונ' קמורה ו-  $L$  - חלקה. והוא  $X$  תחום האילוץ שהוא קמור וקומפקטי (= סגור וחסום).  
תזה ( $\cdot$ ) פון' קמורה ו-  $L$  - חלקה. והוא  $X$  תחום האילוץ שהוא קמור וקומפקטי (= סגור וחסום).  
אזי הפעלת אלג' FW עם גודל צעד  $\gamma_t = \frac{2}{t+1}$  מבטיחה כי  $\forall T \geq 2$  כי:

$$f(\mathbf{x}_T) - \min_{\mathbf{x} \in X} f(\mathbf{x}) \leq \frac{2LR^2}{T+1}, \quad R = \max_{\mathbf{x}, \mathbf{y} \in X} \|\mathbf{x} - \mathbf{y}\|$$

**הערה 14.8** כאמור, האיטרציה הראשונה של האלג' היא  $\mathbf{x}_1 = \mathbf{x}$ . ככלומר נקודת האיתחול היא  $\mathbf{x}_1$ .

**הערה 15.8** נבחין כי  $\|\mathbf{x} - \mathbf{y}\| = \max_{\mathbf{x}, \mathbf{y} \in X} \|\mathbf{x} - \mathbf{y}\|$ .

**הערה 16.8** במוני אפסילון,  $\frac{2LR^2}{T+1} \leq \epsilon$

$$\Rightarrow \frac{2LR^2}{T+1} \leq \epsilon \Rightarrow \frac{2LR^2}{\epsilon} \leq T+1 \Rightarrow \boxed{\frac{2LR^2}{\epsilon} - 1 \leq T}$$

כלומר בשביל להגעה לפתרון שהוא  $\epsilon$  תת אופטמלי: נזקק לסדר גודל של  $(\frac{1}{\epsilon})$  איטרציות. וזה קצב התכונות של אלג' פרנק וולף

הוכחת קצב התכונות של אלג' פרנק וולף: ההוכחה של האלג' לא כל כך מסובכת.  
הוכנות להוכחה:

- אנו יודעים כי כלל העדכון נראה כך:  $\mathbf{x}_{t+1} = (1 - \gamma_t) \mathbf{x}_t + \gamma_t \mathbf{s}_t$ . נסדר אותו מחדש ונקבל

$$\begin{aligned} \mathbf{x}_{t+1} &= (1 - \gamma_t) \mathbf{x}_t + \gamma_t \mathbf{s}_t \\ &= \mathbf{x}_t - \gamma_t \mathbf{x}_t + \gamma_t \mathbf{s}_t \\ &= \mathbf{x}_t + \gamma_t \mathbf{s}_t - \gamma_t \mathbf{x}_t \\ &= \mathbf{x}_t + \gamma_t (\mathbf{s}_t - \mathbf{x}_t) \end{aligned}$$

כלומר

$$\star : \mathbf{x}_{t+1} = \mathbf{x}_t + \gamma_t (\mathbf{s}_t - \mathbf{x}_t)$$

- נזכיר בהגדרת החלקות:

**הגדרה שנייה:** פון'  $\mathbb{R}$  תקרא פון'  $L$ -חלקה (עבור פרמטר  $0 \leq L \leq \infty$  אם היא קמורה, גזירה ובנוסף  $\forall \mathbf{x}, \mathbf{y} \in \mathbb{R}^d : f(\mathbf{y}) \leq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x}) + \frac{L}{2} \cdot \|\mathbf{x} - \mathbf{y}\|^2$ ).  
בפרט עבור  $\mathbf{x} = \mathbf{x}_t, \mathbf{y} = \mathbf{x}_{t+1}$

$$\begin{aligned} \star\star : f(\mathbf{x}_{t+1}) &\leq f(\mathbf{x}_t) + \nabla f(\mathbf{x}_t)^T (\mathbf{x}_{t+1} - \mathbf{x}_t) + \frac{L}{2} \cdot \|\mathbf{x}_t - \mathbf{x}_{t+1}\|^2 \\ &= f(\mathbf{x}_t) + \nabla f(\mathbf{x}_t)^T (\mathbf{x}_{t+1} - \mathbf{x}_t) + \frac{L}{2} \cdot \|\mathbf{x}_{t+1} - \mathbf{x}_t\|^2 \end{aligned}$$

$\star\star\star : \|(\mathbf{s}_t - \mathbf{x}_t)\|_2^2 \leq \max_{\mathbf{x}, \mathbf{y} \in X} \|\mathbf{x} - \mathbf{y}\|_2^2 = R^2$  • ולכן בפרט עבור  $R = \max_{\mathbf{x}, \mathbf{y} \in X} \|\mathbf{x} - \mathbf{y}\|_2$

• נזכיר כי  $\mathbf{s}_t = \arg \min_{\mathbf{s} \in X} [\nabla f(\mathbf{x}_t)]^T \mathbf{s}$  • ולכן

$$\forall \mathbf{x} \in X : [\nabla f(\mathbf{x}_t)]^T \mathbf{s}_t \leq [\nabla f(\mathbf{x}_t)]^T \mathbf{x}$$

ובפרט עבור  $\mathbf{x} = \mathbf{x}^* \in X$

$$\star\star\star\star : \forall \mathbf{x} \in X : [\nabla f(\mathbf{x}_t)]^T \mathbf{s}_t \leq [\nabla f(\mathbf{x}_t)]^T \mathbf{x}^*$$

• נזכירbai שוויון הגרדייאנט

$$\forall \mathbf{x}, \mathbf{y} \in \text{dom}(f) : f(\mathbf{y}) - f(\mathbf{x}) \geq +\nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$$

בפרט עבור  $\mathbf{x} = \mathbf{x}_t, \mathbf{y} = \mathbf{x}^*$  מתקיים:

$$\boxed{\star} : f(\mathbf{x}^*) - f(\mathbf{x}_t) \geq \nabla f(\mathbf{x}_t)^T (\mathbf{x}^* - \mathbf{x}_t)$$

וחרי להוכיח:

$$\begin{aligned} f(\mathbf{x}_{t+1}) &\overset{\star\star}{\leq} f(\mathbf{x}_t) + \nabla f(\mathbf{x}_t)^T (\mathbf{x}_{t+1} - \mathbf{x}_t) + \frac{L}{2} \cdot \|\mathbf{x}_{t+1} - \mathbf{x}_t\|^2 \\ &\overset{\star}{=} f(\mathbf{x}_t) + \nabla f(\mathbf{x}_t)^T ((\mathbf{x}_t + \gamma_t(\mathbf{s}_t - \mathbf{x}_t)) - \mathbf{x}_t) + \frac{L}{2} \cdot \|(\mathbf{x}_t + \gamma_t(\mathbf{s}_t - \mathbf{x}_t)) - \mathbf{x}_t\|^2 \\ &= f(\mathbf{x}_t) + \nabla f(\mathbf{x}_t)^T (\gamma_t(\mathbf{s}_t - \mathbf{x}_t)) + \frac{L}{2} \cdot \|\gamma_t(\mathbf{s}_t - \mathbf{x}_t)\|^2 \\ &= f(\mathbf{x}_t) + \gamma_t \nabla f(\mathbf{x}_t)^T (\mathbf{s}_t - \mathbf{x}_t) + \frac{L}{2} \cdot |\gamma_t|^2 \|\mathbf{s}_t - \mathbf{x}_t\|^2 \\ &\overset{\gamma_t \geq 0}{=} f(\mathbf{x}_t) + \gamma_t \nabla f(\mathbf{x}_t)^T (\mathbf{s}_t - \mathbf{x}_t) + \frac{L}{2} \cdot \gamma_t^2 \|\mathbf{s}_t - \mathbf{x}_t\|^2 \\ &= f(\mathbf{x}_t) + \gamma_t \nabla f(\mathbf{x}_t)^T (\mathbf{s}_t - \mathbf{x}_t) + \frac{L}{2} \cdot \gamma_t^2 \|\mathbf{s}_t - \mathbf{x}_t\|^2 \\ &\overset{\star\star\star}{\leq} f(\mathbf{x}_t) + \gamma_t \nabla f(\mathbf{x}_t)^T (\mathbf{s}_t - \mathbf{x}_t) + \frac{L}{2} \cdot \gamma_t^2 R^2 \\ &\overset{\star\star\star\star}{\leq} f(\mathbf{x}_t) + \gamma_t \nabla f(\mathbf{x}_t)^T (\mathbf{x}^* - \mathbf{x}_t) + \frac{L}{2} \cdot \gamma_t^2 R^2 \\ &\overset{\star}{\leq} f(\mathbf{x}_t) + \gamma_t [f(\mathbf{x}^*) - f(\mathbf{x}_t)] + \frac{L}{2} \cdot \gamma_t^2 R^2 \\ &= f(\mathbf{x}_t) + \gamma_t f(\mathbf{x}^*) - \gamma_t f(\mathbf{x}_t) + \frac{L}{2} \cdot \gamma_t^2 R^2 \\ &= f(\mathbf{x}_t) + \gamma_t f(\mathbf{x}^*) - \gamma_t f(\mathbf{x}_t) + \frac{L}{2} \cdot \gamma_t^2 R^2 + f(\mathbf{x}^*) - f(\mathbf{x}^*) \\ &= f(\mathbf{x}_t) - \gamma_t f(\mathbf{x}_t) + \gamma_t f(\mathbf{x}^*) - f(\mathbf{x}^*) + \frac{L}{2} \cdot \gamma_t^2 R^2 + f(\mathbf{x}^*) \\ &= (1 - \gamma_t) f(\mathbf{x}_t) + (\gamma_t - 1) f(\mathbf{x}^*) + \frac{L}{2} \cdot \gamma_t^2 R^2 + f(\mathbf{x}^*) \\ &= (1 - \gamma_t) f(\mathbf{x}_t) - (1 - \gamma_t) f(\mathbf{x}^*) + \frac{L}{2} \cdot \gamma_t^2 R^2 + f(\mathbf{x}^*) \\ &= (1 - \gamma_t) (f(\mathbf{x}_t) - f(\mathbf{x}^*)) + \frac{L}{2} \cdot \gamma_t^2 R^2 + f(\mathbf{x}^*) \end{aligned}$$

קייםנו

$$f(\mathbf{x}_{t+1}) \leq (1 - \gamma_t) (f(\mathbf{x}_t) - f(\mathbf{x}^*)) + \frac{L}{2} \cdot \gamma_t^2 R^2 + f(\mathbf{x}^*)$$

חסיר  $f(\mathbf{x}^*)$  משני הצדדים ונקבל

$$f(\mathbf{x}_{t+1}) - f(\mathbf{x}^*) \leq (1 - \gamma_t) (f(\mathbf{x}_t) - f(\mathbf{x}^*)) + \frac{L}{2} \cdot \gamma_t^2 R^2$$

נסמן  $(f(\mathbf{x}_t) - f(\mathbf{x}^*))$  כלומר  $h_t$  הוא השגיאה בזמן  $t$ , נקבל

$$\star : h_{t+1} \leq (1 - \gamma_t) h_t + \frac{L}{2} \cdot \gamma_t^2 R^2$$

זכור כי

$$\star\star : \gamma_t = \frac{2}{t+1}$$

נוכיח כי באידוקציה על  $t$ , לפחות  $T \geq 2$ :

• בסיס: נוכיח את נכונות הטענה עבור  $T = 2$

$$\begin{aligned} h_2 &\stackrel{\star}{\leq} (1 - \gamma_1) h_1 + \frac{L}{2} \cdot \gamma_1^2 R^2 \\ &\stackrel{\star\star}{=} \left(1 - \frac{2}{1+1}\right) h_1 + \frac{L}{2} \cdot \left(\frac{2}{1+1}\right)^2 R^2 \\ &= \frac{L}{2} \cdot (1)^2 R^2 \\ &= \frac{LR^2}{2} \\ &= \frac{2LR^2}{4} \\ &\stackrel{(2LR^2)>1}{\leq} \frac{2LR^2}{3} \\ &= \frac{2LR^2}{2+1} \end{aligned}$$

• הנחה: נניח את נכונות הטענה עבור  $T \geq 2$ . נסמן את בנתה האינדוקציה כי  $\diamond$ .

• צעד: נוכיח את נכונות הטענה עבור  $T + 1$ : קלומר צ"ל כי

$$h_{(T+1)} \leq \frac{2LR^2}{(T+1)+1}$$

הוכחה:

$$\begin{aligned}
h_{(T+1)} &\overset{*}{\leq} (1 - \gamma_T) h_T + \frac{L}{2} \cdot \gamma_T^2 R^2 \\
&\overset{\star\star}{=} \left(1 - \frac{2}{T+1}\right) h_T + \frac{L}{2} \cdot \left(\frac{2}{T+1}\right)^2 R^2 \\
&\overset{\star\star\star}{\leq} \left(1 - \frac{2}{T+1}\right) \cdot \frac{2LR^2}{T+1} + \frac{L}{2} \cdot \left(\frac{2}{T+1}\right)^2 R^2 \\
&= \left(\frac{T+1}{T+1} - \frac{2}{T+1}\right) \cdot \frac{2LR^2}{T+1} + \frac{LR^2}{2} \cdot \left(\frac{2^2}{(T+1)^2}\right) \\
&= \left(\frac{T-1}{T+1}\right) \cdot \frac{2LR^2}{T+1} + \frac{2LR^2}{(T+1)} \cdot \left(\frac{1}{(T+1)}\right) \\
&= \left[\left(\frac{T-1}{T+1}\right) + \left(\frac{1}{(T+1)}\right)\right] \cdot \frac{2LR^2}{T+1} \\
&= \left[\overbrace{\left(\frac{T}{T+1}\right)}^{\leq 1}\right] \cdot \frac{2LR^2}{T+1} \\
&\leq 1 \cdot \frac{2LR^2}{T+1} \\
T+1 &\leq (T+1) + 1 \\
\frac{1}{T+1} &\leq \underbrace{\frac{1}{(T+1)+1}}_{\leq \frac{2LR^2}{(T+1)+1}}
\end{aligned}$$

כלומר הוכחנו  $.h_{(T+1)} \leq \frac{2LR^2}{(T+1)+1}$

ולכן הוכחנו באינדוקציה כי  $.T \geq 2 \leq h_T \leq \frac{2LR^2}{T+1}$  לכל  $T \geq 2$   
 נזכיר כי  $f(\mathbf{x}^*) = \min_{\mathbf{x} \in X} f(\mathbf{x})$  ובנוסף  $h_t = (f(\mathbf{x}_t) - f(\mathbf{x}^*))$   
 ומכאן ייובע כי הפעלת אלג' FW עם גודל צעד  $\gamma_t = \frac{2}{t+1}$  מבטיחה כי

$$f(\mathbf{x}_T) - \min_{\mathbf{x} \in X} f(\mathbf{x}) \leq \frac{2LR^2}{T+1}, \quad R = \max_{\mathbf{x}, \mathbf{y} \in X} \|\mathbf{x} - \mathbf{y}\|$$

זה מוכיח את אלג' FRANK וולף

■

**רחבות ושימושים של אלג' FRANK וולף:** נזכיר כי solver LMO  $\equiv$  Linear Minimization Oracle הוא למעשה solver שמשתמשים בו בכל איטרציה לפתרון בעיה הילינארית בכל איטרציה.  
**רחבות:**

1. עבור המקרה שאין solver מדויק שפותר את הביעות הילינאריות בכל איטרציה (מציאת  $s_t$ ) אלא פותר אותו בקירוב

Randomized LMO.

2. הרחבה לבעיה הלא מאולצת unconstrained problems(Matching Pursuit variants)  
 (Matching Pursuit)

**הערה 17.8** נראה בתרגול שההרחבה הטבעית של אלג' פרנק וולף למקורה הסטטיסטי היא גרוועה מאד ולא עובדת. יש דרכי טובות יותר לעשות את זה.

#### מרקם שימושים

באופן כללי משתמשים באלג' במרקם בהם הטלת מסובכת יותר חישובית לפתרון מאשר בעיות ליניאריות. האלג' כבר הרבה פופולריות ומשתמשים בו רבות לפתרון של בעיות מהסוגים הבאים:

#### 1. בעיות **lasso** וביעות $L_1$ מאולצות אחרות

2. בעיות שבهم הפתרון שלו הוא למעשה מטריצה. בעיות כאלה הרבה פעמים הטללה היא מאוד קרכה (עלות חישובית של חישוב הטללה לפי המימד **שלישית**, כאשר המימד מאד גדול שימוש באלג' הגראדיינט המוטל זו אופצייה שאינה מעשית). מסתבר שאלג' פרנק וולף הוא מאוד מתאים לפתרון בעיות מהסוגים האלה והוא הרבה יותר חישובית.

3. בעיות **matching, network, flows** (לדוגמא, בעיות שידוך/רשתות/זרימה Relaxation of **Combinatorial problems** לא נרחב את השיח עליו בקורס).

#### 8.1.6 האצה acceleration ומומנטום momentum

כעת נחזר לאלגוריתמים של GD. אנו ראיינו שעבור בעיות אופטימיזציה קמורות ו- $L$ -חלקות ראיינו שאלגוריתם GD מושג קצב של  $(\frac{1}{T}) \mathcal{O}$  (בשפת אפסילון  $(\frac{1}{\epsilon}) \mathcal{O}$ ) כאשר  $T$  הוא מספר האיטרציות. ואז נשאלנו האם זה הקצב הטוב ביותר שאפשר להציגו ומסתבר שההתשובה היא לא (אפשר להראות שנייה להשיג קצב טוב יותר, של  $(\frac{1}{T^2}) \mathcal{O}$  (בשפת אפסילון  $(\frac{1}{\sqrt{\epsilon}}) \mathcal{O}$ )). בשנות האחרונות היה איש אופטימיזציה מפורסם בשם נסטורוב שהראה שאלגוריתם שהוא לא GD שמקבל את הקצב המוצלח יותר של  $(\frac{1}{T}) \mathcal{O}$  (והוכיח בנוסחזה  $(\frac{1}{T^2}) \mathcal{O}$  ) הוא הקצב האופטימי לכל השיטות מסדר ראשון (שיטות שמציאות עדכוניות לפי הפוך והגרדיינטיים שלה)). בשיביל להגעה לאלג' נסטורוב השתמש במושג של **מומנטום** נדבר על הרעיון הזה בהרחבה נציג מדוע שהוא מאוד פופולרי וכן נציג את החרסונות שלו.

**סיכום ביניים** טבלה שמסכמת את התוצאות עבור ביצוע GD עבור תכונות של  $f$  ובחרית גדי צעד שונים:

property of $f$	Learning Rate $\eta$	Number of steps
$f$ is convex $\ \mathbf{x}_0 - \mathbf{x}^*\  \leq R$ $\forall \mathbf{x} : \ \nabla f(\mathbf{x})\  \leq B$	$\frac{R}{B\sqrt{T}}$	$\mathcal{O}(\frac{1}{\epsilon^2})$
$f$ is convex and $f$ is $L$ smooth	$\frac{1}{L}$	$\mathcal{O}(\frac{1}{\epsilon})$
$f$ is convex and $f$ is $L$ smooth and $f$ is $\mu$ strongly convex	$\frac{1}{L}$	$\mathcal{O}(\log(\frac{1}{\epsilon}))$

אם הפוך  $f$  היא גם קמורה וגם חלקה ניתן להגעה לקצבים טובים עוד יותר.


**מומנטום** נציג תוספת לככל העדכון שנקראת מומנטום:

$$\mathbf{x}_{t+1} = \mathbf{x}_t - \eta \mathbf{g}_t + \beta (\mathbf{x}_t - \mathbf{x}_{t-1}) \quad ; \quad \mathbf{g}_t = \nabla f(\mathbf{x}_t)$$

כאשר  $0 < \beta$  נקרא **פרמטר המומנטום**.

אינטואטיבית, המומנטום "דוחף" את התקדמותו של יעד טיפה בכיוון הגרדיינט הקודם שלו התקדמותי. מה הדבר הזה הגיוני, ניתן לבדוקו זהה יכול לעזור, לדוגמה בציור הבא:

**דוגמה 18.8** נתבונן בדוגמא הבאה:



בשחור, קו הפוטנציאלי של פונ' המטרה.

הפונ' נראית כמו אליפסות דחוסות, והאופטימיות נמצאת במרכזו.

רוב הרכיב הדומיננטי של הגרדיינט יהיה בציר  $x$  (אנכי) וניתן לראות שאלו הGD הרגיל שמתקדם לאוכו מגזג הרבה ניתן להבחין שהאל' מתקדדים הרבה ציר  $y$  ופחות בציר  $x$ ,כלומר לא מתקדם "מהר" מספיק לעבר האופטימום.


באלו momentum הרגילים המומנטום למעשה "מפחית את הזוגים" עבור המקרה זהה, בכל צעד אנו נתקדם גם עוד קצת בכיוון של הצעד הקודם שביצענו. זאת האיטואציה הצירית מאחר רעיון המומנטום.

**הערה 19.8** לא הוכח עדין (המרצה אמר "אי אפשר להוכיח") שהמומנטום אכן מתקנס יותר מהר, אבל משתמשים בו בפועל הרבה פעמים בעולם האמיתי והוא נותן תוצאות מוצלחות גם עבור פונ' שאין קמורים.

**דוגמא 20.8** נתבונן בדוגמא הבאה:

דוגמה לבעה קמורה שפותרים באמצעות stochastic GD

(Stochastic) gradient descent vs. momentum



למעשה יש כאן שימוש באלאג' הגרדיינט הסטוכסטי עם ו בלי מומנטום.  
כאן פון' המטרה היא סכום של המנו פון'.

1. מה שראים בשחור הוא מה שקורה שמשיעלים את האלאג' הגרדיינט הסטוכסטי על הפון'. (ניתן להבחן באלמנט האקראי בתנודות השחורות)
2. מה שראים באפור הוא מה שקורה שמשיעלים את האלאג' הגרדיינט הסטוכסטי יחד עם איבר מומנטום. נבחן כי גם עבור המקרה הזה ניתן לראות שהפון מתכנסת באופן טוב יותר וושימוש במומנטום שיפור את ההתכנסות

**הערה 21.8** גם בהרחבה זו משתמשים בפועל הרבה פעמים בעולם האמיטי והוא נותן תוצאות מוצלחות גם עבור פון' קמורות.

### אלגוריתם הגרדיינט המואץ - AGD

(נראה אלג' שמצויר מאוד את אלג' הגרדיינט המואץ של נסטורוב, שנראית בתרגול) לאלאג' שנציג ניתן להוכיח באופן אנליטי את ההתכנסות שלו:

$$\begin{aligned} \mathbf{x}_0 &:= \mathbf{y}_0 := \mathbf{z}_0 \quad , \text{init} \\ \mathbf{y}_{t+1} &:= \mathbf{x}_t - \frac{1}{L} \nabla f(\mathbf{x}_t) \quad , \text{the regular 'smooth' step} \\ \mathbf{z}_{t+1} &:= \mathbf{z}_t - \frac{t+1}{2L} \cdot \nabla f(\mathbf{x}_t) \quad , \text{the fast 'aggressive' smooth step} \\ \mathbf{x}_{t+1} &:= \tau \mathbf{y}_{t+1} + (1-\tau) \mathbf{z}_{t+1} \quad , \text{where : } \tau := \frac{t+1}{t+3} \end{aligned}$$

**הערה 22.8** נבחן כי

1. לאלאג' יש שלושה איטרנטים (משתנים פנמיים שמתעדכנים בכל איטרציה) והם:  $\mathbf{x}_t, \mathbf{y}_t, \mathbf{z}_t$ :
2. צעד העדכון ( $\mathbf{x}_t$ )  $\mathbf{y}_{t+1} := \mathbf{x}_t - \frac{1}{L} \nabla f(\mathbf{x}_t)$  זהה לצעד עדכון מוכך של המקרה החלק.
3. צעד העדכון ( $\mathbf{x}_t$ )  $\mathbf{z}_{t+1} := \mathbf{z}_t - \frac{t+1}{2L} \cdot \nabla f(\mathbf{x}_t)$  מבצע עדכון מאד אגרסיבי, שהוא וגדל ככל  $t$  גדול.
4. צעד העדכון של הנקודה הבאה  $\mathbf{z}_{t+1} = \tau \mathbf{y}_{t+1} + (1-\tau) \mathbf{z}_{t+1}$  הוא ממוצע משוקלל של  $\mathbf{y}_{t+1}$  ושל  $\mathbf{z}_{t+1}$ . נבחן כי מצד אחד  $\mathbf{z}_{t+1}$  גדל מסיבוב לסיבוב, אבל מצד שני המקדם שלו  $(\tau - 1)$  הולך וקטן מסיבוב לסיבוב. ( $c_t$  כבר גדול מאד  $\approx 1$ )

5. קלומר  $1 = \lim_{t \rightarrow \infty} \tau$  קלומר ככל ש  $t$  גדול כהה  $\tau$  מתקרב להיות 1, ובאייטרציות מאוחרות האלג' מתנהג כמו GD במקרה ה-L-חלק. (בקביעת  $x_{t+1}$  יש יותר משקל לעדכון  $x_t$  מאשר בעמקרה ה-L-חלק. פחות משקל לעדכון  $x_{t+1}$  מאשר בעמקרה באופן אגרסיבי).

6. בתחלת האלג' יש יותר משקל בקביעת  $x_{t+1}$  לעדכון לפי העדכנים האגרסיביים  $z$  מאשר לעדכנים הסטנדרטיים  $y$ . נבחין כי עבור  $t$ -ים كانوا שבתחלת האלג'  $t$  עוד לא גדולים מדי ולכן  $z$  לא מגע לערבים גדולים מדי.

7. מסתבר שהאלג' הזה מתכנס באופן וניתן להראות את זה אנליטית.

נשווה את אלג' GD לעומת אלג' AGD (accelerated gradient descent) בביטויים עבור פונ' קמורות. במנח  $\epsilon$  (=מספר העדכנים שנדשים להשגת פתרון אופטמלי)

<b>תכנות על <math>f</math></b>	GD steps	AGD steps
$f$ is convex and L-smooth	$\mathcal{O}\left(\frac{1}{\epsilon}\right)$	$\mathcal{O}\left(\frac{1}{\sqrt{\epsilon}}\right)$
$f$ is convex and L-smooth and $\mu$ strongly convex	$\mathcal{O}\left(\frac{L}{\mu} \cdot \log\left(\frac{1}{\epsilon}\right)\right)$	$\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \cdot \log\left(\frac{1}{\epsilon}\right)\right)$


הערה 23.8 נזכיר כי תמיד  $\frac{L}{\mu} \geq 1$ , בד"כ הוא מספר גדול מאוד מ-1 (בד"כ שורות או מאות אלפיים). וכן הקצב של AGD steps שהוא  $\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \cdot \log\left(\frac{1}{\epsilon}\right)\right)$  הוא לפחות טוב מהקצב GD steps שהוא  $\mathcal{O}\left(\frac{1}{\epsilon}\right)$ . ניתן לראות באופן כללי בהשוואה זו של אלג' AGD מישג תוצאות טובות יותר מאלג' הגרדיינט הרגיל.

הערה 24.8 האלג' שריאנו של AGD הוא רק עבור המקרה שבו  $L$  חלקה. (מתעלמים מהקומות חזק) אם רוצים שהאלג' יקח בחשבון את הפונ' קמורה חזק ויגע לתוצאות של  $\mathcal{O}\left(\sqrt{\frac{L}{\mu}} \cdot \log\left(\frac{1}{\epsilon}\right)\right)$  אז האלג' AGD הוא מסובך יותר ולא נר奇יב עליו כאן.

דוגמה 25.8 דוגמא בפועל:

## Acceleration in practice

Application to a Lasso problem



- ציר  $Y$ , השניה. הציר ה-n"ל הוא בסקללה לוגריתמית.
- ציר  $X$  מספר האיטרציות.

ניתן לבדוק האלג' המואץ של נסטורוב מתכנס מאוד מהר.

אלג' GD הוא האלג' האדום (מתכנס לאט יותר).

אלג' subgradient (האלג' השחור) מתכנס הכி לאט.

מכאן ניתן לראות שגם GD מואץ באופן ממשמעותי את הביצועים של AGD.

**הערה 26.8** האלג' של המומנטום מאוד מואוד פופולרי אבל אלג' מואצים כדוגמת האלג' של נסטורוב הם הרבה פחות פופולריים מכיוון שאלג' של נסטורוב לדוגמא הוא מאוד רגש. עברו בעיות עם רוש, האלג' של נסטורוב ישג ביצועים לא מוצלחים במיוחד. ככלומר האלג' של נסטורוב מאוד רגיש לרעש ולכן פופולרי בשימושים של העולם האמיטי. מכון גם, שלא מפעלים את נסטורוב בעיות סטוכסטיות (אקריאות, כפי שראינו) ובמקרה משתמשים באלג' המומנטום (שהוא קרוב לרעיון של נסטורוב).

## 8.2 תרגול 8

### 8.2.1 אלגוריתם פרנק וולף

נתבונן בעיית האופטימציה הבאה

$$(P) \quad \begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ & \text{s.t. } \mathbf{x} \in C \end{aligned}$$

כאשר  $f$  פונ' קמורה ו- $L$ -חלקה והקבוצה  $C$  קמורה וקומפקטיבית (=סגורה וחסומה).

- **זיכרון:** בתרגול מס' 6 הזכירנו את אלג' הגandanit המוטל לפתרון בעיות אופטימציה מואולצות. נזכר כי ככל העדכון עבור אלג' זה היה נתון על ידי

$$\mathbf{x}_t = P_C(\mathbf{x}_{t-1} - \eta_t \nabla f(\mathbf{x}_{t-1}))$$

במקרה שהפונ' היא חלקה או ראיינו כי האלג' מתכנס בקצב של  $(\frac{1}{t})$ . (=כדי לקבל פתרון  $\epsilon$  תת אופטימי علينا לבצע סדר גודל של  $\frac{1}{\epsilon}$  צעדים).

לעתים חישוב הטלה על קבוצה  $C$  יכול להיות מסובך ובכך הופך האלג' להיו לא יעיל ולא פרקטני ככלומר העלות החישובית לביצוע כל איטרציה עלולה להיות גבוהה מאוד. עצם חישוב הטלה הוא עלול להיות מסובך.

- אלגוריתם פרנק וולף (frank-wolfe) הוא אלגוריתם איטרטיבי שפותר בעית אופטימציה לינארית LP בכל איטרציה. אלגוריתם פרנק וולף הוא אלג' איטרטיבי בו בכל איטרציה מבצעים עדכון בכיוון המינימר על פני  $C$ , את הקירוב הלינארי של הפונ' באותה איטרציה. אם כן **בכל איטרציה** של האלג' פרנק-וולף علينا **לפזר את בעית האופטימציה עם פונ' מטרה לינארית**. במרקמים רבים פתרון בעיה כזו הוא **כל יותר** מאשר ביצוע הטלה.

**מוצבציה לכל העדכון:** כזכור הקירוב הלינארי של פונ' קמורה וגיירה בריצפות, מהו חסם תחתון על הפונ' (אֵי שווין הגדריאנט לפונ' קמורות):

$$\forall \mathbf{x}, \mathbf{y} \in C : f(\mathbf{y}) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{y} - \mathbf{x})$$

כלומר הקירוב הלינארי של הפונ'  $f$  בנקודה  $\mathbf{y}$ :  $f(\mathbf{y}) = \text{ערך הפונ'} \text{ בנקודה } \mathbf{y}$ .

**הערה 27.8** בסלנג של סטטיסטיק ריאון ובחד מימד: זה מזכיר לנו "שיעור הגראף מתחת לגרף".

ובפרט עבור הפתרון האופטלי  $\mathbf{x}^*$  ( $\mathbf{x}^* = \mathbf{y}$  מתקיים):

$$* : \forall \mathbf{x} \in C : f(\mathbf{x}^*) \geq f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{x}^* - \mathbf{x})$$


נפתח את הבטווי:

$$\begin{aligned} \forall \mathbf{x} \in C : f(\mathbf{x}^*) &\stackrel{*}{\geq} f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{x}^* - \mathbf{x}) \\ &\geq \min_{\mathbf{s} \in C} \left\{ f(\mathbf{x}) + \nabla f(\mathbf{x})^T (\mathbf{s} - \mathbf{x}) \right\} \\ &= \min_{\mathbf{s} \in C} \left\{ f(\mathbf{x}) + \nabla f(\mathbf{x})^T \mathbf{s} - \nabla f(\mathbf{x})^T \mathbf{x} \right\} \\ &= \min_{\mathbf{s} \in C} \left\{ f(\mathbf{x}) - \nabla f(\mathbf{x})^T \mathbf{x} + \nabla f(\mathbf{x})^T \mathbf{s} \right\} \\ &= f(\mathbf{x}) - \nabla f(\mathbf{x})^T \mathbf{x} + \min_{\mathbf{s} \in C} \left\{ \nabla f(\mathbf{x})^T \mathbf{s} \right\} \end{aligned}$$

$$\forall \mathbf{x} \in C : f(\mathbf{x}^*) \geq f(\mathbf{x}) - \nabla f(\mathbf{x})^T \mathbf{x} + \min_{\mathbf{s} \in C} \left\{ \nabla f(\mathbf{x})^T \mathbf{s} \right\}$$

קיבלנו שבכל נקודה  $\mathbf{x} \in C$  החסם התחתון לערך האופטמלי של הפונ' הוא איזה שהוא גודל קבוע  $(f(\mathbf{x}) - \nabla f(\mathbf{x})^T \mathbf{x})$  שתלי בנקודה  $\mathbf{x}$  שאנו מתחוננים עליה כרגע ועוד פתרו לבעיית מינימזציה ליניארית LP:  $\min_{\mathbf{s} \in C} \left\{ \nabla f(\mathbf{x})^T \mathbf{s} \right\}$ : כאשר פונ' המטרה היא  $\nabla f(\mathbf{x})^T \mathbf{s}$ . הרעיון בפרק וולף יהיה לתקדם בכל צעדי קצת בכיוון  $\mathbf{s}$  (=הוקטור שמשער את הפונ'  $\left\{ \nabla f(\mathbf{x})^T \mathbf{s} \right\}$ ) (=החסם התחתון המינימלי ביותר שנמצא על הקירוב הלינארי (הנקודה הפסיבלית הנמוכה ביותר ש实施细则 על-המשור שהוא הקירוב הלינארי של הפונ' בנקודה  $\mathbf{x}$ ) על ערך פונ' המטרה האופטימלית  $(\mathbf{x}^*)$ ). הראנו בהרצאה שאם מתקדים בכיוון  $\mathbf{s}$  אכן אנו מתקדים בכיוון הנכון לסייע הפונ'.

**איור לדוגמא:**



תחום האילוץ הוא  $X$ , אנו נמצאים בנקודה  $\mathbf{x}$  ופונ' המטרה שנרצה לסייע היא  $f$ . הקירוב הלינארי בנקודה  $\mathbf{x}$  הוא על מישור זה הוא העל מישור האדום. אם היינו רוצים לסייע על כל העל מישור לא היינו יכולים לבצע את המינימזציה כי העל מישור הוא אינו חסום. (כלומר אם רוצים רק לסייע את הפונ' באדום אפשר לרדת עד  $-\infty$ ) אבל הרעיון הוא שכאשר אנו חסומים על ידי תחום קומפטי  $X$  (=סגור וחסום) (או במקרה הכללי) ניתן לסייע את העל מישור על גבי תחום האילוץ. (למצוא את הנקודה על פני העל מישור שמשערת אותה ומקיימת את האילוץ  $X$ ) ברגע שנמצא את הנקודה זו, נתקדם מעד בכיוונה.

---

**Data:** Initial guess,  $\mathbf{x}_0 \in C$

**for**  $t = 1, 2, \dots$  **do**

Solve minimization problem:

$$\mathbf{s}_{t-1} = \arg \min_{\mathbf{s} \in C} \nabla f(\mathbf{x}_{t-1})^T \mathbf{s}$$

$$\eta_t \leftarrow \frac{2}{t+2} \quad // \text{ or exact line-search}$$

$$\mathbf{x}_t \leftarrow (1 - \eta_t) \mathbf{x}_{t-1} + \eta_t \mathbf{s}_{t-1}$$

**end**

---

אלג' פרנק וולף:

### הערה 28.8

- בכל איטרציה אנו מוצאים את  $s$  שמייא למינימום את  $\{\nabla f(\mathbf{x}_{t-1})^T s\}$  (כפי שראינו במודולו, מביא למינימום את החסם הפיסבלי על הערך של הפונ' בנק' האופטימלית)
- **シימוש לב שהגודל הנוכחי חייב להיות בקטע**  $[0, 1]$   $\eta_t$  ולכן  $\mathbf{s}_{t-1} = \min_{s \in C} \{\nabla f(\mathbf{x}_{t-1})^T s\}$  הוא פתרון של בעית אופטימציה עם האילוץ  $C$  ולכן  $\mathbf{x}_t \leftarrow (1 - \eta_t) \mathbf{x}_{t-1} + \eta_t \mathbf{s}_{t-1}$  (אפשר להראות ש  $x_t$  פיזיילי קלומר ש  $x_t \in C$ )

$\mathbf{s}_{t-1} \in C$  קלומר  $\mathbf{s}_{t-1} = \min_{s \in C} \{\nabla f(\mathbf{x}_{t-1})^T s\}$  –  
(כלומר הוא מקיים את האילוץ).

$$\mathbf{x}_{t-1} \in C -$$

– ולכן עבור כל  $\eta \in [0, 1]$  מכיוון שהוא בתחום קמור אנו יודעים כי:  
 $\overbrace{((1 - \eta) \mathbf{x}_{t-1} + \eta \mathbf{s}_{t-1})}^{x_t} \in C$ .  
כלומר  $x_t$  הוא נקודת פיזibilitה.

- **כמה מתקדים בביון?**

- אפשרות אחת (גרסה אחרת של האלג') להתקדם בצורה זו:  $\eta_t \leftarrow \frac{2}{t+2}$  (גודל צעד דוועך)
- אפשרות שנייה (גרסה אחרת של האלג') להתקדם בגודל צעד מדויק: (דורש פתרון של בעית אופטימיזציה נוספת):  
 $\eta_t = \arg \min_{\eta \in [0, 1]} f((1 - \eta) \mathbf{x}_{t-1} + \eta \mathbf{s}_{t-1})$  :Exact line search (למזהה את ה  $\eta$  שתמזרע את הערך של האלג').
- האלג' מבטיח קצב התכנסות של  $(\frac{1}{t})$  (כמו projected gradeint descent) רק הפעם שבמקרים בכל איטרציה לפטור בעית אופטימיזציה של הטלה שיכולה להיות מסוובכת נפתח בעית אופטימיזציה לינארית (LP))

### 8.2.2 אינוורנטיות לטרנספורמציה אפינית

הגדרה 29.8 נתונה בעית האופטימיזציה הבאות

$$(P) \quad \min_{\mathbf{y} \in C} f(\mathbf{y})$$

כאשר קיימות  $A \in \mathbb{R}^{n \times n}$  מטריצה הפיכה כשליה. כתעת נגדיר את בעיה השוקלה לאחר הטרנספורמציה על ידי

$$(P') \quad \min_{\mathbf{x} \in C'} g(\mathbf{x})$$

כאשר  $C' = A^{-1}C \triangleq \{A^{-1}\mathbf{y} \mid \mathbf{y} \in C\}$  ו  $g(\mathbf{x}) \triangleq f(A\mathbf{x})$

מפעלים אלגוריתם איטרטיבי כלשהו על הבעה ( $P$ ) ומקבלים את סדרת הפתרונות  $y_1, y_2, \dots, y_T$ . מפעלים את אותו אלגוריתם איטרטיבי כלשהו על הבעה ( $P$ ) ומקבלים את סדרת הפתרונות  $x_1, x_2, \dots, x_T$ . נאמר כי **אלגוריתם אופטימציה הוא אינוריאנטי לטנסופומציה אפינית** אם לכל ניחושים התחלתיים המקוריים את הקשר  $y_t = Ax_t$  וtout  $t \geq 1$  מקבלים  $y_0 = Ax_0$ .

**הערה 30.8**  $A$  היא טנסופומציה הפיכה מט'  $n \times n$  לינארית ולכן מה היא יכולה לעשות:

- **כיווץ/מתיחה**

- **סיבוב**

כלומר הטנסופומציה רק משנה לנו את מערכת הצירים

כלומר אנו מסתכלים על מערכת קורדינטות אחרות (לאחר הפעלת הטנסופומציה), על בעיה שקופה. בעיות שколоות כי אם נציג  $y' \in C'$  עבור  $y = A^{-1}y'$  ונציג ב-  $x \in C$  עבור  $y$  קיבל

$$g(x) \triangleq f(Ax) = f(A(A^{-1}y)) = f(y)$$

כלומר הפונ' היא אותה הפונ' והתחום הואאותה התחום, רק פשוט יותר אנו מסתכלים על הבעיה ממערכות צירים שונות. (מתוחה/מקווצת/מסובבת). רוצים להראות שאם מפעלים אל' אופטימציה על  $P'$ , ונרcha להראות שהאל' אינוריאנטי לטנסופומציה.

**הערה 31.8** התוכונה אינוריאנטיות לטנסופומציה אפינית היא תכונה רצiosa של אל':  
(אנו לא רוצים שהביצועים של האל' יושפעו מ"כמה הצירים מתוחים" או כמה ה"צירים מסובבים").

**הערה 32.8** הוכחה של אינוריאנטיות של אל' לטנס' אפינית היא הוכחה על סדרה של נקודות (אולי אינסופית) ולכן נוח ומקובל להשתמש באינדוקציה לצורך הוכחות אינוריאנטיות.

- הוכחה של אינוריאנטיות עבורה דרך זיהות שראינו בתרגול 1:

– **זיכרון:** אם  $f$  גזירה ברציפות,  $\nabla f(x) = A$   $\in \mathbb{R}^{n \times m}$  אז

$$\boxed{\begin{aligned}\nabla g(x) &= A^T \nabla f(Ax) \\ \nabla^2 g(x) &= A^T \nabla^2 f(Ax) A\end{aligned}}$$

**הערה 33.8** הראנו בתרגול כי אל' פרנק וולף הוא אינוריאנטי לטנסופומציה אפינית

**הערה 34.8** הראנו בתרגול כי אל' הגרדיאנט הוא לא אינוריאנטי לטנסופומציה אפינית

### 8.2.3 מומנטום ואלגוריתם הגרדיאנט המואץ של נסטרוב

נזכר בכלל העדכון עבור אלגוריתם הגרדיאנט :

$$x_{t+1} = x_t - \eta_{t+1} \nabla f(x_t)$$

**זיכרון:**

הכללה של המספר ה**condition number** לפונ'  $f$  קמורות ה**מקיימות** L-חולקות ומ-מתכנסות חזק חזק ה**condition number** ה**condition number** גדר את ה**condition number**.

$$\kappa \triangleq \frac{1}{\gamma} = \frac{L}{\mu}$$

בעבר כי ביצועי האל' GD מקיים :

$$f(\mathbf{x}_t) - f(\mathbf{x}) \leq \left( \frac{\kappa - 1}{\kappa + 1} \right)^{2t} (f(\mathbf{x}_0) - f(\mathbf{x}^*))$$

כלומר הביצועים


יכולים להיות גראויים במקרים בהם  $\kappa$  (condition number) של הפונ' גדול מדי.  
 (ככל שהוא גדול, הקבוע  $\frac{\kappa - 1}{\kappa + 1}$  יותר ויותר קרוב ל 1, וכך הסתכנות אומנם אפקטיבית אבל הקבוע שיש לנו בסיס מאוד קרוב לו. לכן עבור  $0 > \kappa \gg 1$  הסתכנות תהיה איטית יותר).  
 בעיות בהם ה  $\kappa$  condition number גדול נקראות poorly conditioned (או ill-conditioned) ובעורן קצב הסתכנות של אלגוריתם הגרדיינט הוא איטי.  
 איטואיטיבית, עבור בעיות אלו האלגוריתם מבצע חלק מהצרירים בכיוונים מנוגדים ("זינגן").

**הוספת איבר מומנטום לאלגוריתם GD** על מנת להתגבר על הבעיה הזו מוצא להוסיף איבר מומנטום momentum לאלגוריתם הגרדיינט:

$$\mathbf{x}_{t+1} = \mathbf{x}_t - \eta_{t+1} \nabla f(\mathbf{x}_t) + \beta (\mathbf{x}_t - \mathbf{x}_{t-1})$$

כאשר  $1 < \beta < 0$  הוא פרמטר כלשהו.

(איבר המומנטום הוא  $\beta(\mathbf{x}_t - \mathbf{x}_{t-1})$  האיבר הזה "מושך אותו" לכיוון של אותוצעד שביצעתו באיתרציה הקודמת) במידה ועדכן הגרדיינט הנוכחי הוא באותו כיוון כמו העדכון הקודם איבר המומנטום יגדיל את הסתכנות בכוון זה (ואילו אם העדכון הנוכחי בכוון מנוגד לעדכון הקודם איבר המומנטום יקטין את הסתכנות).



**הערה 35.8** הרבה פעמים נתונים אנלוגיה פיזיקלית של ירידה במורד הגרדיינט (אלג' גרדיינט רגיל) כאיש שיורד בכיוון הירידה ה��rm. חזקה של החר והקצב הסתכנות של האיש, וירידה במורד הגרדיינט עם מומנטום לכדור שבסופה יירידה מההר צובר תאוצה לאורץ המורד.

**הערה 36.8** באופן מעשי משתלים לבחור את  $\beta$  שהיא כמה שיותר גדול ובתחום  $0 < \beta < 1$  לדוגמה  $\beta = 0.99$ .

כעת ניתן לרשום את צעד העדכון בצורה דו שלבייה:

$$\begin{cases} \mathbf{v}_{t+1} = \beta \mathbf{v}_t - \eta_{t+1} \nabla f(\mathbf{x}_t) \\ \mathbf{x}_{t+1} = \mathbf{x}_t + \mathbf{v}_{t+1} \end{cases}$$


למה זה נכון? כי :

$$\begin{aligned}
 \mathbf{x}_{t+1} &= \mathbf{x}_t + \mathbf{v}_{t+1} \\
 &= \mathbf{x}_t + \beta \mathbf{v}_t - \eta_{t+1} \nabla f(\mathbf{x}_t) \\
 &= \mathbf{x}_t - \eta_{t+1} \nabla f(\mathbf{x}_t) + \beta \mathbf{v}_t \\
 \mathbf{x}_{t+1} &= \mathbf{x}_t + \mathbf{v}_{t+1} \\
 \Rightarrow \mathbf{x}_t &= \mathbf{x}_{t-1} + \mathbf{v}_t \\
 \Rightarrow \mathbf{x}_t - \mathbf{x}_{t-1} &= \mathbf{v}_t \\
 &\stackrel{\text{ר'}מ}{=} \mathbf{x}_t - \eta_{t+1} \nabla f(\mathbf{x}_t) + \beta (\mathbf{x}_t - \mathbf{x}_{t-1})
 \end{aligned}$$

**אלגוריתם הגרדיינט המואץ של נסטרוב Nesterov's accelerated gradient** הוא וריאציה נוספת של אלגוריתם הגרדיינט. כלל העדכון עבור אלגוריתם זה דומה לשיטת המומנטום אך במקומו לחשב את הגרדיינט בנקודה  $\mathbf{x}_t$  ולאחר מכן לבצע עדכון גריידנאט ועדכון מומנטום, הגרדיינט מחושב בנקודה המתקבלת לאחר עדכון המומנטום כלומר כלל העדכון עבור אלגוריות הרדיינט המואץ הינו

$$\begin{cases} \mathbf{v}_{t+1} = \beta \mathbf{v}_t - \eta_{t+1} \nabla f(\mathbf{x}_t + \beta \mathbf{v}_t) \\ \mathbf{x}_{t+1} = \mathbf{x}_t + \mathbf{v}_{t+1} \end{cases}$$

אייר להמחשה:



נזכיר כי גם כאן :

$$\begin{aligned}
 \mathbf{x}_{t+1} &= \mathbf{x}_t + \mathbf{v}_{t+1} \\
 \Rightarrow \mathbf{x}_t &= \mathbf{x}_{t-1} + \mathbf{v}_t \\
 \Rightarrow \mathbf{x}_t - \mathbf{x}_{t-1} &= \mathbf{v}_t
 \end{aligned}$$

nestrov הרואה שכלל עדכון זה מישג קצב של  $(\frac{1}{t^2})$  עבור פונ' קמורות וחלקות (ולעומת  $(\frac{1}{t})$  עבור אלג' הגרדיינט הרגיל).  
כלומר כלל עדכון זה עדכון זה מישג קצב של  $(\frac{1}{t^2})$  עבור פונ' קמורות וחלקות. כלומר עבור פתרון  $\epsilon$  תת אופטמלי נוצר לכת סדר גודל של  $\frac{1}{\sqrt{\epsilon}}$  סיבובים


$$\begin{aligned}
 \frac{1}{t^2} &\leq \epsilon \\
 \Rightarrow \frac{1}{\epsilon} &\leq t^2 \\
 \Rightarrow \frac{1}{\sqrt{\epsilon}} &\leq t
 \end{aligned}$$

(שזה הרובה יותר טוב לעומת  $\frac{1}{\epsilon}$  צעדים בלבד הרגיל).

**מחוץ לחומר הקורס:**

נסטרוב הראה שגם קצב של  $(\frac{1}{t^2})$  הוא הקצב הכי טוב שאפשר להשיג לכל שיטה מסדר ראשון. (חסם על קצב התכנסות עבור שיטות מסדר ראשון (שיטות שבמציאות עדכוניות לפי הפון והגרדיינטיים שלה) זה למעשה הקצב הנמוך ביותר שניתן להשיג, שימוש על ידי האלגוריתם של נסטרוב).

**איור לסייע:**



animación מוחשב של אלג' המומנטום (יש באתר הסברים על הנושא של מומנטום)

<https://distill.pub/2017/momentum/>

### 8.3 תרגיל בית 3

הינו צריכים לזכור בתרגיל בית 3 כי עברו הפרבולה נתון על ידי  $y = ax^2 + bx + c$  (אפשר להגיע מותוך גזירה והשוואה לאפס)

### חלק III

## הLAGRANGIAN והבעה הדואלית

### 9 הרצאה 9 ותרגול 9

#### 9.1 הרצאה 9

מה שעשינו בשבועות האחרונים - התרכנו באלו' מסדר ראשון.(שיטת שימושות בנגזרת הראשונה של פונ' המטרה כדי להתקדם).  
אינו מספר שיטות כללה, הראשונה הייתה GD וגרסאותיה ( GD עם אילוצים/GD עם סטטיסטי) ובשיעור האחרון למדנו גם על  
אל' פרנק וולף ועל אל' המונטום של נסטרוב.  
בשיעורים הקרובים נדבר על מושג הדואליות ונראה שהוא מאד שימושי, במיוחד בהקשר של בעיות קמורות.

#### 9.1.1 לAGRANGIAN

נתבונן בבעית האופטימציה הבאה

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{subject to: } & h_i(\mathbf{x}) \leq 0, i = 0, 1, 2, \dots, m \\ & l_i(\mathbf{x}) = 0, i = 0, 1, 2, \dots, r \end{aligned}$$

הבעה לא חייבת להיות בעית אופטימציה קמורה אבל הקורס נשים דגש מיוחד על המקירה שבו היא קמורה.  
(כרגע הדיון הוא עבור המקירה הכללי - הבעיה לא חייבת להיות בעית אופטימציה קמורה)

- נציג את מושג הLAGRANGIAN שהרעיון שלו הוא להתאים לכל אילוץ משתנה סקלרי.  $\mathbf{u}$  הוא סקלר שיוטאם לאילוץAi שווין לה?  $(l_i(\mathbf{x}) = 0, i = 0, 1, 2, \dots, r)$

הגדרה 9.1 נגידיר את הLAGRANGIAN באופן הבא:

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) + \sum_{j=1}^r v_j l_j(\mathbf{x})$$

כאשר  $\mathbf{u} \in \mathbb{R}^r$ ,  $\mathbf{v} = (v_1 \ v_2 \ \dots \ v_r) \in \mathbb{R}_+^m$ ,  $\mathbf{u} = (u_1 \ u_2 \ \dots \ u_m) \in \mathbb{R}_+^m$ ,  $v_i \geq 0 \quad \forall i \in \{1, \dots, m\}$ :  
 $L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = -\infty$  אם  $(\mathbf{x}, \mathbf{u}) \notin \mathbb{R}_+^m$  אחרת (אם

הערה 2.9 באופן כללי נגish כי הLAGRANGIAN מוגדר גם עבור  $\mathbf{x}$ -ים שאינם בתחום האילוץ (=שאים פיזיים). ככלומר הLAGRANGIAN מוגדר לכל  $\mathbf{x}$ . (כלומר  $\mathbf{x} \in \mathbb{R}^n$ )

כעת ניתן לראות שלקחנו את בעית האופטימציה המקורית (בעיה עם אילוצים) ועשינו לה מניפולציה באופן כזה שבו קיבלנו בעיה חדשה שאינה עם אילוצים, שבvezים אילוצי הבעיה המקורית נכניםים לפונ' המטרה החדשה שלנו ( $\mathbf{u}, \mathbf{v}, L(\mathbf{x})$  ע"י הLAGRANGIAN).

אם בוחרים את  $\mathbf{u}$ ,  $\mathbf{v}$  באופן שירוטי הבעיה (בעית האופטימציה המקורית ובעית  $(\mathbf{u}, \mathbf{v}, L)$  הנ"ל אינם שקולות, אנחנו נראה באילו מקרים הבעיה הילו כן שקולות. בעצם דרך כתיבת הLAGRANGIAN היא מעבר מבעה מאולצת לבעיה אחרת שאינה מאולצת שבה האילוצים נכניםים לתוך פונ' המטרה.

היתרון שנראה בשינויים הבאים הוא שונעשה זאת נחפוץ את הבעיה המאולצת לבעיה לא מאולצת "נבטל את אילוצים".

#### 9.1.2 אינטואיציה לגבי הLAGRANGIAN

נתעלם לרגע מאיוצי השוויון (אפשר להזכיר את האינטואיציה עבורם גם למשזה זה שילוב של שני אילוצי Ai שווין חלש  $\leq$ ). לצורך פישוט הדיון.

נתבונן בבעיה המקורית (נקראת גם הבעיה המקורית, או הבעיה הפרימלית (primal)):

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{subject to: } & h_i(\mathbf{x}) \leq 0, i = 0, 1, 2, \dots, m \end{aligned}$$

$$\min_{\mathbf{x}} \max_{\mathbf{u} \geq 0} f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x})$$

(נזכיר שהמשמעות  $0 \leq \mathbf{u}$  היא  $\mathbf{u} = (u_1 \ u_2 \ \dots \ u_m) \in \mathbb{R}_+^m$ ).  
למה הבעיות הם שקולות? ה $\mathbf{x}$  האופטמלי הוא זהה עבור שתי הבעיות האלה.  
למה?

- אם  $\mathbf{x}$  נקודה פיזבלית (נקודת פיזבלית=נקודת המקיממת את האלוצים),  $\forall i : h_i(\mathbf{x}) \leq 0$  (כי הנקודת מקיימת את האלוצים) ולבסוף

$$\max_{\mathbf{u} \geq 0} f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) = f(\mathbf{x})$$

– במקרה הזה  $0 \leq \forall i : h_i(\mathbf{x}) \leq 0$  ועל מנת להגיע למצב שעבורו מקבלים את המקסימום של הפונ'  $f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) = f(\mathbf{x})$ . נבחר  $0 \leq u_i \equiv 0$ . ואז אכן  $\exists i : h_i(\mathbf{x}) > 0$ :

$$\max_{\mathbf{u} \geq 0} f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) = \infty$$

– במקרה הזה מכיוון ש  $0 \leq \exists i : h_i(\mathbf{x}) > 0$  נוכל לבחור את  $u_i = \infty$  ואז ערך הבוטוי הכלול יהיה אינסופי.

**מסקנה 3.9** מסקנה, עבור כל  $\mathbf{x}$  פיזבל:

$$\max_{\mathbf{u} \geq 0} f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) = f(\mathbf{x})$$

עבור כל  $\mathbf{x}$  שאינו פיזבל,

$$\max_{\mathbf{u} \geq 0} f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) = \infty$$

המסקנה היא שאם רוצים למצוא בעיה שוקלה לבעה המקורית שלנו נרצה את ה $\mathbf{x}$  עבורו הבוטוי יהיה מינימלי.  $\mathbf{x}$ -ים לא פיזబליים "סוננו" מכיוון ש  $\max_{\mathbf{u} \geq 0} f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) = \infty$ .  
ולכן מכאן נובע כי קיבלנו בעיה שוקלה לבעה המקורית שלנו.

$$\begin{aligned} \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{subject to: } h_i(\mathbf{x}) \leq 0, i = 0, 1, 2, \dots, m \end{aligned} \iff \min_{\mathbf{x}} \max_{\mathbf{u} \geq 0} L(\mathbf{x}, \mathbf{u})$$

$$\max_{\mathbf{u} \geq 0} \underbrace{\min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u})}_{g(\mathbf{u})}$$

למעשה, (החלפנו בין  $\max_{\mathbf{u} \geq 0}$  ל  $\min_{\mathbf{x}}$ ). ככלומר בעיה דואלית קודם נרצה למצוא מינימום של  $\mathbf{x}$  על הלגראנג'יאן ורק לאחר מכן נמצא מינימום על פני כל ה $\mathbf{u}$ . נשאלת השאלה מתי/אם ניתן להחליף  $\min \leftrightarrow \max$

#### הגדרה 4.9 נגדיր את הפונ' הדואלית

$$g(\mathbf{u}) = \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u})$$

#### הגדרה 5.9 נגדייר את הבעה הדואלית (או: בעיית גראנג' הדואלית)

$$\max_{\mathbf{u} \geq 0} g(\mathbf{u}) = \max_{\mathbf{u} \geq 0} \underbrace{\min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u})}_{g(\mathbf{u})}$$

**הערה 6.9** כלומר בבעיה זו מתקאים את  $\mathbf{u}$  ומצביעים את  $\min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u})$  על פני  $\mathbf{x}$  הפלט הוא פונ' של  $\mathbf{u}$  שאוותה מצביעים לפני  $\mathbf{u}$ .

**הערה 7.9** נציג כי באופן כללי  $\min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v}) \triangleq g(\mathbf{u}, \mathbf{v})$

**הערה 8.9** במקרה הכללי הבעיה הדואלית  $\max_{\mathbf{u} \geq 0} g(\mathbf{u}) = \max_{\mathbf{u} \geq 0} \underbrace{\min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u})}_{g(\mathbf{u})}$  והבעיה  $\min_{\mathbf{x}} \max_{\mathbf{u} \geq 0} L(\mathbf{x}, \mathbf{u})$  אין שקולות, אבל במקרה שאנו מתעניינים בו. הרבה פעמים נראה שניתן לפטור את הבעיה הדואלית ביותר קלות ודרך הפתרון שלה נראה שייתור קל להגיע לפתרון של הבעיה המקורי (הבעיה הפרימלית).

בשיעורים הבאים נדבר מדוע הבעיות הללו שימושיות. בשיעור זהה נדבר על תוכנות של הבעיות הללו. בהמשך המוטבציה לנושא הדואליות תהיה ברורה יותר.

**הערה 9.9** במקרה שאנו מדברים על אילוצי שווין בעיה, נוכל לפרט את הבעיה השוקלה לבעיה הפרימלית באופן הבא:

$$\max_{\mathbf{u} \geq 0, \mathbf{v}} \underbrace{f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) + \sum_{j=1}^r v_j l_j(\mathbf{x})}_{L(\mathbf{x}, \mathbf{u}, \mathbf{v})} = f(\mathbf{x})$$

תבונה חשובה של הלגראנ'יאן לכל  $0 \leq \mathbf{u}$  ו  $\mathbf{v}$  מתקיים ש  
לכל  $\mathbf{x}$  פיזבילי :

$$f(\mathbf{x}) \geq L(\mathbf{x}, \mathbf{u}, \mathbf{v})$$


מדוע?

מכיוון שלכל  $\mathbf{x}$  פיזבילי (=משמעותם את האילוצים) מתקיים

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = f(\mathbf{x}) + \sum_{i=1}^m u_i \underbrace{h_i(\mathbf{x})}_{\leq 0} + \sum_{j=1}^r v_j \underbrace{l_j(\mathbf{x})}_{= 0}$$


כלומר הלגראנ'יאן לכל  $\mathbf{x}$  פיזבילי חוסם מלמטה את הפונ'.

**דוגמה 10.9** איור לדוגמא:



- Solid line is  $f$
  - Dashed line is  $h$ , hence feasible set  $\approx [-0.46, 0.46]$
  - Each dotted line shows  $L(x, u, v)$  for different choices of  $u \geq 0$

(From B & V page 217)




כל הערכים  $\alpha$  הפיאבולים (או  $0.5, 0.5,-$ ) לכל הערכים של  $\pi$  נראה שהלגראנזיאן מתחת לפונ' המטרה  $f$ . עבור ערכים שאינם פיאבולים קיימים ווקטוריו  $\pi$  עבורם הלגראנזיאן מעל הפונ'

נסמן  $C$  זה התחום האילוֹז של הבעה הפרימלית  $C$  הוא התחום בו האילוֹזים מתקיימים  $= C$  הוא אוסף כל הנק' הפיזבוליות. נסמן  $(x)$   $f^* = \min_{x \in C} f$  קלומר  $f^*$  הוא הערך האופטמלי של הבעה הפרימלית. אז נוצר  $L(x, u, v)$  מעל כל  $x$  נוציא לנו את החסם התחתון הבא:

$$f^* = \min_{\mathbf{x} \in C} f(\mathbf{x}) \geq \min_{\mathbf{x} \in C} L(\mathbf{x}, \mathbf{u}, \mathbf{v}) \geq \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v}) \triangleq g(\mathbf{u}, \mathbf{v})$$

### דוגמה 11.9 איור לדוגמא:



- Dashed horizontal line is  $f^*$
  - Dual variable  $\lambda$  is (our  $u$ )
  - Solid line shows  $g(\lambda)$

(From B & V page 217)

(From B & V page 217)

**הערה 12.9** נבחין כי אכן הסימן  $\lambda$  הוא למעשה מעשה  $u$ .  
כלומר  $f^*$  חסום מלמטה לכל ערך של  $u$ ,

**דוגמה 9.13 דוגמא: תוכנות ריבועי**

$$\begin{aligned} & \min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{c}^T \mathbf{x} \\ & \text{subject to: } A \mathbf{x} = \mathbf{b}, \mathbf{x} \geq 0 \end{aligned}$$

כasher 0 <

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{c}^T \mathbf{x} - \mathbf{u}^T \mathbf{x} + \mathbf{v}^T (\mathbf{A} \mathbf{x} - \mathbf{b})$$

**הערה 14.9** מדוע כי בבעיה הפרימילית  $0 \leq h(\mathbf{x})$  ומכיוון ש  $h(\mathbf{x}) = -\mathbf{u}^T \mathbf{x} = \sum_{i=1}^m u_i h_i(\mathbf{x})$  נובע ש  $\mathbf{x} \geq 0$  כאשר  $h_i(\mathbf{x}) = -x_i$ .

נבחין כי הבעיה  $(\mathbf{u}, \mathbf{v}, \mathbf{x})$  היא בעיה ריבועית בא' ומכיוון ש  $0 \prec Q$  נובע כי  $\mathbf{Q}$  היא חיובית. (כל הע"ע שלה חיוביים).

הבעיה  $(\mathbf{u}, \mathbf{v}, \mathbf{x})$  היא בעיה קמורה בא' ונitinן לאור לפ'  $\mathbf{x}$  ולפי כללי גזירה וקטוריות ולמוצה לה מינימום.

מסתבר שams גזרנו ומיצאנו את  $\mathbf{x}$  האופטימי והצבנו אותו בחזרה בביטוי  $(\mathbf{u}, \mathbf{v}, \mathbf{x})$  נקבל את **בעיית הלגאנגייאן הדואלית** בلمור

**נקבל כי:**

**בעיית הלגאנגייאן הדואלית :**

$$g(\mathbf{u}, \mathbf{v}) = \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = -\frac{1}{2} (\mathbf{c} - \mathbf{u} + \mathbf{A}^T \mathbf{v})^T Q^{-1} (\mathbf{c} - \mathbf{u} + \mathbf{A}^T \mathbf{v}) - \mathbf{b}^T \mathbf{v}$$

לכל  $0 \leq \mathbf{u}$  ולכל  $\mathbf{v}$ , זה בעצם חסם תחתון על הערך האופטימי של הבעיה המקורית  $f^*$  (הבעיה הפרימילית).

**תזכורת של הסימון :**  $(f^* = \min_{\mathbf{x} \in C} f(\mathbf{x}))$

**הערה 15.9** איך מוצאים את  $g(\mathbf{u}, \mathbf{v}) = ?$

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{c}^T \mathbf{x} - \mathbf{u}^T \mathbf{x} + \mathbf{v}^T (\mathbf{A} \mathbf{x} - \mathbf{b})$$

נשים לב ש  $L(\mathbf{x}, \mathbf{u}, \mathbf{v})$  היא קמורה בא' מכיוון ש  $0 \prec Q$ . וכן נרודת המינימום הכלובלי שלה היא הנקודה שבה הנגרת מותאמת. ככלומר

$$\mathbf{x}^* = \arg \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v}) \iff \nabla_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v})|_{\mathbf{x}=\mathbf{x}^*} = 0$$

לאחר מכן נציב את  $\mathbf{x}^*$  ב- $L(\mathbf{x}, \mathbf{u}, \mathbf{v})$  נקבל את  $g(\mathbf{u}, \mathbf{v})$  ככלומר

$$g(\mathbf{u}, \mathbf{v}) = L(\mathbf{x}^*, \mathbf{u}, \mathbf{v})$$

**דוגמה 16.9 דוגמא: תכונות ריבועי**  $Q \subseteq 0$  כמו קודם, נזכיר בבעיית התכונות הריבועי

$$\begin{aligned} & \min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{c}^T \mathbf{x} \\ & \text{subject to: } \mathbf{A} \mathbf{x} = \mathbf{b}, \mathbf{x} \geq 0 \end{aligned}$$

הפעם  $Q \subseteq 0$  כמו קודם, הלאגראנזיאן נתון על ידי

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = \frac{1}{2} \mathbf{x}^T Q \mathbf{x} + \mathbf{c}^T \mathbf{x} - \mathbf{u}^T \mathbf{x} + \mathbf{v}^T (\mathbf{A} \mathbf{x} - \mathbf{b})$$

**בעיית הלגאנגייאן הדואלית :**

$$g(\mathbf{u}, \mathbf{v}) = \begin{cases} -\frac{1}{2} (\mathbf{c} - \mathbf{u} + \mathbf{A}^T \mathbf{v})^T Q^\dagger (\mathbf{c} - \mathbf{u} + \mathbf{A}^T \mathbf{v}) - \mathbf{b}^T \mathbf{v} & \text{if } (\mathbf{c} - \mathbf{u} + \mathbf{A}^T \mathbf{v}) \perp \text{null}(Q) \\ -\infty & \text{else} \end{cases}$$

**סימון 17.9** כאשר  $Q^\dagger$  מסמן את **ההופכי המוכלל (=הפסאדו אינורס)** של  $Q$ .  
 $\Lambda = \Lambda^T$  סמטרית. המשפט הפירוק הספקטורי קיימת מט' יונטרית  $U$  ( $I = U^T U = UU^T$ ) ומט' אלכסונית  $\Lambda = \begin{pmatrix} 0 & & & \\ \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ 0 & \cdots & 0 & \lambda_n \end{pmatrix}$  אזי נגדיר את **ההופכי המוכלל (=הפסאדו אינורס)** של  $Q$ . להיוות  $Q = U^T \Lambda U$  diag( $\lambda_1, \dots, \lambda_n$ ) =

$$Q^\dagger = U^T \Lambda^\dagger U$$

כאשר  $\tilde{\lambda}_i = \begin{cases} \lambda_i^{-1} & \text{if } \lambda_i > 0 \\ 0 & \text{if } \lambda_i = 0 \end{cases}$  וכאשר  $\Lambda^\dagger = \text{diag}(\tilde{\lambda}_1, \dots, \tilde{\lambda}_n)$  כל הע' שלה אי-שליליים ולכן  $Q^\dagger$  מוגדרת היטב).

**הערה 18.9** עמודות  $U$  מהוות בסיס אורתונומלי למרחב  $\mathbb{R}^n$  אשר عمودותיה הם הע' של  $Q$ . (כאשר העמודה  $u$  של  $U$  היא הווגטור העצמי המתאים לערך העצמי  $\lambda_i$  של  $Q$  (שהע' זה נמצוא את האלכסון של  $\Lambda$ )).

לכל  $0 \geq u$  ולכל  $v$ , עבור  $(c - u + A^T v) \perp \text{null}(Q)$  נובע כי  $(c - u + A^T v) \perp \text{null}(Q)$  (שאינו טרוואלי, כיוון אינו  $\infty$ ) ש- $f^*$  (תזכורת של הסימון:  $f^* = \min_{x \in C} f(x)$ )

**הערה 19.9** הסביר על מה זה  $(c - u + A^T v) \perp \text{null}(Q)$ . (הסימן  $\perp$  משמעו "אורטוגונלי". ככלומר המשמעות היא שהווקטור  $(c - u + A^T v)$  אортוגונלי ל  $\text{null}(Q)$ .

**הערה 20.9** שני וקטורים הם אוטוגונליים זה לזה אם ורק אם מכפלתם הפנימית שווה ל-0. ככלומר  $0 = u^T v \iff u \perp v$

**סימון 21.9** הסביר על מה זה  $\text{null}(Q)$ , זה אוסף כל הווקטורים שהכפלה שלהם מימין ל- $Q$  ב- $Q$  תניב את וקטור האפס. ככלומר  $\text{null}(Q) = \{x \mid Qx = 0\}$

כלומר  $(v, u)$  מhoeה חסם תחתון על  $f^* = \min_{x \in C} f(x) \geq g(u)$  (בנקודות הפיזבליות, חסם תחתון טרוואלי ובנקודות שלא מהוות  $\infty$  – שזה גם חסם תחתון על  $f^*$ ). אינטואטיבית לביעית הלגאנגיין הדואלית הנ'':

$$g(u, v) = \begin{cases} -\frac{1}{2} (c - u + A^T v)^T Q^\dagger (c - u + A^T v) - b^T v & \text{if } (c - u + A^T v) \perp \text{null}(Q) \\ -\infty & \text{else} \end{cases}$$

מדובר בעיית הלגאנגיין הדואלית יש אפשרויות לקבל  $-\infty$ ?

**לحلו אינטואטיבית בדוגמא:**  $c = \begin{pmatrix} c_1 \\ c_2 \end{pmatrix}$ ,  $x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$  ( $c^T x = 0$  (כלומר  $Q \succeq 0$  (נסמן  $Q = \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$ )) מטאפסים או המינימום של הפונ'  $\min_x \frac{1}{2} x^T Q x + c^T x$  יהיה מינוס אינסופי). איך רואים את זה:


$$\begin{aligned} \frac{1}{2} x^T Q x + c^T x &= \frac{1}{2} \begin{pmatrix} x_1 & x_2 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + \begin{pmatrix} c_1 & c_2 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} \\ &= \frac{1}{2} \begin{pmatrix} x_1 & 0 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + c_1 x_1 + c_2 x_2 \\ &= \frac{1}{2} x_1^2 + c_1 x_1 + c_2 x_2 \end{aligned}$$

בגלו' של  $x_2$  אין רכיב ריבועי כלל (אין  $\frac{1}{2} x_2^2$  בבטוי), אז אם ניקח את  $x_2$  להיות אינסוף בסימן הפוך משל  $c_2$  נקבל  $-\infty$ .

**דוגמה 22.9** איור לדוגמא:

## Example: quadratic program in 2D

We choose  $f(x)$  to be quadratic in 2 variables, subject to  $x \geq 0$ .  
 Dual function  $g(u)$  is also quadratic in 2 variables, also subject to  
 $u \geq 0$



Dual function  $g(u)$   
 provides a bound on  
 $f^*$  for every  $u \geq 0$

Largest bound this  
 gives us: turns out  
 to be exactly  $f^*$  ...  
 coincidence?

More on this later,  
 via KKT conditions

נגיש כי הנקודה התחתונה ביותר בביטוי בבעיה המקורית (נקודה אדומה) שווה בערך לנקודה הגבוהה ביותר בבעיה הדואלית (הנקודה החוללה).

הדבר הזה הוא לא צירוף מקרים, המינימום של הבעיה המקורית והמקסימום של הבעיה הדואלית הם מתלכדים עבור עוביות מהצורה האזוי, ככלומר עבור בעיות קשורות (ותחת תנאים נוספים שנלמד בהמשך).

הדבר הזה הוא לא נכון באופן כללי. ככלומר, אנו כן יודעים שבאופן כללי ערכי פונ' המטריה הפרימלית קטנים או שווים מערכי פון' המטריה המקורית אבל המינימום של הדואלי מתלכד עם המינימום של הפרימלי מתקיים רק עבור בעיות עם תכונות מיוחדות, ככלומר ההתלכדות הזאת לא נכונה באופן כללי.

עד כה, ראיינו כי:  
 הבנתן הבעיה הפרימלית:

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{subject to: } & h_i(\mathbf{x}) \leq 0, i = 0, 1, 2, \dots, m \\ & l_i(\mathbf{x}) = 0, i = 0, 1, 2, \dots, r \end{aligned}$$

הפונ' הגואלית  $(\mathbf{v}, \mathbf{u})$  מקיימת  $g(\mathbf{u}, \mathbf{v}) \geq f^*$  לכל  $0 \geq \mathbf{u}$  ולכל  $\mathbf{v}$ . נרצה למצוא את החסם החדוק ביותר של  $f^*$  מלמטה. (היחסים התחתון הגדול ביותר).

לכן החסם התחתון החדוק ביותר הוא מיקסום של  $(\mathbf{v}, \mathbf{u})$  מעל אוסף הנקודות  $\mathbf{u}$ ,  $\mathbf{v}$  הפיזבוליות. ביצעו מקסימציה זו ייבא את **בעיית לגראנג הדואלית**:

$$\begin{aligned} & \max_{\mathbf{u}, \mathbf{v}} g(\mathbf{u}, \mathbf{v}) \\ \text{subject to: } & \mathbf{u} \geq 0 \end{aligned}$$

### 9.1.2. **תכונות של הבעיה הדואלית**

**דואליות חלשה** תכונת מפתח נוספת של הבעיה הדואלית היא **דואליות חלשה**:

נסמן את הערך המקסימלי של בעיית לגראנג הדואלית  $g^*$  (כלומר  $(\mathbf{v}, \mathbf{u}) = g^*$ ) ונסמן את ערך המינימלי של הבעיה הפרימלית (כלומר  $(\mathbf{x}) = f^*$ ) אז **תכונת הדואליות חלשה** היא שמתקיים

$$f^* \geq g^*$$

**הערה 23.9** נשים לב שאנו שווין זה **תמיד מתקיים**. אי שווין זה מתקיים גם במקרה ההפוך. ככלומר, תמיד המינימום של הבעיה הדואלית קטן או שווה למינימום של הבעיה הפרימלית.

**בעיה קמורה** תכונת מפתח נוספת של הבעיה הדואלית היא שהיא **בעיית אופטימציה קמורה**. (כפי שכותבנו אותה קודם, היא בעית מקומציה קעורה שזה שקול לבעית אופטימציה קמורה (ראה הערת מטה)).

$$\max_{\mathbf{u}, \mathbf{v}} g(\mathbf{u}, \mathbf{v})$$

subject to:  $\mathbf{u} \geq 0$   
לפי הגדרה:

$$\begin{aligned} g(\mathbf{u}, \mathbf{v}) &= \min_{\mathbf{x}} \{L(\mathbf{x}, \mathbf{u}, \mathbf{v})\} \\ &= \min_{\mathbf{x}} \left\{ f(\mathbf{x}) + \underbrace{\sum_{i=1}^m u_i h_i(\mathbf{x})}_{L(\mathbf{x}, \mathbf{u}, \mathbf{v}) \text{ is linear in } \mathbf{u}, \mathbf{v}} + \sum_{j=1}^r v_j l_j(\mathbf{x}) \right\} \\ &= -\max_{\mathbf{x}} \left\{ \underbrace{\left[ (-1) \left[ f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) + \sum_{j=1}^r v_j l_j(\mathbf{x}) \right] \right]}_{-L(\mathbf{x}, \mathbf{u}, \mathbf{v}) \text{ is linear in } \mathbf{u}, \mathbf{v} \text{ too}} \right\} \end{aligned}$$

**הערה 24.9** אם  $(\mathbf{u}, \mathbf{v})$  קעורה אז  $-g(\mathbf{u}, \mathbf{v})$  היא קמורה, אז  $\min_{\mathbf{u}, \mathbf{v}} -g(\mathbf{u}, \mathbf{v})$  היא פונקציית קמורה. אם לכל  $\mathbf{u} \geq 0$  הערך הדואלי היא בעיה שתמיד קל לפתור. אנו יודעים לפתור בצורות ייעילות בעיות אופטימציה קמורות אז הבעיה הדואלית נחשבת בעיה קלה יחסית.

זכור במשפט

**משפט 25.9** ("מקסימום של פונקציות קמורות") Pointwise maximization . תהיה קבוצה  $S$  . ויהיו  $\{f_1, f_2, \dots\}$  פונקציות. אם לכל  $s \in S$  הפונקציה  $f_s$  היא פונקציה קמורה אז הפונקציה  $g(\mathbf{x}) = \max_{s \in S} f_s(\mathbf{x})$  היא גם פונקציה קמורה. אנו יודעים כי  $L(\mathbf{x}, \mathbf{u}, \mathbf{v})$  – לינארית במשתנים  $\mathbf{u}$ ,  $\mathbf{v}$ . ואנו יודעים כי  $L(\mathbf{x}, \mathbf{u}, \mathbf{v})$  – לינארית במשתנים  $\mathbf{u}$ ,  $\mathbf{v}$ . ולכן הפונ'  $\max_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v})$  גם היא פונ' לינארית וגם  $\max_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v})$  – לינארית במשתנים  $\mathbf{u}$ ,  $\mathbf{v}$ . המרצה מדבר על השקף הנ"ל בשעה 00:06:01 ולא הבנתי אותו. בהרצאה מס' 9 להלן השקף

Another key property: the dual problem is a **convex optimization** problem (as written, it is a concave maximization problem)

Again, this is always true (even when primal problem is not convex)

By definition:

$$\begin{aligned}
 g(u, v) &= \min_x \left\{ f(x) + \sum_{i=1}^m u_i h_i(x) + \sum_{j=1}^r v_j \ell_j(x) \right\} \\
 &= -\max_x \underbrace{\left\{ -f(x) - \sum_{i=1}^m u_i h_i(x) - \sum_{j=1}^r v_j \ell_j(x) \right\}}_{\text{pointwise maximum of convex functions in } (u, v)} \\
 &\quad \text{!! } L(x, u, v) \text{ is linear in } (u, v)
 \end{aligned}$$

That is,  $g$  is concave in  $(u, v)$ , and  $u \geq 0$  is a convex constraint, so dual problem is a concave maximization problem

12

המסקנה היא שהבעיה הדואלית היא בעית אופטימציה מסווג מקסימיזה קעורה או (=שスクולה ל) בעית מינימיזה קוונבקסית (קעורה). (כלומר, רוב הבעיות שראינו עד כה) מה שמעניין זה שהתכוונה הנ"ל על הבעיה הדואלית כלל לא תלואה בתכונות של הבעיה הפרימלית. (לא משנה איך נראה פונ' המטריה או האילוצים ב

$$\begin{aligned}
 &\min_{\mathbf{x}} f(\mathbf{x}) \\
 \text{subject to: } &h_i(\mathbf{x}) \leq 0, i = 0, 1, 2, \dots, m \\
 &l_i(\mathbf{x}) = 0, i = 0, 1, 2, \dots, r
 \end{aligned}$$

תמיד הבעיה הדואלית היא אופטימיזה מסווג מקסימיזה קעורה או בעית מינימיזה קוונבקסית (קעורה)


### 9.1.3 דוגמא

#### דוגמה 26.9 דוגמא : מזעור בעיה ריבועית אינה קמורה

נניח את הפונ' הבאה (פונ' לא קמורה) רוצחים למזרע את  $f(x) = x^4 - 50x^2 + 100x$  (לא קמורה) תחת האילוצים ש  $x \geq -4.5$

Example: nonconvex quartic minimization

Define  $f(x) = x^4 - 50x^2 + 100x$  (nonconvex), minimize subject to constraint  $x \geq -4.5$



Dual function  $g$  can be derived explicitly, via closed-form equation for roots of a cubic equation

כלומר לפי שתי תכונות המפתח, אכן  $g(u)$  מהוות חסם תחתון על  $f^*(u)$ . בנוסח  $f^*(u) = g(u)$  (קמור). לכן מהוות בעית אופטימיזה.

הפונ' הדואלית  $g$  נתונה במופרש על ידי נוסחה סגורה של המשוואות של השורשים הריבועיים של הבעיה הנ"ל.

(נזכיר שהלגראנגייאן מוגדר על ידי במקרה הכללי)  
נתובן בבעיה

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{subject to: } & h_i(\mathbf{x}) \leq 0, i = 0, 1, 2, \dots, m \\ & l_i(\mathbf{x}) = 0, i = 0, 1, 2, \dots, r \end{aligned}$$

עבור המקרה שלנו

$$\min_{x \geq 4.5} f(x) = x^4 - 50x^2 + 100x$$

ניתן לרשום את האילוץ באופן הבא

$$x \geq -4.5 \Rightarrow \overbrace{-x - 4.5}^{h(x)} \leq 0 \Rightarrow h(x) = -x - 4.5 \leq 0$$

נרשום את הלגראנגייאן של במקרה הכללי

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) + \sum_{j=1}^r v_j l_j(\mathbf{x})$$

ונרשום את הלגראנגייאן של במקרה שלנו

$$\begin{aligned} L(x, u) &= f(x) + uh(x) \\ &= x^4 - 50x^2 + 100x + u^T(-x - 4.5) \\ &= x^4 - 50x^2 + 100x - u^T(x + 4.5) \end{aligned}$$

כלומר הלגראנגייאן של הפונ' נתון על ידי

$$L(x, u) = x^4 - 50x^2 + 100x - u^T(x + 4.5)$$

אנו יודעים כי

$$g(u) = \min_x L(x, u)$$

איך מחשבים את  $\min_x L(x, u)$

$$\nabla_x L(x, u) = \frac{d}{dx} L(x, u) = 0$$

לאחר הגזירה מקבלים משווה מסדר 3, עם שלושה שורשים ואחד מהם הוא המינימום הגלובלי. ולכן נציב את כל אחד מהשורשים בבעיה המקורית ונמצא מי מהם יניב את הערך המינימלי. (הנזרת תמיד מתאפסת במינימום הגלובלי ולכן נציב את שלושת השורשים שמצאנו ונראה מי יניב את הערך הכי נמוך).

אפשר ממש לחשב את  $g(u)$  לכל  $u$  (פתרון משווה ממולה 3 לכל  $u$ ) וקבל פתרון סגור ל $(u)$ . זה לא נעים אבל אפשרי. הפתרון זהה אינו טריוואלי והוא נתון על ידי:

$$g(u) = \min_{i=1,2,3} \{F_i^4(u) - 50F_i^2(u) + 100F_i(u)\}$$

כאשר לכל  $i \in \{1, 2, 3\}$

$$\begin{aligned} F_i(u) &= \frac{-a_i}{12 \cdot 2^{\frac{1}{3}}} \cdot \left( 432(100-u) - \left( 432^2(100-u)^2 - 4 \cdot 1200^3 \right)^{\frac{1}{2}} \right)^{\frac{1}{3}} \\ &\quad - 100 \cdot 2^{\frac{1}{3}} \cdot \frac{1}{\left( 432(100-u) - \left( 432^2(100-u)^2 - 4 \cdot 1200^3 \right)^{\frac{1}{2}} \right)^{\frac{1}{3}}} \end{aligned}$$

כasher  $a_1 = 1, a_2 = \frac{(-1+i\sqrt{3})}{2}, a_3 = \frac{(-1-i\sqrt{3})}{2}$   
 מבלי ההקשר של דואליות היה מאד קשה לומר האם  $g$  קמורה או שאינה קמורה, אבל בגלל תוכנות הדואליות אלו ידועים כי  $g$  היא קמורה. (אנו ידועים כי  $g$  היא בעיה דואלית של איזה שהיא בעיה פרימלית ולכן אנו מידית מסיקים כי  $g$  היא בעיה קעורה).

**מסקנה 27.9** ולכן אם יש לי פונ'  $g$  כלשהיא שרטוטים להוכיח (לדוגמא בבדיקה) שהיא קעורה, אז נוכל להראות שהיא מהוות בעיה דואלית של איזה שהיא בעיה פרימלית ולפי התוכונה של בעיה דואלית יונגע כי  $g$  היא פונ' קעורה. **ז' תכונה מאוד שימושית.**

#### 9.1.4 דואליות חזקה.

נזכר כי ראיינו שתמיד  $f^* \geq g^*$  (دواליות חלשה).  
 מצד שני, קיימות בעיות עבורות ניתן להראות כי  $f^* = g^*$ . לתוכנה זו קוראים **دواליות חזקה**.

#### משפט 28.9 תנאי סלטר.

$$\min_{\mathbf{x}} f(\mathbf{x})$$

subject to:  $h_i(\mathbf{x}) \leq 0, i = 1, 1, 2, \dots, m$   
 $l_i(\mathbf{x}) = 0, i = 1, 1, 2, \dots, r$

כך ש  $f$  חן פון קמורה והאלוצים,  $\{h_i\}_{i=1}^m$  קמורים והאלוצים  $\{l_i\}_{i=1}^r$  אפינים (=לינאריים)

2. **ובנוסך קיימת נקודה**  $\mathbf{x} \in \mathbb{R}^n$  **כך** שמתקיים

$$\forall i \in \{1, \dots, m\} : h_i(\mathbf{x}) < 0$$

and

$$\forall i \in \{1, \dots, r\} : l_i(\mathbf{x}) = 0$$

(נקודת פיצולית שמקיימת את כל אלוצי האי שווין כדי שווין חזק)

אזי נאמר שתנאי סלטר מתקיימים **ולמן תכונת הדואליות חזקה מתקיימת, כולם מתקיימים**, כלומר  $f^* = g^*$ .

**הערה 29.9** ההוכחה של המשפט היא לא טרוואלית (היא לא פשוטה ודורשת רקע נוסף) בקורס המתקדם שניתן הסמינר על ידי המרצה כפיר לוי הוכחו את המשפט הנ"ל.

**מסקנה 30.9** אם תנאי סלטר מתקיימים אז תכונת הדואליות חזקה מתקיימת, כולם מתקיימים  $f^* = g^*$ .

#### 9.1.5 דואליות בעיות תוכנות לינאריס linear programs

בהתאם:  $c \in \mathbb{R}^n, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, G \in \mathbb{R}^{r \times n}, h \in \mathbb{R}^r$ ,

Primal LP	dual LP
$\min_{\mathbf{x}} c^T \mathbf{x}$ subject to $A\mathbf{x} = b$ $G\mathbf{x} \leq h$	$\max_{\mathbf{u}, \mathbf{v}} -b^T \mathbf{u} - h^T \mathbf{v}$ subject to $-A^T \mathbf{u} - G^T \mathbf{v} = c$ $\mathbf{v} \geq 0$

כלומר אם לוקחים בעיית linear program ומטסכלים על הבעיה הדואלית שלה, מגלים שגם היא בעית linear program.

הסבר:

לכל  $\mathbf{u}$  ולכל  $\mathbf{x}$  פיזבלי

$$\begin{aligned} \mathbf{u}^T (A\mathbf{x} - b) + \mathbf{v}^T (G\mathbf{x} - h) &\leq 0 \\ \iff (-A^T \mathbf{u} - G^T \mathbf{v})^T \mathbf{x} &\geq -b^T \mathbf{u} - h^T \mathbf{v} \end{aligned}$$

**הערה 31.9** (נבחן כי בסמני השאלה הוא  $\mathbf{x}, \mathbf{u}$  בתקפדים הפוכים מבד"כ, זה סטם סימונים הפוכים מבד"כ) ואיןפה איזה משחו מעבר להזיה)

ולכן אם  $\mathbf{v} = -A^T \mathbf{u} - G^T \mathbf{c}$  קיבל חסם של הערך האופטמלי של הבועה הפרימלית.  
נוכיח את השקילות הנ"ל:

וכoch את השקלות עם הסימונים של  $x$ ,  $u$  בתקפדים כמו שאנו מכירים (ולא הנקטים כמו לעלה) ולבסוף נהפוך את הנקדים של  $u$ ,  $v$

$$\text{Primal LP : } \begin{array}{ll} \min_x c^T x \\ \text{subject to} \\ Ax = b \\ Gx \leq h \end{array}$$

נמצא את הלגאנגיון. האילוצים הלינארים ( $Ax = b$ ) מייצגים על ידי הווקטור  $b$  והאלוצים הלא לינארים ( $Gx \leq h$ ) מייצגים על ידי הווקטור  $h$ . איז?

$$\begin{aligned} Ax = b &\Rightarrow Ax - b = 0 \Rightarrow Ax - b = 0 \\ Gx \leq h &\Rightarrow Gx - h \leq 0 \end{aligned}$$

הlagrangian  
נתון על ידי

$$\begin{aligned} L(x, u, v) &= c^T x + u^T (Gx - h) + v^T (Ax - b) \\ &= c^T x + u^T Gx - u^T h + v^T Ax - v^T b \\ &= c^T x + u^T Gx + v^T Ax - u^T h - v^T b \\ &= (c^T + u^T G + v^T A)x - u^T h - v^T b \end{aligned}$$

(כאשר  $0 \geq u$  ו  $v$  הוא ווקטור מממד מתאים) כלומר lagrangian נתון על ידי

$$L(x, u, v) = (c^T + u^T G + v^T A)x - u^T h - v^T b$$

נזכיר שבונם את בעיה הדואלית  $L(x, u, v)$  על ידי מזעור lagrangian  $(v)$  על פניו  $x$ . (כלומר  $\min_x L(x, u, v)$  נבחן בין 2 מקרים:

1. המקרה הראשון כאשר  $0 \neq (c^T + u^T G + v^T A)$  במקרה זה

$$g(u, v) = \min_x L(x, u, v) = -\infty$$

(מכיוון שנוכל לבחור  $x$  באופן כזה שיביאו את הפונ' למינום אינסוף, נבחר רכיב שאינו מתאפס ב- $(c^T + u^T G + v^T A)$  ונגיד רכיב שקיים לו באט סימן הפוך וגדול (בערך מוחלט) גדול מאוד, כרצוננו, ונקבל  $(-\infty)$ ,

2. אחרת כאשר  $0 = (c^T + u^T G + v^T A)$  ואז

$$g(u, v) = \min_x L(x, u, v) = -u^T h - v^T b$$

ולכן הבעיה הדואלית נתונה על ידי:

$$g(u, v) = \min_x L(x, u, v) = -u^T h - v^T b$$

ולכן

$$\max_{u,v} g(u, v) \iff \begin{array}{l} \max_{u,v} -u^T h - v^T b \\ \text{s.t. : } u \geq 0, v \\ c^T + u^T G + v^T A = 0 \end{array} \quad (\text{Dual LP})$$

מסקנה: אם בעיית האופטימציה היא LP אז גם בעיית האופטימציה הדואלית שלה היא גם LP. ואו אחת התכונות החשובות של דואליות.

אם קיימים פער בין מה שכתוב כאן לבין מה שכתוב במלבון הוא הקובע(המカリע), (זה מה שהמרצה כפיר אמר, ופיתח בהרצאה בעצמו).

**תזכורת: בהינתן**  $\forall i \in \{1, \dots, n\} : x_i \in X = \begin{pmatrix} -x_1- \\ -x_2- \\ \vdots \\ -x_n- \end{pmatrix}$  כאשר  $x_1, \dots, x_n$  עם שורות  $X \in \mathbb{R}^{n \times p}$  ו  $y \in \{-1, 1\}^n$  (כלומר  $C \geq 0$  והוא יש לנו אוסף של זוגות  $(x_i, y_i)$  כאשר  $\{(x_i, y_i)\}_{i=1}^n$ ) נגיד את בעית SVM support vector machine:

$$\begin{aligned} \min_{\beta \in \mathbb{R}^p, \beta_0 \in \mathbb{R}, \xi \in \mathbb{R}^n} & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i + \frac{1}{2} \beta_0^2 \\ \text{subject to } & \xi_i \geq 0, i = 1, \dots, n \\ & y_i (\mathbf{x}_i^T \beta + \beta_0) \geq 1 - \xi_i, i = 1, 2, \dots, n \end{aligned}$$

**הערה 32.9** את הרכיב  $\frac{1}{2} \beta_0^2$  הוספנו לבעה, הוא לא היה בבעיה המקורי SVM (המקורית) כלומר פונ' המטריה מושפעים את הרכיב  $\frac{1}{2} \beta_0^2$  הזה:

ברבבה קורסים מציגים את בעית SVM ומציגים את בעית SVM הדואליות ביל' ממש הרבה הסברים מאיפה הדואליות של הבעיה נולדה. הדואליות שמדוברים עליה בקורסים שקיים או בדיק הדואליות במובן שדיברנו עליי בקורס. הבעיה הדואלית היא הבעיה SVM שהצגנו כעת והבעיה הדואלית היא ניתנת לפיתוח באותו אופן שהציגנו עד כה (cotubim את הפונ' הדואלית ומנסים את הפונ' הדואלית במקומם לפחות את הפונ' הפרימלית). בעית SVM מקיימת את תכונת הפירמליות החזקה, כלומר  $f^* = g^*$ . (למה זה נכון? כי הבעיה היא בעית אופטימציה קמורה ונראה שהיא מקיימת את תנאי סליידר, קיימים  $\beta$  ו- $\xi$ -ים שמייקרים את אילוצי האי שווין בתצורה של אי שוויונות החזקים (בלשון העם: מקיימים אותם ממש)). אין לנו בבעיה או אילוצי שווין, יש לנו 2 סוגים של אילוצי אי שווין

ממצא את הבעי הדואלית של בעית SVM.

נציג את המשתנים החדשניים  $w$ ,  $v$  כך ש  $w \in \mathbb{R}^n$ ,  $v \in \mathbb{R}^n$   $\geq 0$ ,  $\mathbf{w} \in \mathbb{R}^n$   $\geq 0$  שמתיחסים לכל אחד מאילוצי האי שווין

- הוא וקטור כופלי לגראנג' שמתאים לאיוצים  $n$ ,  $\xi_i \geq 0$ ,  $i = 1, \dots, n$  (יש  $n$  אילוצים כאלו ולכן  $v \in \mathbb{R}^n$ ) אילוץ זה הוא אילוץ אי שווין ולכן  $0 \geq 0$ .

- $w$  הוא וקטור כופלי לגראנג' שמתאים לאיוצים  $n$  ( $y_i (\mathbf{x}_i^T \beta + \beta_0) \geq 1 - \xi_i$ ,  $i = 1, 2, \dots, n$ ) (יש  $n$  אילוצים כאלו ולכן  $w \in \mathbb{R}^n$ ) אילוץ זה הוא אילוץ אי שווין ולכן  $0 \geq 0$ .

במקרה הזה הלאנג'יאן נתון על ידי

$$L(\beta, \beta_0, \xi, w, v) = \underbrace{\frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i + \frac{1}{2} \beta_0^2}_{\text{comes from original SVM target fuction}} - \sum_{i=1}^n v_i \xi_i + \sum_{i=1}^n w_i (1 - \xi_i - y_i (\mathbf{x}_i^T \beta + \beta_0))$$

**סימון 33.9** נוסיף את הסימונים הבאים:

$$\mathbf{1} = \begin{pmatrix} 1 & 1 & \dots & 1 \end{pmatrix} \in \mathbb{R}^n, \xi = \begin{pmatrix} \xi_1 \\ \xi_2 \\ \vdots \\ \xi_n \end{pmatrix}$$

$$\tilde{\mathbf{x}}_i = \begin{pmatrix} y_i \mathbf{x}_i \\ y_i \end{pmatrix} \in \mathbb{R}^{p+1}$$

נבחן כי  $\beta_0 \in \mathbb{R}$  ו  $\beta \in \mathbb{R}^p$ . את שני אלו נאחד לכדי משתנה אחד.

$$\tilde{\beta} = \begin{pmatrix} \beta \\ \beta_0 \end{pmatrix} \in \mathbb{R}^{n+1}, \tilde{X} = \begin{pmatrix} -\tilde{x}_1- \\ -\tilde{x}_2- \\ \vdots \\ -\tilde{x}_n- \end{pmatrix} \in \mathbb{R}^{n \times (p+1)}$$

$$L(\beta, \beta_0, \xi, w, v) = \underbrace{\frac{1}{2} \|\tilde{\beta}\|_2^2}_{\frac{1}{2} \|\beta\|_2^2 + \frac{1}{2} \beta_0^2} + \underbrace{C \xi^T \mathbf{1}}_{C \sum_{i=1}^n \xi_i} - \underbrace{v^T \xi}_{\sum_{i=1}^n v_i \xi_i} + \underbrace{w^T (1 - \xi - y_i (\mathbf{x}_i^T \beta + \beta_0))}_{w^T (1 - \xi - \tilde{X} \beta)}$$

באמצעות ההגדרות החדשות נוכל לכתוב את הלגראנגיין מחדש באופ' הבא:

$$L(\tilde{\beta}, \xi, w, v) = \frac{1}{2} \|\tilde{\beta}\|_2^2 + C \xi^T \mathbf{1} - v^T \xi + w^T (1 - \xi - \tilde{X} \beta)$$

נוכל לרשום אותו גם באופן הבא:

$$\begin{aligned} L(\tilde{\beta}, \xi, w, v) &= \frac{1}{2} \|\tilde{\beta}\|_2^2 + C \xi^T \mathbf{1} - v^T \xi + w^T \mathbf{1} - w^T \xi - w^T \tilde{X} \beta \\ &= \frac{1}{2} \|\tilde{\beta}\|_2^2 + w^T \mathbf{1} - w^T \tilde{X} \beta + C \mathbf{1}^T \xi - v^T \xi - w^T \xi \\ &= \frac{1}{2} \|\tilde{\beta}\|_2^2 + w^T \mathbf{1} - w^T \tilde{X} \beta + (C \mathbf{1}^T - v^T - w^T) \xi \\ &= \frac{1}{2} \|\tilde{\beta}\|_2^2 + w^T \mathbf{1} - w^T \tilde{X} \beta + (C \mathbf{1} - v - w)^T \xi \end{aligned}$$

כלומר

$$L(\tilde{\beta}, \xi, w, v) = \frac{1}{2} \|\tilde{\beta}\|_2^2 + w^T \mathbf{1} - w^T \tilde{X} \beta + (C \mathbf{1} - v - w)^T \xi$$

נרצה כזכור למצוא את הבעה הדואלית. נבחן כי הלגראנגיין הוא פונ' קמורה ב $\xi, \tilde{\beta}$ .

**מציאת הבעה הדואלית:**  
איך נראית הבעה הדואלית?

$$g(v, w) \triangleq \min_{\tilde{\beta}, \xi} L(\tilde{\beta}, \xi, w, v)$$

הלגראנגיין הוא פונ' קמורה ב $\xi, \tilde{\beta}$ . ולכן מספיק למצוא  $\xi, \tilde{\beta}$  כך ש

- אם רוצים לעשות מינימיזציה בהתייחס ל $\xi$  ובנוסח  $\mathbf{0} \neq \mathbf{0} = -\infty \neq -\infty$  (כפי שראינו בעבר).

- ולכן, נוסף **איילוץ שווין** על הבעה כך ש  $\mathbf{0} = -\infty \neq -\infty$  (נטרל את ההשפעה של  $\xi$ ) (כי אם נבחר את  $v, w$  כך שהווקטור  $C \mathbf{1} - v - w \neq \mathbf{0}$  אז הבעה הדואלית ערכה יהיה  $-\infty$ ). אנו רוצים למזער את הדואליות ולכן נוסף את איילוץ השווין  $\mathbf{0} = -\infty$  על הבעה הדואלית.

- ואז מספיק למצוא  $\xi, \tilde{\beta}$  כך ש

ולכן מזער על פנ'  $\xi, \tilde{\beta}$  (כלומר על פנ'  $\xi, \beta, \beta_0$ ) ייב את הפונ' הדואלית (פונ' הלגראנגיין הדואלית):

$$g(u, v) = \begin{cases} -\frac{1}{2} w^T \tilde{X} X w + \mathbf{1}^T w & \text{if } w = C \mathbf{1} - v \\ -\infty & \text{else} \end{cases}$$

(היא מתקיים עבור גירהה לפי  $\tilde{\beta}$  והצבה בלגראנגיין, כלומר  $0 = 0$  נרצה להפטר מהה בטוי).

נזכיר כי  $1 \leq v \leq 0$  ולכן איילוץ השווין  $v = C \mathbf{1} - w$  נוכל לרשום כך את

$$\begin{aligned} \max_{\mathbf{w}} & -\frac{1}{2} \mathbf{w}^T \tilde{X} X \mathbf{w} + \mathbf{1}^T \mathbf{w} \\ \text{s.t.} & 0 \leq \mathbf{w} \leq C \mathbf{1} \end{aligned}$$

בדיקה:

תנאי סלטר מתקיימים ולכן יש לנו דואליות חזקה. בנוסף, נזכר שהפתרון של SVM מקיים  $\mathbf{w} = \tilde{X}^T \mathbf{w}$ , זה לא מקרי, כמו שנקרא בהמשך על ידי תנאי KKT.

## 9.2 תרגול 9

### 9.2.1 דואליות

נתבונן בבעיית האופטימציה (נסמנה בעיה  $(P)$ ):

$$\begin{aligned} (P) : \quad & \min_{\mathbf{x}} f(\mathbf{x}) \\ & \text{s.t. } g_i(\mathbf{x}) \leq 0, i = 1, \dots, m \\ & h_j(\mathbf{x}) = 0, j = 1, \dots, p \\ & \mathbf{x} \in C \end{aligned}$$

**סימון 34.9** נסמן את הערך האופטימי שלה ב  $P^*$ .

**הגדרה 35.9** הלגראנגיין המתאים לבעיה זו הינו

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_{i=1}^m \lambda_i g_i(\mathbf{x}) + \sum_{j=1}^p \mu_j h_j(\mathbf{x}), \quad \mathbf{x} \in C, \mathbb{R}^m \ni \boldsymbol{\lambda} \geq \mathbf{0}, \boldsymbol{\mu} \in \mathbb{R}^p$$

פונ' המטריה הדואלית נתונה על ידי

$$q(\boldsymbol{\lambda}, \boldsymbol{\mu}) = \inf_{\mathbf{x} \in C} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu})$$

**הערה 36.9** יכול להיות אינפימום  $\inf \{ \text{מכוון שփו'} (\boldsymbol{\mu}, \boldsymbol{\lambda}) \}$  קולח לשאוף לא  $\infty$ . במקרה של  $C$  קבועה פتوוחה (ולכן נגידר את המינימציה על ידי  $\inf$ ).

**הערה 37.9** לעיתים הקבוצה  $C$  היא לא מסוימת במפורש, ואז  $C = \mathbb{R}^n$ . כלומר אין מקבילות נספות מעבר לאלוצי היא שווין והשוויון חשוב להדגיש כי  $\inf_{\mathbf{x} \in C} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu})$  מוצע מעל  $C$  (כלומר כשאנו מחפשים את  $\boxed{L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu})}$ ).

לא אכפת לנו כלל מאילוצי השווין והאי שווין יותר (כלומר לא אכפת לנו מ  $\begin{cases} g_i(\mathbf{x}) \leq 0, i = 1, \dots, m \\ h_j(\mathbf{x}) = 0, j = 1, \dots, p \end{cases}$  יותר). ולכן כאשר אין אילוץ  $C$  נוסף ( $C = \mathbb{R}^n$ ), אז המינימציה על הלגראנגיין תהיה מהצורה  $q(\boldsymbol{\lambda}, \boldsymbol{\mu}) = \inf_{\mathbf{x} \in \mathbb{R}^n} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu})$ .

**הערה 38.9** בהערכתה ראיינו כי  $C = \{ \mathbf{x} \mid \forall i \in \{1, \dots, m\} : g_i(\mathbf{x}) \leq 0 \text{ and } \forall j \in \{1, \dots, p\} : h_j(\mathbf{x}) = 0 \}$  הקורס בהערכתה ובתרגול קצר שונים כי הקורס עבר שוניים ולכן  $C$  בתרגול מוגדר אחרת (יכול להיות מוגדר בנפרד מ- $(g_i(\mathbf{x}), h_j(\mathbf{x}))$ ). כלומר הגדרה של מודדים כאן שונה מההערכאות וחשוב לשים לב זאת.

באופן כללי, לא כל קבוצת אילוץ  $C$  אפשר לבטא על ידי סט אלוצי שווין ואי שווין  $\{ \mathbf{x} \mid g_i(\mathbf{x}) \leq 0 \text{ and } j \in \{1, \dots, m\} \}$  וולכן האופן הכללי ביותר שבו ניתן להביע אילוץ הוא על ידי קבוצה  $C$  כלשהיא.

**דוגמה 39.9** נניח וישנו אילוץ  $\geq x$  אז נוכל ליצג אותו ככמה אפשרויות (אין סתיירה בינהם וזה שיקול שעומד בפני עצמו פוטר התרגיל):  
1. בثور פונ'  $g$  כלשהיא ואז הוא ייתבטא באיבר של הלגראנגיין ( $\sum_{i=1}^m \lambda_i g_i(\mathbf{x})$  מהצורה  $\{ \mathbf{x} \mid \sum_{i=1}^m \lambda_i g_i(\mathbf{x}) \leq 0 \}$ ), ואז כשנחפש את הבעיה הדואלית נוכל לבצע מנימזציה על כל  $\mathbb{R}^m$  מציאת הבעיה הדואלית ( $q(\boldsymbol{\lambda}, \boldsymbol{\mu}) = \inf_{\mathbf{x} \in \mathbb{R}^m} L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu})$ )

2. מצד אחר נוכל להכנסו אותו לקבוצה  $C$  ואז הוא אלא ייטבעה כאייר של הלגנגיין אבל מציאת הבעה הדואלית  $= q(\lambda, \mu)$ . תتبצע על ידי מינימיזיה מעל התחום של  $C$ .

**הגדרה 40.9** יתכן כי ערך פונקציית המטרה הדואלית הוא  $\infty$ . נגידר לפיכך את התחום של פונקציית המטרה הדואלית על ידי

$$\text{dom}q = \{\lambda, \mu \mid \mathbb{R}^m \ni \lambda \geq 0, \mu \in \mathbb{R}^p, q(\lambda, \mu) > -\infty\}$$

**הערה 41.9** נציג כי  $\infty >$  כלומר בתחום ההגדירה של  $q$  ישנו רק ערכים גדולים  $\infty$ . כלומר  $q$  על תחום הגדירה היא פונ' סופית.

**משפט 42.9** אם בבעיה (P) כל הפונ' סופיות מעלה הקבוצה  $C$ , אז הקבוצה  $\text{dom}q$  קמורה והפונ'  $q(\lambda, \mu)$  קורה מעלה  $\text{dom}q$ .

**הגדרה 43.9** הבעה הדואלית נתונה על ידי (נסמנה בעיה (D)):

$$\begin{aligned} & \max_{\lambda, \mu} q(\lambda, \mu) \\ & \text{s.t. } (\lambda, \mu) \in \text{dom}q \end{aligned}$$

**משפט 44.9** הבעה הדואלית תמיד קמורה (המשפט נכון גם אם הבעה (P) אינה קמורה).

**הערה 45.9** נשים לב כי  $\in \text{dom}q$  ולכן לפי הגדרת  $\text{dom}q$  נובע כי  $< \infty >$  כלומר המשפט הקודם הקבוצה  $\text{dom}q$  קמורה והפונ'  $q(\lambda, \mu)$  קורה מעלה  $\text{dom}q$  ולכן הבעה (D) היא בעית אופטימאלית מסווג מקסימאלית של פונ' קורה (שקלול בעית אופטימאלית מסווג מינימאלית קונבקטית) כלומר בעית האופטימאלית היא בעית אופטימאלית קמורה.

כלומר יש כאן **משפט מאד חזק**, התחלו מבעיה כללית כלשהיא שלא ידעו עליה כלום (אפיו לא חייב שהבעיה המקורית תהיה בעיה קמורה) ויצרנו מותוכה בעית אופטימאלית קמורה חדשה (הבעיה הדואלית) שפתרונות נוכלים להסיק מסקנות (בתקווה) על פתרון בעית מקורית). ולפתרון את הבעה הדואלית יכול להיות קל יותר מכיוון שהוא בעית אופטימאלית קמורה, ויש לנו לא מעט כלים בארגנו לפתרון בעיות מסווג צזה.

**סיכום 46.9** נסמן את הערך האופטימי של הבעה הדואלית ב  $D^*$ .

כלומר לפי הסימונים

primal problem	dual problem
$\min_{\mathbf{x}} f(\mathbf{x})$ $(P) : \begin{array}{l} \text{s.t. } g_i(\mathbf{x}) \leq 0, i = 1, \dots, m \\ h_j(\mathbf{x}) = 0, j = 1, \dots, p \\ \mathbf{x} \in C \end{array}$	$(D) : \begin{array}{l} \max_{\lambda, \mu} q(\lambda, \mu) \\ \text{s.t. } (\lambda, \mu) \in \text{dom}q \end{array}$
solution:	$P^*$

**משפט 47.9** (דו-אליות חלשה) עבור הבעיות (P) ו (D) מתקיים

$$P^* \geq D^*$$

**הערה 48.9** המשפט הנ"ל (דו-אליות חלשה) הנ"ל נכון תמיד.

**מסקנה 49.9** בפרט מתקיים

$$P^* \geq q(\lambda_0, \mu_0), \quad \forall (\lambda_0, \mu_0) \in \text{dom}q$$

זה נכון מכיוון ש  $(\lambda_0, \mu_0) \in \text{dom}q : D^* \triangleq \max_{\lambda, \mu} q(\lambda, \mu) \geq q(\lambda_0, \mu_0)$  כלומר מכאן נובע כי  $D^*$  הוא החסם התיכון ההדוק ביותר שנייה להציג על בעיה (P) שנולדדים מהבעיה הדואלית.

**הגדירה 50.9** ההפרש  $P^* - D^*$  נקרא **פער הדואליות**.

**הגדירה 51.9** אם פער הדואליות הוא 0, כלומר  $P^* = D^*$  אז אנו אומרים כי מתקיימת **דואליות חזקה**.

**הגדירה 52.9** אנו אומרים שהבעה (P) מקיימת את **תנאי סליעטור אם קיים** ( $\hat{x} \in \text{int}(C)$  שקיים לפניו של  $C$  קלומר ל  $C$ Interior ש  $\hat{x}$  שייך לפנים של  $C$ ) אם  $\sum_{i=1}^p g_i(\hat{x}) < 0$  ו  $\sum_{i=1}^m h_j(\hat{x}) = 0 \forall j \in \{1, \dots, m\}$ .  
כלומר, תנאי סליעטור מתקיים אם קיימת נקודה ש"מקיימת ממש" את האילוצים. (מקיים את אי השווונות שבאלוצים גם אילו היו אי שווונות חזקים ונמצאת בפנים של  $C$ )

**משפט 53.9 (דואליות חזקה במקרה הקמור)** אם הבעה (P) קמורה, מקיימת את תנאי סליעטור וכן  $-\infty < P^* \leq D^*$  אז מתקיימת **דואליות חזקה**. קלומר

$$P^* = D^*$$

הערך האופטמלי של הבעה הדואליות, תמיד מווה חסם תחתון לערך האופטמלי של הבעה המקורית (הפרימאלית).  
כאשר מתקיימת דואליות חזקה, ניתן לעתים - לפתור את הבעה המקורית באמצעות הבעה הדואלית.  
(כלומר אם הבעה מקיימת 3 תנאים: 1. קמורה 2. מקיימת את סליטר 3. הפטרו וahooptimaliy שלה הוא  $-\infty < P^* \leq D^*$  אז מתקיימת **דואליות חזקה**)

**הערה 54.9** לעיתים יותר קל לפתור את הבעה הדואלית בבעיה המקורית מאשר מינימציה על וקטור אחד בגודל  $n \times n$  (n משתנים) בבעיה הדואלית צריך לעשות מינימציה על 2 וקטורים  $\mu, \lambda$  (כאשר  $\mu \in \mathbb{R}^m, \lambda \in \mathbb{R}^n$ ) קלומר יש לנו שני וקטורים ושה"כ אופטימציה על  $(p+m$  משתנים).  
ולכן כאשר  $n < p+m$  ישן יותר פתרון הבעיה הדואלית במקום הבעיה המקורית (פחות משתנים לבצע עליהם מינימציה, הסדר של בעיית האופטימציה קטן). בעיות פרימאליות שלהם יש מינימם גבולה המות מושתנים, ( $n$  גדול מאוד) ויש מעט אלוצים  $p+m$  קטן יחסית ל  $n$  ) קלומר מתקיים  $n < p+m$  יתכן שכדי לנו לעבור לבעיה הדואלית ולפתור אותה.

**הערה 55.9** המעבר לבעיה הדואלית לא מתבצע בפועל על בעיות largecscale מכיוון שהמעבר לבעיה הדואלית מבוצע באופן אנלטי שהוא דבר שנחשב קשה יחסית בבעיות largecscale (כלומר לבשבל להציג לבעיה הדואלית צורך הרבה דברים שקשרים לפתור בסדרי גודל גדולים) אבל השיטה זה רלוונטית לסדרי גודל לא ענקים (לדוגמא השיטה שימושית כישל לנו לצורך העניין 10, 20, 30, מושתנים בעיה הפרימלית)

**מסקנה 56.9** (מסקנה מתרגיל ראשון) הבעיה הדואלית של בעיית LP היא גם עצמה בעית LP.

**הגדירה 57.9** בהינתן  $\mathbb{R} \rightarrow \mathbb{R}^n$   $f(x)$  נגידיר את הפונ' הצמודה של  $f$  להיות

$$f^*(y) = \sup_x \{x^T y - f(x)\}$$

**משפט 58.9** משפטים מתורת הקבוצות שהיו בשימוש בתרגיל 3:

Negative of Infimum is Supremum of Negatives :

Let T be set s.t.  $\emptyset \neq T \subseteq \mathbb{R}$  than :

$$-\inf_{x \in T} x = \sup_{x \in T} (-x)$$

Negative of Supremum is Infimum of Negatives:

Let T be set s.t.  $\emptyset \neq T \subseteq \mathbb{R}$  than :

$$-\sup_{x \in T} x = \inf_{x \in T} (-x)$$

[https://proofwiki.org/wiki/Negative\\_of\\_Supremum\\_is\\_Infimum\\_of\\_Negatives](https://proofwiki.org/wiki/Negative_of_Supremum_is_Infimum_of_Negatives)

[https://proofwiki.org/wiki/Negative\\_of\\_Infimum\\_is\\_Supremum\\_of\\_Negatives](https://proofwiki.org/wiki/Negative_of_Infimum_is_Supremum_of_Negatives)

## 10 הרצאה 10 ותרגול 10

### 10.1 הרצאה 10 תנאי karush kugn tucker KKT

#### 10.1.1 תזכורת מההרצאה הקודמת

נזכר על תנאי קרווש קונטקר (KKT) הם למשה תנאים שמאפשרים לנו פתרונות אופטימליים לביעות אופטימציה ובפרט לביעות אופטימציה קונבנציונליות עם אילוצים. הם מתחברים מאוד לנושא הדואליות שראינו בעברם הקודמת. בפעם שUberה ראיינו שבנתן בעית האופטימציה הבאה

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{subject to: } & h_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, m \\ & l_i(\mathbf{x}) = 0, i = 1, 2, \dots, r \end{aligned}$$

בעיה זו נקראת **הבעיה הפרימלית**.  
 אפשר להתאים כופלי לגראנג'  $\{v_i\}_{i=0}^m, \{u_j\}_{j=1}^r$  כאשר  $u_i$  הוא סקלר שיטות אלילוזי שווין לה  $i$  ( $h_i(\mathbf{x}) \leq 0, i = 0, 1, 2, \dots, m$ ), ו  $v_j$  הוא סקלר שיטות אלילוזי השווין לה  $j$  ( $l_i(\mathbf{x}) = 0, i = 0, 1, 2, \dots, r$ ). לאחר מכן **הגדרנו את הלגאנגיון** באופן הבא:

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) + \sum_{j=1}^r v_j l_j(\mathbf{x})$$

הлегאנגיון מוגדר מוגדר  $\forall \mathbf{v} = (v_1 \ v_2 \ \dots \ v_r) \in \mathbb{R}_+^r, \forall \mathbf{u} = (u_1 \ u_2 \ \dots \ u_m) \in \mathbb{R}_+^m$  ו  $\mathbf{x} \in \mathbb{R}^n$  מסמנים גם  $\mathbf{u} \in \mathbb{R}^m \leq 0$ .  
 ואת **הפונ' הדואלית** הגדרנו באופן הבא:

$$g(\mathbf{u}, \mathbf{v}) \triangleq \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v})$$

מה שהרנו בשיעור שעבור זה שמותוך הבעיה המקורית (הבעיה הפרימלית) אפשר להציג בעיה דואלית (בעיה שימושני האופטימציה שלה הם אילוצים (כופלי לגראנג' שלה הם אילוצים וכופלי אלו הם משתני האופטימציה שלה) ואת **הבעיה הדואלית** הגדרנו באופן הבא

$$\begin{array}{ll} \max_{\mathbf{u}, \mathbf{v}} & g(\mathbf{u}, \mathbf{v}) \\ \text{subject to} & \mathbf{u} \geq 0 \end{array}$$

#### תכונות חשובות של הבעיה דואלית:

- **הבעיה הדואלית תמיד מוגדרת בעית אופטימציה קמורה** (כלומר, הבעיה  $g$  היא תמיד קווראה (אפילו אם הבעיה הפרימלית היא לא קמורה) והAILוצים הם תחום קמור). בעית מקסימיזציה קווראה שקופה בעית מינימיזציה של פונ' קונבנציון.
- לא משנה מה הייתה הבעיה הפרימלית, תמיד הבעיה הדואלית תהיה מלחורה של בעית מקסימיזציה קווראה (שזו סוג של בעית אופטימיזציה קמורה)
- ככלומר בלי תלות בעיה הפרימלית המקורית אנו יודעים לפתור בצורה טובה (יש הרבה כלים) לפתורן של הבעיה הדואלית. כי היא בעית אופטימיזציה ולפתור את זה יש לנו הרבה כלים).
- **הערך האופטימלי של הבעיה הפרימלית מסומן  $f^*$ , הערך האופטימלי של הבעיה הדואלית מסומן  $g^*$ .**

- **תמיד מתקיימת תכונת הדואליות החלשתה:**  $g^* \leq f^*$ .

- **תנאי סלטר:**

– עבור בעיה פרימלית וקמורה, אם קיים  $\mathbf{x}$  כך ש  $\mathbf{x}$  ש

$$\forall i \in \{1, \dots, m\} : h_i(\mathbf{x}) < 0, \forall j \in \{1, \dots, r\} : l_1(\mathbf{x}) = 0$$

(קרי: אילוצי אי השווין מתקיימים בשוויון ואילוצי השווין מתקיימים)  
 אז תנאי סלטר מתקיימים.

– קיימת הרחבה לתנאי סלטר

- אם תנאי סלטר מתקיים אז מתקיימת **דו-אליות חזקה** כלומר  $g^* = f^*$ .
- **קיימת הרחבה לתנאי סלטר**: דרישת של נקודה שמקיימת את האילוצים (פייבילית) ורק עבור פונקציות  $h_i$  שאין אפיניות (שאינם מהצורה  $h_j(x) = a_j^T x + b_j$ ) יש אי שוויון חזק  $<$ .

### 10.1.2 תנאי KKT

בהתנאים על שם שלושה אנשים קרוש,kuhn,tucket במשותה פרסמו מאמר שמדובר על התנאים האלה בשנת (1951) ובディעד התברר שההיה בחור בשם קרוש שגילה שמצא את התנאים האלה עוד לפני קרוש וטקר, בתזה שלו (1939). כשהם מצאו זאת זה נתנו לו את הכבוד ושמו אותו ראשוני בראשי תיבות. בהינתן בעית האופטימציה הבאה

$$\begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ \text{subject to: } & h_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, m \\ & l_i(\mathbf{x}) = 0, i = 1, 2, \dots, r \end{aligned}$$

נאמר שנקודה  $(\mathbf{v}, \mathbf{u}, \mathbf{x})$  מקיימת את תנאי KKT אם כל התנאים הבאים מתקיימים:

1. **stationarity**  $0 \in \partial_{\mathbf{x}}(L(\mathbf{x}, \mathbf{u}, \mathbf{v}))$

2. **complementary slackness**  $\forall i \in \{1, 2, \dots, m\} : u_i \cdot h_i(\mathbf{x}) = 0$

3. **Primal feasibility**  $\begin{aligned} \forall i \in \{1, 2, \dots, m\} : h_i(\mathbf{x}) \leq 0 \\ \forall j \in \{1, 2, \dots, r\} : l_j(\mathbf{x}) = 0 \end{aligned}$

4. **dual feasibility**  $\forall i \in \{1, 2, \dots, m\} : u_i \geq 0$

**הערה 1.10** הערות על תנאי KKT

1. הערות על התנאי של **stationarity**

(א) כלומר  $0 \in \partial_{\mathbf{x}} \left( f(\mathbf{x}) + \sum_{i=1}^m u_i h_i(\mathbf{x}) + \sum_{j=1}^r v_j l_j(\mathbf{x}) \right)$

(ב) כלומר אם תגזרו את הגלגנון'יאן של הנקודה הזו לפי  $\mathbf{x}$  נקבל 0. מה שכתוב כאן קצת יותר עדין ומתייחס לביעות שהן לא בהכרח גיירות. בוא נניח שהגלגנון'יאן הוא אין גייר אבל כך קמור במשתנה  $\mathbf{x}$  אז אפשר להגדיר את המשג של סאב גרדיאנט (בນוקודות במס' הפונ' גיירה אם קיימות אז הסאב גרדיאנט שווה לגרדיינט) במקרה שהפונ' לא גיירה אז אפשר להגדיר סאב גרדיאנט

(ג) במקרה שהפונ' גיירה בנקודה  $(\mathbf{v}, \mathbf{u}, \mathbf{x})$  (סאב גרדיאנט מתלכד עם הגדרינט) התנאי קבוע כי  $0 = (\mathbf{v}, \mathbf{u}, \mathbf{x}) \nabla_x L$ . כלומר במקרה שהפונ' גיירה נדרש התאפסות של הגראינט.

(ד) במקרה שההפונ' לא גיירה בנקודה  $(\mathbf{v}, \mathbf{u}, \mathbf{x})$  (ניתן למצוא סאב גרדיאנטים) נדרש שהווטור שכלו אפסים 0 שייך לקבוצת הסאב גרדיאנטים של  $(\mathbf{v}, \mathbf{u}, \mathbf{x})$ . כלומר  $0 \in \partial_{\mathbf{x}}(L(\mathbf{x}, \mathbf{u}, \mathbf{v}))$ .

2. התנאים של dual feasibility ו-primal feasibility. פיזibilite גם בבעיה הפרימלית (תנאי על  $\mathbf{x}$ ) וגם בבעיה הדואלית (תנאי על  $\mathbf{u}$ )

3. התנאי של Complementary slackness. בוא נסתכל על נקודה  $(\mathbf{v}, \mathbf{u}, \mathbf{x})$  אז מהתנאים הקודמים אנו יודעים כי:

- אנו יודעים כי  $0 \geq \mathbf{u}$  (כלומר  $\forall i \in \{1, 2, \dots, m\} : u_i \geq 0$ )
- וגם  $0 \leq \mathbf{u}$  (כלומר  $\forall i \in \{1, 2, \dots, m\} : u_i \leq 0$ )

התנאי  $\forall i \in \{1, 2, \dots, m\} : u_i \cdot h_i(\mathbf{x}) = 0$  הוא **Complementary slackness** קובע כי  $\forall i \in \{1, 2, \dots, m\} : u_i \cdot h_i(\mathbf{x}) = 0$  אזי לכל  $i$  מתקיים:

- אזי אם  $u_i > 0$  אזי לפי Complementary slackness מתקיים כי  $h_i(\mathbf{x}) = 0$
- אזי אם  $h_i(\mathbf{x}) < 0$  אזי לפי Complementary slackness מתקיים כי  $u_i = 0$
- או שגם  $u_i = 0$  וגם  $h_i(\mathbf{x}) = 0$


במילים אחרות:

(א) אם  $u_i > 0$  אזי לפי Complementary slackness מושך את  $h_i(\mathbf{x}) = 0$  (אין דרישת מיוחדת כי  $h_i(\mathbf{x}) \geq 0$ ).

(ב) אם  $u_i = 0$  אזי לפי Complementary slackness מושך את  $h_i(\mathbf{x}) \leq 0$  (אין דרישת מיוחדת כי  $h_i(\mathbf{x}) \leq 0$ ).

### Complementary Slackness:

$(x, u, v)$  - מתקיים  $h_i(x) \leq 0$ ,  $h_1(x) \leq 0$ ,  $h_2(x) \leq 0$



$$u_1 \cdot h_1(x) = 0 \quad \& \quad h_1(x) = 0 \Rightarrow u_1 \geq 0$$

$$u_2 \cdot h_2(x) = 0 \quad \& \quad h_2(x) < 0 \Rightarrow u_2 = 0$$

הקו האדום : האילוץ  $h_2$  מתקיים בשווין.

הקו הכהול : האילוץ  $h_1$  מתקיים בשווין.

התחומים המוקוקו - המיקום בו שני האילוצים מתקיימים.

עבור נקודת  $x$  האילוץ הכהול מתקיים בשווין כלומר  $0 = h_1(x)$  ולכן  $0 \geq u_1$ .  
עבור נקודת  $x$  האילוץ האדום מתקיים באישווין כלומר  $0 < h_2(x)$  ולכן  $0 = u_2$ .

:Complen

### משפט שיקולות של KKT ושל פתרון אופטמלי

**טענה 2.10** אם  $x^*, u^*, v^*$  הינו פתרון אופטמלי של בעיה הדואלית, עם אזי zero duality gap אז  $x^*, u^*, v^*$  מקיימת את תנאי KKT.

**הערה 3.10** נשים לב שבטענה זו הנחנו דבר על על קמיות הבעיה המקורית שלנו או על קמיות תחום האילוץ)

הוכחת הטענה:

יהיו  $x^*, u^*, v^*$  פתרון של בעיה הפרימלית ופתרונות של בעיה הדואלית

$x^*$  ממזער את  $f(x)$  ופייבלי (כי הוא פתרון לבעיה הפרימלית)

$(u^*, v^*)$  ממקסימות את  $(u, v)$  ופייבליות (כי הן פתרונות לבעיה הדואלית)

אזי נרצה להראות כי  $x^*, u^*, v^*$  מקיימים את תנאי KKT.

אזי מדואליות חזקה :  $f^* = g^*$

$$\begin{aligned}
 \overbrace{f(\mathbf{x}^*)}^{f^*} &= \overbrace{g(u^*, v^*)}^{g^*} \\
 &\stackrel{\text{definition of } g(u^*, v^*)}{\triangleq} \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*) \\
 &\stackrel{\text{definition of } L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)}{\triangleq} \min_{\mathbf{x}} \left( f(\mathbf{x}) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}) \right) \\
 &\leq f(\mathbf{x}^*) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*) \\
 &\stackrel{\begin{array}{c|c} \mathbf{x}^* \text{ solution to primal} & u^* \text{ solution to dual} \\ \text{optimaztion problem} & \text{optimaztion problem} \\ \Rightarrow \mathbf{x}^* \text{ is feasibil:} & \Rightarrow u_i^* \text{ is feasibil:} \\ \forall j \in \{1, \dots, r\} : l_j(\mathbf{x}^*) = 0 & \forall i \in \{1, \dots, m\} : u_i^* \geq 0 \end{array}}{=} \\
 &= f(\mathbf{x}^*) + \underbrace{\sum_{i=1}^m u_i^* h_i(\mathbf{x}^*)}_{\substack{0 \leq \\ \leq 0}} + \underbrace{\sum_{j=1}^r v_j^* l_j(\mathbf{x}^*)}_{= 0} \\
 &\leq f(\mathbf{x}^*)
 \end{aligned}$$

כלומר הראנו כי

$$\begin{aligned}
 \overbrace{f(\mathbf{x}^*)}^{f^*} &= \overbrace{g(u^*, v^*)}^{g^*} \\
 &= \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*) \\
 &= \min_{\mathbf{x}} \left( f(\mathbf{x}) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}) \right) \\
 &\leq f(\mathbf{x}^*) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*) \\
 &\leq f(\mathbf{x}^*)
 \end{aligned}$$

ולכן כל מעברי ה הם למעשה מעברי = כלומר

$$\begin{aligned}
 f(\mathbf{x}^*) &= g(\mathbf{u}^*, \mathbf{v}^*) \\
 &= \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*) \\
 &= \min_{\mathbf{x}} \left( f(\mathbf{x}) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}) \right) \\
 &= f(\mathbf{x}^*) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*)
 \end{aligned}$$

$$\bullet \text{ מהשווין (Necessary condition)}: f(\mathbf{x}^*) = f(\mathbf{x}^*) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*) = 0$$

$$\sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*) = 0. \text{ ראיינו קודם כי } 0 \text{ נובע כי } \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*) = 0$$

- מכיוון ש  $\sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) = 0$  ומכיוון ש  $x^*$  ו  $\mathbf{u}^*$  פיזibilities ידוע כי  $\sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) \leq 0$  קלומר הסכום הוא סכום של איברים אי חיוביים והסכום הכלול יוצא 0 ולכן הסכום יוצא אפס וრק אם הסכום הוא סכום רק של אפסים כמובן נובע כי  $\sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) = 0 \forall i \in \{1, \dots, m\}$
- הוכחנו את התנאי של Complementary slackness
- 

$$L(\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*) = \min_{\mathbf{x}} \overbrace{f(\mathbf{x}) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}) + \sum_{j=1}^r v_j^* l_j(\mathbf{x})}^{L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)} = f(\mathbf{x}^*) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*)$$

$\bullet \text{ מהשווין (Necessary condition)}: \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)$

- קלומר  $\mathbf{x}^*$  היא מינימום גלובלי של הפונ'  $L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)$  (משמעותו לב שזו פונ' של  $\mathbf{x}$ ) קלומר
- \* אם הפונ'  $L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)$  גירה (לפי  $\mathbf{x}$ ) אז  $\mathbf{0} \in \partial L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)|_{\mathbf{x}=\mathbf{x}^*}$  בפונ' גירות הסאגראדיינט מתכלד עם הגראדיינט ולכן  $\mathbf{0} \in \partial L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)$ .
- \* אם הפונ'  $L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)$  אינה גירה אז המשמעות היא ש  $\mathbf{0} \in \partial L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*)$  שייך לسان גראדיינט של הפונ'.
- \* **ולכן הראנו את קיומו התנאי של stationarity**

- $\bullet$  בנוסח  $\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*$  ומכיוון  $\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*$  הם פיזibilites ולכן מקיימים dual feasibility את התנאים קלומר הראנו כי אם  $\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*$  הם פתרון אופטמלי של בעיה הגדולית, עם zero duality gap מקיימת את תנאי KKT.

**טענה 4.10** אם קיימים שמקיימים את תנאי KKT. אז  $\mathbf{x}^*, \mathbf{v}^*, \mathbf{u}^*$  הם פתרונות של בעיה הדואלית. ובנוסח פער הדואליות dual gap הוא 0.

**הוכחת הטענה:**  
היו  $\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*$  נקודות שמקיימות את תנאי KKT  
כלומר

**1. stationarity**  $\mathbf{0} \in \partial_{\mathbf{x}}(L(\mathbf{x}, \mathbf{u}, \mathbf{v}))$

(א) כמובן נובע כי בפרט כי עבור  $\mathbf{x}^* \in [\partial_{\mathbf{x}}(L(\mathbf{x}, \mathbf{v}^*, \mathbf{u}^*))]_{\mathbf{x}=\mathbf{x}^*}$  קלומר  
מכאן נובע כי מכיוון ש  $L(\mathbf{x}, \mathbf{v}^*, \mathbf{u}^*)|_{\mathbf{x}=\mathbf{x}^*}$  קמורה ב  $\mathbf{x}$  ו  $L(\mathbf{x}, \mathbf{v}^*, \mathbf{u}^*)|_{\mathbf{x}=\mathbf{x}^*}$  נובע כי  $\mathbf{x}^*$  נקודת מינימום גלובלי של  $L(\mathbf{x}, \mathbf{v}^*, \mathbf{u}^*)$  קלומר  $L(\mathbf{x}, \mathbf{v}^*, \mathbf{u}^*) = L(\mathbf{x}^*, \mathbf{v}^*, \mathbf{u}^*)$

$\forall i \in \{1, 2, \dots, m\} : u_i \cdot h_i(\mathbf{x}) = 0$  **Complementary slackness** .2

$\forall i \in \{1, 2, \dots, m\} : h_i(\mathbf{x}) \leq 0$  Primal feasibility .3  
 $\forall j \in \{1, 2, \dots, r\} : l_j(\mathbf{x}) = 0$

$\forall i \in \{1, 2, \dots, m\} : y_i \leq 0$  dual feasibility .4

$$\begin{aligned}
g(\mathbf{u}^*, \mathbf{v}^*) &\stackrel{\text{definition of } g(\mathbf{u}^*, \mathbf{v}^*)}{=} \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}^*, \mathbf{v}^*) \\
&\stackrel{\text{stationarity}}{\equiv} (\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*) \\
&\stackrel{\text{definition of } L(\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*)}{=} f(\mathbf{x}^*) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) + \sum_{j=1}^r v_j^* l_j(\mathbf{x}^*) \\
&\text{Primal feasibility} \\
\forall j \in \{1, 2, \dots, r\} : l_j(\mathbf{x}^*) = 0 &\stackrel{\text{Primal feasibility}}{=} f(\mathbf{x}^*) + \sum_{i=1}^m u_i^* h_i(\mathbf{x}^*) \\
&\text{Complementary slackness} \\
\forall i \in \{1, 2, \dots, m\} : u_i \cdot h_i(\mathbf{x}) = 0 &\stackrel{\text{Complementary slackness}}{=} f(\mathbf{x}^*)
\end{aligned}$$

כלומר הראנו כי  $f(\mathbf{x}^*) = f(\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*)$  ובנוסף אנו יודעים כי  $\mathbf{x}^*$  פיאבוליס כי הם נקודות KKT. ולכן מכיון ש  $f(\mathbf{x}^*) = f(\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*)$  והנקודות פיאבוליות, נבע כי ה gap duality הוא אפס (כלומר מתקיות דואליות חזקה). הוכחנו כי מתקיות דואליות חזקה.

- אנחנו יודעים שלכל  $\mathbf{x}$  פיאבוליס ולכל  $(\mathbf{u}, \mathbf{v})$  כך ש  $0 \geq \mathbf{u}$  מתקיים

$$f(\mathbf{x}) \geq f(\tilde{\mathbf{x}}^*) \geq g(\tilde{\mathbf{u}}^*, \tilde{\mathbf{v}}^*) \geq g(\mathbf{u}, \mathbf{v})$$

כאשר  $\tilde{\mathbf{u}}^*, \tilde{\mathbf{v}}^*, \tilde{\mathbf{x}}^*$  הם פתרונות אופטימליים לביעות  $f, g$ .

לכן אם מצאנו  $\mathbf{x}$  פיאבוליס ו  $(\mathbf{u}, \mathbf{v})$  כאשר  $0 \geq \mathbf{u}$  כשלهم כך ש  $g(\mathbf{u}, \mathbf{v}) = f(\mathbf{x})$  אז בהכרח כל האי שוויונות מתקימים בשווין כלומר

$$\begin{aligned}
f(\mathbf{x}) &= g(\mathbf{u}, \mathbf{v}) \\
f(\mathbf{x}) \geq f(\tilde{\mathbf{x}}^*) &\geq g(\tilde{\mathbf{u}}^*, \tilde{\mathbf{v}}^*) \geq g(\mathbf{u}, \mathbf{v}) \\
&\Downarrow \\
f(\mathbf{x}) &= f(\tilde{\mathbf{x}}^*) = g(\tilde{\mathbf{u}}^*, \tilde{\mathbf{v}}^*) = g(\mathbf{u}, \mathbf{v})
\end{aligned}$$

כלומר אם מצאנו  $\mathbf{x}$  פיאבוליס ו  $(\mathbf{u}, \mathbf{v})$  כאשר  $0 \geq \mathbf{u}$  נבע כי  $f(\mathbf{x}) = f(\tilde{\mathbf{x}}^*)$  כי  $g(\mathbf{u}, \mathbf{v}) = g(\tilde{\mathbf{u}}^*, \tilde{\mathbf{v}}^*)$  כלומר מושגנו פתרון אופטימי לביעת הפרימלית ו  $(\mathbf{u}, \mathbf{v})$  הם פתרונות אופטימליים לביעת הדואלית.

- הראנו כי שלכל  $\mathbf{x}$  פיאבוליס ולכל  $(\mathbf{u}, \mathbf{v})$  כך ש  $0 \geq \mathbf{u}$  שקיימים  $f(\mathbf{x}) = f(\mathbf{u}, \mathbf{v})$  מתקיים כי  $\mathbf{x}$  פתרון אופטימי לביעת הפרימלית ו  $(\mathbf{u}, \mathbf{v})$  הם פתרונות אופטימליים לביעת הדואלית. בפרט, עבור הנקודות  $\mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*$  הראו שקיימים

$$\begin{aligned}
g(\mathbf{u}^*, \mathbf{v}^*) &= f(\mathbf{x}^*) \\
0 \geq u_i &\quad \forall i \in \{1, 2, \dots, m\} : u_i \geq 0 \text{ dual feasibility}
\end{aligned}$$

ולכן מכאן נבע כי  $\mathbf{x}^*$  פתרון אופטימי לביעת הפרימלית ו  $(\mathbf{u}^*, \mathbf{v}^*)$  הם פתרונות אופטימליים לביעת הדואלית.

**лемmas: משפט 5.10** עבור בעיה שבה מתקימת דואליות חזקה :  
 $\mathbf{x}^*$  הוא פתרון של בעיה הפרימלית ו  $\mathbf{u}^*, \mathbf{v}^*$  הן הפתרונות של בעיה הדואלית  $\iff \mathbf{x}^*, \mathbf{u}^*, \mathbf{v}^*$  מקיימות את תנאי KKT

**הערה 6.10** דואליות חזקה מתקיימת לדוגמא כאשר תנאי סלייטר מתקיימים: בעיה קמורה שבה קיימת נקודה  $\mathbf{x}$  שעבורה כל אילוצי האי שווין הלא אפינים מתקיימים ממש. (מתקיימים בסימן אי שווין חריף).

תנאי KKT הם תנאים מאוד שימושיים :

1. מציאת פתרונות בצורה אנליטית של בעיות אופטימציה עם אילוצים KKT
2. גם אם אי אפשר למצוא את הפתרונות של בעיות האופטימציה עם האילוצים בצורה אנליטית נוכל להשתמש בתנאי KKT בשביל לבדוק תכונות של הפתרונות האופטימליות (בעיות עם האילוצים).
3. אם אין אילוצים תנאי KKT שקיים לתנאי האופטימליות הרגיל ( $\nabla f(x) = 0$ ) יתיר קל לפתור בעיות אופטימציה עם אילוצים על ידי תנאי KKT.

### 10.1.3 דוגמאות

**דוגמה: בעיה ריבועית עם אילוצי שווין** תהא  $Q \succeq 0$  נתובן בעיית האופטימציה הבאה:

$$\begin{aligned} & \min_x \frac{1}{2} x^T Q x + c^T x \\ & \text{s.t. } Ax = 0 \end{aligned}$$

(לדוגמא, זה שקול לצעד ניטון עבור הבעיה המאולצת  $\min_x f(x)$  שcpfופה לאילוץ  $Ax = b$  הbiעה היא בעיה קמורה, ואין בה אילוצי אי שווין).

**רוצחים להראות כי:**  
אזי לפי תנאי KKT  $x$  הוא פתרון אופטימלי של בעיית האופטימציה  $\iff$

$$\begin{bmatrix} Q & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ v \end{bmatrix} = \begin{bmatrix} -c \\ 0 \end{bmatrix}$$

עבור  $x$  בלבדו.

**נוכיח מזוע זה נכון:**

אין אילוצי אי שווין ולכן הלגאנגיון נתון על ידי

$$L(x, v) = \frac{1}{2} x^T Q x + c^T x + v^T A x$$

(האילוץ  $Ax = 0$  הוא מספר אילוצי שווין:  $x \in \mathbb{R}^m$  ו-  $A \in \mathbb{R}^{m \times n}$  אז יש  $m$  אילוצי שווין (כל אילוץ מתאים לשורה אחרת של שווין והוקטורים  $Ax = 0$  ולכן יש לנו את וקטור  $v$  ווקטור הכופלי לגראנג')).  
תנאי KKT גורסים:

$$\begin{cases} \nabla_x L(x, v) = 0 \\ Ax = 0 \end{cases}$$

ש הוא כופל לגראנג' של אילוצי שווין ולכן הוא לא מאולץ.  
נפתח את התנאים:

$$\begin{aligned} 0 &= \nabla_x L(x, v) \\ &= \nabla_x \left( \frac{1}{2} x^T Q x + c^T x + v^T A x \right) \\ &= Qx + c + A^T v \end{aligned}$$

$$\Rightarrow 0 = Qx + c + A^T v$$

$$\Rightarrow Qx + A^T v = -c$$

והתנאי השני לא משתנה  $Ax = 0$   
ניתן לרשום באופן קומפקטי:

$$\begin{bmatrix} Q & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} x \\ v \end{bmatrix} = \begin{bmatrix} -c \\ 0 \end{bmatrix}$$

כלומר הראנו כי מציאת נקודה שמקיימת את תנאי KKT שקול למציאת הפתרון של המשווה הлиינארית המטריצית שהציגנו כתה.

$$\begin{aligned} \min_{\mathbf{x}} \quad & - \sum_{i=1}^n \log (\alpha_i + x_i) \\ \text{subject to} \quad & \mathbf{x} \geq 0, \mathbf{1}^T \mathbf{x} = 1 \end{aligned}$$

המטרה שלנו היא להשתמש בתנאי KKT על מנת לתאר את הפתרון האופטמלי של הבעיה זו.  
מתורת האינפורמציה, ניתן לקבל אינטואיציה על הבעיה על ידי דמיון של משדר עם כמות אנרגיה סופית והוא רוצה לנצל את האנרגיה שלו בין כמה ערכות שידור ובכל ערך שידור ישנים רמות רעש שונות.  $x_i$  זה האנרגיה שאנו משקיעים בשידור בערך  $\alpha_i$  ו-  $\alpha_i$  זה הרעש שיש לנו בערך  $i$ . (פחות או יותר) אינטואטיבית נרצה להבין כיצד הדרך הכי טובה לחלק את האנרגיה שלנו בשידור בין הערכות. אינטואטיבית זאת ברור לנו שבערוצים יותר רועשים נרצה לשדר פחות ובערוצים פחות רועשים נרצה לשדר יותר. הפרומולציה של הבעיה נתונה מעלה.  
נזכיר כי  $\mathbb{R}^n \in \mathbb{R}^n$  ( $1 \ 1 \ \dots \ 1$ ) = 1 כלומר משמעות התנאי  $\mathbf{1}^T \mathbf{x} = 1$  היא ש  $x_i \geq 0$  ובנוסף  $\sum_{i=1}^n x_i = 1$ .

- האם הבעיה היא בעיה קוונקטיבית?

- כן, כי פונקציית המטרה קוונקטיבית כי  $\sum_{i \in \{1, \dots, n\}} (-\log(\alpha_i + x_i))$  הוא קונקטי והסכום על האילוצים קונקטיבי ושוויון לפונקציית המטרה  
- האילוצים הם קונקטיבים:  
-  $x \geq 0$  חצי מישור ולכן בתחום קמור  
-  $\mathbf{1}^T \mathbf{x} = 1$  למעשה אילוץ שווין לינארי ולכן קמור.

- האם מתקימים תנאי סליידר עבור הבעיה זו?

- נחפש נקודת שמקיימת ממש את האילוצים. קיימת כזו כי  $\left( \frac{1}{n}, \dots, \frac{1}{n} \right)$  היא נקודת כדרוש ולכן תנאי סליידר ולכן יש דואליות חזקה.  
- לכן נחפש נקודות KKT.

נרשום קודם כל את הבעיה באופן שבו אנו רגילים לראות אותה לצורך פיתוח הלגראנגיין.

$$\begin{aligned} \min_{\mathbf{x}} \quad & - \sum_{i=1}^n \log (\alpha_j + x_i) \\ \text{subject to} \quad & \forall i \in \{1, \dots, n\} : h_i(x) = -x_i \leq 0 \\ & , \mathbf{1}^T \mathbf{x} - 1 = 0 \end{aligned}$$

נרשום את הלגראנגיין של הבעיה הנ"ל :

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = - \sum_{i=1}^n \log (\alpha_j + x_i) + v(\mathbf{1}^T \mathbf{x} - 1) - \sum_{i=1}^n u_i x_i$$

- אנו יודעים כי מתנאי KKT כל העדים ו-  $x$  (יחד) צריך להיות פיזבלי (בפועל יש דרישת רק על העדים ו-  $x$  כי הבעיה לא מאולצת לפי ה-  $v$ ).

$$\forall i \in \{1, \dots, n\} : \frac{\partial}{\partial x_i} L(\mathbf{x}, \mathbf{u}, v) = 0$$

- אנו יודעים כי סטציונריות צריכה להתקיים  $0 = u_i \cdot h_i(\mathbf{x}) = u_i \cdot (-x_i) = -u_i x_i$  (או בקיצור CS) כלומר  $u_i x_i = 0$

1. מסתצינריות,

$$\begin{aligned}\frac{\partial}{\partial x_j} L(\mathbf{x}, \mathbf{u}, v) &= \frac{\partial}{\partial x_j} \left[ -\sum_{i=1}^n \log(\alpha_j + x_i) + v(\mathbf{1}^T \mathbf{x} - 1) - \sum_{i=1}^n u_i x_i \right] \\ &= -\frac{1}{\alpha_j + x_i} + v - u_j = 0\end{aligned}$$

כלומר

$$\forall i \in \{1, 2, \dots, m\} : -\frac{1}{\alpha_j + x_i} + v - u_i = 0$$

אנו יודעים כי  $\mathbf{x}$  פיזבילי ולכן

הא  $i \in \{1, 2, \dots, m\}$  כלשהו נפרד למקרים זרים ומשלים:

$x_i > 0$  • נרצה להפטור מ  $u$ .ולכן נכפול ב  $x_i$  את המשוואות ונקבל

$$-\frac{x_i}{\alpha_i + x_i} + x_i v - u_i x_i = 0$$

מתנאי הסטצינריות אנו יודעים כי  $i \in \{1, 2, \dots, m\}$   $u_i \cdot x_i = 0$  ולכן נקבל כי

$$-\frac{x_i}{\alpha_i + x_i} + x_i v = 0$$

נעביר אגפים ונקבל

$$x_i v = \frac{x_i}{\alpha_i + x_i}$$

$x_i \neq 0$  ולכן מותר לחלק ב  $x_i$  נבעצז את ונקבל

$$v = \frac{1}{\alpha_i + x_i}$$

נבודד את  $x_i$  ונקבל

$$v(\alpha_i + x_i) = 1 \Rightarrow v\alpha_i + vx_i = 1 \Rightarrow vx_i = 1 - v\alpha_i \Rightarrow x_i = 1 - v\alpha_i$$

נחלק ב  $v$  ונקבל

$$x_i = \frac{1}{v} - \alpha_i$$

אנו יודעים שבמקרה הזה מתקיים  $x_i > 0$  ולכן מתקאים גם כי

$$0 < x_i = \frac{1}{v} - \alpha_i$$

נעביר אגפים ונקבל:

$$\alpha_i < \frac{1}{v}$$

• המקרה השני הוא ש  $x_i = 0$ .

• לא יתכו מקרים נוספים מכיוון ש  $x_i \geq 0$  כי זה היא פיסבלית.

ולכן שימוש ישיר בתנאי הסצטניוריות וslackness Complementarityreceived Ci

$$\forall i \in \{1, 2, \dots, m\} : x_i = \begin{cases} \frac{1}{v} - \alpha_i & \alpha_i < \frac{1}{v} \\ 0 & \alpha_i \geq \frac{1}{v} \text{ (else)} \end{cases} = \max \left\{ 0, \frac{1}{v} - \alpha_i \right\}$$

כלומר מצאנו בטי של  $x = (x_1 \ x_2 \ \dots \ x_n)^T$  כפוני של  $v$ .

עדין אן ודורשים ש  $x$  תהיה פיזבלית (אלו ז השווון שטרם ניצלנו שנთנו לנו מותוק קיום של נקודת KKT) ולכן נקבל

$$1 = \sum_{i=1}^n x_i = \sum_{i=1}^n \max \left\{ 0, \frac{1}{v} - \alpha_i \right\}$$

כלומר קיבל


$$1 = \sum_{i=1}^n \max \left\{ 0, \frac{1}{v} - \alpha_i \right\}$$

זו משווה חד מימדית שדרכה ניתן למצוא את  $v$ . אפשר לסמך  $\lambda = \frac{1}{v}$  (הבעיה הזו היא אפילו קונבקטיבית ב- $\lambda$ ). כלומר התחלנו עם בעיה קונבקטיבית רב מימדית ולאחר הפעלת KKT הפכנו אותה בעיה פשוטה יחסית שתלויה רק בפרמטר אחד. בעיות מהסוג הזה : water filling

אינטואציה גרפית ל : watter filling

This reduced problem is called water-filling

(From B & V page 246)



רוצים שהשיטה האפור יהיה בסה"כ 1. קלומר נרצה למזוג בדיקת כמות מסוימת של מים ככה שיהיה אפור ששטחו אחד. (המים הם האפור)

הגבעות הלבנות הם הרעשים בכל ערוֹץ. ההפרש בין קו המים לבין הרעש הוא  $x_i$  כמות התשדרות לערוֹץ.

איך מוצאים את ה  $x$  האופטמלי?

לקחים את הרעשים, ממיינים אותם לפי גודל  $\alpha_i$  מהנמוך לגבוהה ( $\alpha_i$  נתונות לנו)



נסמן את ה  $\alpha_i$  המומוניים בסדר עולה ככה. אם הם לא יכולים לשאת משטנה חדש ממויין  $\tilde{\alpha}_i$ . מסמנים את הערוֹץ האחרון (עם ה  $i$  הכי גדול) שנשדר בו  $m^*$ . קלומר כל  $x_i$ 'ים עד אל  $m^*$  כולל אותו הם חיובים ממש ולאחריו הם מתאפסים) אילו  $m^*$  היה שווה ל 1 אז ערוֹץ עם  $\alpha_2$  רעש וגם את הערוֹצים שאחריו לא נשדר קלומר נבדוק מה  $\frac{1}{v}$  שמקיים את התנאי

$$1 = \sum_{i=1}^1 \max \left\{ 0, \frac{1}{v} - \alpha_i \right\}$$

ולאחר מכן נודא ש  $0 < \frac{1}{v} - \alpha_2$ . אם זה נכון מתקיים אז מצאנו את הפתרון האופטמלי.  
אם לא מתקיים:

נניח ש  $m^*$  היה שווה ל 2 אז ערוֹץ עם  $\alpha_3$  רעש וגם את הערוֹצים שאחריו לא נשדר קלומר נבדוק מה  $\frac{1}{v}$  שמקיים את התנאי

$$1 = \sum_{i=1}^2 \max \left\{ 0, \frac{1}{v} - \alpha_i \right\}$$

ולאחר מכן נודא ש  $0 < \frac{1}{v} - \alpha_3$ . אם זה נכון מתקיים אז מצאנו את הפתרון האופטמלי. אם לא מתקיים, נמשיך ונגדיל את  $m^*$  וنعשה את אותה הבדיקה. ככה עד שנמצא את הפתרון האופטמלי.

ולאחר שמצאנו את  $x$  יהיה לנו בטוי סגור לפתרון האופטמלי של הבעיה:

$$\forall i \in \{1, 2, \dots, m\} : x_i = \max \left\{ 0, \frac{1}{v} - \alpha_i \right\}$$

**דוגמא: ריבועיםՓחות מאולצים** נtabונן בעיה הבאה: Constrained Least squares

$$\begin{aligned} \min_{\mathbf{x}} \quad & \|A\mathbf{x} - \mathbf{b}\|^2 \\ (\text{CLS}) \text{s.t.} \quad & \|\mathbf{x}\|^2 \leq \alpha \end{aligned}$$

כאשר  $A \in \mathbb{R}^{m \times n}$  היא מטריצה מדינה מלאה,  $\mathbf{b} \in \mathbb{R}^m$  הוא וקטור  $\alpha > 0$  סקלר חיובי.

- בעיית CLS היא בעית אופטימציה קמורה שמקיימת את תנאי סלייטר.

- (מכיוון שהאילוץ היחיד על  $\mathbf{x}$  הוא  $\alpha \|\mathbf{x}\|^2 \leq \alpha$ 我们知道  $\|\mathbf{x}\|^2 > \alpha$  יודעים כי וקטור האפס  $\mathbf{0} = \mathbf{x}$  מקיים את האילוצים ממש. לכן תנאי סלייטר מתקיים.
- תנאי סלייטר מותקיים ולכן יש דואליות חזקה.

- נחשב את הלגראנגיון:

$$L(\mathbf{x}, \lambda) = \|A\mathbf{x} - \mathbf{b}\|^2 + \lambda (\|\mathbf{x}\|^2 - \alpha) \quad \lambda > 0$$

• תנאי KKT:

– מתנאי Complementary slackness יודעים כי

$$\lambda (\|\mathbf{x}\|^2 - \alpha) = 0 \quad \lambda \geq 0$$

– סטציונריות

$$\nabla_{\mathbf{x}} L = 2A^T(A\mathbf{x} - \mathbf{b}) + 2\lambda\mathbf{x} = 0$$

–  $\mathbf{x}$  פיזibilit וכאן מקיימת את האילוץ

$$\|\mathbf{x}\|^2 \leq \alpha, \quad \alpha \geq 0$$

- $\lambda$  הוא כופל לגראנג' שנווב מותו אילוץ אי שוויון ולכן  $0 \geq \lambda$ . נפריד לשני מקרים זרים ומשלים.

– אם  $\lambda = 0$  (המשמעות של  $\lambda = 0$  : שאין אילוצים בעיה כלומר מתייחסים במקרה זהו ל蹶ה אילו הבעיה הייתה בעיה לא מאולצת כלומר אנו נקרה זה מתייחס למקרה שבו שהפתרון הכלובלי בעיה שלנו מתקיים את האילוץ) נציג במשוואת שמתבבלת מסטציונריות ונקבל  $2A^T(A\mathbf{x} - \mathbf{b}) = \mathbf{0}$

$$2A^T(A\mathbf{x} - \mathbf{b}) = \mathbf{0} \Rightarrow A^T(A\mathbf{x} - \mathbf{b}) = \mathbf{0} \Rightarrow$$


$$A^T A\mathbf{x} - A^T \mathbf{b} = \mathbf{0} \Rightarrow A^T A\mathbf{x} = A^T \mathbf{b}$$

$$\Rightarrow \mathbf{x} = (A^T A)^{-1} A^T \mathbf{b}$$

ונקבל


$$\mathbf{x} = \mathbf{x}_{LS} = (A^T A)^{-1} A^T \mathbf{b}$$

כלומר  $\mathbf{b} - A\mathbf{x}_{LS}$  הוא פתרון אופטימי אם ורק אם  $\|\mathbf{x}_{LS}\|^2 \leq \alpha$  (כלומר אם  $\mathbf{x}_{LS}$  פיזייל). כלומר



(איור להמחשה, האילוץ באדום  $\mathbf{x}_{LS}$  נמצאת בתחום האילוץ)

כאשר



\* אם  $\alpha > \|\mathbf{x}_{LS}\|^2$  נבחן את המקרה הבא עבורו  $0 > \lambda$ . (כלומר  $\mathbf{x}_{LS}$  לא פיזייל):  
נבחן את המקרה הבא:

- אם  $0 > \lambda$  אז לפי המשוואה של היחס Complementary slackness ציינו ידועים כי

$$\lambda (\|\mathbf{x}\|^2 - \alpha) = 0$$

מצמצום ב  $\lambda$  (omore לחלק בווא כי בפרט  $0 \neq \lambda$  במקרה זה) והערת אגף נקבל כי  $\alpha = \|\mathbf{x}\|^2$  (נסמן במקרה זהה הפתרון יתקבל על השפה של תחומי האילוץ). אי השוויון החלש מתקיים בשוויון

- עבור מקרה זה אנו יודעים שמתקיים  $\|\mathbf{x}_{LS}\|^2 > \alpha$

- מסתציניות

$$\begin{aligned} 2A^T(A\mathbf{x} - \mathbf{b}) + 2\lambda\mathbf{x} &= 0 \\ \iff A^T(A\mathbf{x} - \mathbf{b}) + \lambda\mathbf{x} &= 0 \\ \iff A^TA\mathbf{x} - A^T\mathbf{b} + \lambda\mathbf{x} &= 0 \\ \iff (A^TA + \lambda I)\mathbf{x} - A^T\mathbf{b} &= 0 \\ \iff (A^TA + \lambda I)\mathbf{x} &= A^T\mathbf{b} \\ \iff \mathbf{x} &= (A^TA + \lambda I)^{-1}A^T\mathbf{b} \end{aligned}$$

נסמן  $\mathbf{b} = \mathbf{x}_{LS}$  אכם מצאנו פתרון עד כדי קבוע  $\lambda$  שאנו לא ידועים מה הוא. נרצה למצוא את  $\lambda$  הנכון.

- ראיינו כי  $\mathbf{b} = (A^TA + \lambda I)^{-1}A^T\mathbf{b}$  ו גם כי  $\|\mathbf{x}_{LS}\|^2 = \alpha$  נעביר אגף ונקבל  $\|(A^TA + \lambda I)^{-1}A^T\mathbf{b}\|^2 - \alpha = 0$

$$f(\lambda) = \|(A^TA + \lambda I)^{-1}A^T\mathbf{b}\|^2 - \alpha$$

נרצה למצוא  $\lambda$  כך ש  $f(\lambda) = 0$ . וו.ו. תהיה  $\lambda$  שאנו מחפשים. נבחן כי בעיה היא בעיה חד מימדית. ונבחן בערכי הקיצון של  $f(\lambda)$  בערכי הקיצון.

$$\begin{aligned} \lim_{\lambda \rightarrow 0} f(\lambda) &= f(0) \\ &= \left[ \|(A^TA + \lambda I)^{-1}A^T\mathbf{b}\|^2 - \alpha \right]_{\lambda=0} \\ &= \|(A^TA + 0I)^{-1}A^T\mathbf{b}\|^2 - \alpha \\ &= \|(A^TA)^{-1}A^T\mathbf{b}\|^2 - \alpha \\ &= \|\mathbf{x}_{LS}\|^2 - \alpha \\ &\stackrel{\|\mathbf{x}_{LS}\|^2 > \alpha}{>} 0 \end{aligned}$$

. $f(0) < 0$  .כלומר

$$\begin{aligned} \lim_{\lambda \rightarrow \infty} f(\lambda) &= \lim_{\lambda \rightarrow \infty} \left[ \left\| (A^T A + \lambda I)^{-1} A^T b \right\|^2 - \alpha \right] \\ &= \left[ \underbrace{\left\| \left( A^T A + \lim_{\lambda \rightarrow \infty} \lambda I \right)^{-1} A^T b \right\|^2}_{=0} - \alpha \right] \\ &= -\alpha \end{aligned}$$

כלומר  $\alpha > f(\lambda)$  ו  $\lim_{\lambda \rightarrow \infty} f(\lambda) = -\alpha$  כלומר  $f(\lambda)$  הולך וורד (לא הוכח בפועל אלא בנפנוף ידיהם ש  $f(\lambda)$  פונקציונלית יורדת).

אפשר למצוא את  $\lambda > 0$  עבור  $f(\lambda) = 0$  על ידי כל מני טכניקות, לדוגמה על ידי טכניקה של שיטת החציה (מצחירה חיפוש ביןاري) יש פה אמירה סטודית על זה ש  $f(\lambda)$  היא פונקציה וולקן לפי ערך הבנים יהיה קיים  $\lambda$  שעבורו  $f(\lambda) = 0$  וזה  $\lambda$  שמתאים לפתרון זהה.

כלומר הפתרון הוא

$$\mathbf{x} = \begin{cases} \mathbf{x}_{\text{LS}} & \|\mathbf{x}_{\text{LS}}\|^2 \leq \alpha \\ (A^T A + \lambda I)^{-1} A^T b & \|\mathbf{x}_{\text{LS}}\|^2 > \alpha \end{cases}$$

כאשר  $\lambda$  היא השורש היחיד (שורש=נקודה שmbיאת את הפונקציית האפס) של  $\alpha$  בתחום  $(0, \infty) \in \lambda$ . (הראנו כי קיים  $\lambda$  כזה וניתן למצוא אותו באופן יעיל לפי שיטות שהוצעו).

### דוגמה לפתרון KKT בהקשר של SVM

#### 10.1.4 דוגמאות

#### 10.1.5 אילוצי לגראנגי'

(זולג בהרצאה אבל אמרו שצרכיך לדעת)

#### Example: support vector machines

Given  $y \in \{-1, 1\}^n$ , and  $X \in \mathbb{R}^{n \times p}$ , the support vector machine problem is:

$$\begin{array}{ll} \min_{\beta, \beta_0, \xi} & \frac{1}{2} \|\beta\|_2^2 + C \sum_{i=1}^n \xi_i \\ \text{subject to} & \xi_i \geq 0, \quad i = 1, \dots, n \\ & y_i(x_i^T \beta + \beta_0) \geq 1 - \xi_i, \quad i = 1, \dots, n \end{array}$$

Introduce dual variables  $v, w \geq 0$ . KKT stationarity condition:

$$0 = \sum_{i=1}^n w_i y_i, \quad \beta = \sum_{i=1}^n w_i y_i x_i, \quad w = C1 - v$$


Complementary slackness:

$$v_i \xi_i = 0, \quad w_i (1 - \xi_i - y_i(x_i^T \beta + \beta_0)) = 0, \quad i = 1, \dots, n$$

$$\begin{aligned}
L(\beta, \omega, \xi, v, w) &= \frac{1}{2} \|\beta\|^2 + C \xi^T \cdot \xi + \sum_i \omega_i \left( 1 - \xi_i - y_i (\mathbf{x}_i^T \beta + \omega_0) \right) \\
\text{HKT: } \nabla_{\beta, \omega, \xi} L(\beta, \omega, \xi, v, w) &= 0 \\
1) \quad 0 = \nabla_{\beta} L(\beta, \omega, \xi, v, w) &= \beta - \sum_i \omega_i y_i \mathbf{x}_i \\
&\Rightarrow \\
2) \quad 0 = \nabla_{\omega} L &= \sum_i \omega_i y_i \\
3) \quad 0 = \nabla_{\xi} L = C \mathbf{1} - v - w &\Rightarrow w_i = C - v_i \quad \forall i \\
4) \quad v, w \geq 0 & \\
5) \quad v_i \xi_i = 0 \quad \forall i & \\
6) \quad \omega_i (1 - \xi_i - y_i (\mathbf{x}_i^T \beta + \omega_0)) = 0 \quad \forall i &
\end{aligned}$$

Hence at optimality we have  $\beta = \sum_{i=1}^n w_i y_i x_i$ , and  $w_i$  is nonzero only if  $y_i(x_i^T \beta + \beta_0) = 1 - \xi_i$ . Such points  $i$  are called the **support points**

- For support point  $i$ , if  $\xi_i = 0$ , then  $x_i$  lies on edge of margin, and  $w_i \in (0, C]$ ;
- For support point  $i$ , if  $\xi_i \neq 0$ , then  $x_i$  lies on wrong side of margin, and  $w_i = C$



KKT conditions do not really give us a way to find solution, but gives a better understanding

In fact, we can use this to screen away non-support points before performing optimization

### Constrained an Lagrange forms 10.1.6

בד"כ בסטטיסטיקה ובלימידת מכונה נבעור הלוק ושוב בין

- **בעוות מאולצות** עבורם  $t \in \mathbb{R}$  הוא פרמטר שנייתן לכווןנו:

$$(C) \quad \min_{\mathbf{x}} f(\mathbf{x}) \text{ s.t. } h(\mathbf{x}) \leq t$$

- **בעוות מצורמת לגראנט** שעבורם  $0 \leq \lambda \leq \lambda$  הוא פרמטר שנייתן לכווןנו:

$$(L) \quad \min_{\mathbf{x}} f(\mathbf{x}) + \lambda \cdot h(\mathbf{x})$$

ונטען שם בעוות שקולות.  
(כלומר

1. לכל בעיה מהצורה  $(C)$  עבור  $t$  נתון קיים  $0 \leq \lambda \leq \lambda$  עבורו הבעוות  $(C), (L)$  שקולות.
2. לכל בעיה מהצורה  $(L)$  עבור  $0 \leq \lambda \leq \lambda$  נתון קיים  $t$  עבורו הבעוות  $(C), (L)$  שקולות.

וכoch רק כיון אחד של הטענה הוא:  
 הוכחת שיקילות וכיון  $(L) \rightarrow (C)$

אם עבר בעיה  $(C)$  תנאי סליידר מתקיימים אז יש  $(C)$  דואליות חזקה ואז מדואליות חזקה אלו יודעים שלכל פתרון אופטמלי של  $(C)$  שנסמננו  $x^*$  קיים \* ככה שהבעיות הם שקולות

$$\begin{aligned} & \text{(C to L): if (C) is strictly feasible, then strong duality holds, and} \\ & \text{there exists } \lambda \geq 0 \text{ (dual solution) such that any solution } x^* \text{ in (C)} \\ & \text{minimizes} \\ & f(x) + \lambda \cdot (h(x) - t) = \min_{\substack{x \\ h(x) \leq t}} f(x) + \lambda^* h(x) \\ & \text{so } x^* \text{ is also a solution in (L)} \quad \min_{\substack{x \\ h(x) \leq t}} f(x) = \min_{\substack{x \\ h(x) \leq t}} \max_{\lambda \geq 0} L(x, \lambda) \end{aligned}$$

בשימושים של מידת מכונה בד"כ מראים את השיקילות ואז בוחרים  $\lambda$  כלשהו. (לא בזרה מדוקית ולכן זה לא יהיה הפתרון האופטמלי אבל בזרה שהפתרון המתkeletal קשור אליו פתרון האופטמלי (לא הרחיב הרבה))

## 10.2 תרגול 10

### 10.2.1 תנאי KKT

נתבונן בבעיית האופטימציה (נסמנה בעיה  $(P)$ ):

$$(P) : \begin{aligned} & \min_{\boldsymbol{x}} f(\boldsymbol{x}) \\ & \text{s.t. } g_i(\boldsymbol{x}) \leq 0, i = 1, \dots, m \\ & h_j(\boldsymbol{x}) = 0, j = 1, \dots, p \\ & \boldsymbol{x} \in C \end{aligned}$$

כאשר כל הפונ' דיפרנציאבילות ברציפות, הפונקציות  $f(\cdot)$  ו  $g_i(\cdot)$  קמורות והפונ'  $h_j(\cdot)$  אפיניות (כלומר, מהצורה  $C$  קמורה).  $h_j(\boldsymbol{x}) = \boldsymbol{a}_j^T \boldsymbol{x} + b_j$

**הגדרה 7.10** תהא  $\boldsymbol{x}^* \in \text{int}(C)$ . אז:

1. הנקודה  $\boldsymbol{x}^*$  נקראת **פיזibilitת אם**  $0 \leq g_i(\boldsymbol{x}^*) \leq 0 \forall i \in \{1, 2, \dots, m\}$

2. הנקודה  $\boldsymbol{x}^*$  נקראת נקודת KKT אם היא **פיזibilitת וקיים**  $\boldsymbol{\mu} \in \mathbb{R}^p$  ו  $\boldsymbol{\lambda}^* \geq 0$  כך ש

$$(1) \quad \underbrace{\nabla_{\boldsymbol{x}} L(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\mu})}_{\nabla f(\boldsymbol{x}^*) + \sum_{i=1}^m \boldsymbol{\lambda}_i^* \nabla g_i(\boldsymbol{x}^*) + \sum_{j=1}^p \boldsymbol{\mu}_j^* \nabla h_j(\boldsymbol{x}^*) = 0}$$

$$(2) \quad \underbrace{\forall i \in \{1, 2, \dots, m\} : \boldsymbol{\lambda}_i^* \nabla g_i(\boldsymbol{x}^*) = 0}_{\text{complementary slackness}}$$

במקרה זה נאמר כי הנקודה  $\boldsymbol{x}^*$  מקיימת תנאי KKT.

(א) (נקודה היא נקודת KKT  $\iff$  סה"כ 4 תנאים עבורו: פיזibilitות (2 תנאים) KKT+ (2 תנאים)).

(ב) אם אין אילוצי אי שווין אין אילוצי complementary slackness.

3. נקודת  $\boldsymbol{x}^*$  נקראת **נקודת מינימום** עבור  $(P)$  אם  $f(\boldsymbol{x}^*) \leq f(\boldsymbol{x}) \forall \boldsymbol{x} \in \mathbb{R}^m$  עבור כל נקודת פיזibilitת אחרת. משום שהבעיה קמורה, לעיתים נקרא לנקודות המינימום גם "פתרון אופטמלי".

לעתים מגדירים לגראנגיין עבור הבעיה:

$$L(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\boldsymbol{x}) + \sum_{i=1}^m \lambda_i g_i(\boldsymbol{x}) + \sum_{j=1}^p \mu_j h_j(\boldsymbol{x})$$

כאשר  $\boldsymbol{0} \leq \boldsymbol{\lambda} \leq \boldsymbol{\mu} \in \mathbb{R}^p$  ו  $\boldsymbol{x} \in \mathbb{R}^m$ . אזי התנאי (2) נקרא  $\nabla_{\boldsymbol{x}} L(\boldsymbol{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = 0$  ניתן כתיב על ידי התנאי (1). נניח שקיים slackness, ומושמעות: אילוץ שאינו מתקיים בשוויון מקבל כופל לגראנגיין 0. (כלומר, לכל  $i \in \{1, \dots, m\}$   $\lambda_i \nabla g_i(\boldsymbol{x}^*) = 0$ ). כלומר  $\lambda_i = 0$  או  $g_i(\boldsymbol{x}^*) = 0$ .

**הגדשה 8.10** הבעה (P) מקיים תאת תנאי Slater אם מקיימת  $x_0 \in \text{int}(C)$  המקיים  $\langle x_0 \rangle < 0$  ו-  $\forall i \in \{1, 2, \dots, m\} : g_i(x_0) \geq 0$  ו-  $\forall j \in \{1, 2, 3, \dots, p\} : h_j(x_0) = 0$ .

**הערה 9.10** קיימת הרחבה עברו תנאי Slater . Slater אם  $\exists k \leq m, g_1, g_2, \dots, g_k$  אפייניות , אי נקודת פיאבולית  $x_0$  תקרא נקודת Slater אם:

$$\begin{aligned} \forall i \in \{1, 2, \dots, k\} : g_i(x_0) \leq 0 \\ \forall i \in \{k+1, k+2, \dots, m\} : g_i(x_0) < 0 \\ \forall j \in \{1, 2, 3, \dots, p\} : h_j(x_0) = 0 \end{aligned}$$

במילים אחרות, תנאי Slater אם קיימת נקודת פיאבולית אשר מקיימת בחריפות את אילוצי אי השוויון הלא לינאריים (=הלא אפיינים) , ומקיימת את כל האילוצי הלינאריים.

**משפט 10.10** תהא  $\text{הבעיה הקמורה לעיל ותהא } x^* \in \text{int}(C)$  נקודת פיאבולית. אז:

1. **תנאי מספיק:** אם הנקודת  $x^*$  היא נקודת KKT אז  $x^*$  הינה נקודת מינימום של (P).
2. **תנאי הכרחי:** אם הבעיה (P) מקיימת תנאי Slater אז תנאי KKT הם הכרחיים על מנת שהנקודה  $x^*$  תהיה נקודת מינימום.

**הערה 11.10** מספר הערות לגבי המשפט:

- התנאי המספיק אינו דורש תנאי Slater .
- אם תנאי Slater אינם מתקיים , נקודת המינימום אינה חייבת לקוים תנאי KKT .
- ככלומר אם מצאנו שתנאי Slater מתקיים , אז תנאי KKT הוא תנאי מספיק והכרחי לנקודת מינימום.( $\iff$  מינימום)
- אם הבעיה (P) מכיל הרק אילוצים אפייניים, ככלומר  $a_i^T x + b_i = g_i(x)$  לעל  $i$  איי תנאי Slater המורחב מותקיים עבור כלנקודת פיאבולית. לפיכך, בבדיקה זה בדיקה של קיום תנאי Slater שקול להיקף נקודת פיאבולית.
- קיימת הרחבה של התנאי ההכרחי לנקודת מינימום עבור בעיות לא קמורות. במקרה זה, מדובר על תנאי הכרחי לנקודת מינימום מקומי. המשפט כאן דומה אך עם תנאי אחר (שיותר קשה לבדוק) במקומות תנאי Slater. נושא זה הוא מעבר להיקף הקורס אך ניתן לקרוא עליו חומר נוספת בספרות , לדוג' בפרק 11.8 בספר

Linear and Nonlinear Programming by David G. Luenberger

- תנאי Slater הוא תכונה של הבעיה (P), נקודת KKT זה נקודה שאנו מחפשים. אין קשר ישיר ביניהם. ככלומר הנקודה שモוכיחה בעיה (P) היא בעיה שמקיימת את תנאי Slater היא לא בהכרח חייבת להיות נקודת KKT.

**הערה 12.10** טיפ של המתרגל.כשיש לנו בעיה בימים קטנים  $\{1, 2, 3\} \in n$  לדוגמה , (3 יותר קשה) או בעיה בימים גבוהים שאפשר לפתש למשך זמן קצר ממליץ לנסות לפרש אותה במנוחים שונים מכיריים אם זה אפשרי , להבין גאומטרית מה קורה בעיה (משוואות מעגלים/אליפסות וכו').

## חלק IV שיטות ואלגוריתמים מסדר שני

עד כה רأינו שיטות מסדר ראשון, שיטות שימושיות בוגזרת ראשונה של פונ' המטרזה. היום ובמהשך נראה בקורס נראת שיש יתרון להסתכל על נגזרות מסדר שני- מכאן שם- שיטות מסדר שני. שיטות פירושן נדבר על שיטות ניוטון (על שם הפיזיקאי והמתמטיקאי הנודע ואנחנו נראה תחת אילו הנחות יש לשיטה זו יתרון ותועל פני השיטות שראינו עד כה).

### 11 הרצתה ותרגול 11

#### 11.1 הרצתה 11

**הגדשה 1.11** עבור פונ' חד מימדי  $f : \mathbb{R} \rightarrow \mathbb{R}$  נאמר שנקודה  $x \in \mathbb{R}$  היא שורש של  $f$  אם  $f(x) = 0$ .

### 11.1.1 שיטת ניוטון

המקורה החד מימדי - **שיטת ניוטון ורפסון** נתחיל ונתבונן על בעיות חד מימדיות  $\mathbb{R} \rightarrow \mathbb{R}$ :  $f$  שהן לאו דווקא בעיות אופטימיזציה. נניח שיש לנו פונ'  $f$  ואנו רוצים למצואו מתי  $f(x)$  מתאפסת (עבור איזה  $x$   $f(x) = 0$ ) מטה אפסת=מה השורשים של  $f(x)$ . מה שצרכי להיות לנו לכ הזמן בראש ש( $f$ ) בהמשך תקופה הנגזרת של הפונ' שעליה אנו עושים את האופטימיזציה ולכן אנחנו רוצים למצואו מתי הנגזרת מתאפסת (אבל זה רק ברקע בנתויים).

כל אופן יש לנו פונ'  $f : \mathbb{R} \rightarrow \mathbb{R}$  ורוצים למצואו עבור אליו  $x$ ים היא מתאפסת.

בماהה ה-17 ניוטון ורפסון (ניוטון קודם ואז רפסון) שני מתמטיקאים, המציאו את השיטה זו.

שיטת ניוטון ורפסון היא איטרטיבית ועקר השיטה היא להתחילה בנקודת קדודה כלשהיא ונבעץ לינאריזציה של הפונ', ניקח את המשיק לפונ'  $f$  בנקודת  $x_t$  ונראה איפה הוא מתאפס, וזו תהיה הנקודה  $x_{t+1}$ . וככה ממשך באופן איטרטיבי. ובכך השאייפה היא שנלך ותקרב לנקודת שבה  $f(x) = 0$ .

**המטרה:** מציאת אפס של הפונ' הגירה  $f : \mathbb{R} \rightarrow \mathbb{R}$

**שיטה:**

$$x_{t+1} = x_t - \frac{f(x_t)}{f'(x_t)} \quad , t \geq 0$$

כאשר  $x = x_{t+1}$  פותר את

$$f(x_t) + f'(x_t)(x - x_t) = 0$$


אפשר להראות זאת :

$$f(x_t) + f'(x_t)(x - x_t) = 0$$

$$f(x_t) = f'(x_t)(x_t - x)$$

$$\frac{f(x_t)}{f'(x_t)} = (x_t - x)$$

$$x = x_t - \frac{f(x_t)}{f'(x_t)}$$



**הערה 2.11** המשוואה  $f(x_t) + f'(x_t)(x - x_t) = 0$  היא משווהת המשיק לפונ' בנקודת  $x_t$ .

**שיטת הבבלית.** ניוטון ורפסון הכלילו את השיטה הבבלית עבור פונ' כלליות אבל הבלתי דרכ השיטה הנ"ל מצאו דרך לשיטתה הנ"ל שורש ריבועי של מספרים. ככלומר השיטה הנ"ל למציאת שורש ריבועי הייתה ידועה לאנושות עוד בשנת 1500 לפני הספירה.

**чисוב שורש קיבועי:**

נניח שיש לנו סקלאר  $R \in \mathbb{R}$  כלשהו וננו רוצים למצואו את  $\sqrt{R}$ .

הבעיה הנ"ל שקולה לבעיה הבאה.

מציאת שורשים לפונקציית  $f : \mathbb{R} \rightarrow \mathbb{R}$  מהצורה הבאה  $f(x) = x^2 - R$ . הנקודה שבה  $f(x)$  ממתאפסת הוא  $\sqrt{R}$ . ככלומר

$$f(x^*) = 0 \Rightarrow x^* = \sqrt{R}$$

ככלומר רוצים את  $\sqrt{R}$  דרך מציאת שורש לפונק'  $f$ . הנקודה שבה  $f(x) = x^2 - R$  ממתאפסת הוא  $\sqrt{R}$ . נסתכל על כלל העדכון של שיטת ניוטון רפסון עבור הפונ'  $f$  עד ניוטון רפסון:

$$x_{t+1} = x_t - \frac{f(x_t)}{f'(x_t)} = x_t - \frac{x_t^2 - R}{(x_t^2 - R)'} = x_t - \frac{x_t^2 - R}{2x_t} = \frac{1}{2} \left( x_t + \frac{R}{x_t} \right)$$

**הערה 3.11** נשים לב שאם  $x_t = \sqrt{R}$  אז מתקיים כי  $x_{t+1} = x_t = \sqrt{R}$ . וזו למעשה נקודת שבת (נקודה שלא משתנה) בכלל העדכון הצעה.

ננסה לבצע אනליזה של השיטה הנ"ל.  
נניח שאנו מתחילה את השיטה ממספר חיובי כלשהו  $x_0 > 0$  קיבל

$$x_{t+1} = \frac{1}{2} \left( x_t + \frac{R}{x_t} \right) \geq \frac{x_t}{2}, x_{t+1} \geq \sqrt{R}, \forall t \geq 1$$

אפשר להראות (לא נוכיח בקורס) שאם מתחילים את השיטה ב- $x_0 = R + 1$  ( $R$  הוא מספר ידוע) אז ייקח  $\mathcal{O}(\log R)$  צעדים (זה מעשה מספר קבוע של איטרציות) לקבלת פתרון  $x_t - \sqrt{R} < \frac{1}{2}$ . ככלומר המרחק שבין הפתרון האופטמלי  $\sqrt{R}$  לבין הפתרון המתקבל  $x_t$  יהיה קטן ממחצית.

אנחנו הולכים להראות **שהחל מנקודה מסוימת**  $x_t - \sqrt{R} < \frac{1}{2}$  (הפתרון קרוב עד כדי חצי לפתרון האופטמלי) **התכנסות הולכת להיות מאוד מהירה** ככלומר כדי להגיע לפתרון שהוא קרוב לפתרון האופטמלי  $\sqrt{R}$  נרצה לשאול כמה איטרציות נחוצות. ככלומר נshall כמה איטרציות נחוצות לקבלת  $x_t - \sqrt{R} < \epsilon$  עבור  $\epsilon$  קטן כרצונו. (לודגנא  $(10^{-9})$ )

**השיטה הבבלית: ניתול**  
נניח כי  $x_0 - \sqrt{R} < \frac{1}{2}$  (אפשרי להשיג  $x_t$  שמקיים זאת לאחר  $\mathcal{O}(\log R)$  צעדים (לא נוכיח זאת)). אז:

$$\begin{aligned} x_{t+1} - \sqrt{R} &= \frac{1}{2} \left( x_t + \frac{R}{x_t} \right) - \sqrt{R} \\ &= \frac{x_t}{2} + \frac{R}{2x_t} - \sqrt{R} \\ &= \frac{1}{2x_t} \left( x_t^2 + R - 2x_t\sqrt{R} \right) \\ &= \frac{1}{2x_t} \left( x_t^2 - 2x_t\sqrt{R} + \sqrt{R}^2 \right) \\ &= \frac{1}{2x_t} \left( x_t - \sqrt{R} \right)^2 \end{aligned}$$

בפרט

$$x_{t+1} - \sqrt{R} = \frac{1}{2x_t} \left( x_t - \sqrt{R} \right)^2$$

נבחן כי  $x_{t+1} - \sqrt{R}$  היא למעשה השגיאה בסיבוב ה- $t+1$  ו- $x_t - \sqrt{R}$  היא השגיאה בסיבוב ה- $t$ . ככלומר קיבלנו כאן מקרה עבורי השגיאה בסיבוב ה- $t+1$  שווה ל- $\frac{1}{2x_t}$  כפול השגיאה בסיבוב הקודם בריבוע. כדי לסביר את האוון, נניח לרוגע כי  $\frac{1}{2x_t}$  שווה בערך לאחד לצורך מחישה של הקשר הזה. אם השגיאה בסיבוב ה- $t+1$  היא  $10^{-6}$  אז השגיאה בסיבוב הבא (ה- $t+1$ ) היא  $10^{-12} = 10^{-6}^2$ . והשגיאה בסיבוב הבא היא  $10^{-24}$ .

כלומר אם משתמשים בשיטת ניוטון רפסון והגענו למצב בו  $x_0 - \sqrt{R} < \frac{1}{2}$  מנקודה זו והלאה ההתכנסות תהיה מאוד מהירה (אפילו על אקפוננסצאלית (=יותר מהירה מאקפוננסצאלית)) וזה תכונה מאוד מאוד מרשים של ניוטון רפסון.

אבל  $\frac{1}{2x_t}$  אינו קבוע.  
 נעשה הנחה נוספת נניח כי  $R \geq \frac{1}{4}$   
 נזכר בכלל העדכו

$$\star : x_{t+1} - \sqrt{R} = \frac{1}{2x_t} (x_t - \sqrt{R})^2$$

הגודל באג' שמאל  $\frac{1}{2x_t}$  תמיד חיובי ולכן

$$x_{t+1} = \overbrace{\frac{1}{2x_t} (x_t - \sqrt{R})^2}^{>0} + \sqrt{R} \geq \sqrt{R}$$

כלומר  $x_{t+1} \geq \sqrt{R}$   
 אם נניח כי  $R \geq \frac{1}{4}$  אזי קיבל כי

$$x_t \geq \sqrt{R} \geq \sqrt{\frac{1}{4}} = \frac{1}{2} \Rightarrow x_t \geq \sqrt{R} \geq \frac{1}{2} \Rightarrow \frac{1}{x_t} \leq 2 \Rightarrow \diamond : \frac{1}{2x_t} \leq 1$$

ואז מאר נקבע

$$(x_{t+1} - \sqrt{R}) \stackrel{\star}{=} \frac{1}{2x_t} (x_t - \sqrt{R})^2 \stackrel{\diamond}{\leq} (x_t - \sqrt{R})^2$$

ובפרט קיבלנו כי

$$(x_{t+1} - \sqrt{R}) \leq (x_t - \sqrt{R})^2$$

כלומר

$$(x_{t+1} - \sqrt{R}) \leq (x_t - \sqrt{R})^{2^1} \leq ((x_{t-1} - \sqrt{R})^2)^2 \leq \dots \leq (x_0 - \sqrt{R})^{2^t}$$

כלומר (נזכור כי אנו התחילו בהתחלה כי נניח כי  $x_0 - \sqrt{R} < \frac{1}{2}$ )

$$x_T - \sqrt{R} \leq (x_0 - \sqrt{R})^{2^T} \stackrel{x_0 - \sqrt{R} < \frac{1}{2}}{<} \left(\frac{1}{2}\right)^{2^T}, T \geq 0$$

כלומר

$$x_T - \sqrt{R} \leq \left(\frac{1}{2}\right)^{2^T}, T \geq$$

איי כדי לקבל פתרון  $\epsilon$  תחת אופטמלי (=השגיאה מיקנית כי  $x_T - \sqrt{R} \leq \epsilon$ ) אנו צריכים רק צעדים. (שזה מעט מאוד!)

$$\begin{aligned}
\left(\frac{1}{2}\right)^{2^T} &\leq \epsilon \iff \\
\iff \frac{1}{2^{2^T}} &\leq \epsilon \\
\iff 2^{(2^T)} &\geq \frac{1}{\epsilon} \\
\iff 2^T &\geq \log \frac{1}{\epsilon} \\
\iff T &\geq \log \log \frac{1}{\epsilon}
\end{aligned}$$

כלומר לקבת פתרון  $\epsilon$  תת אופטמלי אנו צריכים רק  $(\frac{1}{\epsilon})$  צעדים.

זה נותן לנו את ההתקנות הסופר מהירה שלילה דיברנו.

כלומר בהנתן ש  $\frac{1}{2} - x_0 < \sqrt{R}$  מנקודה זו ואילך השגיאה בצד הקודם תהיה ריבוע השגיאה בצד הנוכחי. לא ראיינו בקורס עוד שיטות שמתכנסות בקצב כזה מהר.  
אז מה ראיינו?

- ראיינו שיטת ניוטון רפסון למציאת שורש לפונ' חד מימדית  $f(x)$ .
- ראיינו כי אם מפעילים את היטהה זו עבור בעיה של מציאת שורש אז החל מנקודה מסוימת ההתקנות היא על-אפקונצאלית (המקרה אמר "סופר אפקונצאלית") למציאת פתרון  $\epsilon$  תת אופטמלי אנו צריכים  $(\log \log \frac{1}{\epsilon})$  צעדים.

### 11.1.2 שיטת ניוטון לאופטימיזציה

זכיר במשפט שראיינו בעבר:

**משפט:** תהא  $\mathbb{R}^n \rightarrow \mathbb{R}$ :  $f$  גירה וקמורה. אז:  $0 = \nabla f(x) \iff x$  היא נקודת מינימום גלובלי של  $f$ .

**במקרה החד מימדי:**

רוצים למצוא נקודת מינימום גלובלי  $x$  של פונ' גירה וקמורה  $\mathbb{R} \rightarrow \mathbb{R}$ .  
מסקנה מהמשפט מעלה היא כי  $0 = f'(x) \iff \min_x f(x) = f'(x)$  (כלומר עבור נקודת מינימום הגלובלי הנוצרת של הפונ' מותאמת).  
בנחחה ש  $f'$  פון' גירה (=כלומר ש  $f$  גירה פעמיים) ולכז נוכל לחפש במקומות נקודת מינימום של  $f(x)$  נוכל  $\min_x f(x)$  נוכל לחפש את השורשים של הפונ'  $f'(x)$  (הנוצרת של  $f$ ). את השורש הזה נוכל למצוא על ידי שיטת ניוטון רפסון שיופעל על הפונ'  $f'$ .  
צעד העדכון במקרה זהו נתון על ידי

$$x_{t+1} = x_t - \frac{f'(x_t)}{f''(x_t)} = x_t - f''(x_t)^{-1} f'(x_t)$$

שיטת זו נקראת **שיטת ניוטון במימד אחד**  
כלומר:

שם	שיטה
שיטת ניוטון רפסון	שיטת למציאת שורשים של פונ'
שיטת ניוטון	שיטת למציאת מינימום גלובלי

**במקרה ה  $d$  מימי** רוצים למצוא נקודת מינימום גלובלי  $x$  של פון' גירה וקמורה  $\mathbb{R}^d \rightarrow \mathbb{R}$ .  
מסקנה מהמשפט מעלה היא כי  $0 = \nabla f(x) = \min_x f(x) \iff$  (כלומר עבור נקודת מינימום הגלובלי של הפונ'  $f$  שקול למציאת התאפסות הגרדיאנט של הפונ'  $(\nabla f)(x)$ ).  
כלומר נרצה להשתמש בשיטה של ניוטון רפסון למציאת  $x$  עבורו  $0 = f(x)$ .  
שיטת ניוטון רפסון עד כה הוגדרה למימד אחד.  
ה הכללה הטבעית לשיטות ניוטון רפסון לפונ' במראה הרוב מימי  $\mathbb{R}^d \rightarrow \mathbb{R}$ :  $f$  היא כל העדכון הבא:

$$x_{t+1} = x_t - (\nabla^2 f(x_t))^{-1} \nabla f(x_t)$$

ולכן שיטה זו נקראת שיטה מסדר שני מכיוון שהיא משתמשת בכלל עדכון שמכיל בתוכו גם את בטוי שתלויה בהאסיאן של  $f$ .

**הערה 4.11** שיטת ניוטון ופסון לפונ' במראה הרב מימדי מוגדרת היטב  $\iff$  הפיכה בנקודה  $x_t$ . אנחנו נראה בהמשך הנחות שנעשה שיאפשרו לנו לומר שהשיטה אכן מוגדרת היטב והאסיאן באמת הפיך.

### 11.1.3 אינרפטציות (דרכי הסתכלות) שונות על שיטת ניוטון

**שיטת ניוטון = adaptive gradient descent** אחת האפשרויות לשחוב על שיטת ניוטון היא בטור הכללה של שיטת הגרדיינט. פונ' עדכון כליה

$$x_{t+1} = x_t - H(x_t) \nabla f(x_t)$$

כאשר  $H(x) \in \mathbb{R}^{d \times d}$  הוא מטריצה.

- בשיטת ניוטון  $(\nabla^2 f(x_t))^{-1}$

- בשיטת ניוטון  $H = \eta I_{d \times d}$  : gradient descent

בשיטת ניוטון: adaptive gradient descent היא אדפטציה לפי הגאומטריה המקומיות של הפונ' בנקודה  $x_t$ . (תclf' נראה את המשמעות של זה)

Newton's method: "adaptive gradient descent", adaptation is w.r.t. the local geometry of the function at  $x_t$ .

### שיטת ניוטון - קירובים מסדר שני

• נזכר כי המוטבציה לgradient descent step בנקודה  $x$ : היהת ליותר את הקירוב מסדר ראשון (של הנקודה  $x$  שאנו נמצאים בה עצם) + רכיב ריבועי. (ראינו את ההסתכלות הזה בעבר)

$$f(y) \approx f(x) + \nabla f(x)^T (y - x) + \frac{1}{2\eta} \|y - x\|_2^2$$

$$\text{ועל } y, \text{ וכאשר זה יניב את צעד העדכון (}x^+ = x_t - \eta \nabla f(x)\text{)}$$

– בשיטה זו "הינו זהירים" והוספנו בשיטה זו איבר  $\frac{1}{2\eta} \|y - x\|_2^2$  שודאג שלא נתרחק יותר מדי בכל עדכון מה  $x$  המקורי.

• בדומה אנלוגית שיטת ניוטון משתמש בקירוב מסדר ראשון ועוד קירוב מסדר שני (זה פשוט קירוב טוב יותר)

$$f(y) \approx f(x) + \nabla f(x)^T (y - x) + \frac{1}{2} (y - x)^T \nabla^2 f(x) (y - x)$$

$$\text{וממiazרים מעל } y \text{ כדי לקבל את צעד העדכון (}x^+ = x - (\nabla^2 f(x))^{-1} \nabla f(x)\text{)}$$

– בשיטה זו אנו לא "זהירים" כלל כי אנו לא מוסיפים איבר נוסף לקירוב מסדר שני ואנו "מאמיינים" רק לקירוב מסדר שני של הפונ' או אחד ממהדרכם שהופכים את שיטת ניוטון לבעייתית.

– הדבר הזה יוביל לקבצים מאד מהירים כשהאיטרנטים של השיטה מאוד קרוביים לאופטימום (תחת הנחות מסוימות שנראה) ויביל לקבצים מאד רחוקים כשהאנחנו רוחקים מהאופטימום הקירוב מסדר שני פחות אמין כקירוב לפונ' ולכן שיטות מסדר שני יתכנסו בד"כ יותר לאט.

– מה שעושים בפועל: הדבר הזה יגרום לנו לרצות להשתמש בGD כאשר רוחקים מהאופטימום ומעבר לנקודה מסויימת שנאו חישבים שנאו קרוביים מספיק לפתורן האופטימי נשתמש בשיטת Newton.(להתקדם על ידי שיטת ניוטון).

– ישן משפחה של פונ' (לדוגמא גרגסיה לוגיסטי) שיש משפט שתמיד מבטיח שההתכנסות של שיטות ניוטון תהיה מהירה יותר מאשר GD ולכן בפתרון בעיות אלו בד"כ משתמשים מהתחלת בשיטת ניוטון.(נדבר על זה בהרצאה הבאה)


**דוגמאות:**

**דוגמא - פונ' ריבועית עם איבר לא ריבועי:**

נסתכל על הפונ' הבא, שמכילה איבר ריבועי ואיבר לא ריבועי

Consider minimizing  $f(x) = (10x_1^2 + x_2^2)/2 + 5 \log(1 + e^{-x_1 - x_2})$   
(this must be a nonquadratic ... why?)

We compare gradient descent (black) to Newton's method (blue), where both take steps of roughly same length



שיטת ניוטון מופיעה בכחול.  
ושיטת GD מופיעה בשחור.

נבחן כי הטעיה היא נכונה ( $x_1, x_2$  בסקלנות שונות) ראיינו כבר כי במקרים מסוימים GD נפגעים מאוד אבל ביצועי שיטות ניוטון לא נפגעים מההפרשים בסקלנות הנ"ל.


**הערה 5.11** אם  $f$  הייתה מכילה רק איברים ריבועיים כלומר  $\frac{10x_1^2+x_2^2}{2}$  אז תהיה לשיטת ניוטון התכנסות תוך איטרציה אחת כי עד העדכון מוצא מינימום לקירוב הריבועי של הפונ' (ניוטון מזעיף את הקירוב הריבועי של הפונ', ואם הפונ' היא ריבועית אז הקירוב שלו זה היא עצמה). וכך לפונ' הושיפו את הרכיב הריבועי כדי שהייתה מעניין ולא מתכנס תוך סיבוב אחד.

#### דוגמא דוגמאות לוגיסטיות:

גרסיה לוגיסטיות עם  $n = 500, p = 100$  נשווה את שיטת GD לשיטת ניוטון שנייה עם backtracking (ולא פירט על זה ולא פירט על הטעיה/הפונ' הלוגיסטיות)

#### Example: logistic regression

Logistic regression example, with  $n = 500, p = 100$ : we compare gradient descent and Newton's method, both with backtracking



Newton's method: in a totally different regime of convergence...!


#### איינפלטציה לשיטות ניוטון ופסון

#### Linearized optimality condition

Alternative interpretation of Newton step at  $x$ : we seek a direction  $v$  so that  $\nabla f(x + v) = 0$ . Let  $F(x) = \nabla f(x)$ . Consider linearizing  $F$  around  $x$ , via first-order approximation

$$0 = F(x + v) \approx F(x) + DF(x)v$$

Solving for  $v$  yields  $v = -(DF(x))^{-1}F(x) = -(\nabla^2 f(x))^{-1}\nabla f(x)$



(From B & V page 486)

History: work of Newton (1685) \* and Raphson (1690) originally focused on finding roots of polynomials. Simpson (1740) applied this idea to general nonlinear equations, and minimization by setting the gradient to zero

#### 11.1.4 תכונות של שיטת ניוטון

**איינוריאנטיות לטרנספורמציה אפינית invariance affine** (תכוונה של שיטת ניוטון) הזכרנו את הנושא הזה גם בתרגול D.G. יכול להכחיש במידה והקדודנות הם בסדרי גודל שונים. הפרש הסקלנות מגולם בגודל condition number וכאשר הגודל הזה גדול מאוד

(כלומר קיים הפרש סקלנות גדול מאוד) ביצועי GD נפגעים מאוד.

ניתן להראות כי שיטת ניוטון איינוריאנטית להפרשי סקלנות affine invariance. כלומר הביצועים שלה לא תלויים בהפרשי הסקלנות שבבעה.

תזכורת: (למשפט שריאנו)

**משפט:** אם  $f$  גירה ברציפות, אז  $g(x) = f(Ax)$  ו  $A \in \mathbb{R}^{n \times m}$

$$\star: \begin{aligned}\nabla g(x) &= A^T \nabla f(Ax) \\ \nabla^2 g(x) &= A^T \nabla^2 f(Ax) A\end{aligned}$$

תכונה חשובה של שיטת ניוטון היא אינואריאנטיות לטרנספורמציה אפינית (affine invariance). בהינתן  $f$ , מטריצה הפיכה  $A$  וקטור על ידי  $y$ , נקבע ניוטון על  $Ay$  על ידי  $g(y) = f(Ay)$  ו  $x = Ay$ .

$$\begin{aligned}y^+ &= y - (\nabla^2 g(y))^{-1} \nabla g(y) \\ &\stackrel{g(y)=f(Ay)}{\overbrace{=}} y - (\nabla^2 f(Ay))^{-1} \nabla f(Ay) \\ &\stackrel{\star}{=} y - (A^T \nabla^2 f(Ay) A)^{-1} A^T \nabla f(Ay) \\ &= y - (A)^{-1} (\nabla^2 f(Ay))^{-1} (A^T)^{-1} A^T \nabla f(Ay) \\ &= y - A^{-1} \nabla^2 f(Ay)^{-1} \nabla f(Ay)\end{aligned}$$

כלומר צעד העדכון עבור  $y$  הוא:

$$y^+ = y - A^{-1} \nabla^2 f(Ay)^{-1} \nabla f(Ay)$$

נכפיל ב  $A$  משמאל ונקבל

$$Ay^+ = Ay - \nabla^2 f(Ay)^{-1} \nabla f(Ay)$$

נambil  $x$  ( $x^+ = Ay$ ) ונקבל לבדוק את כל העדכון של ניוטון:


$$x^+ = x - \nabla^2 f(x)^{-1} \nabla f(x)$$

אזי ההתקדמות האלג'רינה תלויה בסקילינג של הבעה (אינואריאנטיות לטרנס' אפינית).  
במילים אחרות, אם נפעיל את השיטה על  $x$  ועל  $y$  כך ש  $y = Ax$  נקבל את אותם האיטרנטים (כך שהקשר ביןיהם יהיה הכפלת  $A$ ).

ולכן אם שמים את המשקפיים של שיטת ניוטון לפחיסות של הבעה (הפרשי סקלארות) אין משמעות להתקדמות הקצב של האלג'רינה (מיאנוורנטיות יכולנו להציג טרנס  $A$  שתקטין את הפחיסות (תתקטין את היחס בין  $x_1$  ו  $x_2$ ) ושימוש באלג'רינה של שיטת ניוטון ייבאת אותן הביצועים בדיקום).

Consider minimizing  $f(x) = (10x_1^2 + x_2^2)/2 + 5 \log(1 + e^{-x_1 - x_2})$   
(this must be a nonquadratic ... why?)

We compare gradient descent (black) to Newton's method (blue), where both take steps of roughly same length



**התכנסות לוקלית Local convergence** (תמונה של שיטת ניוטון) נוכחים כי מעל תנאים מסוימים וכאשר אנו מתחילה את השיטה בנקודה  $x$  שקרוב מספיק לנקודת המינימום הכלובלי, הקצב של שיטת ניוטון להשת פתרון  $\epsilon$  אופטמלי הוא  $\mathcal{O}(\frac{1}{\epsilon} \log \log \epsilon)$  צעדים.

**הערה 6.11** זה למשarra הרבה יותר מהיר מכל שיטה אחרת שריאנו עד כה... אבל החסרון הוא שהוא צרכיים להתחיל מראש בנקודת שמספיק קרובה למינימום.

תמונה זו נקראת **תוצאת התכנסות לוקלית**.

**הגדירה 7.11** בהינתן מטריצה סמטרית  $A \in \mathbb{R}^{n \times n}$  (שייכת למרחב המט' הסמטריות ממימד  $n \times n$  שמסומן  $\mathbb{S}^n$  כלומר  $\mathbb{S}^n \subseteq \mathbb{R}^{n \times n}$ ) נגיד את **הנורמה הספקטרלית Spectral norm** באופן הבאה  $\|A\|_L \triangleq \max_{x \neq 0} \frac{\|Ax\|_2}{\|x\|_2}$ . נבחן כי הנורמה הספקטרלית היא נורמה על מטריצה. כלומר  $\mathbb{S}^n \rightarrow \mathbb{R} : \| \cdot \|_L$ .

**הערה 8.11** הקשר בין הנורמה הספקטרלית הוא כדלקמן:  $\|A\|_L = \lambda_{\max}$  כלומר הנורמה הספקטרלית של מטריצה סמטרית  $A \in \mathbb{R}^{n \times n}$  הוא הע"ע הגדול ביותר של  $A$ .

**משפט 9.11** מתקיים:  $\forall x \in \mathbb{R}^n, A \in \mathbb{S}^n \subseteq \mathbb{R}^{n \times n} : \|Ax\|_2 \leq \|A\|_L \cdot \|x\|_2$  (נובע ישירות מההגדרה)

**סימון 10.11** מעכשו כל פעם שנרשום  $\| \cdot \|$  על וקטור נתכוון לנורמה האוקלידית (נורמת  $\ell_2$ ) כלומר  $\| \cdot \|_2$ .

**סימון 11.11** מעכשו כל פעם שנרשום  $\| \cdot \|$  על מטריצה נתכוון לנורמה הספקטרלית כלומר  $\| \cdot \|_L$ .

בשאלה מתقارب מספיך אתה כבר שם...

**משפט 12.11** תהא  $f : \mathbb{R} \rightarrow \mathbb{R}$  פונ' קמורה עם מינימום גלובלי ייחיד  $x^*$ .  
אם

קיים כדור  $X \subseteq \text{dom}(f)$  שמרכזו בנקודה  $x_t$  כך ש:

.1. ( $\nabla^2 f(x)$ ) $^{-1}$  (קיים הופכי להessian): מתקיים כי ההesian הפיך בכל  $X$  כלומר  $\forall x \in X$  קיים

(הופכי להesian חסום): קיים מספר  $0 < \mu \in \mathbb{R}$  כך ש:

$$\forall x \in X : \left\| \nabla^2 f(x)^{-1} \right\| \leq \frac{1}{\mu} \Rightarrow \nabla^2 f(x) \geq \mu I$$

(א) אפשר לומר שהתמונה  $\left\| \nabla^2 f(x)^{-1} \right\| \leq \frac{1}{\mu}$  המשמעות היא  $\nabla^2 f(x) \geq \mu I$  כלומר, הע"ע הכינומך של ההesian בכל נקודה  $x \in X$  גדול מ  $\mu$ . לתמונה זו קראונו בשם: strongly convex. ככלומר התמונה זו שולחה לאמירה שקיים מספר  $\mu > 0$  כך  $\forall x \in X$  היא  $f$  שילכל  $\mathbb{R}$  מעל תחום  $X$  strongly convex.

.2. (רציפות לפשצית של ההesian): קיים מספר  $0 < B < \infty$  כך ש Lipschitz continuous hessians .3

$$\forall x, y \in X : \left\| \nabla^2 f(x) - \nabla^2 f(y) \right\| \leq B \cdot \|x - y\|$$

אזי:

לכל  $X$  ו  $x_{t+1}, x_t \in X$  שנוצר מצעד ניוטון בנקודה  $x_t$  קיבל

$$\|x_{t+1} - x^*\| \leq \frac{B}{2\mu} \|x_t - x^*\|^2$$

**הערה 13.11** הבטו'  $\|x_{t+1} - x^*\|^2 \leq \frac{B}{2\mu} \|x_t - x^*\|^2$  שוב מרמז לנו על התוכניות על אקפוננציאלית כפי שראינו קודם.

**התוכניות סופר אקפוננסציאלית (על-אקפוננציאלית)**

**מסקנה 14.11** עם ההנחה והטרמינולוגיה שהזוכרה קודם, ואם  $\frac{\mu}{B}$  אזי שימוש בשיטת ניוטון ייב

$$\|x_t - x^*\| \leq \frac{\mu}{B} \left( \frac{1}{2} \right)^{2^T - 1}, T \geq 0$$

כלומר אם נתחיל להשתמש בשיטת ניוטון כאשרנו קרובים מספיך למינימום גלובלי, נגיע לפתרון  $\epsilon$  תחת אופטימי לוד  $\mathcal{O}(\log \log(\frac{1}{\epsilon}))$  צעדים.

(חחסם מאד דומה לחסם שהראנו בשיטה הבבלית).

## אינטואציה לגבי התכונות הסופר אקסוננטית

- אם הפונקציה המקורית היא ריבועית אז שיטת ניוטון מוצאת את הפתרון בצעד אחד (ראינו את זה)

Lipschitz continuus hessians ב $\mathbf{x}$ .לפי

$$\forall \mathbf{x}, \mathbf{y} \in X : \|\nabla^2 f(\mathbf{x}) - \nabla^2 f(\mathbf{y})\| \leq B \cdot \|\mathbf{x} - \mathbf{y}\|$$

אז בפרט  $\mathbf{x} = \mathbf{x}_t, \mathbf{y} = \mathbf{x}^*$  ונקבל

$$\|\nabla^2 f(\mathbf{x}_t) - \nabla^2 f(\mathbf{x}^*)\| \leq B \cdot \|\mathbf{x}_t - \mathbf{x}^*\|$$

כלומר כאשר  $\|\mathbf{x}^* - \mathbf{x}_t\|$  קטן אז קלומר באזור קרובה ל $\mathbf{x}^*$  הפונ' היא בקרוב ריבועית (ההסיאן של  $f$  בנקודה  $\mathbf{x}_t$  מתקרב להסיאן של  $f$  בנקודה  $\mathbf{x}^*$ ).

**הוכחה של משפט ההתכנסות** נסמן את ההسان באוט  $H$  כלומר  $\nabla^2 f(\mathbf{x})$ ,  $\mathbf{x} = \mathbf{x}_t$ ,  $\mathbf{x}' = \mathbf{x}_{t+1}$  נtabون בצעד ניוטון:

$$\mathbf{x}_{t+1} = \mathbf{x}_t - (\nabla^2 f(\mathbf{x}_t))^{-1} \nabla f(\mathbf{x}_t)$$

נסמן לפי הסימונים ונקבל

$$\mathbf{x}' = \mathbf{x} - (H(\mathbf{x}))^{-1} \nabla f(\mathbf{x})$$

נחסר  $\mathbf{x}^*$  משני האגפים

$$\mathbf{x}' - \mathbf{x}^* = \mathbf{x} - \mathbf{x}^* - (H(\mathbf{x}))^{-1} \nabla f(\mathbf{x})$$

כלומר

$$\begin{aligned} \mathbf{x}' - \mathbf{x}^* &= \mathbf{x} - \mathbf{x}^* - (H(\mathbf{x}))^{-1} \nabla f(\mathbf{x}) \\ &\stackrel{(\nabla f(\mathbf{x}^*)=0)}{=} \mathbf{x} - \mathbf{x}^* + (H(\mathbf{x}))^{-1} \left( \overbrace{\nabla f(\mathbf{x}^*)}^{=0} - \nabla f(\mathbf{x}) \right) \\ &= \mathbf{x} - \mathbf{x}^* + (H(\mathbf{x}))^{-1} \int_0^1 H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) [\mathbf{x}^* - \mathbf{x}] dt \end{aligned}$$

כאשר המעבר האחרון מוכיח על ידי המשפט הבא מחדואה

$$\int_a^b h'(t) dt = h(b) - h(a)$$

עבור

$$\begin{aligned} h(t) &= \nabla f(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) \Rightarrow & h(0) &= \nabla f(\mathbf{x}) \\ && h(1) &= \nabla f(\mathbf{x}^*) \\ && h(1) - h(0) &= \nabla f(\mathbf{x}^*) - \nabla f(\mathbf{x}) \end{aligned}$$

$$h'(t) = \nabla^2 f(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) [\mathbf{x}^* - \mathbf{x}]$$

ולכן

$$\nabla f(\mathbf{x}^*) - \nabla f(\mathbf{x}) = h(1) - h(0) = \int_0^1 h'(t) dt = \int_0^1 (\nabla^2 f(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) [\mathbf{x}^* - \mathbf{x}]) dt$$

כלומר קיבלנו כי

$$\mathbf{x}' - \mathbf{x}^* = \mathbf{x} - \mathbf{x}^* + (H(\mathbf{x}))^{-1} \int_0^1 H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) [\mathbf{x}^* - \mathbf{x}] dt$$

בנוסח נזכיר כי הנחנו כי ההסיאן הוא הפיך:

$$\begin{aligned}
 \mathbf{x} - \mathbf{x}^* &= I(\mathbf{x} - \mathbf{x}^*) \\
 &= [H(\mathbf{x})]^{-1} \overbrace{[H(\mathbf{x})](\mathbf{x} - \mathbf{x}^*)}^{\not\propto t} \\
 &\stackrel{*}{=} [H(\mathbf{x})]^{-1} \int_0^1 [H(\mathbf{x})](\mathbf{x} - \mathbf{x}^*) dt \\
 &= [H(\mathbf{x})]^{-1} \int_0^1 [-H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) dt
 \end{aligned}$$

(\*הבטוי לא תלוי ב  $t$  ולכן מותר לעשות אינטגרל על פניו)  
כלומר הראו כי

$$(I) \quad \mathbf{x}' - \mathbf{x}^* = \mathbf{x} - \mathbf{x}^* + (H(\mathbf{x}))^{-1} \int_0^1 H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x}))[\mathbf{x}^* - \mathbf{x}] dt$$

$$(II) \quad \mathbf{x} - \mathbf{x}^* = [H(\mathbf{x})]^{-1} \int_0^1 [-H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) dt$$

נציב את (II) בתוך (I) ונקבל

$$\mathbf{x}' - \mathbf{x}^* = \underbrace{\mathbf{x} - \mathbf{x}^*}_{[H(\mathbf{x})]^{-1} \int_0^1 [-H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) dt} + (H(\mathbf{x}))^{-1} \int_0^1 H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x}))[\mathbf{x}^* - \mathbf{x}] dt$$

כלומר

$$\mathbf{x}' - \mathbf{x}^* = [H(\mathbf{x})]^{-1} \int_0^1 [-H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) dt + (H(\mathbf{x}))^{-1} \int_0^1 H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x}))[\mathbf{x}^* - \mathbf{x}] dt$$

$$\underbrace{\mathbf{x}' - \mathbf{x}^*}_{\text{vector}} = \underbrace{[H(\mathbf{x})]^{-1}}_{\text{matrix}} \underbrace{\left( \int_0^1 [H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) - H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) dt \right)}_{\text{vector}}$$

ראינו כי לפי ההערה בתחילת השיעור כי  $\forall \mathbf{y} : \|A\mathbf{y}\| \leq \|A\| \cdot \|\mathbf{y}\|$  ונקבל

$$\|\mathbf{x}' - \mathbf{x}^*\| \leq \left\| [H(\mathbf{x})]^{-1} \left\| \int_0^1 [H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) - H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) dt \right\| \right\|$$

(אפשר להראות שהנורמה על האינטגרל קטנה שווה לנורמה (לא נראה זאת אבל זה נכון אבל זה נובע מכך שוויון גיסן על פונ' הנורמה  $\|\cdot\|$  שהוא פון' קומפקטי) ) ולכן:

$$\begin{aligned}
 \|\mathbf{x}' - \mathbf{x}^*\| &\leq \left\| [H(\mathbf{x})]^{-1} \right\| \left\| \int_0^1 [H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) - H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) dt \right\| \\
 &\leq \left\| [H(\mathbf{x})]^{-1} \right\| \int_0^1 \| [H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) - H(\mathbf{x})](\mathbf{x}^* - \mathbf{x}) \| dt \\
 &\leq \left\| [H(\mathbf{x})]^{-1} \right\| \int_0^1 \| [H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) - H(\mathbf{x})] \| \cdot \| (\mathbf{x}^* - \mathbf{x}) \| dt \\
 &\leq \left\| [H(\mathbf{x})]^{-1} \right\| \| (\mathbf{x}^* - \mathbf{x}) \| \int_0^1 \| [H(\mathbf{x} + t(\mathbf{x}^* - \mathbf{x})) - H(\mathbf{x})] \| dt
 \end{aligned}$$

נשותמש בתוכנות Lipschitz continuus hessians **Bounded inverse hessians** ונקבל כי

$$\begin{aligned}
 \|x' - x^*\| &\leq \left\| [H(x)]^{-1} \right\| \|(x^* - x)\| \int_0^1 \|[H(x + t(x^* - x)) - H(x)]\| dt \\
 &\stackrel{\text{Bounded inverse hessians}}{\leq} \frac{1}{\mu} \|(x^* - x)\| \int_0^1 \|[H(x + t(x^* - x)) - H(x)]\| dt \\
 &\stackrel{\text{Lipschitz continuus hessians}}{\leq} \frac{1}{\mu} \|(x^* - x)\| \int_0^1 B \cdot \|x + t(x^* - x) - x\| dt \\
 &= \frac{1}{\mu} \|(x^* - x)\| \int_0^1 B \cdot \|t(x^* - x)\| dt \\
 &= \frac{B}{\mu} \|(x^* - x)\|^2 \underbrace{\int_0^1 t dt}_{=\frac{1}{2}} \\
 &= \frac{B}{2\mu} \|(x^* - x)\|^2
 \end{aligned}$$

כלומר הראנו כי

$$\|x' - x^*\| \leq \frac{B}{2\mu} \|(x^* - x)\|^2$$

מציב בחזרה

$$\|x_{t+1} - x^*\| \leq \frac{B}{2\mu} \|(x^* - x_t)\|^2$$

ולכן סיום.

■

**קמיות ממש  $\Leftarrow$  ההופכי של ההסיאן חסום** **Bounded inverse hessians** דרך אחת להבטיח שיטקים הוא אלדרוש קמיות חזקה מעל  $X$ .

**лемה 15.11** תהא  $f : \text{dom}(f) \rightarrow \mathbb{R}$  גירה פעמים וקמורה חזק עם פרמטר  $\mu$  מעל תחום פתוח וקמור  $X \subseteq \text{dom}(f)$  כלומר

$$\forall x, y \in X : f(y) \geq f(x) + \nabla f(x)^T (y - x) + \frac{\mu}{2} \|x - y\|^2$$

אי (15.11) היא הפיכה וגם  $\|\cdot\|$  היא הנורמה הספקטרלית.

$$\nabla^2 f(x)^{-1} \leq \frac{1}{\mu} \quad \text{שקל להנחה כי } \mu \geq 1$$

**הערה 17.11** יש פרטים בהוכחה שלא התמקדנו בו, לא התמכו בשהلة האירנטים של ניוטון נשארים בתוך התחים  $X$  שבו כל הדברים והתכונות מתקיימות. והhocחה נכונה תחת ההנחה ש  $x_t$  תמיד נשאר בתחום  $X$ . מדוע לכל  $t$  נשאר ב  $X$ ? אפשר להראות את הדבר הזה ש  $x_t$  אנו ככל שמותקדמים בז'ים בכל אינטרנט אנו תמיד הולכים ומתקרבים ל  $x^*$  (לדוגמא אפשר להראות באינדוקציה בסיס עבור  $X \in \mathbb{R}^n$  ולהראות באינדוקציה שלכל  $x$  באינטרנט הבא רק מתקרבים ל  $x^*$  (ולא מתרחקים ממנו)). לא התעסקנו עם החלק הזה בהוכחה אבל חשוב להכיר שגם זה צריך להראות אם וכחמים את שיטת ניוטון

- זכרו:

newton – כל איטרציה של שיטת ניוטון דורשת  $\mathcal{O}(n^2)$  מקום (מטי' הסיאן במימדי  $n \times n$ )  
GD – כל איטרציה של שיטת GD דורשת  $\mathcal{O}(n)$  מקום (ווקטור גרדיאנט במימד  $n$ )

- **סובכיות חישובית:**

newton – כל איטרציה של שיטת ניוטון דורשת flops(floating points operations)  $\mathcal{O}(n^3)$  (פתרון של מע' משוואות  $n \times n$ : היפוך מט' במימדי  $n \times n$  דורשת  $\mathcal{O}(n^3)$  חישובים)


(scaling/adding n-dimensional vectors) flops(floating points operations)  $\mathcal{O}(n)$  GD –

- **conditioning:**

Newton's method is not affected by a problem's conditioning. לעומת זאת, GD: מאוד מושפע מההיבשות של הבעיה ובעיה עם סדרי גודל שונים (גבוהה) יכול להוביל לירידה משמעותית בביצועים.

**הערה 18.11** יתרון נוסף של שיטות מסדר שני הוא קצב התכנסות סופר אקספוננציאלי קרוב לאופטימום.

Back to logistic regression example: now x-axis is parametrized in terms of time taken per iteration



Each gradient descent step is  $O(p)$ , but each Newton step is  $O(p^3)$

כעת מסתכלים על הבדלי הביצועים בין GD לבין ניוטון בהתחשב בזמן. וההיתרון של שיטה אחת על האחרת נראה פחות ברור. ככל שמייד הבעיה גדול יותר כך שימוש בשיטת ניוטון יהיה פחות כדי כי המאמץ החישובי לכל צעד יהיה מאוד גדול.

### Equality-constrained Newton's method

Consider now a problem with equality constraints, as in

$$\min_x f(x) \text{ subject to } Ax = b$$

Several options:

- **Eliminating equality constraints:** write  $x = Fy + x_0$ , where  $F$  spans null space of  $A$ , and  $Ax_0 = b$ . Solve in terms of  $y$
- **Deriving the dual:** can check that the Lagrange dual function is  $-f^*(-A^T v) - b^T v$ , and strong duality holds. With luck, we can express  $x^*$  in terms of  $v^*$
- **Equality-constrained Newton:** in many cases, this is the most straightforward option

עם אילוצים

פחות התעקבנו על השקף הנ"ל.

בדרך הראשונה פותרים לפי הבעיה הלא מאולצת שנוצרה לפי  $u$  שהוא וקטור לא מאולץ. (ואז נוכל להשתמש בשיטת ניוטון)

הדרך השנייה מתעסקת בעיה הדואלית של הבעיה. (לא דיברנו על החומר זהה)

הדרך הימרה היא לעשות ניוטון עם אילוצי שווין

## אלג' ניוטון עם אילוצי שווין (הכללה של שיטת ניוטון):

In equality-constrained Newton's method, we start with  $x^{(0)}$  such that  $Ax^{(0)} = b$ . Then we repeat the updates

$$x^+ = x + tv, \quad \text{where}$$

$$v = \underset{Az=0}{\operatorname{argmin}} \quad \nabla f(x)^T(z - x) + \frac{1}{2}(z - x)^T \nabla^2 f(x)(z - x)$$

This keeps  $x^+$  in feasible set, since  $Ax^+ = Ax + tAv = b + 0 = b$

Furthermore,  $v$  is the solution to **minimizing a quadratic subject to equality constraints**. We know from KKT conditions that  $v$  satisfies

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} v \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

for some  $w$ . Hence Newton direction  $v$  is again given by solving a linear system in the Hessian (albeit a bigger one)

## שיטות קווזי ניוטון:

### Quasi-Newton methods

If the Hessian is too expensive (or singular), then a **quasi-Newton** method can be used to approximate  $\nabla^2 f(x)$  with  $H \succ 0$ , and we update according to

$$x^+ = x - tH^{-1}\nabla f(x)$$

- Approximate Hessian  $H$  is recomputed at each step. Goal is to make  $H^{-1}$  cheap to apply (possibly, cheap storage too)
- Convergence is fast: **superlinear**, but not the same as Newton. Roughly  $n$  steps of quasi-Newton make same progress as one Newton step
- Very wide variety of quasi-Newton methods; common theme is to "propagate" computation of  $H$  across iterations

משערכות את ההסיאן (לא מחשבות אותו במדויק) ומבצעות כלל עדכון שמצויר מאוד את הכלל של ניוטון. במטרה לחסוך את החישוב של ההסיאן בכל איטרציה.

## 11.2 תרגול 11

### 11.2.1 אלג' ניוטון

נתבונן בבעיית אופטימיזציה מהצורה

$$(P) \min_{\mathbf{x}} f(\mathbf{x})$$

כאשר הפונ'  $f$  גזירה פעמיים בראציות. נניח כי ברשותנו ניחוש  $\mathbf{x}_t$  עברו נקודת המינימום וברצוננו למצוא ניחוש טוב יותר. לשם כך נבצע קירוב טילור מסדר שני לפונ' סביב  $\mathbf{x}_t$ :

$$f(\mathbf{x}_t + \mathbf{d}_t) \approx f(\mathbf{x}_t) + \mathbf{d}_t^T \nabla f(\mathbf{x}_t) + \frac{1}{2} \mathbf{d}_t^T \nabla^2 f(\mathbf{x}_t) \mathbf{d}_t$$

נבחר  $\mathbf{x}_{t+1} = \mathbf{x}_t + \mathbf{d}_t$  כאשר  $\mathbf{d}_t$  הוא המזעיר של הקירוב טילור לעיל. לשם כך נגזר את הבטווי ונשווה לאפס ונקבל את מע' המשוואות

$$(\nabla^2 f(\mathbf{x}_t)) \mathbf{d}_t = -\nabla f(\mathbf{x}_t)$$

אם  $\nabla^2 f(\mathbf{x}_t) \succ 0$  הרि שפרטון מע' המשוואות הוא המינימום (היחיד) של קירוב הטילור והוא נתון על ידי

$$\mathbf{d}_t = -(\nabla^2 f(\mathbf{x}_t))^{-1} \nabla f(\mathbf{x}_t)$$

משמעותה של הקירוב הריבועי הוא רק קירוב, בפועל בשיטת ניוטון הכוון  $d_t$  מחושב על פי הבטווי לעיל אך מחושב בנפרד גודל צעד שיבתייה ירידת.

## אלגוריתם 8 שיטת ניוטון

---

```

Algorithm A: Newton's Method
Data: Initial guess,  $\mathbf{x}_0$ 
Result: An estimate  $\mathbf{x}_{t+1}$  of the minimizer
 $t \leftarrow 0$ 
while  $t \leq t_{\max}$  do
    /* Solve the system  $(\nabla^2 f(\mathbf{x}_t))\mathbf{d}_t = -\nabla f(\mathbf{x}_t)$ : */
     $\mathbf{d}_t \leftarrow \text{SolveNewtonSystem}(\nabla^2 f(\mathbf{x}_t), \nabla f(\mathbf{x}_t))$ 
     $\eta_t \leftarrow \text{ComputeStepSize}(\mathbf{x}_t, \mathbf{d}_t)$  // exact / backtracking
     $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \eta_t \mathbf{d}_t$ 
    if  $\text{StoppingCondition}(\mathbf{x}_{t+1}) == \text{true}$  then
        return  $\mathbf{x}_{t+1}$ 
    else
         $t \leftarrow t + 1$ 
    end
end

```

---

### הערה 19.11

1. למה בוחרים גודל עצם  $\eta$  ולא מתקדם פשוט לפי הממוצע  $d_t$ ? כי הפונ' הזה היא בסה"כ קירוב.(קירוב ריבועי לפונ' המקורי) ולא בטוח ש  $d_t$  שמאזר את הקירוב ממאזר גם את הפונ' המקורי.
2. באופן כללי אם הניחוש ההתחלתי קרוב מספיק לנקודת המינימום והפונ' חלקה דיה איז אלג' ניוטון מתכנס לנקודת המינימום מהר.
3. על מנת להפעיל את אלג' ניוטון علينا לחשב הן את הגרדיינט והן את ההסיאן של הפונ' וכן לפתור מע' משוואות לינארית
4. השיטה מוגדרת היטב כאשר  $f$  בעלת הסיאן חיובי מוגדר. אם הפונ'  $f$  קמורה איז מובטח כי ההסיאן שלו הוא אי שלילי מוגדר. אך הוא אינו בהכרח הפיך. במקרה כזה האלג' לעיל אינו מוגדר היטב.

### 11.2.2 אלג' גאוס-ניוטון לביעית איבועים פחותים

בעיית הריבועים הפחותים Least squares הינה בעיה מהצורה

$$\min_{\mathbf{x}} \frac{1}{2} \sum_{i=1}^N f_i^2(\mathbf{x})$$

כאשר הפונ'  $f_1, f_2, \dots, f_N$  נתונות וצירות ברכיפות. בעיה מסוימת זה נפוצה מאוד בהנדסה. לדוג' בעיות של שערוך פרמטרים או התאמת פרמטרי מודל. שימושו לביעית אופטימלית זו אינה קמורה.

נסמן:

$$\mathbf{f}(\mathbf{x}) = \begin{bmatrix} f_1(\mathbf{x}) & f_2(\mathbf{x}) & \cdots & f_N(\mathbf{x}) \end{bmatrix}^T$$

$$F(\mathbf{x}) = \frac{1}{2} \|\mathbf{f}(\mathbf{x})\|_2^2 = \frac{1}{2} \sum_{i=1}^N f_i^2(\mathbf{x}).$$

הweeneyון באלגוריתם גאוס ניוטון הוא לבצע קירוב מסדר שני לפונקציה  $(\mathbf{x}) F$  סביר הניחוש הנוכחי, לפחות את הקירוב, ולבצע צעד ניוטון באותה נקודת. לשם כך, נדר את מטריצת הייעוקויאן (Jacobian) של הפונקציה  $\mathbf{f}(\mathbf{x})$ :

$$J(\mathbf{x}) = \begin{bmatrix} \nabla f_1(\mathbf{x})^T \\ \nabla f_2(\mathbf{x})^T \\ \vdots \\ \nabla f_N(\mathbf{x})^T \end{bmatrix}.$$

זהו מטריצה שבה השורה ה- $i$  הוא שחלוף של הגרדיאנט של הפונקציה  $f_i$ . באמצעות הייעוקויאן ניתן לקבל ביטויים עבור הגרדיאנט וההסיאן של  $F(\mathbf{x})$ :

$$\begin{aligned} \nabla F(\mathbf{x}) &= \frac{1}{2} \sum_{i=1}^N \nabla(f_i^2(\mathbf{x})) = \sum_{i=1}^N f_i(\mathbf{x}) \nabla f_i(\mathbf{x}) \\ &= J(\mathbf{x})^T \mathbf{f}(\mathbf{x}) \\ \nabla^2 F(\mathbf{x}) &= \sum_{i=1}^N \nabla f_i(\mathbf{x}) \nabla f_i(\mathbf{x})^T + \sum_{i=1}^N f_i(\mathbf{x}) \nabla^2 f_i(\mathbf{x}) \\ &= J(\mathbf{x})^T J(\mathbf{x}) + \underbrace{\sum_{i=1}^N f_i(\mathbf{x}) \nabla^2 f_i(\mathbf{x})}_{\text{את האיבר הזה נזיה}} \\ &\approx J(\mathbf{x})^T J(\mathbf{x}). \end{aligned}$$

צעד מרכזי באלגוריתם הוא פישוט הביטוי ל- $\nabla^2 F(\mathbf{x})$ , כפי שצוין לעיל. במקרה בו הפונקציות  $f_i(\mathbf{x})$  אפיניות, אין צורך לבצע קירוב, כי אז  $\nabla^2 f_i(\mathbf{x}) = 0$ .

**Algorithm B:** Gauss Newton Algorithm

---

```

Data: Initial guess,  $\mathbf{x}_0$ 
Result: An estimate  $\mathbf{x}_{t+1}$  of the minimizer
 $t \leftarrow 0$ 
while  $t \leq t_{\max}$  do
     $\mathbf{J} \leftarrow \text{ComputeJacobian}(\mathbf{x}_t)$ 
     $\mathbf{f} \leftarrow \begin{bmatrix} f_1(\mathbf{x}_t) & f_2(\mathbf{x}_t) & \cdots & f_N(\mathbf{x}_t) \end{bmatrix}^T$ 
    /* Solve the system  $J^T J \mathbf{d}_t = -J^T \mathbf{f}$ : */  

     $\mathbf{d}_t \leftarrow \text{SolveNewtonSystem}(\mathbf{J}^T \mathbf{J}, -J^T \mathbf{f})$ 
     $\eta_t \leftarrow \text{ComputeStepSize}(\mathbf{x}_t, \mathbf{d}_t)$  // exact / backtracking
     $\mathbf{x}_{t+1} \leftarrow \mathbf{x}_t + \eta_t \mathbf{d}_t$ 
    if StoppingCondition( $\mathbf{x}_{t+1}$ ) == true then
        return  $\mathbf{x}_{t+1}$ 
    else
         $t \leftarrow t + 1$ 
    end
end

```

---

**הערה 2** 1. תנאי עצירה פופולרי:  $\epsilon < |F(\mathbf{x}_{t+1}) - F(\mathbf{x}_t)|$ , עבור פרמטר  $\epsilon$  כלשהו.

2. אם המטריצה  $J^T J$  הפיכה, אז כיוון גאוס ניוטון הוא כיוון ירידה (מדוע?).

3. אם המטריצה  $J^T J$  אינה הפיכה, אז יש "لتקן" אותה על ידי הוספת מטריצה אלכסונית (ואז השיטה נקראת שיטת Levenberg-Marquardt).

4. ביצועי אלגוריתם זה תלויים מאוד בנקודות ההתחלת, לכן צריך להתחיל מנקודת "טוב".

5. ההזנחה שביצענו בחישוב ההסיאן מניחה שבקרבת נקודת המינימום האיבר שהזנחה קטן יחסית. הנחתה זו הגיונית כאשר הפונקציות  $(x)_i$  הן בקירוב אפיניות באזור נקודת המינימום.

6. מטרתנו למazure את  $F(x)$  ולכון הגיוני לנחש שרכיבי  $f$  יהיו קטנים בקרבת הפתרון.

## 12 הרצאה ותרגול 12

### 12.1 הרצאה 12

#### 12.1.1 חזרה על שיעור קודם

**שבע שער:** שיטת ניוטון התבוננו בעיה  $\min_x f(x)$  עבור  $f$  קמורה ונגירה פעמיים עם  $\text{dom}(f) = \mathbb{R}^n$ , איז שיטת ניוטון הייתה כלהלן: בחר  $x_0 \in \mathbb{R}^n$  התחלתי ובצע את צעד העדכון

$$\begin{aligned}x_{t+1} &= x_t - H(x_t)^{-1} \nabla f(x_t) \\H(x_t) &= \nabla^2 f(x_t)\end{aligned}$$

עד להתקנסות.

**חסרונות:**

- דורש הפיכה של מט' בגודל  $n \times n$  ( $H(x_t) = \nabla^2 f(x_t)$  ← (פתרון בעיה זו): שימוש בשיטות קוואזי ניוטון (שיעור  $(x_t)^{-1}$  במקום חישוב מפורש שלו))
- שיטת ניוטון יכולה להתמודד רק אם אילוצי שוויון. (יש הרבה בעיות עם אילוצי אי שוויון אותן נקaza לפטור) ← (נראה פתרון בעיה זו בהרצאה הנוכחית).

ראינו שלשיטה ניוטון יש שני מצבים של התקנסות :

1. כאשרנו וחוקים מהפתרון האופטמלי (ואז קצב השיפור של השגיאה בכל אינטרנט) הוא עד כדי קבוע.
2. כשהנו קרובים לפתרון האופטמלי ואז השגיאה דועכת באופן סופר אקספוננציאלית. (ומכאן הכח הגדל של שיטת ניוטון).

ראינו שנית להרחיב את שיטת ניוטון עבור אילוצי שוויון

$$\min_{Ax=b} f(x)$$

An important variant is **equality-constrained Newton**: start with  $x^{(0)}$  such that  $Ax^{(0)} = b$ . Then we repeat the updates

$$\begin{aligned}x^+ &= x + tv, \quad \text{where} \\v &= \underset{Az=0}{\operatorname{argmin}} \nabla f(x)^T(z-x) + \frac{1}{2}(z-x)^T \nabla^2 f(x)(z-x)\end{aligned}$$

which keep  $x^+$  in feasible set  $Ax = b$

Here  $v$  is characterized by KKT system

$$\begin{bmatrix} \nabla^2 f(x) & A^T \\ A & 0 \end{bmatrix} \begin{bmatrix} v \\ w \end{bmatrix} = \begin{bmatrix} -\nabla f(x) \\ 0 \end{bmatrix}$$

for some  $w$ . Hence Newton direction  $v$  is again given by solving a linear system in the Hessian (albeit a bigger one)

**היררכיה של שיטות מסדר שני** היררכיה=כמה קל לפתור את הבעיה האלו בעזרת שיטת ניוטון. נניח שככל הבעיה הינט קמורות, נוכל לחשב כמה קל לפתור את הבעיה הללו על ידי שימוש בשיטות ניוטון.

1. בעיות ריבועיות Quadratic problems : הם הקЛОות ביותר יש להם פתרון פשוט. (הקירוב הריבועי של פונ' המטרה, ובאיטרציה אחת פותרים את הקירוב הריבועי הנ"ל וכן פותרים את בעיית המינימציה באיטרציה אחת)
2. בעיות ריבועיות עם אילוצי שוויון עדין קלות. משתמשים בתנאי KKT על מנת להגיע לפתרון סגור של הבעיה.

3. בעיות  $L$ -חלקות (ההאסיאן שלהם חלק - רציף לשפיץ) ובנוסף הבעיות קמורות חזק מושתמשים בשיטת ניוטון לפתרון.

4. בעיות Inequality constrained (and also equality constrained) and smooth problems משמש בשיטות של נקודות פנים לפתרון. נראה זאת בהרצתה היום.

### Barrier Method 12.1.2

נתבונן בבעית האופטימיזציה הקמורה הבאה:

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & h_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, m \\ & A\mathbf{x} = b \end{aligned}$$

נניח כי  $f, h_1, \dots, h_m$  הם קמורים, גירות פעמיים כל אחת מעל התוחם  $\mathbb{R}^n$ .

**הגדלה 1.12** נגידר את הפונ' barrier של הבעיות מעלה להיות( $\phi$ ) התחום של ( $\phi$ . $\phi(x) = -\sum_{i=1}^m \log(-h_i(x))$ ) הוא תחום כל הנקודות הפנים של האילוץ (כל הנקודות שמקיימות ממש את האילוץ) כל  $\{\phi\} = \{\mathbf{x} \mid \forall i \in \{1, \dots, m\} : h_i(\mathbf{x}) < 0\}$  כאשר  $\text{dom}\{\phi\} \neq \emptyset$ . (שים לב כי ההנחה זו היא למעשה סמיה שדואליות חזקה מותקינית).

**הערה 2.12** ההסיאן של ( $\phi$  מתפוץז (הולכת לאיסנוף) כאשר  $0 \rightarrow (\mathbf{x}).h_i(\mathbf{x})$ ) כאשר  $\phi$  מתפוץז (הולכת לאיסנוף) אבל לא כל כך מהר. היא הולכת לשם כמו log. ההתפוצצות באיסנוף היא בקצב יחסית איטי.

**דוגמה 3.12** נניח שיש לנו בעיה חד ממדנית

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & x \in [0, 1] \end{aligned}$$

כלומר האילוצים נראים מהצורה

$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & -x \leq 0 \\ & x \leq 1 \end{aligned}$$

כלומר


$$\begin{aligned} \min_{\mathbf{x}} \quad & f(\mathbf{x}) \\ \text{s.t.} \quad & -x \leq 0 \\ & x - 1 \leq 0 \end{aligned}$$

$$h_1 = -x, h_2(x) = x - 1$$

דילון

$$\begin{aligned} \phi(x) &= -\log(-h_1(x)) - \log(-h_2(x)) \\ &= -\log(-(-x)) - \log(-(x-1)) \\ &= -\log(x) - \log(-(x-1)) \end{aligned}$$

הפונק' נראית ככה (ברצף בין 0, 1 היא משתנית ואין אותה בشرطוט) בקצוות האילוץ היא מתפופצת



כלומר ככל שאנו קרובים לתוחם האילוץ ככתה הפונ' מתפוצצת יותר. וכך מכאן שמה של השיטה - Barrier Method (שיטת המחלסום).

זה היה במקרה החד מימדי. במקרה הרב מימדי אפשר לדמיין משחו דומה (בקצוזות האילוץ  $\phi$  מתפופצת).

מײַפה נולד  $\log$  זהה?  
נתעלם לרגע מאלוצי השוויון. הבעיה המאולצת שלנו יכולה להכתב כך


$$\min_{\mathbf{x}} f(\mathbf{x}) + \sum_{i=1}^m \mathbb{I}_{\{h_i(\mathbf{x}) \leq 0\}}(x) \quad \forall i \in \{1, \dots, m\} : \mathbb{I}_{\{h_i(\mathbf{x}) \leq 0\}}(x) = \begin{cases} \infty & h_i(\mathbf{x}) > 0 \\ 0 & h_i(\mathbf{x}) \leq 0 \end{cases}$$

נבחן כי עם פונ' אינקונטורים מאד לא נוח לעבור (לא רציפות, לא גזירות) וכך ולכן נרצה לחפש פונ' דומה מספיק ש諾ול לעובוד איתנו.

לכן נוכל לנסות לקרב את הפונ' הנ"ל על ידי סכום של  $\log$  barriers ננסה לחכotta את barrier האידאלי.

$$\min_{\mathbf{x}} f(\mathbf{x}) - \frac{1}{t} \sum_{i=1}^m \log(-h_i(\mathbf{x}))$$

כאשר  $t > 0$  הוא קבוע, מספר גדול מאוד.



- המקווקו זה ה barrier האידאלי (עם האינדיקטור)
- הקו הרציף מתאים ל $L^2$ -ים שאנו בוחרים.

הקירוב הזה הוא יותר מדויק ככל ש $t$  הוא מספר גדול יותר. אבל לכל ערך של  $t > 0$  אנו יודעים כי  $\log \text{barriers}$  כוונתני לאיולז.


- כאשר  $\infty \rightarrow t$  אז מקטינים את ההשפעה של האילוז ונותנים יותר משקל לפונ' המטרה (וככה מתקרבים יותר רלפונ' המטרה המקורית שלנו)
- כאשר  $0 \rightarrow t$  אזי מקטינים את ההשפעה של פונ' המטרה ונותנים יותר משקל לאילוז.

### Self-concordant 12.1.3

חירה קצחה לשיטות ניוטון נרצה להבין כיצד שיטות ניוטון מתמודדות עם המקרה של פונ' מהצורה של log barriers כלומר של  $f(\mathbf{x}) - \frac{1}{t} \sum_{i=1}^m \log(-h_i(\mathbf{x}))$

#### Self-concordance

##### shortcomings of classical convergence analysis

- depends on unknown constants ( $\mu, \theta, \dots$ ) 
- bound is not affinely invariant, although Newton's method is

##### convergence analysis via self-concordance (Nesterov and Nemirovski)

- does not depend on any unknown constants
- gives affine-invariant bound
- applies to special class of convex functions ('self-concordant' functions)
- developed to analyze polynomial-time interior-point methods for convex optimization

#### חרונות של ניתוח התכונות (= האנליה הקלאסית) של שיטת ניוטון

- תלויות בפרמטרים לא ידועים  $(\mu, B, \dots)$  :
  - $\mu$  - קמירות חזק.
  - $B$  - חלקות של הessian.
- חסומה
  - אם ניקח את הקורדינטות של הבעה המקורית ונעשה שניי קורדינטות קבועים ביחס  $(\mu, B, \dots)$  הולכים להשתנות.(משפיעים על קצב התכונות).זה לא ממש איטואנטי כי בכל זאת ראיינו שהשיטה היא affine invariant.
  - הפונ' הטבעיות נתוח עבורם את שיטת ניוטון יש להם תוכונה שנראית Self concordance.(נדבר עליה בהמשך)

#### ניתוח התכונות עבור פונ' שיש להם את תכונת self-concordance על ידי (Nesterov and nemirovski)

- לא תלויות באפ' פרמטרים לא ידועים.
- נותנת חסם שהוא affine invariant bound (חסם שאינו ניתן לשוני קורדינטות-לאחר שניי קורדינטות החסם לא ישתנה)
- רלוונטי רק למושפה של פונ' קמורות שמקיימות את תוכנות self-concordance

## תבונת Self-concordant

**הגדירה 4.12** (במקרה חד מימדי) פונ' קמורה  $f : \mathbb{R} \rightarrow \mathbb{R}$  תקרא Self-concordant אם  $|f'''(x)| \leq 2 \left[ (f''(x))^{\frac{3}{2}} \right]$

**דוגמה 5.12** דוגמאות ל蹶ה חד מימדי:

- פונ' לינאריות ופונ' ריבועית.(נגזרת שלישית מתאפסת) لكن מקיימות
- לוגריתם שלילי

$$f(x) = -\log(x) \Rightarrow \begin{aligned} f'(x) &= \frac{1}{x} \\ f''(x) &= \frac{-1}{x^2} \\ f'''(x) &= \frac{2}{x^3} \end{aligned} \Rightarrow \begin{aligned} |f'''(x)| &\leq 2 \left[ (f''(x))^{\frac{3}{2}} \right] \iff \\ \left| -\frac{2}{x^3} \right| &\leq 2 \left[ \left( \frac{1}{x^2} \right)^{\frac{3}{2}} \right] \iff \\ \left| \frac{2}{x^3} \right| &\leq 2 \left[ \left( \frac{1}{x^2} \right) \right] \text{ and that's correct} \end{aligned}$$

כלומר פונ' זו היא מקיימת Self-concordant

- אנטרופי שלילית ועוד לוגריתם שלילי:  $f(x) = x \log x - \log x$

**הגדירה 6.12** (במקרה הרב מימדי) פונ' קמורה  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  תקרא Self-concordant אם ( $\forall x \in \text{dom } f, v \in \mathbb{R}^n$ )  $g(t) = f(x + tv)$  Self-concordant

**הערה 7.12** המשמעות של  $g(t) = f(x + tv)$  היא להתבונן בחתך חד מימדי של  $f$  בכל כיוון. כלומר ההגדרה של Self-concordant אם הפונ' לאורך כל התיכים האפשריים (קיבלנו פונ' חד מימדי) היא(Self-concordant) הינה(Self-concordant) הוא(Self-concordant) ב蹶ה חד מימדי.

**הגדירה 8.12** פונ' קמורה  $f : \mathbb{R} \rightarrow \mathbb{R}$  שהיא Afifine invariantve Self-concordant כלומר לכל מופיע לנארו' המקרים  $\tilde{f}(y) = f(ay + b)$   $\forall a, b \in \mathbb{R}$ :

$$\begin{aligned} \tilde{f}'''(y) &= a^3 f'''(ay + b) \\ \tilde{f}''(y) &= a^2 f''(ay + b) \end{aligned}$$

## תבונת Self-concordant של פונ'

1. סגירות לחיבור.(סכום של שני פונ' Self-concordant מניב פונ' Self-concordant)
2. סגירות לכפל בסקלר  $\alpha \geq 1$ . (מכפלה של פונ' Self-concordant בסקלר  $\alpha \geq 1$  מניב פונ' Self-concordant)
3. סגירות להתרמה אפינית ועוד קבוע (זה לבדוק מה שראינו : התמונה Self-concordant הינה Self-concordant)
4. אם  $g$  פונ' חד מימדי קמורה עבור  $\text{dom } g = \mathbb{R}_{++}$  (התחום שלה הוא עבר ערכים חיוביים ממש כלומר  $|g'''(x)| \leq 2 \left[ (g''(x))^{\frac{3}{2}} \right]$  ) וגם

$$f(x) = \log(-g(x)) - \log(x)$$

היא Self-concordant

**דוגמאות נוספת לפונקציות Self-concordant** באמצעות התכונות הללו ניתן להוכיח שהפונ' הבאות מקיימות את תוכנת Self-concordant

.1

$$f(x) = - \sum_{i=1}^m \log(b_i - \mathbf{a}_i^T \mathbf{x}) \text{ on } \{x \mid \forall i \in \{1, \dots, m\} : \mathbf{a}_i^T \mathbf{x} < b_i\}$$

האלו הם למעשה barriers log barriers של אי שוויונות לינאריים.(=פוליטופ). זה barriers Self-concordant כי זה התרמה Self-concordant ( שראינו כבר שהוא(self-concordant) לינארית של הפונ'  $-\log(x)$  )

.2

$$f(x) = -\log(y^2 - \mathbf{x}^T \mathbf{x}) \text{ on } \{(\mathbf{x}, y) \mid \|\mathbf{x}\|_2 < y\}$$

זה מתייחס לאילוץ של כדור. נזכיר כי  $\|\mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|^2$ . הכתיבה של פונ' המטרה כהה  $\mathbf{x}^T \mathbf{x} - y^2$  היא על מנת להמחיש ש  $\mathbf{x}$  הוא וקטור) וכן עבור אילוץ של הדור barriers שמתאים לו הוא log barriers שנראית כהה).

.3

$$f(X) = -\log(\det(X)) \text{ on } \mathbb{S}_{++}^n$$

ישנים בעיות אופטימיזציה שימושתית החלטה שלנו הוא מט'  $X$ . אחד מהאילוצים הנפוצים הוא ש  $X$  היא מט'  $f(X) = -\log(\det(X))$  (כל הע"ע שלה גודלים שווים לאפס) log barriers שמתאים לה הוא (כל הע"ע). נזכיר כי אם יש לנו מט' שהוא PSD אז הדטרמיננטה שלה  $\det(X)$  שווה למכפלת כל הע"ע שלה. לכן נקבל מינוס סכוםלוג של כל הע"ע.

לא נבער שום הוכחות. הם מסובכים מדיזמן שנדרש לנו לקורס) והם מאוד דומים להוכחות שראינו בהוכחה של ניוטן.

**אנליזת התכונות עבור פונ' Self-concordant בשיטת ניוטון** כמו קודם ישנו 2 מצבים של התכונות. כאשר אנו קרובים לנקודת המינימום  $x^*$  וכאשר אנו רחוקים ממנו.

**סיכום:**

עבור פונ'  $f$  קמורה ו Self-concordant קיימים 2 קבועים  $\eta, \gamma > 0$  כך ש

- אם  $\eta \geq \gamma$  אז:

$$f(\mathbf{x}_{t+1}) - f(\mathbf{x}_t) \leq -\gamma$$

(מוד התכונות איטית). ככלומר השגיאה הולכת וקטנה לכל הפחות בערך קבוע  $\gamma$ .

• אם  $\eta \leq \gamma$  אז:

$$2(f(\mathbf{x}_{t+1}) - f(\mathbf{x}_t)) \leq (2(f(\mathbf{x}_t) - f(\mathbf{x}_t)))^2$$

(מוד התכונות סופר אקפוננציאלית). ככלומר השגיאה באיטרציה הבאה הוא קטן מריבוע השגיאה הנוכחית.

**חסם על הסיבוכיות Complexity bound** אם מתרגמים את התוצאות הנ"ל לשפת אפסילון אז: כדי לקבל פתרון  $\epsilon$  אופטימי נוצר

$$\frac{f(\mathbf{x}^{(0)}) - p^*}{\gamma} + \log_2 \log_2 \left( \frac{1}{\epsilon} \right)$$

צעדים.

#### 12.1.4 שיטה barrier - השיטה עצמה

. Self-concordant כי אנו מניחים כי לכל  $i \in \{1, \dots, m\}$  גזירה שלוש פעמים. ובנוסף כי  $\phi$  היא עבור ה log barrier function

$$\phi(x) = -\sum_{i=1}^m \log(-h_i(x))$$

יש לנו את הגרדיינט שלו:

$$\nabla \phi(x) = -\sum_{i=1}^m \frac{1}{h_i(x)} \nabla h_i(x)$$

ואת ההסיאן שלו:

$$\nabla^2 \phi(x) = -\sum_{i=1}^m \frac{1}{(h_i(x))^2} (\nabla h_i(x)) (\nabla h_i(x))^T - \sum_{i=1}^m \frac{1}{h_i(x)} \nabla^2 h_i(x)$$

$$\begin{array}{ll} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{s.t.} & A\mathbf{x} = \mathbf{b} \\ & h_i(\mathbf{x}) \leq 0, \forall i \in \{1, \dots, m\} \end{array}$$

נתבונן בבעיה הבאה:

$$\begin{array}{ll} \min_{\mathbf{x}} & tf(\mathbf{x}) + \phi(\mathbf{x}) \\ \text{s.t.} & A\mathbf{x} = \mathbf{b} \end{array}$$

- שיטת Central Path מוגדרת על ידי הפתרון  $(t)^*$  עבור  $0 < t < \infty$  קוראים  $\mathbf{x}^*(t)$  הנקרא central path הראשי/המרכזי
- בעצם לנקנו את אילוצי האי שווין והחלפנו אותם בbarrier function. והבעז הוא לא הבעיה המקורית, אבל היא שואפת בעיה המקורית כאשר  $t \rightarrow \infty$ . כלומר אנו נקבע  $t$  ולכל  $t$  כזה נמצא את הפתרון של הבעיה זו (שותפה ב- $t$ ) את הפתרון הזה נסמן  $(t)^*$  (הפתרון האופטימלי עבור  $t$  מסוים) והתקווה שלנו הוא שכאשר  $t \rightarrow \infty$  הפתרון האופטימלי עבור הבעיה המקורית ( $=$ הפתרון שאנו מחפשים) ככלומר ישאף לפתרון האופטימלי עבור הבעיה הבאה:

$$\text{as } t \rightarrow \infty \text{ we will have } \mathbf{x}^*(t) \xrightarrow{t \rightarrow \infty} \mathbf{x}^*$$

- למה שלא נבחר מראש פשוט  $t$  עם ערך מאוד גדול ונפתח את הבעיה מעלה? מסתבר שזה רעיון לא טוב (מואוד לא "יעיל בפועל"), ושהרעיון הטוב והנכון הוא להתחיל ב- $t$  קטן ולהתחליל להגדיל אותו מעד לעד traverse the central path כמו שנראה בהמשך.
- לכל  $0 < t < \infty$  פותרים את הבעיה  $\min_{\mathbf{x}} tf(\mathbf{x}) + \phi(\mathbf{x})$  s.t.  $A\mathbf{x} = \mathbf{b}$  שמתאימות לכל  $t$ .
- ככל שמנידלים את  $t$  השיטה נסעת על הנקיב המרכזי (אוסף הפתרונות שמתאימים לכל  $t$ ) עד שכאשר  $t \rightarrow \infty$  הנקיב שואף ל $\mathbf{x}^*$ .

#### אופן הפתרון :Master plan

- רוצחים לפתרור את

$$\begin{array}{ll} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{s.t.} & A\mathbf{x} = \mathbf{b} \\ & h_i(\mathbf{x}) \leq 0, \forall i \in \{1, \dots, m\} \end{array}$$

- נתשמש בInterior point method (IPM) approach

—начילה עם  $t^{(0)} > 0$

—נפתרן את הבעיה הבאה באמצעות שיטת ניוטון

$$\begin{array}{ll} \min_{\mathbf{x}} & tf(\mathbf{x}) + \phi(\mathbf{x}) \\ \text{s.t.} & A\mathbf{x} = \mathbf{b} \end{array}$$

ונסמן את הפתרון של הבעיה  $(t)^*$

- נגדיל את  $t$  ונפתרן  $(t - 1)^*$ . הפתרון שבו מצאנו באיטרציה הקודמת יהיה נקודת ההתחלה של הפתרון של האיטרציה הנוכחית.

איך בוחרים כמה להגדיל את  $t$ ?

$$\mathbf{x}^*(t_1) \xrightarrow{\text{choose } t_2:} \|\mathbf{x}^*(t_1) - \mathbf{x}^*(t_2)\| \text{ is small}$$

כמה קטן? קטן בוגדול שבו מוד ההתקנסות של שיטת ניוטון תהיה עדין בקצב סופר אקספוננציאלי.(זה הרעיון)  
בכל פעם ניקח  $t$  מסוים וنمצא את  $(t)^*$  אז נגידיר את  $t$  ככה שהפתרון באיטרציה הקודמת הוא פתרון שמספריק קרוב לפתרון  
באיטרציה החדשה (שאנו לא יודעים מה הוא אבל אנו כן יכולים לוודא שהוא מספיק קרוב לפתרון של האיטרציה הנוכחית) ככה  
שאנו מפעילים את שיטת ניוטון החל מ  $(t)^*$  (הפתרון באיטרציה הוקדמת) אז ההתקנסות באיטרציה הנוכחית של שיטת ניוטון  
תהייה סופר אקספוננציאלית ל  $(t_{\text{new}})^*$  (הפתרון של שיטת ניוטון של האיטרציה הנוכחית).

- התאוריה אומרת לנו איך כמה להגדיל את  $t$  ככה שנשאר במצב של ההתקנסות הסופר אקספוננציאלית.

**מקרה של בעיית LP** מקרה חשוב: שיטת barrier עבורי בעיית תכונות לינארית LP.  
הבעיה המקורי:

$$\begin{aligned} \min_{\mathbf{x}} & \quad \mathbf{c}^T \mathbf{x} \\ & D\mathbf{x} \leq e \end{aligned}$$

רוצים למשער בעיה תחת אילוצים לינאריים. (פוליטופ)  
הבעיה כפי שפורטים על ידי barrier


$$\min_{\mathbf{x}} \quad t\mathbf{c}^T \mathbf{x} - \sum_{i=1}^m \log(e_i - \mathbf{d}_i^T \mathbf{x})$$

(נבחן כי)


$$\min_{\mathbf{x}} \overbrace{t\mathbf{c}^T \mathbf{x} + \phi(\mathbf{x})}^{m \log(e_i - \mathbf{d}_i^T \mathbf{x})}$$

מתאים למעשה לאילוצים שלנו בעיה (פוליטופ). הולך ומ�파ץ ככל שמתקדמיים לנצח.

## Central path:



פונ' מטריה לינארית  $\leftarrow$  המינימום נמצא בקצוות התוחום.  
הולך לאורך המסלול הבא (כasher אנחנו הולכים ומגדילים את  $t$ ).



צודים לעבר  $x^*$  לאורך central path  
בגלו שהבעיה מתפרקת בקצוות התוחום המינימום שלו נמצא בתחום. ולכן המינימום מתקבל כאשר גודיאנט פון' המטריה שווה לאפס כלומר כאשר

$$0 = \nabla(t\mathbf{c}^T \mathbf{x} + \phi(\mathbf{x})) = t\mathbf{c} - \sum_{i=1}^m \frac{1}{e_i - \mathbf{d}_i^T \mathbf{x}^*(t)} \mathbf{d}_i$$

כלומר המשמעות היא שהגדריאנט  $(\mathbf{x}^*(t)) \nabla \phi$  חייב להיות **מקביל** ל- $c$ .  
(כלומר העל מישור  $\{x \mid \mathbf{c}^T x = \mathbf{c}^T \mathbf{x}^*(t)\}$  משיק לקונטור (קונטור = קווי הגובה) של  $\phi$  בנקודה  $(\mathbf{x}^*(t))$ .

**נוסף בחזרה את אילוצי השוויון לבועה** נזכיר כי הבעיה המקורית היא.

•

$$\begin{aligned} \min_{\mathbf{x}} & f(\mathbf{x}) \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b} \\ & h_i(\mathbf{x}) \leq 0, \forall i \in \{1, \dots, m\} \end{aligned}$$

לאחר שימוש ב**barrier** נקבעה הבעה הבאה:

$$\begin{aligned} \min_{\mathbf{x}} \quad & t \mathbf{c}^T \mathbf{x} - \sum_{i=1}^m \log(e_i - \mathbf{d}_i^T \mathbf{x}) \\ & A \mathbf{x} = \mathbf{b} \end{aligned}$$

נסמן את  $\mathbf{w}$  בתור כופלי הלגראנג' שמתאים לאילוצי השווון. אז הלגראנג'יאן נתון על ידי:

$$L(\mathbf{x}, \mathbf{w}) = tf(\mathbf{x}) - \sum_{i=1}^m \log(-h_i(\mathbf{x})) + \mathbf{w}^T(A\mathbf{x} - \mathbf{b})$$

ופטרוں הבעה נתון על ידי \*

$$\overbrace{\mathbf{x}_t^*}^{\equiv \mathbf{x}^*(t)} = \arg \min_{A\mathbf{x}=\mathbf{b}} \left\{ tf(\mathbf{x}) - \sum_{i=1}^m \log(-h_i(\mathbf{x})) \right\}$$

**תנאי KKT ודו-אליות** נניח שקיים מוקודה שמקיימת את תנאי KKT (ולכן היא גם פיאבלית) אז ה  $\mathbf{x}^*$  מואפיינת על ידי תנאי KKT. המוקודה האופטימלית מקיימת את התנאים הבאים (תנאי KKT central path):

$$t \nabla f(\mathbf{x}^*(t)) - \sum_{i=1}^m \frac{1}{h_i(\mathbf{x}^*(t))} \nabla h_i(\mathbf{x}^*(t)) + A^t \mathbf{w} = 0$$

(לגראנג'יאן מתאפס-סטציונריות)

$$A\mathbf{x}^*(t) = \mathbf{b} \quad , h_i(\mathbf{x}^*(t)) < 0 \quad , i = 1, 2, \dots, m$$

**הערה 9.12** נבחן כי אין שימוש בתנאי Complementary slackness (barirer) כי כאן אילוצי האי שווין יתקיימו ממש כי לאחרת הזרה צפוצץ. כלומר מכיוון שיש לנו את ה  $\mathbf{x}^*$  ניתן להיות בתוחם כי אילוצי האי שווין יהיו קטנים ממש (יתקיימו ממש) (פיאבליות וקיים אילוצי האי שווין).

עבור  $\mathbf{w} \in \mathbb{R}^m$  (אבל אנו לאמתעננים באמצעות עבור המשתנים של בהבעה הדואליות של בעיית ה- $\mathbf{x}^*$  KKT אפשר למצאו פתרונות דואליים לבעה המקורית. בהנתן  $(t)^*$   $\mathbf{x}$  ו- $\mathbf{w}$  המתאים. נגידר Centreal path pointss

$$\mathbf{u}_i^*(t) = -\frac{1}{th_i(\mathbf{x}^*(t))} \quad , i = 1, \dots, m \quad , \mathbf{v}^*(t) = \frac{\mathbf{w}}{t}$$

למה נגידר את זה? כי ניקח את המשווה של הסטציונריות מתנאי KKT :

$$t \nabla f(\mathbf{x}^*(t)) - \sum_{i=1}^m \frac{1}{h_i(\mathbf{x}^*(t))} \nabla h_i(\mathbf{x}^*(t)) + A^t \mathbf{w} = 0$$

ונציב שם את זה? כי ניקח את המשווה של הסטציונריות מתנאי KKT ונקבל

$$L(\mathbf{x}, \mathbf{u}, \mathbf{v}) = f(\mathbf{x}) + \sum_{i=1}^m \mathbf{u}_i h_i(\mathbf{x}) + \mathbf{v}^T(A\mathbf{x} - \mathbf{b})$$

נטען כי  $(t)^*, \mathbf{u}^*(t), \mathbf{v}^*(t)$  הם נקודות דואליות ופיאבליות לבעה המקורית. למה?

- $\bullet$  מכיוון ש  $h_i^*(t) < 0 \forall i \in \{1, \dots, m\}$  לכל  $t > 0$  (כי האילוצי אי השוויון החלש מתקיימים באית שוויון חריף בغال הנקודה (barrier) אחרת הפונ' תתפוץץ)).  
בנוסף לכל הנקודה  $(\mathbf{x}^*(t), \mathbf{u}^*(t), \mathbf{v}^*(t))$  נמצאת בתחום של בעיית גראנג' הדואלית מכיוון שלפי הגדרה

$$[\nabla_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}^*(t), \mathbf{v}^*(t))]_{\mathbf{x}=\mathbf{x}^*(t)} = 0$$

$$\nabla f(\mathbf{x}^*(t)) + \sum_{i=1}^m u_i(\mathbf{x}^*(t)) \nabla h_i(\mathbf{x}^*(t)) + A^T \mathbf{v}^*(t) = 0$$

כך ש  $\mathbf{x}^*$  מזעיר את הלגראנגיאן  $L(\mathbf{x}, \mathbf{u}^*(t), \mathbf{v}^*(t))$  (כלומר) מעל  $L(\mathbf{x}, \mathbf{u}^*(t), \mathbf{v}^*(t))$ . נזכיר  $g(\mathbf{u}, \mathbf{v}) = \min_{\mathbf{x}} L(\mathbf{x}, \mathbf{u}, \mathbf{v})$

**פער הדואליות Duality gap** זה מאפשר לנו לחסום את הסאב אופטימליות של  $f(\mathbf{x}^*(t))$  לפי הבעה מקורית דרך **פער הדואליות** נחישב:

$$f^* \geq g(\mathbf{u}^*(t), \mathbf{v}^*(t)) = f(\mathbf{x}^*(t)) + \left[ \sum_{i=1}^m \underbrace{\mathbf{u}_i^*(t)}_{-\frac{1}{th_i(\mathbf{x}^*(t))}} h_i(\mathbf{x}^*(t)) \right] + \underbrace{\mathbf{v}^*(t)^T (A\mathbf{x}^*(t) - \mathbf{b})}_{\mathbf{x}^*(t) \text{ feasible : } A\mathbf{x}^*(t) = \mathbf{b}} = f(\mathbf{x}^*(t)) - \frac{m}{t}$$

ואז מכאן נסיק כי:

$$f(\mathbf{x}^*(t)) - f^* \leq \frac{m}{t}$$

(זה הדבר היפה barriers) זה הולך להיות אי שוויון מאד ימושי בתורת תנאי עצירה. הוא גם מאשר את התקווה שלנו כי

$$\mathbf{x}^*(t) \xrightarrow{t \rightarrow \infty} \mathbf{x}^*$$

כומר ככל שגדילים את  $t$  הפתרון הולך וושא לפתרון של הבעה המקורית.

## Perturbed KKT conditions

We can now reinterpret central path  $(x^*(t), u^*(t), v^*(t))$  as solving the perturbed KKT conditions:

$$\begin{aligned}\nabla f(x) + \sum_{i=1}^m u_i \nabla h_i(x) + A^T v &= 0 \\ u_i \cdot h_i(x) &= -1/t, \quad i = 1, \dots, m \\ h_i(x) &\leq 0, \quad i = 1, \dots, m, \quad Ax = b \\ u_i &\geq 0, \quad i = 1, \dots, m\end{aligned}$$

Only difference between these and actual KKT conditions for our original problem is second line: these are replaced by

$$u_i \cdot h_i(x) = 0, \quad i = 1, \dots, m$$

i.e., **complementary slackness**, in actual KKT conditions

אפשר לחשב על  $x^*(t)$  בתור פתרון שמקיים בקירוב את תנאי KKT. (מקיימים אותם עד כדי הנטה KKT). אפשר לחשב עליהם בתור כללי שמקיימים גרסה מוקרבת של תנאי KKT. ככל שגדל כהה הם "ילכו" היו פתרון שעונה על KKT בצורה יותר מדויקת (הנטה יתקרב לאפס)

## Barrier method

The **barrier method** solves a sequence of problems

$$\begin{aligned} \min_x \quad & tf(x) + \phi(x) \\ \text{subject to} \quad & Ax = b \end{aligned}$$

for increasing values of  $t > 0$ , until duality gap satisfies  $m/t \leq \epsilon$ . We fix  $t^{(0)} > 0$ ,  $\mu > 1$ . We use Newton to compute  $x^{(0)} = x^*(t)$ , solution to barrier problem at  $t = t^{(0)}$ . For  $k = 1, 2, 3, \dots$

- Solve the barrier problem at  $t = t^{(k)}$ , using Newton initialized at  $x^{(k-1)}$ , to yield  $x^{(k)} = x^*(t)$
- Stop if  $m/t \leq \epsilon$ , else update  $t^{(k+1)} = \mu t$

The first step above is called a centering step (since it brings  $x^{(k)}$  onto the central path)

המטרה barrier

Considerations:

- **Choice of  $\mu$ :** if  $\mu$  is too small, then many outer iterations might be needed; if  $\mu$  is too big, then Newton's method (each centering step) might take many iterations
- **Choice of  $t^{(0)}$ :** if  $t^{(0)}$  is too small, then many outer iterations might be needed; if  $t^{(0)}$  is too big, then the first Newton solve (first centering step) might require many iterations

Fortunately, the performance of the barrier method is often quite robust to the choice of  $\mu$  and  $t^{(0)}$  in practice

(However, note that the appropriate range for these parameters is scale dependent)

## 1 שיטת המחסום לאופטימיזציה עם אילוצי אידשווין

נתבונן בבעית האופטימיזציה

$$(P) \quad \begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) \\ & \text{s.t. } g_i(\mathbf{x}) \leq 0, i = 1, \dots, m, \\ & A\mathbf{x} = \mathbf{b} \end{aligned}$$

כאשר הפונקציות  $\mathbb{R}^n \rightarrow \mathbb{R}^n$  :  $f, g_1, \dots, g_m$  קשורות ונזרות פעמיים ברכיפות, המטריצה  $A \in \mathbb{R}^{p \times n}$  מדרגה  $p$  (וכן  $n < m$ ). נניח כי הבעה מקיימת תנאי Slater. כלומר, קיימת נקודה פיזיבילית המקיים את כל אילוצי אידשווין בחריפות. כמו כן, נניח כי הבעה פתירה. בפרט, קיים פתרון אופטימלי \*  $\mathbf{x}$  וניתן להתקרב אליו כרצונו מתוך הפנים היחסי (relint) של התחום הפיזיבילי (למשל, אם התחום הפיזיבילי חסום).

נתבונן במשפחה של אלגוריתמי אופטימיזציה שנקראים אלגוריתמי שיטות פנים (interior-point methods). אלגוריתמים אלה מוחפשים את נקודת המינימום מבפנים. קרי, כל איטרציה שלהם מייצרת נחש חדש לנקודת המינימום המקיים את האילוצים. האלגוריתמים האלה פותרים בכל איטרציה בעית אופטימיזציה עם אילוצי שווין. הפתרון של כל בעיה צו מותקרב לפתרון של הבעיה המקורית. בשיטה זו, מחליפים את אילוצי אידשווין בתוספת של פונקציית מחסום לפונקציית המטרה.

פונקציית מחסום (barrier) ( $\mathbf{x}$ ) היא פונקציה קמורה וऐ-שלילית שמקבלת את הערך  $\infty$  כאשר מתקרבים לשפה של תחום האילוץ. (כאן רלוונטיים רק אילוצי אידשווין, כי אין מינימום שאילוצי השווין תמיד מתקיימים). דוגמאות:

$$\begin{aligned} B(\mathbf{x}) &= -\sum_{i=1}^m \frac{1}{g_i(\mathbf{x})} \\ B(\mathbf{x}) &= -\sum_{i=1}^m \ln(-g_i(\mathbf{x})) \end{aligned}$$

ואז נחליף את בעית האופטימיזציה בבעית

$$(P_t) \quad \begin{aligned} & \min_{\mathbf{x}} f(\mathbf{x}) + \frac{1}{t} B(\mathbf{x}) \\ & \text{s.t. } A\mathbf{x} = \mathbf{b} \end{aligned}$$

הבעיה החדשה תליה בפרמטר  $t > 0$ , אך היא נשארת קמורה בתחום האילוץ (מדובר?) לדוגמה, אם האילוצים הם  $x \geq 2, 1 \geq x$  קיבל פונקציות מחסום המופיעות באIOR להלן. כאשר מגדילים את  $t$ , פונקציית המחסום מקרבת את האילוצים טוב יותר. נדגים זאת באIOR עבור  $(x - 2) - 1/(1 - x)$ .  $B(x) = -1/(x - 2) - 1/(1 - x)$ , ואז גודיל את לפיכך, בכל איטרציה של האלגוריתם נפתר או את הבעיה  $(P_t)$  לקבלת נקודה חדשה  $(\mathbf{x}_t)$ , ואז גודיל את  $t$ . כאשר  $t \rightarrow \infty$ , פתרון הבעיה  $(P_t)$  מקרב היטב את פתרון הבעיה המאולצת  $(P)$ . כלומר, נגידר סדרה  $\mathbf{x}_{t_k}, \mathbf{x}_{t_{k-1}}, \dots, \mathbf{x}_{t_1}, \mathbf{x}_{t_0}$ , ובאי-טרציה  $t_k < t_{k-1} < \dots < t_1 < t_0$ , נפתר או את בעית האופטימיזציה  $(P_{t_k})$ . סדרת הנקודות נקראת "מסלול המרכזי". הוא, כאמור, מותכנס לעבר הפתרון האופטימלי של הבעיה.

## 13 הרצתה ותרגול 13

תבורת המשיעור הקודם:

היום בהרצאה נסימן את הדין על שיטות barrier ונתן הרצאת העשרה על הקשר של חומר הקורס ל-machine learning (העשרה - لكن לא סיכומי  $\odot$ ). נזכר כי שיטת barrier מתחממת עם בעית אופטימיזציה עם אילוצים.

$$\begin{aligned} & \min f(x) \\ \forall i \in \{1, \dots, m\} : & h_i(x) \leq 0 \\ Ax = b & \end{aligned}$$

רוצחים ל缀ער פונ' מטרה  $f$  תחת אילוצי אי שווין 0  $\forall i \in \{1, \dots, m\} : h_i(x) \leq 0$ . הינו רוצחים להשתמש בשיטת ניוטון לפתרון של הבעיה הללו. הבעיה היא שיטת ניוטון ידעת רק להתמודד עם אילוצי שווין. וכן אוסף הפתרון (הרעין של שיטת barrier) הוא רקחת את אילוצי האיש שווין ולשלב אותם בתוך פונ' המטרה, בתוך  $(x)$  שמודרת להיות  $\phi$  ( $\phi = -\sum_{i=1}^m \log(-h_i(x))$ ) והוא בעצם הכלומר  $(x)$  מהריה זה הפונ' של barrier. ההגנון מהריה עם האילוצים, שיכולה להכתב באופן הבא עם פונ' אידיקטור:

$$\min_x f(x) + \sum_{i=1}^m \mathbb{I}_{\{h_i(x) \leq 0\}}(x) \quad \forall i \in \{1, \dots, m\} : \mathbb{I}_{\{h_i(x) \leq 0\}}(x) = \begin{cases} \infty & h_i(x) > 0 \\ 0 & h_i(x) \leq 0 \end{cases}$$

נבחן כי עם פונ' אינקטוריים מאוד לא נוח לעבור (לא רציפות, לא גירות).

כלומר לאחר ההמרה נקבל בעית אופטימיזציה קמורה מהצורה:

$$\begin{aligned} \min_x & tf(x) + \phi(x) \\ \text{s.t.} & Ax = b \end{aligned}$$

כאשר  $0 < t$  הוא קבוע, מספר גדול מאוד.

בכל אירציה נגדיל את המשקל של פונ' המטרה  $(x)$   $f$  לעומת barrier  $(x)$   $\phi$  כלומר בכל אירציה אנו מגדילים את  $t$ . אנו מסמנים את הפתרון של הבעיה עבור  $t$  מסוים להיות  $(t)^*$ . ככל שנגדיל את  $t$  נראה ש  $x^* \xrightarrow{t \rightarrow \infty} (t)^*$ . (בכל פעם נגדיל את  $t$  בפקטור קבוע  $\mu$  בכל פעם שיטת ניוטון התקבל קלט ראשוני את הנזודה האופטימלית מהסיבוב הקודם). אום קבועים את  $t$  ומואפנו נכון באתומים מהסיבובים הקודמים ההתכנסות תהיה בקצב ספר אקספוננציאלי. אחרת אם לא הגענו לשלב הזה נאלץ לחכות כיוון שההתכנסות איטית עד שמניגעים לשלב זהה).

כברנוסף אנו יודעים כי  $\frac{m}{t} - f^*(t) \leq \frac{m}{t}$  ככלمر ערך התת אופטימליות של הפתרון הולכת כמו  $\frac{m}{t}$ . השגיאה הולכת כמו  $\frac{m}{t}$ . וכך אם נרצה פתרון  $\epsilon$  תת אופטימי נרים את האלג' עד אשר  $\epsilon \leq \frac{m}{t}$ . אז מהו צריך לשחק אם  $t$ ?

- אם נתחיל ב- $t$  מודד גדול מראש (=משקל גדול לפונ' המטרה) אז הרבה מהזמן נבלה בשיטת ניוטון במוד ההתכנסות האיטי.
- כשמגדלים את  $t$  בזרה הדרגתית אנו בעצם מבטיחים שרוב הזמן שהאלג' יבוצע בשיטת ניוטון יבוצע במוד ההתכנסות הסופר אקספוננציאלי.

אנליזה מלאה של שיטת barrier היא מורכבת יחסית ולכן לא נספק לעשות אותה בקורס הנ"ל כיון שאין לנו מספיק זמן לביצוע אנליזה זו.

**בחירה הפרמטרים  $\mu, t^{(0)}$ :**  
לעתים כמשמעותם ב-solver מוקן (לדוגמא חבילת קוד חיצונית) היא יכולה לבחור באופן אוטומטי את  $\mu$ . חשוב להבין את המשמעות שלבחירה הפרמטרים. על מה כל אחד משפיע):  
שיקולים בבחירה הפרמטרים:

$\mu$  הוא הפרמטר שדרכו מגדלים את  $t$ . כלומר בכל אירציה  $\mu \leftarrow t_{\text{old}}$ .  
נזכיר כי השגיאה הולכת כמו  $\frac{m}{t}$ . ככל  $t$  גדול משמעתו שגיאה נמוכה יותר.  
ולכן אם  $\mu$  גדול או  $t$  יגדל מסיבוב לסיבוב בגודל גדול יותר.

• **שיקולים בבחירה  $\mu$ :**

1. אם  $\mu$  מאד קטן אז נבלה יותר זמן בלולאה החיצונית זמן ארוך יותר (נפעיל יותר פעמים את שיטת ניוטון אבל כל שיטת ניוטון תתכנס מהר יותר).

כלומר  $\mu$  קטן מדי  $\rightarrow$  ייקח יותר זמן (יותר הפעולות של שיטת ניוטון) עד שנגיע לא' שיאנייב שגיאה נמוכה יותר.

2. אם  $\mu$  מאד גדול אז נבלה יותר זמן בלולאה הפנימית זמן ארוך יותר (נפעיל פחות פעמים את שיטת ניוטון אבל כל שיטת ניוטון תתכנס לאות יouter = עלולים לצאת מהמוד של התכונות סופר אקפוננציאלית).

$\mu$  גדול מדי  $\rightarrow$  הפער בין  $t_{\text{new}}, t_{\text{old}}$  גדול מאוד ויכול להיות שהפתרון של הסיבוב הקודם והפתרון של הסיבוב הנוכחי רוחקים מדי וההנחה שהם קרובים מספיק ככה שההתכונות תהיה סופר אקפוננציאלית, תשבר. אז מה שאומרים שיטת ניוטון בסיבוב זהה תצטרך יותר איטרציות על מנת להתכנס לסיבוב הנוכחי (כי יתכן שכבר לא תתרחש התכנסות סופר אקפוננציאלית).

• **שיקולים בבחירה  $t^{(0)}$ :**

שיקולים מאוד דומים. אפשר לבטא את  $t_{\text{new}}^{(T)}$  כЛОMER  $t$  (נסמן  $t$  באירטציה ה- $T$ ) על ידי הקשר הבא:  

$$t^{(T)} = t^{(T-1)}\mu = t_{\text{new}}^{(T)}$$

$$t^{(T)} = t^{(0)}\mu^T$$


1. אם  $t^{(0)}$  מאד קטן אז ייקח יותר איטרציות חיצונית להגיע לא' מספיק טוב שיאנייב שגיאה נמוכה יותר. (בדוק כמו השיקול של בחירת  $\mu$  קטן מדי)

2. אם  $t^{(0)}$  גדול מדי אנו עלולים להיות במצב שבאייטרציה הראשונה לשיטת ניוטון ייקח המון זמן להתכנס לפתרון הטוב.

אלו tradeoffs בבחירה  $\mu, t^{(0)}$ . למשלנו שבפועל שיטת barrier לא כל כך רגילה לבחירת הפרמטרים  $\mu$ .  
(אם זאת חשוב לנו שהבחירה של הפרמטרים הלו תלויה מושפעת מסדר גודל).

**דוגמא מהספר של Boyd להשפעה של בחירת  $\mu$ :**

Example of a small LP in  $n = 50$  dimensions,  $m = 100$  inequality constraints (from B & V page 571):



נבחן כי היביצועים עבור  $\mu = 50$  ו  $\mu = 2$  מוגבלים הבדל של פ' 2 וקצת בערך בקצב התוכנות למורות שההפרש בין הע'ים הוא

25. ככלומר הפרש גדול בין הע' לא מניב הפרש גדול במילוי ביביצועים.

מכאן שהשיטה עמידה יחסית לבחירת הפרמטרים  $\mu$ . לא משפיעה בהרבה. ככלומר שיטת barrier די' חסינה לבחירת  $\mu$ .

**ניתוח התוכנות של שיטת barrier** נציג שלא נבעצ' את הנитוח המלא כאן אלא נסתפק בניתוח חלקי בלבד. באופןיה שלנו נתיחס רק לאייטרציות החיצונית (כמויות הפעולה של שיטת ניוטון) ולא לאייטרציות הפנימית (=כמהת אייטרציות בתוך כל הפעלה של שיטת ניוטון). נמצא את מספר האיטרציות החיצונית שאנו זוקקים להפעיל על מנת לגעת לפתרון מסוימים.

נניח שאנו יודעים לפתור את steps centering של שיטת ניוטון באמצעות ניוטון בכל אייטרציה מניב בדיקת הפתרון האופטמלי בכל הפעלה שלו) אז התוצאה הבאה היא מיידית:

**משפט 1.13** שיטת barrier לאחר  $k$  centering steps  $f(x^{(k)}) - f^* \leq \frac{m}{\mu^k t^{(0)}}$  מניבה את התוצאה הבאה:

$$f(x^{(k)}) - f^* \leq \frac{m}{\mu^k t^{(0)}}$$

במילים אחרות, על מנת לגעת לפתרון  $\epsilon$  תת אופטמלי נדרש להפעיל

$$\frac{\log \left( \frac{m}{(\bar{t}^0 \epsilon)} \right)}{\log (\mu)}$$

centering steps (אייטרציות חיצונית = קריאות לפתרון על ידי שיטת ניוטון) במהלך השימוש בשיטת barrier. (וועוד ההגדרה של step הראשוני)


הוכחה:

- ראיינו כי לאחר  $t$  לאחר  $k$  centering steps היא  $.t^{(k)} = t^{(0)}\mu^k$
- ראיינו כי  $\frac{m}{t} \leq f(\mathbf{x}^*(t)) - f^*$  כלומר ערך התת אופטימלית של הפתרון הולכת כמו  $\cdot \frac{m}{t}$ .
- לכן משלוב שני העבודות נקבל כי  $f(\mathbf{x}^*(t^{(k)})) - f^* \leq \frac{m}{t^{(0)}\mu^k}$  כלומר נקבע כי הערך של התת אופטימלית הולך כמו  $\cdot f(\mathbf{x}^*(t^{(k)})) - f^* \leq \frac{m}{t^{(0)}\mu^k}$
- נרצה למצוא את  $k$  (מספר steps) הדורש לפתרון  $\epsilon$  תת אופטימי כלומר נבודד את  $k$  מתוך המשוואה  $\epsilon \leq \frac{m}{t^{(0)}\mu^k}$

$$\begin{aligned} & \frac{m}{t^{(0)}\mu^k} \leq \epsilon \\ \iff & \frac{m}{\epsilon} \leq t^{(0)}\mu^k \\ \iff & \frac{m}{t^{(0)}\epsilon} \leq \mu^k \\ \iff & \log\left(\frac{m}{t^{(0)}\epsilon}\right) \leq \log(\mu^k) \\ \iff & \log\left(\frac{m}{t^{(0)}\epsilon}\right) \leq k \log(\mu) \\ \iff & \frac{\log\left(\frac{m}{t^{(0)}\epsilon}\right)}{\log(\mu)} \leq k \end{aligned}$$

כלומר  $k \leq \frac{\log\left(\frac{m}{t^{(0)}\epsilon}\right)}{\log(\mu)}$ . נבחן כי הדרישה לפתרון  $\epsilon$  תת אופטימי היא הוגרתמי ב- $\frac{1}{\epsilon}$ . ובנוסף היא לוגריתמית בדמיות האילוצים  $m$  (= לא מושפעת מאוד מכדיות האילוצים). ניתן לראות זאת בגרף הבא (השפעה של  $m$  על כמיות האיטרציות החיציות לצורך התכנסות).

Example of barrier method progress for an LP with  $m$  constraints  
(from B & V page 575):  $\eta = 2m$



Can see roughly linear convergence in each case, and logarithmic scaling with  $m$

עלות חישובית בפועל של שיטת barrier (כמו איטרציות ניוטון) נציג במבט מלמעלה את כמות האירציות הפנימית (כמות האירציות של איטרציות ניוטון) במהלך הפעלת האלגוריתם, או אנליזה חלקית.  
אם הפרמטרים  $\mu$  ו- $t^{(0)}$  נבחרים בצורה נכונה אז סך כל האירציות של ניוטון איזי **כמota האירציות הכלולות של ניוטון** היא עדין  $\mathcal{O}(\log(\frac{m}{\epsilon}))$ .  
המסקנה היא שסך כל העלות החישובית של barrier הוא לוגרמי ב- $m$  ולוגרמיים ב- $\frac{1}{\epsilon}$ . בפועל זו נחשבת עלות חישובית יחסית נמוכה.

עוד בותרת על barrier אחד מהקלטיות לשיטת barrier הוא  $x_0$  שהוא פיזבלי (=מקיים את האילוצים) (בין הית על מנת ש( $x_0$ )  $\phi$  תהיה מוגדרת היטב). בבעיות בחד מימד לעיתים קל לנחש  $x_0$  פיזבלי זהה. בעיות רב ממדיות מציאה של  $x_0$  פיזבלי הופכת להיות משימה לא טרוואלית.

איך עליינו למציא  $x$  פיזבלי כזה?

עלינו לפתור בעיית פיסבליות. נזכיר כי במקור אנו רוצים למציא נקודה  $x$  עבורה  $0 \leq h_i(x) \leq s \quad \forall i \in \{1, \dots, m\}$  ובנוסף  $Ax = b$  וזו בעצם תהייה נקודה פיזבליות .  
איך פתרים בעית פיסבליות? עלינו להוסיף עוד משתנה לבעה, נקרא לו  $s$ . נשכח לרגע מפונ' המטרה ונתמקד רק במצבה נקודה פיזבליות (=נקודה שמקיימת את האילוצים) .  
כלומר, על ידי פתרון של המשוואה:

$$(F) : \begin{array}{ll} \min_{x,s} & s \\ \text{subject to} & h_i(x) \leq s, i = 1, \dots, m \\ & Ax = b \end{array}$$

בעצם אנו מבצעים "ריכוך" של הדרישה של האילוץ המקורי  $0 \leq h_i(\mathbf{x}) \forall i \in \{1, \dots, m\}$  על ידי הוספת המשתנה  $s$ .  
איך פותרים את בעיית הפיסබליות הנ"ל ? משתמשים בשיטת barrier.

- אבל רגע, לא נוצר פה טיעון מעגלי (ביצה ותרגונגולת) ? לא.

כי פתרון של בעיית הפיסබליות על ידי barrier הוא נחسب קל.  
**איך מוצאים נקודת התחלית  $s_0$  לפתרון בעיית הפיסබליות ( $F$ )?**

- ניקח  $\mathbf{x}$  כלשהו שמקיים את איחוצי השוויון  $A\mathbf{x} = b$  (זה בד"כ נחשב ממשימה קלה למצוא  $\mathbf{x}$  שמקיימת את הדרישה הזו - לא ניכנס להז). נסמן  $\mathbf{x}_0$ . ככלומר מתקיים  $A\mathbf{x}_0 = b$ .

- נבחר  $s_0 = \max_{i=1, \dots, m} h_i(\mathbf{x}_0)$ .
- אז הנקודה  $(\mathbf{x}_0, s_0)$  היא נקודת פיסබליות לבעיית הפיסබליות ( $F$ ).

משלב זה כישיש לנו את הנקודה  $(\mathbf{x}_0, s_0)$  שהיא נקודת פיסබליות לבעיית הפיסබליות ( $F$ ). נוכל לפתור את בעיית הפיסබליות ( $F$ ) בשיטת barrier עם אתחול  $(\mathbf{x}_0, s_0)$ .

ובכך למצוא נקודת התחלית פיסබליות לבעה המקורית שאנו רוצים לפתור על ידי שיטת barrier.  
נדגיש כי אין צורך לפתור את בעיית הפיזබליות ( $F$ ) בדיק מודן גדול כדי כיוון שמספריק למצוא  $\mathbf{x}$  עבורם  $0 < s < s_0$  וזו במצב כזה  $\mathbf{x}$  המתאים לו יהיה פיסברי בבעיה המקורית.

כלומר אפשר לעזור את שיטת barrier על בעיית הפיסබליות מהשלב שבו  $0 < s$ .  
פה הסטיים הדין על שיטות barrier.

**סוף הסיכום.**